

Propuesta de Tesis para Optar al Grado de Magíster en Ciencias de la Ingeniería Electrónica

Propuesta de Tesis de grado presentada por
Carlos Ignacio Saldivia Heinz,
como requisito parcial para optar al grado de
Magíster en Ciencias de la Ingeniería Electrónica Mención Telecomunicaciones y Procesamiento de
Señales.

Director de Tesis: Matías Zañartu Salas
Profesor Co-Guía: Alejandro Weinstein

ROL USM
201721001-K

RUT
19.541.512-9

e-mail
carlos.saldivia@sansano.usm.cl

1. Definición del Tema de Tesis

1.1. Título

Desarrollo de técnicas de construcción de grafos y extensión de algoritmos clásicos de procesamiento de señales EEG basado en GSP.

1.2. Resumen

En este proyecto de investigación se plantea la hipótesis de que la utilización de Graph Signal Processing (GSP) en la etapa de pre-procesamiento de señales de electroencefalografía (EEG), mejora el desempeño en comparación con la utilización de métodos clásicos convencionales.

Para probar esta hipótesis se proponen dos objetivos específicos: Desarrollar técnicas efectivas de construcción de grafos, y extender los algoritmos clásicos de procesamiento de EEG utilizando GSP y validar su desempeño. Para el primer objetivo se compararán dos enfoques para construir un grafo ponderado: kernel gaussiano con umbral y enfoque basado en datos. Se evaluará el efecto de los parámetros en el rendimiento de distintas tareas de procesamiento de datos y se buscará un umbral adecuado para las medidas de similitud.

Para el segundo objetivo se extenderán métodos clásicos de procesamiento de señales EEG como el filtrado y el rechazo de artefactos utilizando ICA con GSP. Se validará el desempeño de los métodos clásicos extendidos con GSP.

Se utilizarán métodos de validación cruzada y optimización de Bayes en ambos objetivos para obtener resultados significativos según el trabajo realizado en [8].

2. Introducción

Una de las técnicas más comunes para medir la actividad cerebral es mediante el EEG, en donde se registran los potenciales eléctricos sobre el cuero cabelludo de una persona. Estos potenciales eléctricos son producto de la actividad en la corteza cerebral [2], por lo que se pueden utilizar para inferir el estado de esta. Esta técnica es no invasiva, de bajo riesgo y es utilizada en entornos clínicos y de investigación. Es utilizada por profesionales de la salud para controlar la profundidad del estado de anestesia de los pacientes, diagnosticar enfermedades como epilepsia y diversos trastornos del sueño, además de monitorear pacientes en UCI, entre otros [3][4]. Los investigadores, en cambio, utilizan el EEG en estudios relacionados principalmente a la neurociencia, la psicología y la neurolingüística [5]. También existen aplicaciones para productos de consumo como se describe en [6].

Por otro lado, el Procesamiento de Señales en Grafos, (GSP por sus siglas en inglés), [7] se puede utilizar para extender las operaciones de procesamiento de señales clásico, como el filtrado, la interpolación, análisis de wavelets, etc., a señales definidas en un grafo, aprovechando así la estructura inherente de datos existentes que de otra manera no se podría explotar. Para la adquisición de señales EEG se coloca un conjunto de electrodos sobre el cuero cabelludo del sujeto en un conjunto predefinido de ubicaciones que depende de la cantidad de electrodos a usar. En este trabajo se mostrará cómo se puede utilizar GSP para procesar la señal EEG considerando estos electrodos como una red de sensores, y que esta red induce, a su vez, un grafo con una señal asociada. En particular, se buscará mostrar como utilizando GSP se puede mejorar el rendimiento de las técnicas clásicas de procesamiento de señales. Para esto primero se desarrollarán técnicas efectivas de construcción de grafos comparando dos enfoques o métodos distintos: Uno basado en kernel gaussiano con umbral, (*thresholded Gaussian kernel*) y otro basado en datos y matriz de covarianzas (*data-driven*.) Una vez desarrolladas estas técnicas, se aplicarán para extender las técnicas mencionadas anteriormente, donde se buscará en particular hacer pruebas de filtrado, rechazo de artefactos y detección de electrodos que se clasifiquen como “malos” o “faltantes”. Para esto se comparará el desempeño de la tarea sobre dataset públicos, que se considerará como *ground-truth*, frente a los métodos clásicos como ICA para rechazo de artefactos. Esto será explicado en detalle en la sección de metodología.

3. Formulación del problema y evaluación del marco teórico y técnico

3.1. Definición de problema

Una secuencia típica de pasos en el procesamiento EEG sigue los siguientes pasos [9]: Adquisición de señal, filtrado de paso de banda, submuestreo, rechazo de artefactos y cuantificación. El paso final depende de la tarea que se quiera desarrollar y puede incluir tareas como segmentación, promedio, análisis de frecuencia y análisis estadístico. En este trabajo se busca demostrar que la incorporación de GSP en esta secuencia beneficiará varias etapas de la secuencia.

En este trabajo se utilizará el entorno definido por Shuman [10], que tiene la ventaja de generalizar el caso estándar de procesamiento de señales discretas de tiempo finito. Este entorno considera un grafo ponderado $\mathcal{G} = \{\mathcal{V}, \mathcal{E}, \mathcal{W}\}$, donde $\mathcal{V}$ es el conjunto de vértice (con cardinalidad $|\mathcal{V}| = N$), $\mathcal{E}$ es el conjunto de aristas y $\mathcal{W}$ es una matriz de adyacencia ponderada. La base de GSP es la matriz Laplaciana $\mathcal{L} = \mathcal{D} - \mathcal{W}$, donde $\mathcal{D}$ es la matriz diagonal de grado con entrada d_i igual a la suma de los pesos incidente al vértice i . Dado que la matriz es simétrica con entradas reales, tiene sus auto valores no negativos. A este conjunto de valores propios $\sigma(\mathcal{L}) = \{\lambda_0, \dots, \lambda_{N-1}\}$ se le llama el espectro de la matriz Laplaciana. Una de sus propiedades es que su valor propio menor es 0. También, se asumen ordenados. Así, se puede escribir $0 = \lambda_0 \leq \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_{N-1}$. También, como la matriz es simétrica con entradas reales, sus vectores propios son ortonormales [11]. Llamamos a este conjunto de vectores propios como $\{u_l\}_{l=0,1,\dots,N-1}$.

Estos vectores proporcionan una noción de frecuencia, donde mayores valores propios se asocian a mayores frecuencias[12]. Por ejemplo, el primer vector propio con valor $\lambda_0 = 0$ es siempre constante y se asocia al componente continuo DC. Otro ejemplo útil para ilustrar esta relación es el caso del grafo de línea. En este grafo, el vértice i esta conectado solo al vértice $i - 1$ y $i + 1$, excepto los vértices 0 y $N - 1$ que se conectan solo a vértice 1 y $N - 2$ respectivamente. Los vectores propios de este grafo son sinusoidales, con frecuencias que incrementan con su valor propio correspondiente. Una señal definida sobre una línea o camino del grafo corresponde con la definición estándar de señal finita considerada en procesamiento tradicional. Así, la naturaleza sinusoidal de los vectores propios de este grafo permiten considerar GSP como una generalización del marco clásico de procesamiento de señales.

Estas propiedades de la matriz Laplaciana permiten la definición de una transformada de Fourier para grafos de una señal $f : \mathcal{V} \rightarrow \mathbb{R}$ definida sobre los vértices del grafo. La transformada de Fourier para grafos de esta señal es $\hat{f}(\lambda_l) = \sum_{i=0}^{N-1} f(i)u_l^*(i)$. La transformada inversa se define por: $f(i) = \sum_{l=0}^{N-1} \hat{f}(\lambda_l)u_l(i)$.

La justificación de lo anterior se basa en lo siguiente: La transformada de Fourier clásica expande la señal en términos de exponenciales complejas, las cuales son funciones propias del operador de una dimensión del operador de Laplace. De forma similar, la transformada de Fourier sobre grafo expande la señal en términos de valores propios de la matriz Laplaciana, un operador similar [10]. Otro componente crítico de GSP es el concepto de *delay* y desplazamientos (*shift*) temporales. En el procesamiento clásico, los desplazamientos de muestras son utilizados para caracterizar tanto la señal como el sistema (filtros). Por esta razón, es crucial llevar este concepto al marco de GSP. Para esto, uno puede definir la operación de desplazamiento en grafo como $\hat{f} = Wf$. Esta definición corresponde a reemplazar el valor de la función para un vértice dado por la suma ponderada de los valores vecinos. Una multiplicación matriz-vector puede describir la operación de un filtro lineal sobre una señal f en un grafo: $f_{out} = Hf$, donde H es una matriz filtro $N \times N$, y f_{out} es la salida del filtro. Este filtro debe ser invariante a desplazamientos para tener propiedades similares a filtros estándar: $W(Hf) = H(Wf)$. Esto significa que es lo mismo filtrar la señal y luego aplicar un desplazamiento que primero hacer este corrimiento y luego filtrar la señal. La matriz H satisface esta propiedad si y solo si existe un polinomio $h(x) = h_0 + h_1x + \dots + h_Lx^L$ tal que $H = h_0I + h_1W + \dots + h_LW^L$, donde L es el orden del filtro e I matriz identidad. Estos coeficientes h_i del polinomio son análogos a los coeficientes del clásico filtro *Finite Impulse Response* (FIR).

Por otro lado, la señal del grafo f puede ser filtrada en el dominio de la frecuencia multiplicando su espectro $\hat{f}(\lambda_l)$ por la función de transferencia $\hat{h}(\lambda_l)$ y luego aplicando la transformada inversa de Fourier para grafos: $f_{out} = \sum_{l=0}^{N-1} \hat{f}(\lambda_l)\hat{h}(\lambda_l)u_l(i)$. Basado en estas operaciones principales: Descomposición de Fourier, desplazamientos temporales y filtrado, muchas de las operaciones clásicas de procesamiento de señales han sido extendidas al marco de GSP. La siguiente sección describe cómo GSP ha sido utilizado en problemas de neuroimágenes en general y EEG en particular. También se presenta un resultado previo relacionado con el objetivo de este trabajo.

3.2. Soluciones y abordajes realizadas por otros autores

El uso de la teoría de grafos en neuroimágenes en general y EEG en particular ha sido tradicionalmente utilizado para analizar la conectividad cerebral luego de aplicar otros procesos de análisis y procesamiento de datos. Sin embargo, la perspectiva GSP es diferente, ya que considera el análisis de señales definidas sobre un grafo. Esta capacidad ha sido explotada en la representación de la interconexión entre las regiones del cerebro en forma de grafo y la actividad de cada región es considerada como una señal dentro de este, medida generalmente con técnicas de imagen por resonancia magnética funcional (fMRI) o técnicas similares. Por ejemplo, en [13] se utiliza la noción de frecuencia de señal de un grafo para caracterizar los niveles de adaptabilidad y exposición a una tarea en un sujeto, usando fMRI. Otro ejemplo en [14] utiliza análisis mediante wavelet en grafos para encontrar patrones de actividad cerebral y descomponer los datos de fMRI.

Actualmente, la mayoría de los trabajos que utilizan GSP se basan en este tipo de datos, fMRI, y en la señal del grafo inducida por la conectividad funcional y anatómica. Existe un número reducido de trabajos que utilizan GSP con datos de EEG, donde la mayoría de ellos no consideran la información geométrica para construir el grafo. Por ejemplo, los autores de [15] utilizan GSP para detectar epilepsia a partir de los datos EEG. En [16], se construye el grafo a partir de los datos de serie de tiempo y muestran como utilizando GSP para reducción de dimensionalidad del problema mejora la tarea de clasificación respecto a técnicas clásicas. Otros trabajos que utilizan GSP para reducción de ruido, reducción de dimensionalidad y clasificación son [17][18][19]. Según la revisión realizada, [20] es el único trabajo donde se utiliza la información geométrica considerando la distancia entre los electrodos para construir el grafo. GSP luego es utilizado para calcular la variación total de la señal del grafo para caracterizar desordenes de conciencia.

Basado en la revisión bibliográfica realizada para este trabajo, se concluye que este resulta ser el primer trabajo que utiliza GSP extensivamente para procesar EEG a nivel de sensores, lo que es importante en un contexto clínico donde los datos de actividad de fuente de fMRI o EEG raramente están disponibles.

A continuación se presenta un experimento realizado por el profesor co-director de este proyecto de tesis en [1], utilizando el dataset de ejemplo de la librería MNE-Python, para demostrar el efecto de utilizar GSP para interpolar datos faltantes de sensores en una señal EEG. Este dataset consiste en una grabación de 60 canales de EEG, con un electrodo de referencia, mientras el sujeto de prueba era estimulado visual y auditivamente. Se calcula el potencial relacionado con evento o ERP por sus siglas en inglés (*Event-Related Potential*) para la condición auditiva izquierda a 100 milisegundos utilizando referencia promedio. (Figura 1-(a)). Se considera cada electrodo como un vértice del grafo y el valor de la ERP a 100 ms en cada electrodo como la señal. Para cada vértice, se añade una arista entre el vértice y sus k -vecinos más próximos, basado en una distancia euclidiana para la posición del electrodo. Las figuras 1-(b) y 1-(c) muestran la matriz de adyacencia correspondiente al grafo y un gráfico del grafo y su señal respectivamente, utilizando $k = 5$ vecinos más cercanos. En este experimento se asume que la información del electrodo 6 (marcado en rojo en la figura 1-(c)) está perdido. Entonces, se utiliza GSP para agregar este valor basado en la señal de los electrodos restantes. En particular, para hacer este proceso se resuelve un problema de regresión lineal de grafo [10]

$$\begin{aligned} \hat{f} &= \underset{x}{\operatorname{argmin}} x^T \mathcal{L} x \\ \text{s.t. } f_M &= Mx \end{aligned}$$

donde $\hat{f}$ es la señal del grafo que se desea estimar, $\mathcal{L}$ la matriz Laplaciana, f la señal del grafo con datos faltantes, f_M un vector con los valores no faltantes y M una matriz máscara que extrae estos valores.

Para evaluar el desempeño de este método basado en GSP se calcula la magnitud del error para diferentes valores de k -vecinos utilizados para construir el grafo. Se comparó este error con el obtenido al utilizar un interpolador *Radial Basis Function* (RBF) estándar. La Figura 2-(a) muestra los resultados. También, para estudiar el efecto de utilizar un grafo ponderado se repite el experimento utilizando un grafo construido utilizando un kernel Gaussiano con umbral, según la ecuación (1). Se calcula la magnitud del error para diferentes valores del parámetro de dispersión θ , donde la Figura 2-(b) muestra los resultados.

Con estos resultados, algunas de las conclusiones son: (a) Para un grafo razonablemente construido, la imputación de valores faltantes basada en GSP es mejor que el método RBF estándar, donde razonablemente se refiere utilizar un número relativamente bajo de k -vecinos, lo cual hace sentido al considerar que aumentar el valor de k significa considerar electrodos considerablemente alejados en distancia euclidiana. (b) Utilizar un grafo ponderado lleva a errores menores que uno sin ponderar, observando que la dependencia del error con respecto al parámetro de escalado es más robusta. Con esto se demuestra

la importancia del grafo utilizado para el análisis y por esa razón se investigará en detalle acerca de los mejores métodos y técnicas de construcción de grafo para un conjunto de sensores EEG.




Figura 1: Se construye un grafo utilizando cada electrodo como vértice y una arista entre cada vértice y sus 5 vecinos cercanos. El ERP en cada electrodo(vértice) es la señal del grafo. (a) Topografía del ERP a 100ms. (b) Matriz de adyacencia del grafo. (c) Grafo y señal del grafo. El punto rojo corresponde al electrodo con datos faltantes.




Figura 2: Magnitud del error de imputación. (a) Con grafo sin ponderar utilizando k -vecinos cercanos como función de k . (b) Con un grafo ponderado construido utilizando kernel Gaussiano con umbral como función de θ .

4. Diseño y método de investigación

4.1. Hipótesis

Se plantea la siguiente hipótesis bajo la cual se realizará la investigación: La extensión planteada de los métodos de filtrado y rechazo de artefactos mediante métodos como ICA, (*Independent Component Analysis*) en señales EEG basada en GSP demuestra mejor desempeño que su contra-parte clásica en la etapa de preprocesamiento de estas señales.

4.2. Objetivos

El objetivo general de esta propuesta es el de mejorar el rendimiento en la etapa de pre-procesamiento de las señales EEG utilizando GSP. La mayoría de las técnicas clásicas de pre-procesamiento EEG no consideran la estructura de grafo intrínseca de los datos. Por esta razón se espera que al incorporar GSP a estas técnicas se observen mejoras en el rendimiento de estos métodos. Algunos de los métodos que se estudiarán son el filtrado y el rechazo de artefactos, como por ejemplo el uso de GSP para mejorar este ultimo método utilizando ICA (*Independent Component Analysis*) Para esto se proponen los siguientes objetivos específicos:

1. **Objetivo específico 1 (OE1):** *Desarrollar técnicas efectivas de construcción de grafos.* Para este objetivo se consideran distintas tareas como: Análisis de las técnicas de construcción, comparando el enfoque utilizando kernel Gaussiano con umbral (*thresholded Gaussian kernel*) y el enfoque basado en datos (*data-driven*); y las pruebas de validación correspondiente.
2. **Objetivo específico 2 (OE2):** *Extensión de los algoritmos clásicos de procesamiento de EEG utilizando GSP.* Basado en las técnicas de construcción de grafos desarrolladas en el objetivo anterior se trabajará en la extensión y validación de las técnicas clásicas de procesamiento de señales, en este caso EEG, utilizando el GSP. Por lo tanto las tareas o hitos de este objetivo consideran pruebas de distintos métodos como filtrado y rechazo de artefactos utilizando métodos estándar como ICA, por ejemplo, entre otras. Un hito siguiente a este sería la validación de extender estos algoritmos clásicos utilizando GSP.

4.3. Metodología

OE1: Desarrollar técnicas efectivas de construcción de grafos En primer lugar, para utilizar correctamente GSP se necesita primero construir un grafo apropiado para la aplicación. El rendimiento de GSP está ligado a como se definan el junto de aristas del grafo. En esta ocasión, se construirá un grafo ponderado utilizando kernel gaussiano con umbral (*thresholded Gaussian kernel*) [10] donde los pesos entre 2 vértices i, j estarán dados por la siguiente expresión:

$$W_{i,j} = \begin{cases} \exp\left(\frac{-dist^2(i,j)}{2\theta^2}\right) & \text{si } dist(i,j) \leq \kappa \\ 0 & \text{en otro caso.} \end{cases} \quad (1)$$

Donde κ es el umbral a utilizar, θ es el factor de dispersión de la gaussiana y $dist(i,j)$ la distancia, euclidiana u otra, entre los vértices i, j . Se evaluará el efecto de estos parámetros comparando el efecto en el rendimiento de distintas tareas de procesamiento de datos, como el rellenado de datos faltantes/perdidos. Como alternativa, se construirá también un grafo utilizando un enfoque basado en datos (*data-driven*) utilizando como base la estimación de matrices de covarianza según las propuestas en ([22][23]). Se propone para este método resolver el problema de maximización log-likelihood multivariable para N observaciones de dimensión ρ , media μ y covarianza Σ , conocida como *Graph-Lasso*:

$$\log \det \Theta - \text{tr} S \Theta - \rho \|\Theta\|_1 \quad (2)$$

Donde $\Theta = \Sigma^{-1}$ y S es la matriz de covarianza empírica, tr la traza y $\|\Theta\|_1$ es la norma L_1 , la suma de los valores absolutos de los elementos de Σ^{-1} . Para solucionar este problema, se demuestra que siendo este convexo, se define W como la estimación de Σ y se demuestra que se puede resolver el problema optimizando sobre cada fila y columna correspondiente de W en una forma de descenso de coordenadas por bloque:

$$W = \begin{pmatrix} W_{11} & w_{12} \\ w_{12}^T & w_{22} \end{pmatrix}, \quad S = \begin{pmatrix} S_{11} & s_{12} \\ s_{12}^T & s_{22} \end{pmatrix} \quad (3)$$

Considerando problema dual, en [22] se define el problema de lasso tal que:

$$\min_{\beta} \|\mathbf{W}_{11}^{1/2} \beta - b\|^2 + \rho \|\beta\|_1 \quad (4)$$

Donde $b = \mathbf{W}_{11}^{-1/2} s_{12}/2$ luego, el algoritmo de lasso de covarianza consiste en:

1. Comenzando con $W = S + \rho I$. La diagonal se mantiene sin cambios en los pasos siguientes.
2. Para cada $j = 1, 2, \dots, p$, resolver el problema lasso, que toma como entrada los productos internos W_{11} y s_{12} . Esto entrega un vector solución $\hat{\beta}$ de dimensión $\rho - 1$. Rellenar la fila y columna correspondiente de W utilizando $w = 2W_{11}\hat{\beta}$
3. Continuar hasta convergencia.

Finalmente, suponiendo que la estimación final de Σ es $\Sigma^{-1} = W$, y guarda el estimador $\hat{\beta}$ en las filas y columnas de una matriz $p \times p$ $\hat{B}$. Entonces se puede obtener la p -ésima fila y columna de $\hat{\Theta} = \hat{\Sigma}^{-1} = \hat{W}^{-1}$ tal que:

$$\hat{\Theta}_{pp} = \frac{1}{W_{pp} - 2\Sigma_{k \neq p} \hat{B}_{kp} W_{kp}} \quad (5)$$

$$\hat{\Theta}_{kp} = -2\hat{\Theta}_{pp} \hat{B}_{kp}; k \neq p \quad (6)$$

Las diferencias entre ambos enfoques permitirán, entre otras cosas, identificar electrodos marcados como “malos”. Se cuantificará la similitud entre ambos grafos utilizando la distancia de edición de grafos, (*graph edit distance*) GED [24] y la distancia de centralidad [25]. El primero, $d_{GED}(G_1, G_2)$ se define como la secuencia de operaciones de edición de menor costo para transformar un grafo G_1 a otro G_2 , lo cual dependerá de los atributos, usualmente nodos y vértices, de los distintos algoritmo. El segundo, la distancia de centralidad $d_C(G_1, G_2)$ se define como la medida de similaridad entre grafos basado en un nodo central C . Formalmente, se define la distancia de centralidad entre 2 grafos vecinos como la diferencia por componente:

$$\forall (G_1, G_2) \in E(\mathcal{G}), d_C(G_1, G_2) = \sum_{v \in V} |C(G_1, v) - C(G_2, v)| \quad (7)$$

Con este análisis se buscará encontrar un umbral adecuado para estas medidas de similitud siguiendo un enfoque basado en validación cruzada y optimización de Bayes [8].

Resulta importante recalcar que para este análisis se asume que el grafo no varía con el tiempo. Este supuesto se justifica al afirmar que la estructura del grafo depende de la relación espacial entre los electrodos y que por lo tanto, incluso si se considera la dinámica cerebral, esta afectará solo la señal, más no el grafo en sí. Por otro lado, no se puede decir lo mismo para el caso del grafo construido basado en datos, utilizando la estimación de la matriz de covarianza debido a la naturaleza de este acercamiento. Sin embargo, esta técnica se utilizará para detectar inconsistencias en los datos y no como la estrategia principal para construir el grafo. De todas maneras, este es un aspecto que se considerará al usar este enfoque basado en datos para la construcción del grafo.

OE2: Extensión de los algoritmos clásicos de procesamiento de EEG utilizando GSP. Luego de completar el objetivo anterior y conocer entonces la manera más efectiva de construir grafos para la red de sensores formada por los electrodos para mediciones de EEG, se extenderán los algoritmos de procesamiento clásicos, como el filtrado y el ICA, utilizando GSP. Estas nuevas técnicas se evaluarán con criterios similares a los utilizados en [8].

Evaluar el rendimiento de los métodos propuestos con datos reales es un problema, ya que no existe una definición clara del *ground-truth*. En el caso del rendimiento del método para identificar electrodos etiquetados como “malos”, se utilizaran 2 dataset públicos donde estos canales fueron marcados manualmente: El dataset de ejemplo de la librería de python MNE [21], que posee los datos de 1 solo sujeto, y el dataset EEGBCI [26], con 109 sujetos. Se consideran estos datos como la verdad de piso o *ground-truth* y se evaluará el rendimiento del método propuesto mediante la diferencia $\|X(\text{método}) - X(\text{dataset})\|_\infty$, donde X es la matriz con los potenciales evocados calculados después de eliminar los electrodos defectuosos y con los datos del dataset, respectivamente. Se comparará su rendimiento con otros métodos de detección de canales defectuosos, como Autoreject, FASTER, SNS y RANSAC [8]. También será importante evaluar el tiempo de ejecución del método comparado con los tiempos de ejecución de estos otros métodos de la literatura, ya que estos son aplicados generalmente a conjuntos de datos grandes como lo puede ser un registro de EEG.

Para evaluar el rendimiento del método propuesto de rechazo de artefactos basado en GSP, se creará una señal mezclando un artefacto conocido con una señal libre de artefactos, y luego se calculará la correlación entre el artefacto original y el extraído por el método [27]. Se comparará esta correlación con la obtenida mediante métodos típicos como la descomposición ICA.

Los métodos desarrollados durante el desarrollo de este objetivo contribuirán al conjunto de técnicas disponibles para manejar grandes conjuntos de datos EEG y resolver problemas de reproducibilidad que requieren evitar intervención manual de los investigadores.[8]

Dataset: Como parte de las principales metas de este proyecto es el de desarrollar nuevas técnicas y algoritmos de procesamiento, los experimentos serán todos realizados utilizando dataset públicos como los ya mencionados anteriormente: (1) MNE sample dataset [21] y (2) el dataset EEGBCI. Se eligieron estos dataset dividido a que poseen características deseables -numero de sujetos, de electrodos y condiciones de experimento- que permiten probar características específicas de la técnica desarrollada. Se espera que con este enfoque el trabajo sea más eficiente, lo que permitirá más certitud de lograr completar los objetivos y metas propuestas.

4.4. Plan de trabajo

A continuación se presenta un plan de trabajo para conseguir resultados finales, considerando la programación semestral del plan de la carrera.

Objetivo	Tarea	Aug	Sept	Oct	Nov	Dic
OE1	Análisis enfoque Gaussiano.	X				
OE1	Análisis enfoque basado en datos.	X				
OE1	Comparación de ambos enfoques.	X	X			
OE2	Evaluar desempeño para identificar electrodos malos		X	X		
OE2	Validación comparando con otros métodos.			X		
OE2	Evaluar desempeño en rechazo de artefactos.		X	X		
OE2	Comparación con métodos estándar como ICA.			X		
Análisis Teórico.	Revisión bibliográfica.	X	X	X	X	X
Artículo Publicable.	Redacción.			X	X	X
Documento de Tesis	Redacción.			X	X	X

Cuadro 1: Planificación del plan de trabajo a realizar durante el semestre 2023-2

4.5. Resultados esperados

Junto a los resultados obtenidos de realizar y validar cada objetivo específico, además del desarrollo del documento de tesis asociado a esta propuesta, se espera desarrollar un documento para ser enviado a publicar en distintas revistas científicas. Algunas opciones de revistas propuestas son Neuroimage, Frontiers in Human Neuroscience, Brain Topography o similares.

Referencias

- [1] Weinstein A. “Imputing missing electroencephalography data using graph signal processing”, Proc. SPIE 12567, *18th International Symposium on Medical Information Processing and Analysis*, 125671C (6 March 2023).
- [2] Jackson, A. F. and Bolger, D. J., “The neurophysiological bases of EEG and EEG measurement: a review for the rest of us,” *Psychophysiology* **51**, 1061–1071 (Nov. 2014).
- [3] Nidermeyer, E. and da Silva, F. L., [*Electroencephalography: basic principles, clinical applications, and related fields*], Lippincott Williams & Wilkins (2005).
- [4] Tong, S. and Thakor, N. V., [*Quantitative EEG analysis methods and clinical applications*], Artech House (2009).
- [5] Cacioppo, J. T., Tassinary, L. G., and Berntson, G., [*Handbook of psychophysiology*], Cambridge university press (2007).
- [6] Vasiljevic, G. A. M. and Miranda, L. C. d., “Brain–Computer Interface Games Based on Consumer-Grade EG Devices: A Systematic Literature Review,” *International Journal of Human–Computer Interaction* **36**, 105–142 (Jan. 2020). Publisher: Taylor & Francis eprint: <https://doi.org/10.1080/10447318.2019.1612213>.
- [7] Ortega, A., Frossard, P., Kovačević, J., Moura, J. M. F., and Vandergheynst, P., “Graph Signal Processing: Overview, Challenges, and Applications,” *Proceedings of the IEEE* **106**, 808–828 (May 2018). Conference Name: Proceedings of the IEEE.
- [8] M. Jas, D. A. Engemann, Y. Bekhti, F. Raimondo, and A. Gramfort, “Autoreject: Automated artifact rejection for MEG and EEG data,” *NeuroImage*, vol. 159, pp. 417–429, Oct. 2017.
- [9] S. Sanei and J. A. Chambers, *EEG signal processing*. John Wiley & Sons, 2013.
- [10] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs: Extending high-dimensional data analysis to networks and other irregular domains,” *IEEE Signal Processing Magazine*, vol. 30, no. 3, pp. 83–98, May 2013, conference Name: IEEE Signal Processing Magazine.
- [11] A. E. Brouwer and W. H. Haemers, *Spectra of graphs*. Springer Science & Business Media, 2011.
- [12] A. Sandryhaila and J. M. F. Moura, “Discrete Signal Processing on Graphs: Frequency Analysis,” *IEEE Transactions on Signal Processing*, vol. 62, no. 12, pp. 3042–3054, Jun. 2014, conference Name: IEEE Transactions on Signal Processing.

- [13] W. Huang, L. Goldsberry, N. F. Wymbs, S. T. Grafton, D. S. Bassett, and A. Ribeiro, “Graph Frequency Analysis of Brain Signals,” *IEEE Journal of Selected Topics in Signal Processing*, vol. 10, no. 7, pp. 1189–1203, Oct. 2016, conference Name: IEEE Journal of Selected Topics in Signal Processing.
- [14] H. Behjat, N. Leonardi, L. Sörnmo, and D. Van De Ville, “Anatomically-adapted graph wavelets for improved group-level fMRI activation mapping,” *NeuroImage*, vol. 123, pp. 185–199, Dec. 2015.
- [15] P. Mathur and V. K. Chakka, “Graph Signal Processing of EEG signals for Detection of Epilepsy,” in *2020 7th International Conference on Signal Processing and Integrated Networks (SPIN)*, Feb. 2020, pp. 839–843, iSSN: 2688-769X.
- [16] L. Rui, H. Nejati, S. H. Safavi, and N.-M. Cheung, “Simultaneous low-rank component and graph estimation for high-dimensional graph signals: Application to brain imaging,” in *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Mar. 2017, pp. 4134–4138, iSSN: 2379-190X.
- [17] L. Rui, H. Nejati, and N.-M. Cheung, “Dimensionality reduction of brain imaging data using graph signal processing,” in *2016 IEEE International Conference on Image Processing (ICIP)*, Sep. 2016, pp. 1329–1333, iSSN: 2381-8549.
- [18] U. Graichen, R. Eichardt, P. Fiedler, D. Strohmeier, F. Zanow, and J. Haueisen, “SPHARA - A Generalized Spatial Fourier Analysis for Multi-Sensor Systems with Non-Uniformly Arranged Sensors: Application to EEG,” *PLOS ONE*, vol. 10, no. 4, p. e0121741, Apr. 2015, publisher: Public Library of Science.
- [19] K. Smith, B. Ricaud, N. Shahid, S. Rhodes, J. M. Starr, A. Ibáñez, M. A. Parra, J. Escudero, and P. Vandergheynst, “Locating Temporal Functional Dynamics of Visual Short-Term Memory Binding using Graph Modular Dirichlet Energy,” *Scientific Reports*, vol. 7, no. 1, p. 42013, Feb. 2017, number: 1 Publisher: Nature Publishing Group.
- [20] S. Mortaheb, J. Annen, C. Chatelle, H. Cassol, G. Martens, A. Thibaut, O. Gosseries, and S. Laureys, “A Graph Signal Processing Approach to Study High Density EEG Signals in Patients with Disorders of Consciousness,” in *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, Jul. 2019, pp. 4549–4553, iSSN: 1558-4615.
- [21] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, and L. Parkkonen, “MEG and EEG data analysis with MNE-Python,” *Frontiers in neuroscience*, vol. 7, p. 267, 2013.
- [22] J. Friedman, T. J. Hastie, and R. Tibshirani, “Sparse inverse covariance estimation with the graphical lasso,” *Biostatistics (Oxford, England)*, vol. 9, no. 3, pp. 432–41, Jul. 2008.
- [23] E. Pavez, “Estimation of graph laplacian and covariance matrices,” Phd Thesis, University of Southern California, 2019.
- [24] X. Gao, B. Xiao, D. Tao, and X. Li, “A survey of graph edit distance,” *Pattern Anal Applic*, vol. 13, no. 1, pp. 113–129, Feb. 2010.
- [25] M. Roy, S. Schmid, and G. Tredan, “Modeling and measuring graph similarity: The case for centrality distance,” in *Proceedings of the 10th ACM international workshop on Foundations of mobile computing*, 2014, pp. 47–52.
- [26] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw, “BCI2000: a general-purpose brain-computer interface (BCI) system,” *IEEE Transactions on biomedical engineering*, vol. 51, no. 6, pp. 1034–1043, 2004, publisher: IEEE.
- [27] S. Halder, M. Bensch, J. Mellinger, M. Bogdan, A. Kübler, N. Birbaumer, and W. Rosenstiel, “Online Artifact Removal for Brain-Computer Interfaces Using Support Vector Machines and Blind Source Separation,” *Comput Intell Neurosci*, vol. 2007, 2007.

5. Firmas del estudiante y del Director de Tesis

Carlos Saldivia

Matías Zañartu Salas