

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INGENIERÍA ELECTRÓNICA

Reconstrucción de Canales EEG Faltantes Mediante Procesamiento de Señales en Grafos con Regularización Temporal

Tesis de grado presentada por

Carlos Saldivia Heinz

Como requisito parcial para optar al grado de

Magíster en Ciencias de la Ingeniería

Director de Tesis: Alejandro Weinstein, Ph.D.

Co-Director de Tesis: Matías Zañartu, Ph.D.

Valparaíso, Chile, Junio de 2026

Resumen

La electroencefalografía (EEG) constituye una herramienta fundamental en neurociencia clínica y experimental, pero sufre de la pérdida frecuente de canales debido a fallas de contacto, artefactos de movimiento o saturación de amplificadores. La interpolación de estos canales faltantes es un paso crítico del preprocesamiento, y tradicionalmente se ha abordado mediante métodos geométricos como los *spherical splines*, implementados en bibliotecas de referencia como MNE-Python. Sin embargo, estos métodos operan exclusivamente en el dominio espacial, ignorando la dinámica temporal de las señales. Esta tesis presenta una evaluación comparativa reproducible y exhaustiva de dieciocho métodos de interpolación de canales EEG, geométricos, estadísticos y basados en Procesamiento de Señales en Grafos (GSP), bajo un protocolo experimental riguroso. El diseño incluye tres bases de datos heterogéneas (PhysioNet de 64 canales, BCI Competition IV 2a de 22 canales y MNE Sample de 60 canales), ciento veinte escenarios de pérdida que combinan modos aleatorio y contiguo con severidades del 10 % al 40 %, y una batería de seis métricas que cubren error de amplitud (MAE, RMSE, SNR), fidelidad morfológica (DTW) y preservación espectral (LSD, Coherencia). Para garantizar una comparación justa, todos los métodos —incluyendo las referencias clásicas— fueron optimizados mediante Optuna con más de quince mil configuraciones paramétricas exploradas, y se incorporó una validación confirmatoria contra la implementación comunitaria de referencia de MNE-Python.

Los resultados muestran una conclusión condicional. En la evaluación confirmatoria balanceada, TRSS fija mejora la mediana de MAE en 12.4 % frente a MNE-Python, alcanza una tasa de victoria de 72.0 % y mejora NRMSE en 13.9 %. La ventaja aumenta en pérdidas agrupadas o periféricas severas, donde la continuidad temporal compensa la pérdida de información espacial local. No obstante, MNE-Python conserva ventajas importantes: obtiene mejor LSD global, es sustancialmente más rápido y supera a TRSS en señales espacialmente suaves. Se concluye que TRSS es preferible cuando la reconstrucción precisa bajo pérdida no trivial es prioritaria, mientras que MNE sigue siendo la opción

robusta para preprocesamiento estándar, análisis espectral sensible a LSD y restricciones de tiempo.

La totalidad del código, las configuraciones experimentales, los registros de optimización y los artefactos de resultados se preservan en el repositorio del proyecto, lo que garantiza la trazabilidad completa de los hallazgos.

Palabras clave: EEG, canales faltantes, interpolación, Procesamiento de Señales en Grafos (GSP), regularización temporal, TRSS, spherical splines, MNE-Python, optimización bayesiana, Optuna, evaluación comparativa reproducible.

Abstract

Electroencephalography (EEG) is a cornerstone tool in clinical and experimental neuroscience, yet it frequently suffers from channel loss due to contact failures, motion artifacts, or amplifier saturation. Interpolating these missing channels is a critical preprocessing step, traditionally addressed through geometric methods such as spherical splines, implemented in reference libraries like MNE-Python. However, these methods operate exclusively in the spatial domain, ignoring the brain’s true functional connectivity and the temporal dynamics of the signals.

This thesis presents a reproducible and exhaustive benchmark comparing eighteen EEG channel interpolation methods —geometric, statistical, and Graph Signal Processing (GSP)-based— under a rigorous experimental protocol. The design encompasses three heterogeneous databases (64-channel PhysioNet, 22-channel BCI Competition IV 2a, and 60-channel MNE Sample), 120 loss scenarios combining random and contiguous modes at severities from 10 % to 40 %, and a battery of six metrics covering amplitude error (MAE, RMSE, SNR), morphological fidelity (DTW), and spectral preservation (LSD, Coherence). To ensure a fair comparison, all methods —including classical baselines— were optimized via Optuna with over 15,000 parametric configurations explored, and a confirmatory validation against MNE-Python’s community reference implementation was incorporated.

The results support a conditional conclusion. In the balanced confirmatory evaluation, fixed TRSS improves median MAE by 12.4 % over MNE-Python, reaches a 72.0 % win rate, and improves NRMSE by 13.9 %. The advantage grows under grouped or peripheral severe losses, where temporal continuity compensates for missing local spatial information. Nevertheless, MNE-Python retains important advantages: it achieves better global LSD, is substantially faster, and outperforms TRSS on spatially smooth signals. We conclude that TRSS is preferable when accurate reconstruction under non-trivial channel loss is the priority, whereas MNE remains the robust choice for standard preprocessing, LSD-sensitive spectral analysis, and time-constrained pipelines.

All code, experimental configurations, optimization logs, and result artifacts are preserved in the project repository, ensuring full traceability of the findings.

Keywords: EEG, missing channels, interpolation, Graph Signal Processing (GSP), temporal regularization, TRSS, spherical splines, MNE-Python, Bayesian optimization, Optuna, reproducible benchmark.

Índice general

1. Introducción	1
1.1. Contexto General y Planteamiento del Problema	1
1.2. Limitaciones de los Enfoques Tradicionales	2
1.3. El Advenimiento del Procesamiento de Señales en Grafos	3
1.4. La Brecha en la Literatura y la Motivación del Trabajo	4
1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?	5
1.5. Objetivos	5
1.5.1. Objetivo General	5
1.5.2. Objetivos Específicos	5
1.6. Preguntas de Investigación	6
1.7. Alcance y Aportes de la Investigación	6
1.8. Estructura de la Tesis	7
2. Marco Teórico y Estado del Arte	8
2.1. Fundamentos Neurofisiológicos de la Señal EEG	8
2.1.1. Generación y Propagación	8
2.1.2. Bandas de Frecuencia y Potenciales Relacionados a Eventos	10
2.2. Procesamiento de Señales en Grafos	10
2.2.1. Definiciones Fundamentales	10
2.2.2. Laplaciano, Suavidad y Transformada de Fourier en Grafos	11
2.2.3. Construcción de Grafos para EEG	11
2.3. Estado del Arte en Interpolación de Señales Biomédicas	14

2.3.1. Métodos Geométricos y Estadísticos	14
2.3.2. Métodos Basados en GSP	15
2.3.3. Regularización Espacio-Temporal: TRSS	15
2.4. Mecanismo Interno de la Interpolación en MNE-Python	16
2.4.1. Formulación Original y sus Seis Mejoras	16
2.4.2. Los Tres Pilares de la Robustez	17
3. Metodología	19
3.1. Conjuntos de Datos	20
3.2. Protocolos de Simulación de Canales Faltantes	20
3.3. Construcción de Grafos	21
3.4. Métodos de Interpolación	22
3.5. Métricas de Evaluación	23
3.6. Optimización Bayesiana con Optuna	23
3.7. Arquitectura del Sistema Experimental	24
3.7.1. Trazabilidad y Gestión de Artefactos	25
3.8. Diseño Experimental	27
3.9. Protocolo de Validación Comparativa	28
3.10. Control de Calidad	28
3.11. Síntesis del Diseño	29
4. Experimentos y Resultados	30
4.1. Mapa de fases experimentales	30
4.2. Selección preliminar de métodos y grafos	31
4.3. Reducción de candidatos	31
4.4. Optimización intermedia	32
4.5. Inventario de la comparación final	33
4.6. Resumen descriptivo de TRSS frente a MNE	34
4.7. Efecto del escenario de pérdida	35
4.8. Señales temporales representativas	36

4.9. Preservación espectral	38
4.10. Contribución temporal de TRSS	39
4.11. Costo computacional	40
4.12. Frontera práctica TRSS–MNE	41

Índice de figuras

2.1. Generación de la señal EEG y manifestaciones relevantes	9
2.2. Conceptos fundamentales de GSP	12
2.3. Descomposición del operador TRSS	16
3.1. Flujo metodológico de evaluación	19
3.2. Diagrama de bloques de la arquitectura	25
3.3. Cadena de trazabilidad experimental	26
4.1. Perfil descriptivo de calidad para TRSS fijo frente a MNE. Las barras positivas favorecen a TRSS después de respetar la dirección de cada mé- trica; las barras negativas favorecen a MNE. El costo temporal se reporta por separado porque su escala es muy distinta a la de las métricas de reconstrucción.	35
4.2. Resumen por patrón y severidad de pérdida. Cada celda muestra mejora mediana de MAE, tasa de victoria (WR) y número de pares. La ventaja de TRSS crece en pérdidas cercanas o periféricas severas, donde la información espacial local disponible para MNE disminuye.	36
4.3. Reconstrucciones temporales representativas en MNE Sample. Cada fila muestra señal original, reconstrucción MNE y reconstrucción TRSS para un canal oculto seleccionado de forma reproducible. Los casos incluyen un escenario favorable a TRSS, uno favorable a MNE, un empate práctico y una pérdida cercana severa.	38

-
- 4.4. PSD original versus PSD interpolado para los casos representativos. La figura compara directamente la densidad espectral de potencia de la señal original con las reconstrucciones MNE y TRSS. Esta lectura permite explicar por qué TRSS puede mejorar error de amplitud sin dominar necesariamente la métrica LSD. 39
- 4.5. Aporte descriptivo del término temporal dentro de TRSS. Las barras muestran la mejora de TRSS completo frente a TRSS sin término temporal. 40

Índice de tablas

2.1. Familias de métodos: principio matemático, fortalezas y limitaciones. . .	18
3.1. Características de los tres conjuntos de datos experimentales.	20
3.2. Estrategias de construcción de grafos. La columna «Fase» indica si el grafo se usó en la fase exploratoria (E), comparativa (C) o ambas (E+C). . . .	21
3.3. Métodos de interpolación implementados y evaluados.	22
3.4. Métricas de evaluación. La notación $\mathcal{F}$ denota el conjunto de canales faltantes, x_i la señal real y $\hat{x}_i$ la reconstrucción.	23
3.5. Espacios de búsqueda de hiperparámetros.	24
3.6. Artefactos generados por el sistema experimental.	27
3.7. Relación entre preguntas de investigación, experimentos y evidencia esperada.	27
4.1. Mejor combinación método-grafo por conjunto durante la selección exploratoria. El ranking corresponde al puntaje compuesto de los resultados preliminares; no constituye la comparación final contra MNE.	31
4.2. Microbenchmark de latencia usado como criterio de reducción de candidatos.	32
4.3. Resumen descriptivo pareado de TRSS fijo frente a MNE para métricas de calidad. La mejora mediana positiva favorece a TRSS después de respetar la dirección de cada métrica; la tasa de victoria indica la proporción de pares donde TRSS supera a MNE. Los intervalos son bootstrap descriptivos al 95 %, no pruebas de hipótesis.	34
4.4. Resumen por patrón y severidad de pérdida para MAE. Cada fila reporta la mejora mediana de TRSS frente a MNE, la tasa de victoria (proporción de pares donde TRSS obtiene menor MAE) y la mejora media como lectura complementaria.	35

4.5. Casos representativos seleccionados de forma reproducible en MNE Sample para inspección temporal y espectral. La mejora se calcula en MAE para TRSS fijo frente a MNE; valores negativos indican que MNE fue mejor en ese caso.	37
4.6. Contribución descriptiva del término temporal dentro de TRSS. La comparación retira el término temporal y mide cuánto cambia el desempeño relativo del modelo completo.	40
4.7. Complejidad computacional e implementación observada. N es el número de canales, T el número de muestras temporales, E el número de aristas del grafo y K el número de iteraciones del resolvidor.	41

Capítulo 1

Introducción

1.1. Contexto General y Planteamiento del Problema

La electroencefalografía (EEG) ha sido, durante décadas, una de las herramientas fundamentales de la neurociencia clínica y experimental. Su alta resolución temporal —en el orden de los milisegundos—, su naturaleza no invasiva y su costo relativamente bajo frente a técnicas como la resonancia magnética funcional o la tomografía por emisión de positrones la han consolidado como el estándar para estudiar la dinámica cerebral en tiempo real [3]. Sus aplicaciones abarcan el diagnóstico de epilepsia y trastornos del sueño, la investigación en neurociencia cognitiva y el desarrollo de interfaces cerebro-computador para comunicación asistida y neurorrehabilitación.

Ahora bien, la adquisición de EEG es un proceso frágil. En la práctica clínica y de investigación, la pérdida parcial o total de información en uno o más electrodos es frecuente. Estas fallas pueden deberse al aumento de la impedancia de contacto por transpiración o secado del gel conductor, a fallas en el amplificador como la saturación de voltaje, a movimientos bruscos del paciente que desconectan los sensores, o simplemente al descarte deliberado de canales que presentan una relación señal-ruido inaceptablemente baja durante la etapa de preprocesamiento [16].

La pérdida de canales no es un problema cosmético: compromete la integridad de todo análisis posterior. La ausencia de información espacial distorsiona la topografía de la señal, afecta la localización de fuentes neuronales y altera biomarcadores electrofisiológicos como los Potenciales Relacionados a Eventos (ERP) y la Densidad Espectral de Potencia (PSD) [14]. En sistemas modernos de aprendizaje automático aplicados a interfaces cerebro-computador, la pérdida impredecible de canales cambia la dimensionalidad de

entrada de los clasificadores y obliga, con frecuencia, a descartar ensayos completos de datos clínicamente valiosos [13]. La interpolación precisa de estos canales es, por tanto, un paso ineludible del flujo de preprocesamiento, y su calidad condiciona directamente la validez de cualquier conclusión neurofisiológica o clínica posterior.

1.2. Limitaciones de los Enfoques Tradicionales

Históricamente, el problema de la interpolación de canales EEG ha sido abordado mediante métodos espaciales o estadísticos. El enfoque más extendido y utilizado por defecto en bibliotecas de análisis como EEGLAB [4] o MNE-Python [7, 8] es la interpolación por *spherical splines* [18]. Este método, junto con otros enfoques basados en distancia euclidiana como la interpolación por vecinos más cercanos o las funciones de base radial, asume que la cabeza humana es una esfera conductora perfecta y estima el voltaje del canal faltante proyectando geométricamente los voltajes de los electrodos circundantes sobre dicha superficie.

Aunque estos métodos son rápidos y matemáticamente elegantes, adolecen de una limitación fundamental: operan estrictamente en el dominio espacial estático para cada instante de tiempo individual. Al hacerlo, ignoran dos realidades neurofisiológicas esenciales. En primer lugar, la distribución espacial del potencial eléctrico en el cuero cabelludo no es isotrópica ni homogénea: la conducción volumétrica a través de tejidos de distinta conductividad —cuero cabelludo, cráneo, líquido cefalorraquídeo— distorsiona el campo de manera no uniforme, de modo que un modelo esférico simplificado no captura completamente esta heterogeneidad [16]. En segundo lugar, las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento. Al reconstruir un canal muestra por muestra de forma aislada, los métodos puramente espaciales son incapaces de preservar la dinámica de alta frecuencia, generando trazos con ruido de fase y distorsiones en los picos transitorios [12]. Los métodos estadísticos de descomposición, Análisis de Componentes Independientes (ICA) y Análisis de Componentes Principales (PCA), proyectan las señales observadas sobre fuentes latentes y reconstruyen el canal perdido a partir de esa proyección [10]. Sin embargo, cuando varios canales contiguos fallan simultáneamente, estos métodos tienden a inyectar ruido global o a perder los picos transitorios locales que definen la morfología fina de los ERP.

1.3. El Advenimiento del Procesamiento de Señales en Grafos

Para superar estas limitaciones, en los últimos años ha emergido con fuerza el marco del Procesamiento de Señales en Grafos (GSP, por sus siglas en inglés) [17, 22]. El GSP ofrece una perspectiva natural y poderosa para lidiar con datos que residen en dominios irregulares no euclidianos. En lugar de modelar la cabeza como un espacio continuo tridimensional, GSP modela la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un nodo ($\mathcal{V}$), las aristas ($\mathcal{E}$) definen qué pares de electrodos están conectados, y la matriz de pesos ($\mathbf{W}$) cuantifica la intensidad de cada conexión. Las relaciones de similitud o distancia fisiológica entre electrodos se codifican en $\mathbf{W}$ mediante núcleos de distancia gaussianos o basados en correlación. Bajo este paradigma, el voltaje medido en un instante se interpreta como una señal de grafo, y conceptos clásicos como la Transformada de Fourier, el filtrado paso-bajo y el muestreo se trasladan al dominio del grafo mediante el operador Laplaciano $\mathbf{L}$. La intuición es simple: las señales en nodos fuertemente conectados tienden a ser similares. Al minimizar una función de costo que penaliza las variaciones abruptas sobre la topología del grafo, los datos faltantes se reconstruyen con mayor fidelidad que usando solo la distancia euclidiana [15].

Una extensión aún más avanzada es la regularización espacio-temporal. Trabajos recientes han introducido enfoques como la Regularización Temporal de Suavidad de Sobolev (TRSS, por sus siglas en inglés) [5], que optimiza conjuntamente la topología espacial y la derivada temporal de la señal. Al penalizar saltos bruscos en el tiempo de forma simultánea a los saltos en el espacio, TRSS impone restricciones fisiológicas reales: las neuronas no cambian su potencial de membrana instantáneamente, sino que obedecen dinámicas de integración continua. Esta restricción dual —espacial y temporal— es lo que la teoría predice como el factor diferencial frente a los métodos puramente espaciales.

Aunque existen enfoques de aprendizaje profundo para imputación de series temporales y representación de señales, esta tesis no los incorpora como línea experimental. La razón es metodológica: el objetivo es comparar métodos algorítmicos sin entrenamiento —geométricos, estadísticos, GSP y regularización espacio-temporal— bajo un protocolo controlado y trazable. Incluir modelos entrenables requeriría particiones de entrenamiento, validación externa y análisis de generalización que exceden el alcance de este trabajo.

1.4. La Brecha en la Literatura y la Motivación del Trabajo

A pesar del potencial teórico de los algoritmos GSP y TRSS, su validación empírica en la literatura de señales biomédicas presenta limitaciones metodológicas relevantes. Se identifican tres brechas que motivan el diseño experimental de esta tesis.

El primer problema es que los estudios que proponen nuevos algoritmos GSP suelen compararse contra *spherical splines* usando las configuraciones por defecto de los paquetes de software, sin realizar una búsqueda rigurosa de hiperparámetros para los métodos de referencia. Esto puede inflar artificialmente las ventajas del método propuesto y distorsionar la percepción del verdadero estado del arte [19]. El segundo problema es que la mayoría de los trabajos restringe su evaluación a métricas de error de amplitud global —como el RMSE o el MAE— y aplica escenarios de desconexión simples, tales como la remoción de canales aleatorios aislados en bases de datos pequeñas. Rara vez se investiga el impacto morfológico de la reconstrucción mediante métricas temporales como el *Dynamic Time Warping* o espectrales como la Distancia Espectral Logarítmica. El tercer problema es la escasez de comparaciones contra implementaciones comunitarias maduras. En particular, la interpolación de MNE-Python incorpora más de una década de refinamientos de ingeniería —normalización de coordenadas, regularización diagonal adaptativa, aumentación del sistema con restricciones lineales, pseudoinversa con tolerancia adaptativa y un mecanismo de reintento automático— que la hacen sustancialmente más robusta que una implementación ingenua de *spherical splines*. Ignorar esta implementación equivale a comparar contra un método de referencia debilitado artificialmente.

La motivación concreta de este trabajo nace directamente de estas brechas. El objetivo no es diseñar desde cero un nuevo marco teórico matemático, sino someter a la frontera del conocimiento actual —métodos geométricos, GSP y regularización temporal— a una evaluación empírica rigurosa, exhaustiva y justa. Al utilizar Optuna [1] para explorar configuraciones comparables en múltiples conjuntos de datos, esta tesis busca identificar el punto de cruce práctico entre el paradigma clásico y el paradigma de grafos: cuándo basta una referencia madura como MNE-Python y cuándo la regularización espacio-temporal aporta valor adicional.

1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?

Una pregunta recurrente que emerge del análisis preliminar —y que motiva una sección dedicada en el marco teórico de esta tesis— es por qué la función de interpolación de MNE-Python produce resultados tan competitivos, incluso frente a métodos teóricamente superiores como TRSS. La respuesta, que se desarrolla en profundidad en el Capítulo 2, reside en que la implementación de MNE no es una simple transcripción del artículo original de Perrin y colaboradores [18], sino que incorpora un conjunto de mejoras de ingeniería acumuladas durante más de diez años de desarrollo como código abierto.

Estas mejoras —normalización de coordenadas a esfera unitaria, uso global de canales, regularización diagonal adaptativa, aumentación del sistema con restricciones lineales, pseudoinversa con tolerancia adaptativa y reintento automático— no aparecen descritas en la literatura académica, pero están presentes en el código fuente de MNE. Son las responsables de que un método formulado en 1989 siga siendo hoy una referencia competitiva. Esta tesis dedica una sección completa del marco teórico (Capítulo 2) a documentar estos mecanismos, y una validación comparativa independiente (Capítulo 4) a cuantificar la brecha real entre TRSS y MNE.

1.5. Objetivos

1.5.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales EEG basados en GSP con regularización temporal frente a las referencias geométricas bajo un marco experimental riguroso, reproducible y optimizado mediante optimización bayesiana.

1.5.2. Objetivos Específicos

- **OE1 — Sistema unificado de evaluación.** Implementar dieciocho métodos de interpolación en un sistema modular con interfaz común, definir protocolos de pérdida aleatoria y contigua (10 %–40 %), e integrar Optuna para la optimización imparcial de todos los algoritmos, incluyendo una fase de selección preliminar y reducción de candidatos antes de la comparación final.

- **OE2 — Evaluación multi-métrica y fisiológica.** Cuantificar el desempeño mediante seis métricas primarias (MAE, RMSE, SNR, DTW, LSD, Coherencia) sobre tres conjuntos de datos y 120 escenarios de pérdida, documentando tanto los resultados preliminares de selección método-grafo como la preservación morfológica y espectral mediante métricas auxiliares, visualizaciones temporales y potencia por banda.
- **OE3 — Trazabilidad y reproducibilidad.** Generar un repositorio de artefactos computacionales —código, configuraciones, registros de optimización y resultados— que garantice la trazabilidad completa de cada afirmación cuantitativa hasta el archivo que la origina.

1.6. Preguntas de Investigación

En lugar de formular la evaluación como una prueba de hipótesis estadística, esta tesis organiza el análisis en torno a dos preguntas comparativas:

P1. ¿En qué condiciones la regularización espacio-temporal mejora la reconstrucción de canales EEG faltantes frente a referencias geométricas y a MNE-Python?

P2. ¿Qué compromiso práctico existe entre precisión de reconstrucción, fidelidad espectral y tiempo de cómputo al elegir entre TRSS y MNE-Python?

Estas preguntas se responden mediante comparaciones pareadas, estratificación por escenario y análisis multi-métrico; no se interpreta la tesis como aceptación o rechazo de hipótesis nulas.

1.7. Alcance y Aportes de la Investigación

El alcance de este trabajo abarca la ejecución computacional a gran escala del sistema de evaluación sobre tres conjuntos de datos, ciento veinte escenarios de falla y dieciocho métodos de interpolación. A diferencia de las evaluaciones acotadas que predominan en la literatura, aquí se consolidan miles de ensayos EEG bajo más de quince mil configuraciones paramétricas exploradas mediante Optuna.

Para garantizar la reproducibilidad, la ejecución se ancla en un registro exhaustivo de corridas experimentales que fija explícitamente las combinaciones de conjuntos de datos,

modos de pérdida, semillas, tipos de grafo y familias de métodos. Este diseño evita las evaluaciones improvisadas y permite trazar cada afirmación cuantitativa reportada en los capítulos posteriores hasta el artefacto experimental que la origina, según se detalla en el Apéndice D.

Los aportes principales se articulan en cuatro ejes. Primero, se proporciona evidencia empírica pareada de que TRSS mejora métricas de amplitud y ajuste temporal frente a referencias geométricas en regímenes difíciles, una vez que todos los métodos han sido optimizados. Segundo, se muestra que bajo pérdida contigua severa (30 % o más de los canales) la restricción temporal puede compensar la pérdida de información espacial local. Tercero, se documentan en formato académico los mecanismos de ingeniería que convierten a MNE-Python en una referencia inesperadamente competitiva. Cuarto, se entrega un sistema unificado en Python, rastreable y reproducible para ejecutar interpolaciones GSP con optimización bayesiana automatizada sobre datos EEG.

1.8. Estructura de la Tesis

Para desarrollar el análisis propuesto, el documento se organiza en seis capítulos. El Capítulo 2 presenta los fundamentos neurofisiológicos del EEG, el Procesamiento de Señales en Grafos, los métodos de interpolación y los mecanismos internos de MNE-Python. El Capítulo 3 define la metodología: datos, máscaras de pérdida, construcción de grafos, métodos, métricas, arquitectura, trazabilidad y separación entre fase exploratoria y fase comparativa. El Capítulo 4 documenta los experimentos y resultados: selección preliminar, reducción de candidatos, optimización intermedia, comparación final TRSS–MNE, señales representativas, PSD, contribución temporal y frontera práctica de uso. El Capítulo 5 discute las causas y limitaciones de los resultados. El Capítulo 6 resume conclusiones y trabajo futuro.

Los apéndices complementan el documento con derivaciones matemáticas, tablas extensas, protocolo de reproducibilidad, inventario de artefactos y material histórico. Esta organización permite seguir una cadena de decisiones verificables: qué métodos y grafos se consideraron, cuáles se descartaron, qué variantes pasaron a la comparación final y cómo se interpretan los resultados sin depender de una prueba de hipótesis como criterio único.

Capítulo 2

Marco Teórico y Estado del Arte

Este capítulo presenta los fundamentos sobre los que se construye la investigación: principios neurofisiológicos del EEG, bases matemáticas del Procesamiento de Señales en Grafos, estado del arte en interpolación de señales biomédicas, y los mecanismos internos que convierten a la implementación de MNE-Python en una referencia comunitaria sólida.

2.1. Fundamentos Neurofisiológicos de la Señal EEG

2.1.1. Generación y Propagación

La señal de voltaje EEG registrada en el cuero cabelludo resulta de la actividad sincronizada de grandes poblaciones de neuronas piramidales en la corteza cerebral [3]. Estas neuronas, orientadas perpendicularmente a la superficie cortical, generan dipolos de corriente ante potenciales postsinápticos. La suma espacial de estos dipolos —se requieren entre diez mil y cien mil neuronas sincronizadas para producir una señal detectable [16]— constituye la fuente primaria del EEG.

La señal de voltaje generada en la corteza atraviesa desde su origen hasta los electrodos de superficie múltiples capas de conductividad variable: líquido cefalorraquídeo, meninges, cráneo (aproximadamente ochenta veces menos conductor que el cuero cabelludo) y cuero cabelludo [16]. Esta conducción volumétrica actúa como un filtro espacial paso-bajo que suaviza la distribución de potencial y limita la resolución espacial efectiva del EEG a unos dos o tres centímetros. La Figura 2.1(a) ilustra este proceso de propagación desde la corteza hasta el cuero cabelludo, y la Figura 2.1(b) muestra la configuración del campo eléctrico generado por un dipolo cortical.




Figura 2.1: Generación de la señal EEG y manifestaciones relevantes para la interpolación de canales. (a) Propagación desde fuentes corticales hasta electrodos de superficie a través de capas con conductividad distinta, representadas sobre una referencia de cabeza. (b) Campo idealizado de un dipolo cortical y sus líneas de potencial. (c) Ejemplo esquemático de ERP con componentes N100, P200 y P300, cuya morfología debe preservarse al interpolar. (d) Topografía de electrodos con canales observados y canales fallados sobre una cabeza con orientación anatómica. Esquema de elaboración propia basado en la descripción neurofísica de [16] y en la nomenclatura ERP de [14].

2.1.2. Bandas de Frecuencia y Potenciales Relacionados a Eventos

La señal EEG se caracteriza por su contenido oscilatorio en bandas de frecuencia asociadas a estados funcionales específicos: delta (0.5–4 Hz, sueño profundo), theta (4–8 Hz, procesamiento de memoria), alpha (8–13 Hz, reposo vigíl), beta (13–30 Hz, procesamiento activo) y gamma (30–100 Hz, procesamiento perceptual de alto nivel) [3]. La preservación de la estructura espectral en cada banda es un criterio fundamental para evaluar la calidad de cualquier interpolación.

Los Potenciales Relacionados a Eventos (ERP) son fluctuaciones de voltaje sincronizadas con un estímulo sensorial, motor o cognitivo, obtenidas mediante promediación coherente de múltiples ensayos [14]. Componentes como N100, P300 y N400 constituyen biomarcadores electrofisiológicos cuya preservación morfológica —amplitud de pico, latencia y distribución topográfica— es uno de los criterios de evaluación más exigentes para cualquier método de interpolación. La Figura 2.1(c) muestra un ejemplo de forma de onda ERP con sus componentes principales, y la Figura 2.1(d) ilustra la topografía de canales buenos y fallados.

2.2. Procesamiento de Señales en Grafos

El Procesamiento de Señales en Grafos (GSP) [17, 22] extiende los conceptos del procesamiento clásico de señales a dominios irregulares representados por grafos.

2.2.1. Definiciones Fundamentales

Un grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$ consiste en N nodos $\mathcal{V} = \{v_1, \dots, v_N\}$ —los electrodos—, un conjunto de aristas $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ que define qué electrodos están conectados, y una matriz de pesos $\mathbf{W} \in \mathbb{R}^{N \times N}$ simétrica que especifica con qué intensidad: $W_{ij} > 0$ si existe arista entre i y j , y $W_{ij} = 0$ en caso contrario. La distinción entre $\mathcal{E}$ y $\mathbf{W}$ es relevante porque $\mathcal{E}$ define la topología (pares conectados) mientras que $\mathbf{W}$ codifica la fuerza de cada conexión; en grafos densos pueden coincidir, pero en grafos sparse como k-NN difieren.

Una señal de grafo en el instante t es el vector $\mathbf{x}_t \in \mathbb{R}^N$ de voltajes en los N electrodos. La matriz $\mathbf{X} \in \mathbb{R}^{N \times T}$ contiene T instantes temporales de la ventana de análisis EEG.

2.2.2. Laplaciano, Suavidad y Transformada de Fourier en Grafos

La matriz Laplaciana se define como $\mathbf{L} = \mathbf{D} - \mathbf{W}$, con $D_{ii} = \sum_j W_{ij}$. La forma cuadrática

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{i,j} W_{ij} (x_i - x_j)^2 \quad (2.1)$$

cuantifica la variación total del vector de voltajes $\mathbf{x} \in \mathbb{R}^N$ sobre el grafo: valores pequeños indican que nodos fuertemente conectados tienen valores similares —la señal es *suave*—. Esta propiedad es el pilar de la interpolación GSP: la mejor reconstrucción minimiza $S(\mathbf{x})$ sujeta a coincidir con los canales observados. La Ecuación 2.1 es la base de todos los métodos de regularización en grafos discutidos en este capítulo.

$\mathbf{L}$ admite la descomposición espectral $\mathbf{L} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$, donde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$ contiene los autovalores ordenados $0 = \lambda_1 \leq \dots \leq \lambda_N$, y $\mathbf{U}$ es la matriz ortogonal de autovectores. Los λ_k actúan como frecuencias en el grafo: valores pequeños corresponden a modos de variación lenta, valores grandes a modos de variación rápida (Figura 2.2b).

La Transformada de Fourier en Grafos (GFT) se define como $\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}$. Una señal es *de banda limitada* si $\hat{x}_k = 0$ para $k > K$, con $K \ll N$. La suavidad en el dominio espectral es $S(\mathbf{x}) = \sum_k \lambda_k \hat{x}_k^2$, penalizando los modos de alta frecuencia proporcionalmente a su autovalor. En este contexto, una reconstrucción regularizada es la estimación de los canales faltantes que conserva los canales observados y minimiza simultáneamente una penalización de variación sobre el grafo.

La Figura 2.2(a) muestra el grafo de electrodos, la Figura 2.2(b) separa explícitamente los autovalores del Laplaciano de la energía modal ilustrativa, y la Figura 2.2(c) resume la reconstrucción regularizada como compromiso entre datos observados y suavidad espacial.

2.2.3. Construcción de Grafos para EEG

La elección del grafo subyacente es una decisión metodológica de primer orden: un mismo algoritmo de interpolación GSP produce resultados distintos según el grafo sobre el que opera. En este trabajo se implementaron y evaluaron diez estrategias de construcción de grafos, organizadas en tres categorías según la fuente de información que utilizan.

Grafos geométricos (basados en distancia). Utilizan exclusivamente las posiciones físicas de los electrodos, lo que los hace inmunes a la presencia de canales faltantes y deterministas por construcción:




Figura 2.2: Conceptos fundamentales de GSP aplicados a EEG. (a) Los electrodos forman un grafo ponderado sobre una topografía de cabeza; las aristas codifican cercanía espacial. (b) El espectro del Laplaciano ordena los modos desde variación suave hasta variación rápida. La curva azul muestra autovalores, mientras que la curva naranja ilustra que la energía de una señal suave tiende a concentrarse en modos bajos. (c) La reconstrucción regularizada estima los canales faltantes combinando fidelidad a los canales observados y suavidad inducida por el grafo.

- **k-NN no ponderado (knn)**. Conecta cada electrodo a sus k vecinos más próximos con pesos binarios $\{0, 1\}$. Es el grafo más simple y sirve como línea base estructural.
- **k-NN gaussiano (knng)**. Extiende el anterior ponderando cada arista con $W_{ij} = \exp(-\|\mathbf{p}_i - \mathbf{p}_j\|_2^2 / 2\sigma^2)$, donde $\mathbf{p}_i \in \mathbb{R}^3$ es el vector de coordenadas 3D del electrodo i según el sistema 10–20 o 10–10, σ controla la escala de decaimiento y k determina la dispersión.
- **k-NN gaussiano variable (vknng)**. Similar al knng pero con k_i adaptativo según la densidad local de electrodos: en regiones densas (e.g., zona occipital en montajes 10–10) usa menos vecinos, y en regiones dispersas usa más. El parámetro α controla la sensibilidad a la densidad local.
- **ε -ball (epsilon_ball)**. Conecta todos los pares cuya distancia es menor que un umbral ε , con pesos $\{0, 1\}$. A diferencia de k-NN, el grado de cada nodo es variable y depende de la densidad local.
- **Distancia completa gaussiana (gaussian)**. Conecta todos los pares de electrodos con el núcleo gaussiano, generando una matriz densa. No requiere el parámetro k y captura interacciones de largo alcance, aunque puede introducir ruido de conexiones débiles.
- **Conectividad total inversa (fully_connected_inverse_distance)**. Usa $W_{ij} = 1/d_{ij}$, generando un grafo denso donde la influencia decae linealmente con la distancia.

Grafos basados en correlación funcional. Utilizan la serie temporal observada para cuantificar similitud entre electrodos. La construcción es $W_{ij} = |\rho_{ij}|$, donde ρ_{ij} es el coeficiente de correlación de Pearson entre los electrodos i y j , calculado solo con canales disponibles. Este criterio es informativo para exploración, pero introduce circularidad si se usa para confirmar desempeño: el grafo queda parcialmente determinado por las mismas señales sobre las que luego se evalúa la reconstrucción. Por esta razón, los grafos de correlación se usaron solo en la fase de selección preliminar y no sostienen las conclusiones comparativas principales. **Grafos data-driven (aprendidos desde los datos).** No requieren especificar un núcleo ni sus parámetros; la estructura del grafo emerge de las señales mismas:

- **Kalofolias (kalofolias)**. Formula el aprendizaje del grafo como optimización convexa que minimiza la variación de la señal observada con restricciones de grado positivo [11]. Se implementó una versión propia con descenso de gradiente proyectado sobre la función objetivo de log-grados más regularización de Frobenius.
- **NNK (nnk)**. Regresión de kernel no-negativa que selecciona automáticamente los vecinos relevantes para cada nodo resolviendo un problema NNLS (*Non-Negative Least*

Squares) local, sin necesidad de especificar k [21].

- **AEW (Adaptive Edge Weighting)**. Optimización conjunta de pesos y topología mediante el algoritmo AEW [21], que alterna entre actualización de pesos vía descenso de gradiente y proyección sobre restricciones de grado.

Los grafos data-driven se evaluaron en la fase exploratoria pero no se incluyeron en la fase comparativa por dos razones: su mayor costo computacional ($O(N^3)$ en el caso de Kalofolias) y la dificultad de garantizar reproducibilidad determinista entre ejecuciones. Esta decisión no es puramente teórica: el Capítulo 4 documenta la selección preliminar de combinaciones método-grafo y la reducción experimental que llevó a concentrar la comparación final en grafos geométricos reproducibles y en la referencia MNE-Python. Su impacto sobre TRSS se propone como trabajo futuro.

2.3. Estado del Arte en Interpolación de Señales Biomédicas

2.3.1. Métodos Geométricos y Estadísticos

El método más establecido es el de *spherical splines* [18], que modela el potencial sobre el cuero cabelludo como una función suave sobre una esfera. El potencial estimado en una posición $\mathbf{r}$ es $\hat{V}(\mathbf{r}) = c_0 + \sum_{i=1}^M c_i g_m(\mathbf{r}, \mathbf{r}_i)$, donde M es el número de canales observados, g_m es la función de Green del operador pseudo-laplaciano de orden m sobre la esfera y los coeficientes se obtienen resolviendo un sistema lineal aumentado. En una forma regularizada, el bloque principal del sistema puede escribirse como $(\mathbf{G} + \lambda \mathbf{I})\mathbf{c} + c_0 \mathbf{1} = \mathbf{v}$, donde $G_{ij} = g_m(\mathbf{r}_i, \mathbf{r}_j)$ y λ estabiliza el ajuste. Así, m controla la rigidez de la superficie y λ regula el compromiso entre ajuste y suavidad. Junto a los splines esféricos, se implementaron y evaluaron otros métodos de la familia geométrica. La **interpolación por distancia inversa** (IDW) estima el canal faltante como promedio ponderado de los canales observados, con pesos $w_i = 1/d_i^p$ donde d_i es la distancia euclidiana al canal faltante y p controla la velocidad de decaimiento. La **interpolación por vecino más cercano** asigna al canal faltante el valor del canal observado más próximo. Las **funciones de base radial** (RBF) generalizan el enfoque usando núcleos gaussianos o multicuádricos y han sido aplicadas explícitamente a reconstrucción de EEG [9]. La **interpolación lineal** estima por triangulación sobre las posiciones 2D/3D de los electrodos. Estos métodos comparten la propiedad de operar exclusivamente en el dominio espacial, ignorando la estructura temporal de la señal.

Entre los métodos estadísticos, el **Análisis de Componentes Independientes (ICA)** [10] se utilizó en dos variantes: una implementación propia con FastICA y la implementación de MNE-Python (ICA-MNE) con algoritmo Picard. ICA proyecta las señales observadas sobre fuentes independientes, elimina componentes artefactuales y reconstruye los canales faltantes desde el espacio de fuentes. Su inclusión se justifica porque es el método estándar de la comunidad EEG para remoción de artefactos, y evaluar su capacidad de reconstruir canales completamente ausentes —no solo corregir canales ruidosos— es una pregunta metodológica relevante. Sin embargo, ICA requiere la estimación de la matriz de mezcla sobre datos completos y su desempeño se degrada cuando la pérdida de canales es severa y contigua, por lo que se reservó para la fase exploratoria. El **Análisis de Componentes Principales (PCA)** se menciona aquí como contexto histórico pero no se evaluó experimentalmente por su desempeño consistentemente inferior en pruebas preliminares.

2.3.2. Métodos Basados en GSP

La **regularización de Tikhonov en grafos** formula la interpolación como un problema de optimización convexa:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \|\mathbf{M} \odot (\mathbf{x} - \mathbf{y})\|_2^2 + \alpha \cdot \mathbf{x}^\top \mathbf{L} \mathbf{x}, \quad (2.2)$$

donde $\mathbf{M} \in \{0, 1\}^N$ es la máscara binaria de canales observados (con $M_i = 1$ si el canal i está observado y $M_i = 0$ si está faltante), $\odot$ denota el producto Hadamard (multiplicación elemento a elemento entre dos matrices o vectores del mismo tamaño), y α controla el compromiso entre fidelidad a los datos y suavidad espacial. La Ecuación 2.2 admite solución cerrada $\hat{\mathbf{x}} = (\text{diag}(\mathbf{M}) + \alpha \mathbf{L})^{-1} (\mathbf{M} \odot \mathbf{y})$. El **método de muestreo en grafos** asume que la señal es de banda limitada y busca la señal de banda limitada que interpola exactamente los valores observados.

2.3.3. Regularización Espacio-Temporal: TRSS

La Regularización Temporal de Suavidad de Sobolev (TRSS) [5] incorpora la continuidad temporal de las señales neuronales mediante un término adicional de penalización. El problema conjunto sobre la matriz espacio-temporal $\mathbf{X} \in \mathbb{R}^{N \times T}$ es

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{X}} \|\mathbf{M} \odot (\mathbf{X} - \mathbf{Y})\|_F^2 + \alpha \cdot \text{tr}(\mathbf{X}^\top \mathbf{L} \mathbf{X}) + \beta \cdot \|\mathbf{X} \mathbf{D}_t\|_F^2, \quad (2.3)$$

donde $\mathbf{D}_t \in \mathbb{R}^{T \times (T-1)}$ es la matriz de diferencias finitas con $(\mathbf{D}_t)_{t,t} = -1$, $(\mathbf{D}_t)_{t+1,t} = 1$, y $\|\mathbf{X}\mathbf{D}_t\|_F^2 = \sum_{i=1}^N \sum_{t=1}^{T-1} (X_{i,t+1} - X_{i,t})^2$ penaliza los cambios abruptos muestra a muestra. β controla la suavidad temporal: $\beta = 0$ reduce TRSS a Tikhonov independiente por instante; $\alpha = 0$ lo convierte en un suavizador temporal sin guía espacial. La interacción de ambos términos se evalúa empíricamente mediante el estudio de descomposición de componentes del Capítulo 4. La Figura 2.3 descompone visualmente la contribución de cada término en la Ecuación 2.3.




Figura 2.3: Descomposición del operador TRSS. La reconstrucción combina fidelidad a los canales observados, suavidad espacial inducida por el Laplaciano del grafo y suavidad temporal inducida por diferencias finitas. El término temporal no agrega información externa: restringe el espacio de soluciones admisibles mediante D_t .

2.4. Mecanismo Interno de la Interpolación en MNE-Python

Esta sección documenta las mejoras de ingeniería —no descritas en la literatura académica— que convierten a la implementación de *spherical splines* en MNE-Python [7, 8] en una referencia sólida. La información se obtuvo mediante inspección directa del código fuente.

2.4.1. Formulación Original y sus Seis Mejoras

El artículo de Perrin [18] formula la interpolación como un sistema lineal aumentado en el que la regularización se incorpora al bloque de Green, de manera análoga a $(\mathbf{G} + \lambda \mathbf{I})\mathbf{c}$. La formulación original ya utiliza todos los canales observados para estimar cada canal faltante; por tanto, la ventaja de MNE-Python no proviene de usar más canales que Perrin, sino de una implementación numéricamente robusta y bien integrada al flujo M/EEG. MNE-Python incorpora las siguientes decisiones de ingeniería:

1. **Normalización a esfera unitaria.** Las coordenadas de electrodos $\mathbf{p}_i$ se centran y escalan: $\mathbf{p}'_i = (\mathbf{p}_i - \bar{\mathbf{p}}) / \max_j \|\mathbf{p}_j - \bar{\mathbf{p}}\|_2$. Esto elimina la dependencia de unidades físicas y mejora el condicionamiento numérico.
2. **Uso global preservado.** Igual que la formulación de Perrin, todos los M canales observados contribuyen a cada estimación. En un montaje de 64 canales con 2 canales malos, la reconstrucción aprovecha 62 electrodos; esto la diferencia de métodos locales como vecino más cercano o k-NN con k pequeño, no de Perrin.
3. **Regularización adaptativa.** El regularizador efectivo se escala según la matriz de Green $\mathbf{G}$: $\varepsilon = 10^{-6} \cdot \text{tr}(\mathbf{G})/M$. Aquí ε cumple el papel numérico de λ en el sistema regularizado.
4. **Aumentación con restricciones lineales.** Se fuerzan $\sum_i c_i = 0$ y condiciones análogas para las coordenadas, garantizando unicidad.
5. **Pseudoinversa con tolerancia adaptativa.** Ante matrices numéricamente singulares, se usa una pseudoinversa con umbral proporcional a la norma.
6. **Reintento automático.** Si la reconstrucción produce valores nulos, el sistema reintenta con parámetros por defecto.

Estas mejoras transforman un algoritmo teóricamente simple en un estimador notablemente robusto. La implicación para esta tesis es clara: no es válido comparar contra implementaciones simplificadas de Perrin; la referencia debe ser MNE-Python mismo.

2.4.2. Los Tres Pilares de la Robustez

Desde el punto de vista **físico**, el modelo de cabeza esférica —cuya solución involucra polinomios de Legendre como base ortogonal natural para la ecuación de Laplace en coordenadas esféricas— es una solución regularizada de dicha ecuación: no es una heurística sino el modelo más simple que captura la física de la conducción volumétrica. Cuando la información previa es correcta —y la suavidad espacial del EEG es un hecho físico bien documentado—, los métodos con restricciones físicas simples superan a alternativas más complejas.

Desde el punto de vista **estadístico**, la regularización de MNE puede interpretarse como un estimador penalizado con una preferencia explícita por superficies suaves. No se afirma que MNE implemente un modelo bayesiano completo; la analogía relevante es que la penalización actúa como información previa de suavidad espacial. En el régimen de alta redundancia espacial típico del EEG de cuero cabelludo, este estimador penalizado aprovecha una propiedad física real de la señal. Desde el punto de vista **informacional**,

el EEG de cuero cabelludo exhibe redundancia espacial alta por el filtrado paso-bajo de la conducción volumétrica. Los métodos globales, que utilizan todos los canales observados, extraen más información que los métodos locales que restringen la estimación a un subconjunto de vecinos, como el vecino más cercano o k-NN con k pequeño. La Tabla 2.1 resume las familias de métodos discutidas en esta sección, indicando su principio matemático, fortaleza principal y limitación característica.

Tabla 2.1: Familias de métodos: principio matemático, fortalezas y limitaciones.

Familia	Principio	Fortaleza	Limitación
Geométrica	Distancia + superficie esférica	Velocidad, simplicidad	Ignora dinámica temporal
Estadística	Descomposición en fuentes (ICA)	Separa artefactos	Requiere datos completos
GSP-Tikhonov	Suavidad espacial en grafo	Topología flexible	Independiente por instante
GSP-Muestreo	Banda limitada en grafo	Fundamento de muestreo	Sensible a selección de K
TRSS	Suavidad espacio-temporal	Preserva morfología	Costo computacional alto
MNE-Python	Splines + mejoras ing.	Robusta en rég. favorable	Pierde precisión bajo pérdida contigua

Capítulo 3

Metodología

Este capítulo integra el diseño metodológico completo: conjuntos de datos, protocolos de simulación de canales faltantes, construcción de grafos, algoritmos de interpolación, métricas de evaluación, motor de optimización bayesiana, arquitectura del sistema experimental, trazabilidad de artefactos, diseño experimental y protocolo de validación comparativa. La Figura 3.1 resume el flujo metodológico completo.




Figura 3.1: Flujo metodológico de evaluación con control pareado. Cada método se aplica sobre los mismos conjuntos de datos, máscaras de pérdida y semillas; luego se calculan métricas de reconstrucción y costo antes de comparar los métodos por escenario pareado.

3.1. Conjuntos de Datos

La evaluación se realizó sobre tres bases de datos EEG públicas que cubren un espectro diverso de densidades de electrodos, paradigmas y poblaciones (Tabla 3.1).

Tabla 3.1: Características de los tres conjuntos de datos experimentales.

Dataset	Canales	Sistema	Frec. (Hz)	Sujetos	Paradigma
PhysioNet	64	10–10	160	109	Reposo
BCI IV 2a	22	10–20	250	9	Imag. motora
MNE Sample	60	10–20 ext.	600	1	Auditivo

PhysioNet [6, 20] contiene 64 canales (10–10) a 160 Hz de 109 sujetos. Se usaron segmentos de reposo con ojos abiertos (60 s por sujeto). **BCI Competition IV 2a** [2] aporta 22 canales (10–20) a 250 Hz de 9 sujetos en tareas de imaginación motora de cuatro clases. Se extrajeron 2592 ensayos de 2 s. **MNE Sample** [7] corresponde a un registro de un sujeto; de ese registro se seleccionaron 60 canales EEG a 600 Hz y 72 ensayos de 0.7 s alrededor de estímulos auditivos.

Estos tres conjuntos cubren el espacio de variabilidad real: desde 22 canales (clínica ambulatoria) hasta 64 (investigación), con frecuencias de 160 a 600 Hz y paradigmas de reposo, imaginación motora y potenciales evocados.

3.2. Protocolos de Simulación de Canales Faltantes

La evaluación de métodos de interpolación requiere conocer la señal verdadera (*ground truth*) para cuantificar el error de reconstrucción. La estrategia adoptada consiste en simular la pérdida sobre canales que sí están presentes y cuya señal real se conoce: se selecciona un subconjunto de canales, se oculta su señal (máscara de falta), se aplica el método de interpolación para estimar dicha señal, y se compara la estimación con la señal original oculta. Esta estrategia —estándar en la literatura de imputación de señales fisiológicas— permite calcular métricas de error exactas sobre datos reales sin requerir registros simultáneos de referencia.

Se definieron dos modos de pérdida de canales. El **modo aleatorio** selecciona un porcentaje p de canales al azar, modelando fallas esporádicas (secado del gel, desprendimiento de electrodos). El **modo contiguo** selecciona un canal semilla y marca como faltantes los p canales más cercanos en distancia euclidiana, modelando fallas catastróficas localizadas (saturación de amplificador).

Para cada modo se evaluaron cuatro severidades ($p \in \{10\%, 20\%, 30\%, 40\%\}$) con 5 semillas aleatorias, generando $3 \times 2 \times 4 \times 5 = 120$ escenarios. La semilla determina qué canales específicos se marcan como faltantes y se preserva para garantizar que todos los métodos se evalúen sobre exactamente las mismas máscaras.

3.3. Construcción de Grafos

Los métodos basados en GSP requieren un grafo subyacente que define la topología de conectividad entre electrodos. La construcción del grafo es una decisión metodológica independiente del algoritmo de interpolación: un mismo método puede operar sobre distintos grafos, y un mismo grafo puede alimentar distintos algoritmos.

Se implementaron diez estrategias de construcción de grafos, organizadas según la fuente de información que utilizan (Tabla 3.2). La nomenclatura entre paréntesis corresponde al identificador usado en el código del repositorio.

Tabla 3.2: Estrategias de construcción de grafos. La columna «Fase» indica si el grafo se usó en la fase exploratoria (E), comparativa (C) o ambas (E+C).

Estrategia	Tipo	Descripción	Fase
knn	Geométrico	k-NN no ponderado (k vecinos, pesos binarios)	E
knng	Geométrico	k-NN con kernel gaussiano (k , σ)	E+C
vknn	Geométrico	k-NN variable según densidad local (α)	E
epsilon_ball	Geométrico	ε -ball (todos los pares con $d < \varepsilon$)	E
gaussian	Geométrico	Distancia completa con kernel gaussiano (σ)	E+C
inv_distance	Geométrico	Conectividad total con $W_{ij} = 1/d_{ij}$	E
correlation	Correlación	$W_{ij} = \rho_{ij} $ (solo fase exploratoria)	E
kalofolias	Data-driven	Optimización de log-grados + regularización Frobenius	E
nnk	Data-driven	Regresión de kernel no-negativa (NNLS local)	E
aew	Data-driven	<i>Adaptive Edge Weighting</i>	E

Los grafos geométricos operan exclusivamente sobre las posiciones físicas de los electrodos, lo que los hace inmunes a canales faltantes y deterministas. Las posiciones se

obtuvieron desde los montajes disponibles en MNE-Python: PhysioNet se estandarizó con el montaje `standard\_1005`; BCI IV 2a se mapeó a los 22 nombres de canal del montaje 10–20 extendido; y MNE Sample usó las coordenadas incluidas en el archivo `sample\_audvis\_raw.fif`. Cuando un canal no tenía coordenada explícita, el sistema lo marcó como caso a revisar y evitó usarlo para conclusiones fuertes. Los grafos de correlación funcional se usaron únicamente en la fase de exploración inicial (*screening*), donde era necesario evaluar un gran número de combinaciones método×grafo; se descartaron para la fase comparativa porque la correlación se estima sobre las mismas señales que luego se reconstruyen, introduciendo circularidad metodológica. Los grafos data-driven se evaluaron en la fase exploratoria pero no pasaron a la fase comparativa por su mayor costo computacional y menor reproducibilidad determinista. Los grafos knng y gaussian fueron los únicos que avanzaron a la fase comparativa, por su balance entre expresividad y reproducibilidad.

3.4. Métodos de Interpolación

Se implementaron dieciocho métodos de interpolación organizados en cuatro familias (Tabla 3.3). La nomenclatura de familias es consistente a lo largo de todo el documento.

Tabla 3.3: Métodos de interpolación implementados y evaluados.

Familia	Métodos	Fase
Geométrica	Vecino más cercano, Distancia inversa (IDW), RBF, Spherical splines, Lineal	E
Estadística	ICA (FastICA), ICA-MNE (Picard)	E
GSP	Tikhonov en grafos, Banda limitada (BGSRP), Suavizado en grafos, TV en grafos, GTT (graph-time Tikhonov)	E
TRSS	Regularización espacio-temporal de Soble	E+C
Referencia	MNE-Python (defecto), MNE-Python (Optuna)	E+C

Es metodológicamente crucial distinguir entre la implementación propia de *spherical splines* y la de MNE-Python, que incorpora mejoras de ingeniería documentadas en el Capítulo 2. Los métodos GSP (Tikhonov, BGSRP, TV, GTT) y TRSS se evaluaron sobre múltiples grafos de la Sección 3.3, generando variantes por método según el grafo subyacente. Los métodos geométricos y estadísticos se evaluaron en la fase exploratoria;

solo TRSS y MNE-Python (en sus variantes por defecto y optimizada) avanzaron a la fase comparativa.

3.5. Métricas de Evaluación

Se emplearon seis métricas primarias organizadas en tres categorías, más el tiempo de cómputo como métrica complementaria (Tabla 3.4). Ninguna métrica individual captura todos los aspectos relevantes; por ello se reportan de forma independiente en los resultados.

Tabla 3.4: Métricas de evaluación. La notación $\mathcal{F}$ denota el conjunto de canales faltantes, x_i la señal real y $\hat{x}_i$ la reconstrucción.

Categoría	Métrica	Símbolo	Dirección
Amplitud	Error absoluto medio: $\frac{1}{ \mathcal{F} } \sum_{i \in \mathcal{F}} x_i - \hat{x}_i $	MAE	↓
	Raíz del error cuadrático medio: $\sqrt{\frac{1}{ \mathcal{F} } \sum_{i \in \mathcal{F}} (x_i - \hat{x}_i)^2}$	RMSE	↓
	Relación señal-ruido: $10 \log_{10}(\ x_{\mathcal{F}}\ ^2 / \ x_{\mathcal{F}} - \hat{x}_{\mathcal{F}}\ ^2)$	SNR	↑
Morfológica	<i>Dynamic Time Warping</i> : $\text{DTW}(x, \hat{x})$	DTW	↓
Espectral	Distancia Espectral Logarítmica: $\sqrt{\frac{1}{B} \sum_b (\log S_x(b) - \log S_{\hat{x}}(b))^2}$	LSD	↓
	Coherencia: $ S_{x\hat{x}}(f) ^2 / (S_{xx}(f) S_{\hat{x}\hat{x}}(f))$	Coh.	↑
Temporal	Tiempo de cómputo por caso (s)	t	↓

Las métricas de **amplitud** cuantifican el error muestra a muestra sobre los canales faltantes. El **DTW** permite deformaciones no lineales del eje temporal, relevante para segmentos con transitorios. Las métricas **espectrales** (LSD, Coherencia) cuantifican la distorsión del espectro de forma independiente del error de amplitud. El **tiempo de cómputo** se reporta como dimensión complementaria porque la mejora en precisión de reconstrucción debe sopesarse contra el costo computacional adicional.

3.6. Optimización Bayesiana con Optuna

Para garantizar una comparación justa, todos los algoritmos fueron optimizados mediante Optuna [1] con muestreo TPE (*Tree-structured Parzen Estimator*). El TPE modela las distribuciones de configuraciones con buen y mal desempeño y guía la búsqueda hacia regiones prometedoras, siendo más eficiente que una búsqueda aleatoria o de grilla para espacios de alta dimensionalidad.

Los espacios de búsqueda se definieron por familia (Tabla 3.5). Se ejecutaron 30 intentos por método de grafo, 10 intentos con NSGA-II multiobjetivo para *spherical splines*, y barridos de grilla fina para TRSS. En total se exploraron más de quince mil configuraciones paramétricas distintas.

Tabla 3.5: Espacios de búsqueda de hiperparámetros.

Familia	Parámetros	Escala	Estrategia
GSP (grafo)	$\sigma \in [0,01, 1,0]$, $k \in \{3, 5, 7, 10, 15, 20\}$	Lineal	TPE (30 intentos)
TRSS	$\alpha \in [10^{-4}, 10^2]$, $\beta \in [10^{-3}, 10^3]$	Log	Grilla fina
Splines propios	$m \in \{2, 3, 4\}$, $\lambda \in [10^{-8}, 10^{-2}]$	Mixta	NSGA-II (10 intentos)
MNE (Optuna)	$m \in \{2, 3, 4\}$, $\lambda \in [10^{-8}, 10^{-2}]$	Mixta	NSGA-II (10 intentos)

3.7. Arquitectura del Sistema Experimental

El sistema se organiza en cinco módulos con interfaces explícitas que operan en cadena (Figura 3.2). El módulo de **datos** expone una interfaz común para los tres conjuntos. El módulo de **simulación de daños** genera máscaras binarias con semilla trazable. El módulo de **métodos** combina la construcción de grafos —diez estrategias que producen **W** y **L**— con las dieciocho implementaciones de interpolación bajo una interfaz unificada. El módulo de **evaluación** calcula las métricas primarias y complementarias, y el módulo de **artefactos/optimización** orquesta Optuna en la fase exploratoria y registra resultados trazables para la fase comparativa.




Figura 3.2: Diagrama de bloques de la arquitectura del sistema experimental. Cinco módulos con interfaces explícitas operan en cadena. La figura distingue fase exploratoria y fase comparativa, indicando que los resultados comparativos no reabren la búsqueda de hiperparámetros.

3.7.1. Trazabilidad y Gestión de Artefactos

En experimentos computacionales a gran escala (18 métodos, 120 escenarios, más de 15 000 configuraciones), la gestión sistemática de artefactos resuelve tres problemas concretos. Primero, **auditoría**: cada número reportado debe poder rastrearse hasta el archivo que lo origina; sin trazabilidad es imposible distinguir un hallazgo real de un error de transcripción. Segundo, **control de contaminación**: las fases exploratoria y

comparativa deben mantenerse físicamente separadas para que resultados exploratorios no influyan inadvertidamente en decisiones posteriores. Tercero, **reproducibilidad**: un tercero con acceso al repositorio (<https://github.com/csaldivia/Tesis-GSP-EEG>) puede re-ejecutar cualquier subconjunto del experimento.

Cada ejecución recibe un identificador único (SHA-256 de la tupla completa de parámetros) y preserva: configuración inmutable (YAML), métricas agregadas (JSON), señales reconstruidas en formato NPZ (NumPy comprimido), máscara de daño, y tiempos de ejecución (Tabla 3.6). El código está versionado con Git y cada conjunto de resultados está asociado a un *commit hash* específico. La Figura 3.3 ilustra la cadena de trazabilidad desde el texto hasta el script generador.




Figura 3.3: Cadena de trazabilidad experimental. Cada afirmación cuantitativa se vincula con la tabla o figura correspondiente, el archivo de datos asociado y el script que generó el resultado.

Tabla 3.6: Artefactos generados por el sistema experimental.

Artefacto	Formato	Función
Configuración	YAML	Registro inmutable de parámetros
Métricas	JSON	Resultados de las métricas requeridas
Señal reconstruida	NPZ (NumPy)	Salida verificable bit a bit
Máscara de daño	NPZ (NumPy)	Trazabilidad de canales faltantes
Tiempos	JSON	Perfil de eficiencia computacional

3.8. Diseño Experimental

El diseño experimental se resume en la Tabla 3.7, que vincula cada pregunta de investigación con el experimento diseñado para responderla y la evidencia esperada. La lógica central es pareada: dos métodos se comparan sobre la misma señal, la misma máscara de canales ocultos y la misma semilla, evitando que diferencias del caso experimental contaminen la comparación.

La ejecución no consistió en un único benchmark final. Primero se realizó una exploración preliminar de combinaciones método-grafo para observar qué familias eran competitivas en datos sintéticos, proxies EEG y registros reales. Luego se redujo el conjunto de candidatos considerando desempeño, costo de ejecución, reproducibilidad y riesgo de circularidad en la construcción del grafo. En una tercera fase se optimizaron hiperparámetros mediante Optuna o grillas controladas y se congelaron las variantes que pasarían a la comparación final. El Capítulo 4 reporta esta trayectoria experimental antes de presentar los resultados finales TRSS-MNE.

Tabla 3.7: Relación entre preguntas de investigación, experimentos y evidencia esperada.

Pregunta	Experimento	Evidencia esperada
P1: ¿Cuándo mejora TRSS?	Comparación global de familias	Reducción de error y ajuste temporal en pérdida agrupada o severa
P1: ¿Aporta el término temporal?	Descomposición α/β	Diferencia observable entre TRSS completo y TRSS sin temporalidad
P1: ¿Preserva morfología temporal?	Series temporales y DTW	Menor distorsión temporal en escenarios representativos
P2: ¿Cuándo conviene MNE?	Comparación TRSS vs. MNE	MNE gana o empata en pérdida baja, señales suaves o restricciones de tiempo
P2: ¿Dónde está el punto de cruce?	Curvas por patrón y severidad	Frontera de uso dependiente de severidad, patrón y métrica

Las **variables independientes** son: método de interpolación, conjunto de datos, modo de pérdida, severidad y semilla (5 réplicas). Las **variables dependientes** son las métricas de la Sección 3.5. Las **variables controladas** incluyen: versiones exactas de todas las bibliotecas, semillas globales, preprocesamiento idéntico (filtro Butterworth 0.5–45 Hz, referencia promedio común, segmentación uniforme), y hardware de ejecución (CPU Intel Core i7-13700H, 32 GB RAM, sin aceleración GPU).

3.9. Protocolo de Validación Comparativa

La validación comparativa es una fase independiente que responde a una necesidad metodológica concreta: los resultados de la fase exploratoria (barridos de 15 000 configuraciones) no deben usarse como evidencia principal porque el riesgo de sobreajuste es alto. Un método que obtuvo buenos resultados porque sus hiperparámetros se ajustaron extensivamente sobre los datos de prueba no demuestra superioridad general; demuestra capacidad de ajuste al protocolo exploratorio. La fase comparativa reduce este riesgo al congelar los hiperparámetros de TRSS tras la optimización exploratoria y evaluarlo sobre una partición independiente, contra MNE-Python con parámetros por defecto.

La fase se diseñó con 100 estratos definidos por régimen de señal, patrón de pérdida y severidad, con tres semillas por estrato (300 casos pareados). Los regímenes incluyen señales reales y controles sintéticos suave/rugoso. El diseño es de medidas repetidas: cada caso comparte la misma señal y máscara, por lo que las diferencias se atribuyen al método bajo las condiciones del protocolo. El análisis reporta diferencias pareadas, medianas por estrato, tasas de victoria e intervalos de incertidumbre vía bootstrap jerárquico (1000 remuestreos), sin convertir la decisión metodológica en una prueba de hipótesis nula.

3.10. Control de Calidad

Antes de cualquier análisis se ejecutaron verificaciones automáticas: todas las ejecuciones contienen las métricas requeridas, ningún identificador duplicado con resultados diferentes, las máscaras coinciden con la semilla, y se excluyen ejecuciones con valores no numéricos, tiempo excesivo (>10 min) o reconstrucción idéntica a la entrada.

3.11. Síntesis del Diseño

El diseño experimental de esta tesis se distingue de la literatura previa en cuatro aspectos: todos los métodos fueron optimizados con el mismo motor bayesiano; se incorporó una comparación independiente contra MNE-Python; la evaluación abarca métricas de amplitud, morfología y espectro; y los escenarios incluyen pérdida aleatoria y contigua en un rango de severidades clínicamente relevante. La arquitectura modular, la separación estricta de fases y la trazabilidad completa de artefactos garantizan que las conclusiones sean auditables y reproducibles.

La consecuencia práctica de este diseño es que el Capítulo 4 debe leerse en dos niveles. El primer nivel es experimental: muestra cómo el repositorio pasó de un espacio amplio de grafos y métodos a un subconjunto final defendible. El segundo nivel es comparativo: evalúa ese subconjunto bajo casos pareados y métricas comunes. Esta distinción evita confundir resultados exploratorios con evidencia final y permite justificar por qué la tesis se concentra en TRSS y MNE-Python.

Además, la separación de fases hace explícitas las decisiones negativas del estudio. No todos los métodos implementados avanzaron a la comparación final; algunos fueron descartados por costo, otros por circularidad potencial en la construcción del grafo, y otros por no mejorar respecto de referencias más simples. Documentar esas reducciones es parte del resultado experimental, porque muestra que la comparación final no fue seleccionada arbitrariamente sino derivada de evidencia intermedia trazable.

Capítulo 4

Experimentos y Resultados

Este capítulo documenta la trayectoria experimental completa de la tesis. No se limita a reportar la comparación final TRSS–MNE: primero describe cómo se exploró el espacio de métodos y grafos, cómo se redujo el conjunto de candidatos, cómo se congelaron variantes para evitar contaminación entre fases, y luego presenta los resultados comparativos finales mediante evidencia descriptiva, temporal, espectral y práctica. Esta organización permite distinguir entre resultados preliminares —útiles para diseñar el experimento— y resultados finales —usados para responder las preguntas de investigación.

4.1. Mapa de fases experimentales

La evaluación se organizó como una cadena de decisiones, no como un único experimento aislado. Primero se realizó una **exploración preliminar** de combinaciones método–grafo sobre datos sintéticos y EEG proxy/real, con el objetivo de identificar familias plausibles sin convertir ese ranking en conclusión final. Luego vino la **reducción de candidatos**: se descartaron alternativas inestables, demasiado costosas o dependientes de información circular. En una tercera fase se hizo **optimización intermedia**, donde se exploraron hiperparámetros y se congelaron variantes antes de la comparación pareada. Solo entonces se ejecutó la **comparación final** TRSS–MNE. Finalmente, la **inspección cualitativa** revisó señales temporales y PSD para comprobar que las métricas agregadas correspondieran a reconstrucciones interpretables.

Esta separación es metodológicamente importante. Los resultados preliminares no se interpretan como evidencia final porque fueron usados para decidir qué métodos seguir explorando. Su función en este capítulo es explicar por qué la comparación final se

concentra en TRSS y MNE, y por qué algunas estrategias teóricamente atractivas no pasaron a la etapa comparativa.

4.2. Selección preliminar de métodos y grafos

La selección preliminar evaluó combinaciones de familias de interpolación y construcción de grafos sobre datos sintéticos, proxies EEG y registros reales. La Tabla 4.1 muestra la mejor combinación método-grafo por conjunto dentro del ranking exploratorio. El patrón general es que las variantes con información temporal aparecen repetidamente en las primeras posiciones, aunque no de manera universal: algunos conjuntos favorecen métodos instantáneos o geométricos simples.

Tabla 4.1: Mejor combinación método-grafo por conjunto durante la selección exploratoria. El ranking corresponde al puntaje compuesto de los resultados preliminares; no constituye la comparación final contra MNE.

Conjunto	Familia	Grafo	Método	MAE	SNR
PhysioNet proxy	TV/Tiempo	aew	trss	$5,00e - 06$	14.361
PhysioNet real	TV/Tiempo	knn k=5	trss	$2,84e - 06$	17.366
MNE Sample proxy	TV/Tiempo	knn k=3	directed_tv	$2,95e - 07$	11.277
BCI IV proxy	TV/Tiempo	kalofolias	trss	$4,07e - 07$	13.024
BCI IV real S1	TV/Tiempo	knn k=3	trss	$1,91e - 06$	17.057
BCI IV real S2	TV/Tiempo	gauss sigma=1	trss	$6,48e - 07$	24.429
BCI IV real S3	GSP Instantáneo	knn k=3	nearest	$6,14e - 07$	15.063
Sintético 16 ch	TV/Tiempo	knn k=3	trss	0.475	3.188
Sintético 32 ch	TV/Tiempo	knn k=3	trss	0.412	3.861

La lectura de esta tabla no es “el mejor método final es siempre el de la primera fila de cada conjunto”. Su función es más limitada: mostrar que el espacio de búsqueda inicial era amplio y heterogéneo. En PhysioNet y varios conjuntos BCI, TRSS aparece como candidato fuerte; en MNE Sample proxy, una variante temporal distinta queda primera; y en algunos casos reales BCI aparece una referencia instantánea. Por eso la tesis no salta directamente a una afirmación de superioridad de TRSS: primero reduce el espacio experimental y luego compara contra una referencia comunitaria fuerte.

4.3. Reducción de candidatos

La reducción de candidatos combinó tres criterios. Primero, se descartaron estrategias que dependían de información potencialmente circular, como grafos construidos desde

correlaciones de la misma señal evaluada. Segundo, se relegaron métodos data-driven cuya reproducibilidad o costo dificultaba una comparación final controlada. Tercero, se consideró el tiempo de ejecución, porque un método que mejora una métrica pero no es operativo puede ser poco útil en flujos EEG reales.

La Tabla 4.2 resume un microbenchmark usado como señal de costo. Métodos simples como media o lineal son muy rápidos pero menos expresivos; TRSS queda en una zona intermedia; y métodos como TV temporal o Visibility NNK resultan costosos para una evaluación extensiva. Esta evidencia apoyó concentrar la fase final en una comparación interpretable: TRSS como representante espacio-temporal y MNE-Python como referencia madura.

Tabla 4.2: Microbenchmark de latencia usado como criterio de reducción de candidatos.

Método	Identificador	Mediana
Media	Media	0.32 ms
Lineal	Lineal	0.34 ms
RBF TPS	RBF TPS	6.58 ms
TRSS	TRSS	9.44 ms
Laplaciano temporal	Laplaciano tempo- ral	6.13 ms
Spline esférica propia	Spline esférica pro- pia	136.64 ms
TV temporal	TV temporal	443.36 ms
Visibility NNK	Visibility NNK	7.04 s

A partir de esa evidencia, la reducción se resolvió así. Los métodos geométricos propios se conservaron como antecedentes, pero MNE-Python pasó a ser la referencia principal por su implementación comunitaria más robusta. Los grafos de correlación se usaron solo como exploración, porque pueden depender de la misma señal evaluada. Los grafos data-driven se dejaron para trabajo futuro por su mayor costo y menor determinismo. Los métodos temporales distintos de TRSS permanecieron como evidencia intermedia, pero no sostienen la comparación final. De esta forma, el cierre experimental queda concentrado en una pregunta más limpia: cómo se comporta TRSS frente a MNE cuando ambos se evalúan sobre casos pareados.

4.4. Optimización intermedia

La fase intermedia usó Optuna y barridos controlados para explorar hiperparámetros de familias candidatas. En esta etapa se evaluaron configuraciones por conjunto, patrón

de pérdida y severidad; también se compararon configuraciones globales contra óptimos locales. El propósito fue estimar si el rendimiento dependía de una calibración específica por escenario o si una variante fija podía sostener la comparación final.

La distinción entre variantes cumple una función práctica. La **búsqueda por familia** identifica rangos plausibles de hiperparámetros, pero no fija conclusiones definitivas. La **configuración global** evalúa si una parametrización única mantiene desempeño razonable entre escenarios. **TRSS fijo** representa la variante reproducible con parámetros congelados antes de la comparación pareada, por lo que es la lectura principal frente a MNE. **TRSS calibrado** aproxima una selección más adaptativa y se usa como análisis auxiliar de sensibilidad. El **oráculo** solo estima una cota superior no desplegable; sirve como contexto metodológico, no como método aplicable.

Esta fase explica por qué la comparación final distingue entre TRSS fijo, TRSS calibrado y oráculo. En la narrativa principal se privilegia TRSS fijo frente a MNE, porque es la lectura más transparente y menos dependiente de sobreajuste. Las variantes calibrada y oracular ayudan a interpretar cuánto podría cambiar el desempeño bajo reglas de selección más flexibles, pero no reemplazan la comparación principal.

4.5. Inventario de la comparación final

La comparación final se apoya en cinco tipos de evidencia. Los **datos** provienen de MNE Sample, PhysioNet, BCI IV 2a y controles sintéticos descritos en el Capítulo 3; los resultados se almacenan en CSV crudos y derivados. Los **métodos** se reducen a MNE como referencia comunitaria y TRSS fijo como variante propuesta principal, dejando TRSS calibrado y oráculo como análisis auxiliares. Los **escenarios** combinan máscaras aleatorias, cercanas, periféricas y de alta varianza con severidades bajas y altas. Las **métricas** separan error de amplitud, forma temporal, preservación espectral y tiempo de cómputo. Finalmente, los **casos cualitativos** muestran ejemplos favorables a TRSS, favorables a MNE, empates prácticos y pérdidas severas seleccionadas de forma reproducible.

Esta descripción reemplaza un inventario tabular porque la información es conceptual, no numérica. Lo importante es que el lector distinga dos niveles de evidencia: las tablas cuantitativas describen tendencias agregadas; las figuras temporales y espectrales muestran cómo se ven esas tendencias en señales concretas. Las métricas se calculan sobre los canales ocultos, no sobre los canales observados. MAE, RMSE y NRMSE describen error de amplitud; DTW y correlación capturan aspectos de forma temporal; LSD y coherencia resumen propiedades espectrales; y el tiempo de cómputo cuantifica el costo práctico.

4.6. Resumen descriptivo de TRSS frente a MNE

La Tabla 4.3 resume la comparación pareada descriptiva entre TRSS fijo y MNE. En las métricas de amplitud, TRSS reduce el error mediano respecto de MNE: la mejora mediana es 12.4 % en MAE, 13.9 % en RMSE y 13.9 % en NRMSE. Las tasas de victoria cercanas al 70 % indican que la mejora no se concentra en un único caso extremo, sino que aparece en una proporción amplia de pares. También se observan mejoras en DTW, correlación y R^2 , lo que sugiere una mejor conservación de la forma temporal en parte importante del protocolo.

Tabla 4.3: Resumen descriptivo pareado de TRSS fijo frente a MNE para métricas de calidad. La mejora mediana positiva favorece a TRSS después de respetar la dirección de cada métrica; la tasa de victoria indica la proporción de pares donde TRSS supera a MNE. Los intervalos son bootstrap descriptivos al 95 %, no pruebas de hipótesis.

Categoría	Métrica	Medianas MNE → TRSS	Mej. med. (%)	Victoria (%)	IC descriptivo (%)
Amplitud	MAE	$1,13 \times 10^{-5} \rightarrow$ $8,46 \times 10^{-6}$	+12.4	72.0	[+7.8, +17.4]
Amplitud	RMSE	$1,47 \times 10^{-5} \rightarrow$ $1,06 \times 10^{-5}$	+13.9	70.3	[+6.4, +19.3]
Amplitud	NRMSE	$7,25 \times 10^{-1} \rightarrow$ $6,34 \times 10^{-1}$	+13.9	70.3	[+6.4, +19.3]
Forma	DTW	$6,73 \times 10^{-4} \rightarrow$ $5,60 \times 10^{-4}$	+9.8	71.0	[+5.5, +12.7]
Amplitud	SNR	$9,47 \times 10^0 \rightarrow$ $1,00 \times 10^1$	+3.7	61.0	[+0.9, +9.6]
Espectral	LSD	$7,51 \times 10^{-1} \rightarrow$ $7,67 \times 10^{-1}$	-2.3	40.7	[-4.0, -0.2]
Espectral	Coherencia	$8,87 \times 10^{-1} \rightarrow$ $8,88 \times 10^{-1}$	+0.2	58.3	[0.0, +0.5]
Forma	Correlación	$9,27 \times 10^{-1} \rightarrow$ $9,42 \times 10^{-1}$	+0.8	68.7	[+0.3, +2.0]
Forma	R^2	$4,75 \times 10^{-1} \rightarrow$ $5,98 \times 10^{-1}$	+16.9	70.3	[+3.4, +52.8]

La lectura cambia al considerar espectro y costo. En LSD, donde valores menores son preferibles, TRSS presenta una mejora mediana negativa y una tasa de victoria inferior al 50 %. Esto indica que TRSS puede mejorar el error de amplitud y aun así no preservar mejor la distancia espectral global. En tiempo de cómputo, MNE domina claramente: TRSS requiere más tiempo por caso, lo que impide recomendarlo como reemplazo universal. La Figura 4.1 resume las métricas de calidad; el costo se analiza por separado en la Sección 4.11 para que la gran diferencia temporal no comprima las demás métricas.




Figura 4.1: Perfil descriptivo de calidad para TRSS fijo frente a MNE. Las barras positivas favorecen a TRSS después de respetar la dirección de cada métrica; las barras negativas favorecen a MNE. El costo temporal se reporta por separado porque su escala es muy distinta a la de las métricas de reconstrucción.

4.7. Efecto del escenario de pérdida

El comportamiento global se entiende mejor al separar patrón y severidad de pérdida. La Tabla 4.4 muestra que la ventaja de TRSS aumenta cuando la pérdida elimina información espacial local: los patrones cercanos y periféricos de alta severidad son los casos donde la regularización temporal se vuelve más útil. En cambio, con pérdida baja o pocos canales ocultos, la diferencia puede acercarse a un empate práctico, porque MNE ya cuenta con suficientes canales vecinos para reconstruir la señal mediante suavidad espacial.

Tabla 4.4: Resumen por patrón y severidad de pérdida para MAE. Cada fila reporta la mejora mediana de TRSS frente a MNE, la tasa de victoria (proporción de pares donde TRSS obtiene menor MAE) y la mejora media como lectura complementaria.

Patrón	Severidad	n	Mej. med. (%)	Victoria (%)	Mej. media (%)
Cercano	40 %	15	+40.8	86.7	+33.5
Cercano	30 %	15	+41.2	80.0	+26.3
Periférico	40 %	15	+31.6	80.0	+25.5
Periférico	10 %	15	+23.2	73.3	+17.4
Aleatorio	40 %	15	+13.0	80.0	+11.6
Aleatorio	10 %	15	+5.7	66.7	+3.8
Alta varianza	40 %	15	+10.1	80.0	+9.2
Cercano	2 canal(es)	15	0.0	46.7	-0.3

La Figura 4.2 ofrece la misma lectura en formato gráfico. Cada celda contiene tres

elementos: la primera línea es la mejora mediana de MAE de TRSS frente a MNE; la segunda línea es la tasa de victoria; la tercera línea es el número de pares. La tabla y el mapa no son resultados independientes: ambos resumen la misma comparación pareada desde dos ángulos. La tabla facilita revisar valores extremos y comprobar magnitudes; el mapa permite ver el patrón global de una sola vez. Esta doble presentación justifica la conclusión de la sección: TRSS no gana por igual en todos los casos, sino que su ventaja aumenta cuando la pérdida reduce información espacial local.




Figura 4.2: Resumen por patrón y severidad de pérdida. Cada celda muestra mejora mediana de MAE, tasa de victoria (WR) y número de pares. La ventaja de TRSS crece en pérdidas cercanas o periféricas severas, donde la información espacial local disponible para MNE disminuye.

4.8. Señales temporales representativas

Las métricas agregadas no bastan para evaluar si una reconstrucción es fisiológicamente plausible. Por ello se seleccionaron casos representativos de manera reproducible desde los resultados balanceados: un caso favorable a TRSS, un caso favorable a MNE, un empate práctico y un caso de pérdida cercana severa. La Tabla 4.5 documenta la regla de selección de cada caso, el patrón de pérdida, la semilla y el canal visualizado.

La selección no busca mostrar únicamente casos favorables. El primer caso ilustra el régimen donde TRSS reduce marcadamente el error; el segundo conserva un ejemplo

Tabla 4.5: Casos representativos seleccionados de forma reproducible en MNE Sample para inspección temporal y espectral. La mejora se calcula en MAE para TRSS fijo frente a MNE; valores negativos indican que MNE fue mejor en ese caso.

Rol	Patrón	Sev.	Sem.	Canal	Mej. MAE (%)	Regla
TRSS favorable	Cercano	40 %	0	15	+71.0	Mayor mejora MAE.
MNE favorable	Periférico	1 canal	2	39	-38.7	Peor caso MAE para TRSS.
Empate práctico	Aleatorio	30 %	1	1	+0.1	Mejora absoluta mínima.
Pérdida cercana severa	Cercano	40 %	2	14	+34.0	Escenario cercano severo.

donde MNE es preferible; el tercero fuerza un empate práctico; y el cuarto representa una pérdida cercana severa típica de la discusión metodológica. Esta combinación hace visible la heterogeneidad del problema y evita que las señales temporales funcionen como ejemplos aislados o escogidos solo por conveniencia.

La Figura 4.3 compara la señal original con las reconstrucciones de MNE y TRSS. La lectura importante es que TRSS no se comporta de forma uniforme. En el caso favorable, conserva mejor la morfología de la señal oculta; en el caso favorable a MNE, la regularización temporal no compensa el sesgo introducido y MNE se acerca más a la señal original; en el empate práctico, ambas reconstrucciones son similares; y en la pérdida cercana severa se observa el régimen donde la continuidad temporal puede aportar estabilidad. Esta figura responde directamente a si un mal caso de TRSS es universal: no lo es, pero sí existe y debe considerarse al decidir el método.

La inspección temporal cumple una función distinta a la métrica agregada. No cambia el ranking global ni reemplaza las tablas, pero permite revisar si la diferencia numérica corresponde a una señal plausible. Por eso se incluyen casos favorables y desfavorables: el objetivo no es escoger ejemplos visualmente convenientes, sino mostrar el tipo de comportamiento que sustenta la frontera práctica entre métodos.




Figura 4.3: Reconstrucciones temporales representativas en MNE Sample. Cada fila muestra señal original, reconstrucción MNE y reconstrucción TRSS para un canal oculto seleccionado de forma reproducible. Los casos incluyen un escenario favorable a TRSS, uno favorable a MNE, un empate práctico y una pérdida cercana severa.

4.9. Preservación espectral

La preservación temporal y la preservación espectral no son equivalentes. Un método puede reducir MAE y NRMSE, pero alterar la distribución de potencia por frecuencia. Por esta razón, la Figura 4.4 reemplaza la comparación espectral multi-método previa por una lectura directa: para los mismos casos representativos, se grafica el espectro de la señal original junto con los espectros de MNE y TRSS. Las curvas se estiman con Welch sobre el canal oculto visualizado, usando la frecuencia de muestreo del registro MNE Sample.




Figura 4.4: PSD original versus PSD interpolado para los casos representativos. La figura compara directamente la densidad espectral de potencia de la señal original con las reconstrucciones MNE y TRSS. Esta lectura permite explicar por qué TRSS puede mejorar error de amplitud sin dominar necesariamente la métrica LSD.

La rugosidad de un espectro estimado depende de la duración de la ventana, la frecuencia de muestreo, el canal observado y el método de estimación. En esta versión, el uso de Welch reduce la variabilidad visual y permite comparar la forma global de las curvas. Si TRSS y MNE se separan en bandas concretas, esa diferencia debe interpretarse junto con LSD y no solo con MAE.

4.10. Contribución temporal de TRSS

En este contexto, el análisis de contribución consiste en repetir la evaluación retirando un componente del modelo para estimar su aporte específico. La comparación de esta sección contrasta TRSS completo contra una variante sin término temporal. Por tanto, no evalúa si TRSS completo supera a MNE, sino cuánto cambia TRSS cuando se elimina la restricción temporal. La Tabla 4.6 resume la magnitud descriptiva de ese aporte.

Tabla 4.6: Contribución descriptiva del término temporal dentro de TRSS. La comparación retira el término temporal y mide cuánto cambia el desempeño relativo del modelo completo.

Métrica	Mej. med. (%)	Mej. media (%)	Victoria (%)
MAE	+0.7	+0.7	100.0
RMSE	+0.7	+0.7	100.0
DTW	+1.5	+2.0	100.0
LSD	+6.4	+6.5	100.0

La Figura 4.5 muestra que el término temporal aporta mejoras descriptivas dentro de la familia TRSS, aunque la magnitud no explica por sí sola toda la diferencia frente a MNE. La interpretación más prudente es que la temporalidad estabiliza la reconstrucción cuando la información espacial es insuficiente, pero no convierte automáticamente a TRSS en dominante para toda métrica ni para todo escenario.




Figura 4.5: Aporte descriptivo del término temporal dentro de TRSS. Las barras muestran la mejora de TRSS completo frente a TRSS sin término temporal.

4.11. Costo computacional

El costo computacional es parte de la conclusión, no un detalle de implementación. Para interpretar la Tabla 4.7, N representa el número de canales, T el número de muestras temporales, E el número de aristas, K las iteraciones del resolutor y H el número de configuraciones evaluadas durante calibración. La variable H no describe el costo de aplicar TRSS con parámetros ya fijados: solo aparece cuando hay búsqueda o calibración de hiperparámetros.

La Tabla 4.7 conecta esa notación con el tiempo observado por caso. MNE resuelve

una interpolación espacial de tamaño moderado y luego aplica la solución a las muestras temporales. TRSS, en cambio, itera sobre un operador que combina estructura espacial y temporal.

Tabla 4.7: Complejidad computacional e implementación observada. N es el número de canales, T el número de muestras temporales, E el número de aristas del grafo y K el número de iteraciones del resolutor.

Método	Operación dominante	Complejidad orientativa	Mediana (s/caso)
MNE spline	Sistema global regularizado y aplicación a muestras	$O(N^3) + O(NT)$	0.0090
TRSS fijo	Iteraciones sobre grafo espacio-temporal disperso	$O(K(ET + NT))$	0.1214
TRSS calibrado	TRSS fijo más selección de hiperparámetros	$O(HK(ET + NT))$	0.0845

Esta diferencia explica la ventaja operativa de MNE en procesamiento masivo o interactivo; TRSS queda para escenarios difíciles donde el análisis puede ejecutarse fuera de línea.

4.12. Frontera práctica TRSS–MNE

Los resultados no muestran una dominancia universal de TRSS. La regla práctica es simple: MNE debe mantenerse como opción por defecto; TRSS debe considerarse cuando la pérdida espacial es difícil y el análisis puede ejecutarse fuera de línea. En los términos de la Tabla 4.4, pérdida baja corresponde a pocos canales o severidad cercana al 10 %, mientras que pérdida severa corresponde a 30–40 % o a patrones cercanos/periféricos que degradan la vecindad espacial. En concreto, MNE es preferible cuando la señal es espacialmente suave, el análisis es principalmente espectral o el costo domina; TRSS es razonable cuando la pérdida amenaza la fidelidad de reconstrucción y la regularidad temporal puede compensar la falta de información local. En casos intermedios, la decisión debe apoyarse en la métrica relevante para el análisis posterior.

Bibliografía

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019.
- [2] Clemens Brunner, Robert Leeb, Gernot R. Müller-Putz, Alois Schlögl, and Gert Pfurtscheller. BCI Competition IV – Dataset 2a. Graz University of Technology, 2008. URL <https://www.bbci.de/competition/iv/>.
- [3] György Buzsáki. Rhythms of the brain. 2006. doi: 10.1093/acprof:oso/9780195301069.001.0001.
- [4] Arnaud Delorme and Scott Makeig. Eeglab: An open source toolbox for analysis of single-trial eeg dynamics including independent component analysis. *Journal of Neuroscience Methods*, 134(1):9–21, 2004. doi: 10.1016/j.jneumeth.2003.10.009.
- [5] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans. Reconstruction of time-varying graph signals via sobolev smoothness. *IEEE Transactions on Signal and Information Processing over Networks*, 8:201–214, 2022. doi: 10.1109/TSIPN.2022.3156886.
- [6] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215.
- [7] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Roman Goj, Mainak Jas, Teon Brooks, Lauri Parkkonen, and Matti Hämäläinen. MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, 7:267, 2013. doi: 10.3389/fnins.2013.00267.

- [8] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Lauri Parkkonen, and Matti S. Hämäläinen. MNE software for processing MEG and EEG data. *NeuroImage*, 86:446–460, 2014. doi: 10.1016/j.neuroimage.2013.10.027.
- [9] Janin Jäger, Alexander Klein, Martin Buhmann, and Wolfgang Skrandies. Reconstruction of electroencephalographic data using radial basis functions. *Clinical Neurophysiology*, 127(4):1978–1983, 2016. doi: 10.1016/j.clinph.2016.01.003.
- [10] Tzyy-Ping Jung, Scott Makeig, Martin J. McKeown, Anthony J. Bell, Te-Won Lee, and Terrence J. Sejnowski. Imaging brain dynamics using independent component analysis. *Proceedings of the IEEE*, 89(7):1107–1122, 2001. doi: 10.1109/5.939827.
- [11] Vassilis Kalofolias. How to learn a graph from smooth signals, 2016. URL <http://arxiv.org/abs/1601.02513>.
- [12] Chun-Hung Lai, Yi-Ming Chen, and Wen-Chieh Liao. A controlled study of the eeg during the performance of neurofeedback. *Clinical EEG and Neuroscience*, 36(4): 219–225, 2005.
- [13] Fabien Lotte, Laurent Bougrain, Andrzej Cichocki, Maureen Clerc, Marco Congedo, Alain Rakotomamonjy, and Florian Yger. A review of classification algorithms for eeg-based brain–computer interfaces: A 10 year update. *Journal of Neural Engineering*, 15(3):031005, 2018. doi: 10.1088/1741-2552/aab2f2.
- [14] Steven J. Luck. *An Introduction to the Event-Related Potential Technique*. MIT Press, 2nd edition, 2014.
- [15] S. K. Narang and A. Ortega. Signal processing techniques for interpolation in graph structured data. In *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5445–5449, 2013. doi: 10.1109/ICASSP.2013.6638704.
- [16] Paul L. Nunez and Ramesh Srinivasan. *Electric Fields of the Brain: The Neurophysics of EEG*. Oxford University Press, 2nd edition, 2006. doi: 10.1093/acprof:oso/9780195050387.001.0001.
- [17] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst. Graph signal processing: Overview, challenges, and applications. *Proceedings of the IEEE*, 106(5):808–828, 2018. doi: 10.1109/JPROC.2018.2820126.

-
- [18] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier. Spherical splines for scalp potential and current density mapping. *Electroencephalography and Clinical Neurophysiology*, 72(2):184–187, 1989. doi: 10.1016/0013-4694(89)90180-6.
 - [19] Carlos Saldivia, Alejandro Weinstein, and Matías Zañartu. Trss vs. Spherical Splines: A reproducible benchmark for EEG channel interpolation under missing-data scenarios. *In Preparation*, 2026. Manuscript in preparation. Results derived from this thesis.
 - [20] Gerwin Schalk, Dennis J. McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R. Wolpaw. BCI2000: A general-purpose brain-computer interface (BCI) system. *IEEE Transactions on Biomedical Engineering*, 51(6):1034–1043, 2004. doi: 10.1109/TBME.2004.827072.
 - [21] S. Shekkizhar and A. Ortega. Graph construction from data by non-negative kernel regression. In *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 3892–3896, 2020. doi: 10.1109/ICASSP40776.2020.9054425.
 - [22] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst. The emerging field of signal processing on graphs. *IEEE Signal Processing Magazine*, 30(3):83–98, 2013. doi: 10.1109/MSP.2012.2235192.