

**Reconstrucción de Canales EEG Faltantes mediante
Procesamiento de Señales en Grafos con
Regularización Temporal** Evaluación comparativa reproducible,

optimización bayesiana de hiperparámetros y validación fisiológica
multi-métrica Tesis presentada para optar al grado de

Magíster en Ciencias de la Ingeniería por

Carlos Saldivia Universidad Técnica Federico Santa María

Departamento de Ingeniería Electrónica Valparaíso, Chile, Mayo de 2026

Agradecimientos

Deseo expresar mi más profundo agradecimiento a mi profesor guía, el Dr. Alejandro Weinstein, por su dirección rigurosa, su paciencia inagotable y su capacidad para transformar cada obstáculo en una oportunidad de aprendizaje. Su visión sobre la intersección entre procesamiento de señales y neurociencia ha sido una fuente constante de inspiración a lo largo de todo este proceso.

Al Dr. Matías Zañartu, profesor co-guía de esta tesis, le agradezco su mirada crítica y su insistencia en que cada afirmación debía estar respaldada por evidencia. Sus preguntas —a veces incómodas, siempre necesarias— mejoraron sustancialmente la calidad de este trabajo.

Al Departamento de Ingeniería Electrónica de la Universidad Técnica Federico Santa María, por proporcionar el entorno académico y los recursos computacionales que hicieron posible esta investigación.

A mis compañeros del laboratorio, por las discusiones técnicas a altas horas de la noche y por recordarme que la investigación también es comunidad. A los desarrolladores de MNE-Python, Optuna, PyGSP y el ecosistema de código abierto científico de Python, cuyo trabajo colectivo hizo posible que esta tesis se construyera sobre hombros de gigantes.

Finalmente, a mi familia —a mis padres, por enseñarme que la curiosidad es el motor más noble; a mi pareja, por su apoyo incondicional durante los meses de escritura intensiva; y a mis amigos, por entender mis ausencias y celebrar mis pequeños avances como si fueran propios.

Valparaíso, Chile, Mayo de 2026

Índice general

1. Introducción	1
1.1. Contexto General y Planteamiento del Problema	1
1.2. Limitaciones de los Enfoques Tradicionales	2
1.3. El Advenimiento del Procesamiento de Señales en Grafos	3
1.3.1. Mención del Paradigma de Aprendizaje Profundo	3
1.4. La Brecha en la Literatura y la Motivación del Trabajo	4
1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?	5
1.5. Cronología del Proyecto	6
1.5.1. Fase 1 — Selección de Métodos y Revisión del Estado del Arte . .	6
1.5.2. Fase 2 — Implementación del Sistema de Experimentación	6
1.5.3. Fase 3 — Barrido Exploratorio Inicial	7
1.5.4. Fase 4 — Selección Fina y Diseño del Espacio de Búsqueda	7
1.5.5. Fase 5 — Optimización Bayesiana con Optuna	7
1.5.6. Fase 6 — Validación Confirmatoria contra MNE-Python	8
1.5.7. Fase 7 — Ablación y Documentación	8
1.6. Objetivos	8
1.6.1. Objetivo General	8
1.6.2. Objetivos Específicos	8
1.7. Hipótesis de Trabajo	9
1.8. Alcance y Aportes de la Investigación	10
1.9. Estructura de la Tesis	10

1.10. Tesis, Contribución y Criterio de Lectura	11
2. Marco Teórico	13
2.1. Fundamentos Neurofisiológicos de la Señal EEG	13
2.1.1. Generación y Propagación de la Señal	13
2.1.2. Características Espectrales y Bandas de Frecuencia	14
2.1.3. Potenciales Relacionados a Eventos	15
2.2. Procesamiento de Señales en Grafos	15
2.2.1. Definición de Grafo y Señal de Grafo	15
2.2.2. Matriz Laplaciana y Suavidad en el Grafo	16
2.2.3. Descomposición Espectral y Frecuencias en el Grafo	17
2.2.4. Transformada de Fourier en Grafos	17
2.2.5. Construcción de Grafos para Datos EEG	18
2.3. Estado del Arte en Interpolación de Señales Biomédicas	18
2.3.1. Métodos Geométricos	18
2.3.2. Métodos Estadísticos de Descomposición	19
2.3.3. Métodos Basados en GSP	19
2.3.4. Regularización Espacio-Temporal: TRSS	20
2.3.5. Mención del Paradigma de Aprendizaje Profundo	21
2.4. Análisis del Mecanismo Interno de la Interpolación por Splines Esféricos en MNE-Python	21
2.4.1. Formulación Original de Perrin y colaboradores	22
2.4.2. Las Seis Mejoras de Ingeniería Incorporadas en MNE-Python . . .	22
2.4.3. Implicaciones para la Evaluación Comparativa	23
2.4.4. ¿Por Qué Funciona Tan Bien? Los Tres Pilares de la Robustez . .	23
2.4.5. Cuándo Fallan los Splines Esféricos	24
2.5. Síntesis del Marco Teórico	24
3. Metodología	26
3.1. Conjuntos de Datos	26
3.1.1. PhysioNet EEG Motor Movement/Imagery	26

3.1.2.	BCI Competition IV – Dataset 2a	27
3.1.3.	MNE Sample	27
3.1.4.	Justificación de la Heterogeneidad	27
3.2.	Protocolos de Simulación de Canales Faltantes	27
3.3.	Métodos de Interpolación	28
3.4.	Métricas de Evaluación	29
3.5.	Motor de Optimización Bayesiana: Optuna	29
3.6.	Protocolo de Validación Confirmatoria	30
3.7.	Arquitectura del Sistema Experimental	30
4.	Arquitectura del Sistema y Trazabilidad	32
4.1.	Arquitectura Modular	32
4.2.	Flujo de Datos y Cadena de Trazabilidad	33
4.3.	Gestión de Artefactos Experimentales	34
4.4.	Decisiones de Diseño Significativas	34
5.	Diseño Experimental	36
5.1.	Variables del Experimento	36
5.2.	Preguntas de Investigación por Experimento	37
5.3.	Plan de Análisis Estadístico	37
5.4.	Control de Calidad Experimental	38
5.5.	Síntesis del Diseño	39

Índice de figuras

2.1. Generación y propagación de la señal EEG	14
2.2. Fundamentos del Procesamiento de Señales en Grafos	16
3.1. Curva de degradación SNR en BCI IV 2a	31
4.1. Comparación global de métodos en PhysioNet	33
5.1. Mapa de calor de desempeño en MNE Sample	38

Índice de tablas

2.1. Familias de métodos de interpolación evaluados: principio matemático, fortalezas y limitaciones según el marco teórico.	25
3.1. Características de los tres conjuntos de datos experimentales.	27
3.2. Lista completa de los dieciocho métodos de interpolación implementados, organizados por familia metodológica.	28
3.3. Batería de métricas de evaluación: definición, categoría y dirección de optimalidad ($\uparrow$ = mayor es mejor, $\downarrow$ = menor es mejor).	29
3.4. Espacios de búsqueda de hiperparámetros por familia metodológica. . . .	30
4.1. Tipos de artefactos generados por el sistema y su función.	34
4.2. Ejemplos de trazabilidad entre afirmaciones del documento y artefactos computacionales.	35
5.1. Relación entre hipótesis, preguntas de investigación, experimentos y evidencia esperada.	37

Resumen

La electroencefalografía (EEG) constituye una herramienta fundamental en neurociencia clínica y experimental, pero sufre de la pérdida frecuente de canales debido a fallas de contacto, artefactos de movimiento o saturación de amplificadores. La interpolación de estos canales faltantes es un paso crítico del preprocesamiento, y tradicionalmente se ha abordado mediante métodos geométricos como los *spherical splines*, implementados en bibliotecas de referencia como MNE-Python. Sin embargo, estos métodos operan exclusivamente en el dominio espacial, ignorando la conectividad funcional real del cerebro y la dinámica temporal de las señales.

Esta tesis presenta una evaluación comparativa reproducible y exhaustiva de dieciocho métodos de interpolación de canales EEG —geométricos, estadísticos y basados en Procesamiento de Señales en Grafos (GSP)— bajo un protocolo experimental riguroso. El diseño incluye tres bases de datos heterogéneas (PhysioNet de 64 canales, BCI Competition IV 2a de 22 canales y MNE Sample de 60 canales), ciento veinte escenarios de pérdida que combinan modos aleatorio y contiguo con severidades del 10 % al 40 %, y una batería de seis métricas que cubren error de amplitud (MAE, RMSE, SNR), fidelidad morfológica (DTW) y preservación espectral (LSD, Coherencia). Para garantizar una comparación justa, todos los métodos —incluyendo las referencias clásicas— fueron optimizados mediante Optuna con más de quince mil configuraciones paramétricas exploradas, y se incorporó una validación confirmatoria contra la implementación industrial de MNE-Python.

Los resultados revelan que la regularización temporal marca un punto de inflexión decisivo: los métodos de la familia TRSS (*Temporal Regularized Sobolev Smoothness*) superan consistentemente a las referencias geométricas y a los métodos GSP puramente espaciales, con ganancias de 5 a 10 dB en SNR bajo pérdida severa contigua del 40 %. El análisis del mecanismo subyacente muestra que esta ventaja no proviene de una mejor representación espacial, sino de la restricción de continuidad temporal que actúa como información previa de naturaleza fisiológica. No obstante, en regímenes favorables —montajes densos, pérdida aleatoria igual o inferior al 20 %—, MNE-Python iguala o

supera a TRSS en preservación espectral, siendo además entre 50 y 100 veces más rápido. Se concluye que TRSS es el método preferido cuando la preservación morfológica bajo pérdida severa es prioritaria, mientras que MNE sigue siendo la opción óptima para entornos con pérdida moderada y restricciones de tiempo real.

La totalidad del código, las configuraciones experimentales, los registros de optimización y los artefactos de resultados están disponibles en un repositorio abierto que garantiza la reproducibilidad completa de los hallazgos.

Palabras clave: EEG, canales faltantes, interpolación, Procesamiento de Señales en Grafos (GSP), regularización temporal, TRSS, spherical splines, MNE-Python, optimización bayesiana, Optuna, evaluación comparativa reproducible.

Capítulo 1

Introducción

1.1. Contexto General y Planteamiento del Problema

La electroencefalografía (EEG) ha sido, durante décadas, una de las herramientas fundamentales de la neurociencia clínica y experimental. Su alta resolución temporal —en el orden de los milisegundos—, su naturaleza no invasiva y su costo relativamente bajo frente a técnicas como la resonancia magnética funcional o la tomografía por emisión de positrones la han consolidado como el estándar para estudiar la dinámica cerebral en tiempo real [4]. Sus aplicaciones abarcan el diagnóstico de epilepsia y trastornos del sueño, la investigación en neurociencia cognitiva y el desarrollo de interfaces cerebro-computador para comunicación asistida y neurorrehabilitación.

Ahora bien, la adquisición de EEG es un proceso frágil. En la práctica clínica y de investigación, la pérdida parcial o total de información en uno o más electrodos es moneda corriente. Estas fallas pueden deberse al aumento de la impedancia de contacto por transpiración o secado del gel conductor, a fallas en el amplificador como la saturación de voltaje, a movimientos bruscos del paciente que desconectan los sensores, o simplemente al descarte deliberado de canales que presentan una relación señal-ruido inaceptablemente baja durante la etapa de preprocesamiento [18].

La pérdida de canales no es un problema cosmético: compromete la integridad de todo análisis posterior. La ausencia de información espacial distorsiona la topografía de la señal, afecta la localización de fuentes neuronales y altera biomarcadores electrofisiológicos como los Potenciales Relacionados a Eventos (ERP) y la Densidad Espectral de Potencia (PSD) [16]. En sistemas modernos de aprendizaje automático aplicados a interfaces cerebro-computador, la pérdida impredecible de canales cambia la dimensionalidad de entrada

de los clasificadores y obliga, con frecuencia, a descartar ensayos completos de datos clínicamente valiosos [15]. La interpolación precisa de estos canales es, por tanto, un paso ineludible del flujo de preprocesamiento, y su calidad condiciona directamente la validez de cualquier conclusión neurofisiológica o clínica posterior.

1.2. Limitaciones de los Enfoques Tradicionales

Históricamente, el problema de la interpolación de canales EEG ha sido abordado mediante métodos espaciales o estadísticos. El enfoque más extendido y utilizado por defecto en bibliotecas de análisis como EEGLAB [6] o MNE-Python [9, 10] es la interpolación por *spherical splines* [20]. Este método, junto con otros enfoques basados en distancia euclidiana como la interpolación por vecinos más cercanos o las funciones de base radial, asume que la cabeza humana es una esfera conductora perfecta y estima el voltaje del canal faltante proyectando geométricamente los voltajes de los electrodos circundantes sobre dicha superficie.

Aunque estos métodos son rápidos y matemáticamente elegantes, adolecen de una limitación fundamental: operan estrictamente en el dominio espacial estático para cada instante de tiempo individual. Al hacerlo, ignoran dos realidades neurofisiológicas esenciales. En primer lugar, la conectividad funcional real del cerebro no es isotrópica: la actividad eléctrica sigue rutas anatómicas complejas que no siempre se correlacionan con la distancia física en el cuero cabelludo, de modo que un modelo esférico resulta una simplificación excesiva [24]. En segundo lugar, las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento. Al reconstruir un canal muestra por muestra de forma aislada, los métodos puramente espaciales son incapaces de preservar la dinámica de alta frecuencia, generando trazos con ruido de fase y distorsiones en los picos transitorios [14].

Los métodos estadísticos de descomposición —Análisis de Componentes Independientes (ICA) y Análisis de Componentes Principales (PCA)— proyectan las señales observadas sobre fuentes latentes y reconstruyen el canal perdido a partir de esa proyección [13]. Sin embargo, cuando varios canales contiguos fallan simultáneamente, estos métodos tienden a inyectar ruido global o a perder los picos transitorios locales que definen la morfología fina de los ERP.

1.3. El Advenimiento del Procesamiento de Señales en Grafos

Para superar estas limitaciones, en los últimos años ha emergido con fuerza el marco del Procesamiento de Señales en Grafos (GSP, por sus siglas en inglés) [19, 23]. El GSP ofrece una perspectiva natural y poderosa para lidiar con datos que residen en dominios irregulares no euclidianos. En lugar de modelar la cabeza como un espacio continuo tridimensional, GSP modela la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un nodo y las relaciones de similitud o distancia fisiológica entre ellos se codifican en las aristas mediante núcleos de distancia gaussianos o basados en correlación.

Bajo este paradigma, el voltaje medido en un instante se interpreta como una señal de grafo, y conceptos clásicos como la Transformada de Fourier, el filtrado paso-bajo y el muestreo se trasladan al dominio del grafo mediante el operador Laplaciano $\mathbf{L}$. La intuición es simple: las señales en nodos fuertemente conectados tienden a ser similares. Al minimizar una función de costo que penaliza las variaciones abruptas sobre la topología del grafo, los datos faltantes se reconstruyen con mayor fidelidad que usando solo la distancia euclidiana [17].

Una extensión aún más avanzada es la regularización espacio-temporal. Trabajos recientes han introducido enfoques como la Regularización Temporal de Suavidad de Sobolev (TRSS, por sus siglas en inglés) [7], que optimiza conjuntamente la topología espacial y la derivada temporal de la señal. Al penalizar saltos bruscos en el tiempo de forma simultánea a los saltos en el espacio, TRSS impone restricciones fisiológicas reales: las neuronas no cambian su potencial de membrana instantáneamente, sino que obedecen dinámicas de integración continua. Esta restricción dual —espacial y temporal— es lo que la teoría predice como el factor diferencial frente a los métodos puramente espaciales.

1.3.1. Mención del Paradigma de Aprendizaje Profundo

Es pertinente mencionar que existe un cuerpo creciente de literatura que aborda la interpolación de señales EEG mediante redes neuronales profundas, incluyendo arquitecturas como autoencoders convolucionales [2], redes generativas antagónicas para imputación de series temporales [25], y más recientemente Redes Neuronales de Grafos que operan directamente sobre la topología de electrodos [5]. Estos enfoques han mostrado resultados prometedores en escenarios controlados, beneficiándose de la capacidad de las redes pro-

fundas para aprender representaciones latentes complejas a partir de grandes volúmenes de datos.

No obstante, estos métodos presentan limitaciones que motivan su exclusión deliberada del alcance de esta tesis. En primer lugar, son inherentemente dependientes de los datos de entrenamiento, lo que introduce riesgos de falta de generalización al transferir modelos entre poblaciones, equipos o paradigmas experimentales distintos. En segundo lugar, carecen de garantías formales de convergencia y de interpretabilidad sobre el mecanismo de interpolación, una propiedad crítica en contextos clínicos donde cada decisión debe ser trazable y justificable. En tercer lugar, su costo computacional de entrenamiento es órdenes de magnitud superior al de los métodos algorítmicos aquí considerados. Por estas razones, la presente investigación se circunscribe exclusivamente a métodos algorítmicos con fundamento matemático explícito —geométricos, estadísticos y basados en GSP— cuya operación no requiere entrenamiento y cuyas propiedades de convergencia y regularización son analíticamente caracterizables.

1.4. La Brecha en la Literatura y la Motivación del Trabajo

A pesar de la inmensa promesa teórica de los algoritmos GSP y TRSS, su validación empírica en la literatura de señales biomédicas sufre de una preocupante fragmentación metodológica. Se identifican tres problemas graves en las evaluaciones comparativas publicadas hasta la fecha.

El primer problema es que los estudios que proponen nuevos algoritmos GSP suelen compararse contra *spherical splines* usando las configuraciones por defecto de los paquetes de software, sin realizar una búsqueda rigurosa de hiperparámetros para los métodos de referencia. Esto infla artificialmente las ventajas del método propuesto y distorsiona la percepción del verdadero estado del arte [21]. El segundo problema es que la gran mayoría de los trabajos restringen su evaluación a métricas de error de amplitud global —como el RMSE o el MAE— y aplican escenarios de desconexión irreales, tales como la remoción de canales aleatorios aislados en bases de datos pequeñas. Rara vez se investiga el impacto morfológico de la reconstrucción mediante métricas temporales como el *Dynamic Time Warping* o espectrales como la Distancia Espectral Logarítmica, que constituyen los verdaderos predictores de la utilidad clínica de la señal interpolada. El tercer problema, y quizás el más grave desde el punto de vista metodológico, es la ausencia

casi total de comparaciones contra implementaciones de referencia industrial. En particular, la función `mne.io.Raw.interpolate\_bads()` de MNE-Python incorpora una década de refinamientos de ingeniería —normalización de coordenadas, regularización diagonal adaptativa, aumentación del sistema con restricciones lineales, pseudoinversa con tolerancia adaptativa y un mecanismo de reintento automático— que la hacen sustancialmente más robusta que una implementación ingenua de *spherical splines*. Ignorar esta implementación equivale a comparar contra un método de referencia debilitado artificialmente.

La motivación concreta de este trabajo nace directamente de estas brechas. El objetivo no es diseñar desde cero un nuevo marco teórico matemático, sino someter a la frontera del conocimiento actual —métodos geométricos, GSP y regularización temporal— a la evaluación empírica más rigurosa, exhaustiva y justa posible. Al utilizar el sistema moderno de optimización bayesiana Optuna [1] para llevar todos los algoritmos a su máximo límite empírico bajo protocolos evaluados en múltiples conjuntos de datos, esta tesis busca revelar el verdadero punto de cruce entre el paradigma clásico y el paradigma de grafos.

1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?

Una pregunta recurrente que emerge del análisis preliminar —y que motiva una sección dedicada en el marco teórico de esta tesis— es por qué la función de interpolación de MNE-Python produce resultados tan competitivos, incluso frente a métodos teóricamente superiores como TRSS. La respuesta, que se desarrolla en profundidad en el Capítulo 2, reside en que la implementación de MNE no es una simple transcripción del artículo original de Perrin y colaboradores [20], sino que incorpora un conjunto de mejoras de ingeniería acumuladas durante más de diez años de desarrollo como código abierto.

Estas mejoras —normalización de coordenadas a esfera unitaria, uso global de canales, regularización diagonal adaptativa, aumentación con restricciones lineales, pseudoinversa con tolerancia adaptativa y reintento automático— no aparecen descritas en la literatura académica, pero están presentes en el código fuente de MNE. Son las responsables de que un método formulado en 1989 siga siendo hoy una referencia formidable. Esta tesis dedica una sección completa del marco teórico (Capítulo 2) a documentar estos mecanismos, y una validación confirmatoria independiente (Capítulo 6) a cuantificar la brecha real entre TRSS y MNE.

1.5. Cronología del Proyecto

La investigación que sustenta esta tesis no siguió un camino lineal, sino un proceso iterativo de descubrimiento guiado por los resultados experimentales que se iban obteniendo. Documentar esta trayectoria es esencial para comprender las decisiones metodológicas que dieron forma al protocolo final, y se presenta a continuación de manera cronológica.

1.5.1. Fase 1 — Selección de Métodos y Revisión del Estado del Arte

Durante los primeros dos meses se realizó una revisión sistemática de la literatura sobre interpolación de señales en dominios irregulares. Este proceso permitió identificar tres familias metodológicas bien diferenciadas: métodos geométricos o espaciales (*spherical splines*, vecinos más cercanos, funciones de base radial), métodos estadísticos de descomposición (ICA, PCA, interpolación lineal) y métodos basados en GSP (regularización de Tikhonov en grafos, regularización de Sobolev, TRSS). De cada familia se seleccionaron los representantes más citados y con fundamento matemático más sólido, resultando en un total de dieciocho métodos candidatos para implementación y evaluación comparativa.

1.5.2. Fase 2 — Implementación del Sistema de Experimentación

Los siguientes dos meses se dedicaron al desarrollo de un sistema modular en Python que unificara la interfaz de todos los métodos bajo una interfaz de programación común. Cada método recibía una matriz de datos $\mathbf{X} \in \mathbb{R}^{C \times T}$ —con C canales y T muestras temporales— junto con una máscara binaria que indicaba qué canales debían tratarse como faltantes, y entregaba como resultado la matriz reconstruida. En paralelo se implementaron los constructores de grafos necesarios —incluyendo k-NN con pesos gaussianos, grafos de correlación funcional y grafos de distancia completa—, los núcleos de interpolación GSP y el resolutor TRSS con regularización dual mediante los parámetros α y β . Esta fase fue particularmente demandante porque requirió validar que cada implementación propia reprodujera exactamente el comportamiento descrito en su artículo original antes de incorporarla al sistema comparativo.

1.5.3. Fase 3 — Barrido Exploratorio Inicial

Con el sistema funcional, se ejecutó un barrido exploratorio sobre escenarios de pérdida aleatoria al 20% en los tres conjuntos de datos. Los resultados revelaron un hallazgo inesperado que redefiniría el curso de la investigación: TRSS mostraba ventajas muy significativas —del orden de 5 a 15 dB en SNR— sobre las implementaciones propias de *spherical splines*, pero esa brecha se reducía de manera importante al comparar contra la función `mne.io.Raw.interpolate\_bads()` de MNE-Python, que incorpora una década de refinamientos de ingeniería. Este hallazgo fue el disparador de dos decisiones metodológicas cruciales: incluir a MNE como referencia confirmatoria independiente en una fase separada del experimento, y diseñar el resto del protocolo para distinguir nítidamente entre resultados exploratorios y confirmatorios.

1.5.4. Fase 4 — Selección Fina y Diseño del Espacio de Búsqueda

Los resultados del barrido permitieron descartar con confianza los métodos claramente inferiores —como la interpolación lineal o el vecino más cercano sin ponderación— y concentrar los recursos de optimización en los métodos con desempeño prometedor. Para cada familia se definió un espacio de búsqueda de hiperparámetros diferenciado: la escala del núcleo gaussiano σ y el número de vecinos k para los métodos de grafo, los coeficientes de regularización espacial α y temporal β para TRSS, y el orden del spline m junto con la regularización λ para los *spherical splines*.

1.5.5. Fase 5 — Optimización Bayesiana con Optuna

Durante los siguientes dos meses se integró Optuna con muestreo TPE (*Tree-structured Parzen Estimator*) como motor de optimización [1]. Se ejecutaron treinta intentos independientes por cada método de grafo, diez intentos con el algoritmo multiobjetivo NSGA-II para los *spherical splines*, y barridos de grilla fina para TRSS dado su mayor costo computacional. En total se evaluaron más de quince mil configuraciones paramétricas distintas. Esta fase constituye el núcleo experimental de la tesis: sus resultados son los que se reportan en el Capítulo 6.

1.5.6. Fase 6 — Validación Confirmatoria contra MNE-Python

En una fase independiente —diseñada para no contaminar los resultados exploratorios— se ejecutó una validación donde TRSS, con sus hiperparámetros congelados tras la optimización de la fase anterior, se comparó directamente contra `mne.io.Raw.interpolate\_bads()` utilizando los parámetros por defecto que cualquier usuario de MNE obtendría sin ajuste adicional. Esta validación se estratificó por conjunto de datos, modo de pérdida y severidad, y empleó pruebas estadísticas pareadas —Wilcoxon signed-rank con corrección de Benjamini-Hochberg para comparaciones múltiples— con el fin de establecer significancia estadística de manera rigurosa.

1.5.7. Fase 7 — Ablación y Documentación

La fase final consistió en un estudio de ablación para cuantificar la contribución relativa de cada componente de TRSS —el término espacial α frente al término temporal β —, la generación sistemática de todas las figuras y tablas que aparecen en este documento, y la redacción de la tesis propiamente dicha.

1.6. Objetivos

1.6.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales EEG basados en Procesamiento de Señales en Grafos con regularización temporal frente a las referencias geométricas clásicas —incluida MNE-Python—, bajo un marco experimental riguroso, reproducible y optimizado mediante optimización bayesiana.

1.6.2. Objetivos Específicos

- **OE1 — Consolidación de Métodos.** Implementar y unificar dieciocho métodos de interpolación —geométricos, estadísticos y basados en grafos— en un sistema modular en Python con una interfaz común que permita la comparación directa entre todos ellos.
- **OE2 — Diseño de Escenarios Clínicamente Relevantes.** Definir protocolos realistas de simulación de canales faltantes, abarcando tanto fallos esporádicos

aleatorios como pérdidas masivas contiguas de amplificadores locales, iterando desde un 10 % hasta un 40 % de degradación del montaje sensor.

- **OE3 — Optimización Imparcial de Hiperparámetros.** Integrar el sistema Optuna con muestreo TPE y NSGA-II multiobjetivo para explorar iterativamente los espacios paramétricos de todos los métodos, garantizando que ningún algoritmo sea evaluado por debajo de su verdadero límite de diseño.
- **OE4 — Evaluación Multi-Métrica Transversal.** Cuantificar el desempeño de reconstrucción mediante una batería de seis métricas —MAE, RMSE, SNR, DTW, LSD y Coherencia— cruzando tres conjuntos de datos heterogéneos y ciento veinte escenarios de pérdida.
- **OE5 — Análisis de Relevancia Fisiológica.** Demostrar, tanto visual como cuantitativamente, el impacto de los distintos enfoques de interpolación en la preservación de Potenciales Relacionados a Eventos específicos —como N100 y P300— y de la dinámica espectral en las bandas de frecuencia naturales del cerebro.
- **OE6 — Trazabilidad y Reproducibilidad Científica.** Generar un repositorio abierto de artefactos computacionales —código fuente, configuraciones, registros de optimización y resultados— que garantice la reproducibilidad completa de todos los hallazgos reportados.

1.7. Hipótesis de Trabajo

H1 — Hipótesis Principal. La integración de restricciones de suavidad espacial basadas en topologías de grafos, junto con información previa de continuidad temporal penalizada mediante regularización de Sobolev (TRSS), permite reconstruir canales EEG faltantes con significativamente mayor precisión y robustez que los métodos geométricos de extrapolación de superficies estáticas. Esta ventaja no solo se refleja en la mitigación del error cuadrático medio, sino fundamentalmente en la preservación fiel de la morfología transitoria de los ERPs y de la densidad espectral de potencia, especialmente ante escenarios de pérdida espacial severa y contigua.

H2 — Hipótesis de Equivalencia Condicional. En regímenes favorables —montajes densos de sesenta canales o más, pérdida aleatoria igual o inferior al 20 % y señales espacialmente suaves—, la implementación industrial de referencia MNE-Python iguala o supera a TRSS en preservación espectral,

ofreciendo una solución significativamente más eficiente —entre 50 y 100 veces más rápida— sin un sacrificio clínico significativo en la calidad de la señal reconstruida.

1.8. Alcance y Aportes de la Investigación

El alcance de este trabajo abarca la ejecución computacional a gran escala del sistema de evaluación sobre tres conjuntos de datos, ciento veinte escenarios de falla y dieciocho métodos de interpolación. A diferencia de las evaluaciones acotadas que predominan en la literatura, aquí se consolidan miles de ensayos EEG bajo más de quince mil configuraciones paramétricas exploradas mediante Optuna.

Para garantizar la reproducibilidad, la ejecución se ancla en un registro exhaustivo de corridas experimentales que fija explícitamente las combinaciones de conjuntos de datos, modos de pérdida, semillas, tipos de grafo y familias de métodos. Este diseño evita las evaluaciones improvisadas y permite trazar cada afirmación cuantitativa reportada en los capítulos posteriores hasta el artefacto experimental que la origina, según se detalla en el Apéndice D.

Los aportes principales se articulan en cuatro ejes. Primero, se proporciona evidencia estadística de que TRSS supera consistentemente a las referencias geométricas en fidelidad morfológica y espectral una vez que todos los métodos han sido optimizados. Segundo, se revela que bajo pérdida contigua severa (30 % o más de los canales) las referencias geométricas colapsan, mientras que la restricción temporal de TRSS preserva la trayectoria fisiológica. Tercero, se documentan por primera vez en formato académico las seis mejoras de ingeniería que convierten a MNE-Python en una referencia inesperadamente robusta. Cuarto, se entrega un sistema unificado en Python, rastreable y de código abierto para ejecutar interpolaciones GSP con optimización bayesiana automatizada sobre datos EEG.

1.9. Estructura de la Tesis

Para desarrollar el análisis propuesto, el resto del documento se organiza de la siguiente manera. El Capítulo 2 presenta los fundamentos neurofisiológicos del EEG, los pilares matemáticos del Procesamiento de Señales en Grafos —incluyendo el Laplaciano, la Transformada de Fourier en Grafos y la construcción de grafos—, el estado del arte en interpolación de señales biomédicas, y una sección dedicada al análisis detallado del

mecanismo interno de la función de interpolación de MNE-Python. El Capítulo 3 detalla el protocolo experimental: los tres conjuntos de datos empleados, el modelado matemático de los dieciocho algoritmos evaluados, los métodos de simulación de daños y la arquitectura del motor de optimización bayesiana. El Capítulo 4 documenta la arquitectura de software del sistema experimental, la trazabilidad entre módulos y la gestión de artefactos. El Capítulo 5 formaliza el diseño experimental: variables independientes, dependientes y controladas, el protocolo de validación y el plan de análisis estadístico. El Capítulo 6 expone los hallazgos empíricos, incluyendo comparativas globales de error, curvas de degradación por pérdida creciente, preservación de ERPs y PSD, el estudio de ablación de TRSS y la validación confirmatoria contra MNE-Python. El Capítulo 7 ofrece una discusión crítica sobre las causas metodológicas de los resultados obtenidos, interpreta los mecanismos subyacentes y transparenta las limitaciones del estudio. Finalmente, el Capítulo 8 sintetiza las conclusiones, valora el cumplimiento de las hipótesis y sugiere vías de investigación futura.

Los apéndices complementan el documento con derivaciones matemáticas completas (Apéndice A), tablas extensas de resultados (Apéndice B), el protocolo de reproducibilidad (Apéndice C), el inventario de artefactos computacionales (Apéndice D) y una adaptación de las tablas del documento original de tesis para referencia histórica (Apéndice E).

1.10. Tesis, Contribución y Criterio de Lectura

La tesis que organiza este documento sostiene que la reconstrucción de canales EEG faltantes debe evaluarse como un problema simultáneamente espacial, temporal y espectral. En consecuencia, una evaluación basada únicamente en métricas de error de amplitud como el MAE o el RMSE no es suficiente para decidir si una interpolación es útil en aplicaciones neurofisiológicas reales, porque estas métricas son insensibles a las distorsiones de fase y a la preservación de la estructura fina del espectro de frecuencias.

Esta investigación adopta una posición deliberadamente conservadora y transparente: los resultados favorables a TRSS se reportan solo cuando pueden trazarse a artefactos reproducibles; las limitaciones se explicitan con honestidad; y se reconoce sin ambages que la implementación de MNE-Python constituye una referencia formidable en sus regímenes de operación óptimos.

La contribución central puede sintetizarse en una sola oración: *esta tesis establece una evaluación comparativa reproducible y justa para la reconstrucción de canales EEG, demostrando que la regularización temporal sobre grafos —en particular TRSS— mejo-*

ra sensiblemente la fidelidad morfológica y espectral bajo escenarios de pérdida severa, incluso después de haber optimizado rigurosamente todos los métodos de referencia, incluyendo la implementación industrial MNE-Python, y documenta por primera vez en formato académico los mecanismos de ingeniería que hacen de esta última una referencia inesperadamente competitiva.

Capítulo 2

Marco Teórico

Este capítulo establece los fundamentos conceptuales sobre los cuales se construye la investigación. Se presentan los principios neurofisiológicos de la señal EEG, las bases matemáticas del Procesamiento de Señales en Grafos —incluyendo la construcción de grafos, el operador Laplaciano y la Transformada de Fourier en el dominio del grafo—, el estado del arte en interpolación de señales biomédicas, y un análisis detallado de los mecanismos internos que convierten a la implementación de *spherical splines* en MNE-Python en una referencia inesperadamente competitiva.

2.1. Fundamentos Neurofisiológicos de la Señal EEG

2.1.1. Generación y Propagación de la Señal

La señal EEG registrada en el cuero cabelludo es el resultado de la actividad sincronizada de grandes poblaciones de neuronas piramidales en la corteza cerebral [4]. Estas neuronas, orientadas perpendicularmente a la superficie cortical, generan dipolos de corriente cuando reciben potenciales postsinápticos excitatorios e inhibitorios. La suma espacial de estos dipolos —típicamente se requieren entre diez mil y cien mil neuronas activándose sincrónicamente para producir una señal detectable— constituye la fuente primaria del EEG.

La señal viaja desde la corteza hasta los electrodos atravesando múltiples capas tisulares con conductividades eléctricas muy diferentes: el líquido cefalorraquídeo (alta conductividad), las meninges (duramadre, aracnoides y piamadre), el cráneo (aproximadamente ochenta veces menos conductor que el cuero cabelludo) y finalmente el cuero cabelludo




Figura 2.1: Generación de la señal EEG por poblaciones neuronales corticales y su propagación hasta los electrodos de superficie. La conducción volumétrica a través del cráneo actúa como un filtro espacial paso-bajo, suavizando la distribución de potencial y limitando la resolución efectiva. Adaptado de [18].

mismo [18]. Este proceso de conducción volumétrica actúa como un filtro espacial paso-bajo: suaviza la distribución de potencial sobre la superficie y limita la resolución espacial efectiva del EEG a unos dos o tres centímetros.

2.1.2. Características Espectrales y Bandas de Frecuencia

La señal EEG se caracteriza por su contenido oscilatorio en distintas bandas de frecuencia, cada una asociada a estados funcionales específicos del cerebro [4]. La banda delta (0.5–4 Hz) predomina durante el sueño profundo y en ciertos estados patológicos. La banda theta (4–8 Hz) se asocia a estados de somnolencia, meditación y procesamiento de memoria episódica en el hipocampo. La banda alpha (8–13 Hz) es característica del estado de reposo vigil con ojos cerrados, especialmente en regiones occipitales. La banda beta (13–30 Hz) se vincula al procesamiento cognitivo activo, la concentración y la actividad motora. Finalmente, la banda gamma (30–100 Hz y más) se asocia al procesamiento perceptual de alto nivel y a la sincronización de redes neuronales distribuidas.

La preservación de la estructura espectral en cada una de estas bandas constituye

un criterio fundamental para evaluar la calidad de cualquier interpolación de canales EEG. Una interpolación que distorsiona la potencia relativa entre bandas —por ejemplo, atenuando la banda alpha mientras introduce ruido en gamma— puede alterar diagnósticos clínicos basados en biomarcadores espectrales. De ahí que esta tesis incorpore métricas espectrales explícitas —la Distancia Espectral Logarítmica y la Coherencia— como criterios de evaluación independientes de las métricas de amplitud.

2.1.3. Potenciales Relacionados a Eventos

Los Potenciales Relacionados a Eventos (ERP, por sus siglas en inglés) son fluctuaciones de voltaje estereotipadas, sincronizadas temporalmente con un estímulo sensorial, motor o cognitivo específico [16]. Se obtienen mediante promediación coherente de múltiples ensayos alineados al evento de interés, asumiendo que la actividad EEG de fondo no relacionada con el evento es ruido aditivo de media cero que se cancela con el promediado.

Entre los componentes ERP más estudiados se encuentran el complejo P1/N1 (80–150 ms), que refleja procesamiento perceptual automático en cortezas sensoriales primarias; el componente P300 (250–500 ms), evocado por estímulos infrecuentes o relevantes para la tarea y asociado a la actualización del contexto en la memoria de trabajo; y el componente N400 (300–500 ms), relacionado con el procesamiento semántico y la detección de incongruencias lingüísticas. La preservación de la morfología de estos componentes —su amplitud de pico, su latencia y su distribución topográfica— es uno de los criterios de evaluación clínica más exigentes para cualquier método de interpolación.

2.2. Procesamiento de Señales en Grafos

El Procesamiento de Señales en Grafos (GSP, por sus siglas en inglés) [19, 23] extiende los conceptos clásicos del procesamiento de señales a dominios irregulares representados por grafos. Esta sección desarrolla los fundamentos matemáticos necesarios para comprender los métodos de interpolación evaluados en esta tesis.

2.2.1. Definición de Grafo y Señal de Grafo

Un grafo $\mathcal{G}$ se define como la tupla $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde $\mathcal{V} = \{v_1, \dots, v_N\}$ es el conjunto de N nodos —correspondientes a los electrodos EEG en nuestro caso—, $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ es el conjunto de aristas que representan relaciones de conectividad entre electrodos, y




Figura 2.2: Conceptos fundamentales de GSP aplicados a EEG: (a) representación de electrodos como nodos de un grafo con pesos de conectividad, (b) descomposición espectral del Laplaciano mostrando los primeros tres autovectores (modos de Fourier en el grafo), (c) reconstrucción de una señal a partir de sus componentes de baja frecuencia en el grafo.

$\mathbf{W} \in \mathbb{R}^{N \times N}$ es la matriz de pesos o adyacencia ponderada, simétrica y con $W_{ij} > 0$ si existe una arista entre los nodos i y j , y $W_{ij} = 0$ en caso contrario.

Una señal de grafo es una función $f : \mathcal{V} \rightarrow \mathbb{R}$ que asigna un valor escalar a cada nodo. En el contexto de EEG, para un instante de tiempo t , la señal de grafo $\mathbf{x}_t \in \mathbb{R}^N$ corresponde al vector de voltajes medidos en los N electrodos. La matriz completa $\mathbf{X} \in \mathbb{R}^{N \times T}$ contiene T instantes temporales, y cada columna $\mathbf{x}_t$ es una señal de grafo en el instante t .

2.2.2. Matriz Laplaciana y Suavidad en el Grafo

La matriz Laplaciana no normalizada se define como $\mathbf{L} = \mathbf{D} - \mathbf{W}$, donde $\mathbf{D}$ es la matriz diagonal de grados $D_{ii} = \sum_j W_{ij}$. $\mathbf{L}$ es simétrica y semi-definida positiva. Su importancia radica en que codifica la noción de suavidad de una señal sobre el grafo. La forma cuadrática del Laplaciano,

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N W_{ij} (x_i - x_j)^2, \quad (2.1)$$

cuantifica la variación total de la señal $\mathbf{x}$ sobre las aristas del grafo. Un valor pequeño de $S(\mathbf{x})$ indica que nodos fuertemente conectados —con W_{ij} alto— tienen valores similares: la señal es *suave* respecto a la topología del grafo. Esta propiedad es el pilar conceptual de la interpolación GSP: si asumimos que la señal EEG verdadera es suave sobre el grafo de electrodos, entonces la mejor reconstrucción de los canales faltantes es aquella que minimiza $S(\mathbf{x})$ sujeta a la restricción de coincidir con los canales observados.

2.2.3. Descomposición Espectral y Frecuencias en el Grafo

La descomposición espectral de $\mathbf{L}$ es la piedra angular que conecta GSP con el procesamiento clásico de señales. Dado que $\mathbf{L}$ es simétrica y semi-definida positiva, admite la factorización

$$\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top = \sum_{k=1}^N \lambda_k \mathbf{u}_k \mathbf{u}_k^\top, \quad (2.2)$$

donde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$ contiene los autovalores ordenados $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$, y $\mathbf{U} = [\mathbf{u}_1 \ \mathbf{u}_2 \ \dots \ \mathbf{u}_N]$ es la matriz ortogonal de autovectores. El autovector $\mathbf{u}_1 = \frac{1}{\sqrt{N}}\mathbf{1}$ corresponde a $\lambda_1 = 0$ y representa la componente constante (frecuencia cero en el grafo).

Los autovalores λ_k cumplen un rol análogo a las frecuencias en el análisis de Fourier clásico. Autovalores pequeños corresponden a modos de variación lenta sobre la topología del grafo —equivalentes a bajas frecuencias espaciales—, mientras que autovalores grandes corresponden a modos de variación rápida —altas frecuencias—. La Figura 2.2 ilustra esta interpretación: los primeros autovectores muestran patrones suaves que varían gradualmente sobre la superficie del cuero cabelludo.

2.2.4. Transformada de Fourier en Grafos

La Transformada de Fourier en Grafos (GFT) de una señal $\mathbf{x}$ se define como la proyección sobre la base de autovectores:

$$\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}, \quad \hat{x}_k = \langle \mathbf{x}, \mathbf{u}_k \rangle, \quad (2.3)$$

y su inversa como $\mathbf{x} = \mathbf{U}\hat{\mathbf{x}}$. Una señal es *suave* en el grafo si su GFT tiene soporte concentrado en los autovalores pequeños: las componentes de alta frecuencia son insignificantes. Equivalentemente, la suavidad puede expresarse en el dominio espectral como $S(\mathbf{x}) = \sum_{k=1}^N \lambda_k \hat{x}_k^2$, lo que muestra que los modos de alta frecuencia son penalizados proporcionalmente a su autovalor.

Una señal es de *banda limitada* en el grafo si $\hat{x}_k = 0$ para todo $k > K$, con $K \ll N$. Esta propiedad es explotada por los métodos de muestreo en grafos: si la señal EEG es de banda limitada —es decir, espacialmente suave—, solo se requiere un subconjunto de canales para reconstruir la totalidad de la señal. La interpolación se formula entonces como encontrar la señal de banda limitada que interpola exactamente los valores observados.

2.2.5. Construcción de Grafos para Datos EEG

La construcción del grafo es una decisión de diseño crítica: determina qué noción de similitud se utiliza para guiar la interpolación. En esta tesis se implementan y comparan tres estrategias.

El **grafo k-NN con pesos gaussianos** conecta cada electrodo a sus k vecinos más próximos en distancia euclidiana tridimensional, con pesos $W_{ij} = \exp(-\|\mathbf{p}_i - \mathbf{p}_j\|_2^2 / 2\sigma^2)$, donde σ controla la escala de decaimiento. Es el enfoque más común en GSP aplicado a EEG, pero ignora la conectividad funcional.

El **grafo de correlación funcional** define los pesos como $W_{ij} = |\rho_{ij}|$, el valor absoluto del coeficiente de correlación de Pearson entre las series temporales de los electrodos i y j . Esta construcción captura conectividad funcional —dos electrodos están conectados si covarían en el tiempo, independientemente de su distancia física— y puede revelar relaciones que la geometría del montaje oculta.

El **grafo de distancia completa** conecta todos los pares con el núcleo gaussiano, sin restricción de vecindad. Esto genera una matriz densa que preserva toda la información de distancia, a costa de un mayor costo computacional en la inversión del Laplaciano.

2.3. Estado del Arte en Interpolación de Señales Biomédicas

2.3.1. Métodos Geométricos

El método más establecido para la interpolación de canales EEG es el de *spherical splines*, introducido por Perrin y colaboradores [20]. Este enfoque modela el potencial sobre el cuero cabelludo como una función suave sobre una esfera, aproximable mediante una combinación lineal de funciones base. Para una posición $\mathbf{r}$ sobre la esfera unitaria, el potencial estimado es

$$\hat{V}(\mathbf{r}) = c_0 + \sum_{i=1}^M c_i g_m(\mathbf{r}, \mathbf{r}_i), \quad (2.4)$$

donde $\mathbf{r}_i$ son las posiciones de los M electrodos observados, $g_m(\cdot, \cdot)$ es la función de Green del operador pseudo-laplaciano de orden m sobre la esfera, y los coeficientes c_i se obtienen resolviendo un sistema lineal aumentado que interpola exactamente los valores

observados y satisface condiciones de contorno.

El parámetro m gobierna la rigidez de la superficie: $m = 2$ produce superficies más suaves (adecuado para montajes de baja densidad), mientras que $m = 3$ y $m = 4$ permiten capturar gradientes espaciales más abruptos en montajes de alta densidad. Un parámetro de regularización λ controla el compromiso entre ajuste exacto a los datos y suavidad de la superficie, protegiendo contra el sobreajuste al ruido de medición.

Otros métodos geométricos incluyen la interpolación por vecino más cercano (simplemente copia el valor del electrodo más próximo), la interpolación por distancia inversa con pesos $w_i \propto 1/d_i^p$, y las funciones de base radial con núcleos como la multiquádrica o la gaussiana. Todos comparten la limitación de operar en el dominio espacial estático, instante por instante.

2.3.2. Métodos Estadísticos de Descomposición

El Análisis de Componentes Principales (PCA) descompone la matriz de datos $\mathbf{X} \in \mathbb{R}^{C \times T}$ en componentes principales mediante la descomposición en valores singulares. Los canales faltantes se reconstruyen proyectando los canales observados sobre el subespacio de las primeras componentes y mapeando de vuelta al espacio de electrodos [12].

El Análisis de Componentes Independientes (ICA) extiende esta idea buscando componentes estadísticamente independientes —no meramente descorrelacionadas— mediante la maximización de la no-gaussianidad de las proyecciones [11, 13]. En el contexto de EEG, ICA ha demostrado utilidad para separar fuentes neuronales de artefactos oculares y musculares. Sin embargo, requiere la estimación previa de la matriz de mezcla sobre datos completos, lo que limita su aplicabilidad cuando la pérdida de canales es severa y simultánea.

2.3.3. Métodos Basados en GSP

La **regularización de Tikhonov en grafos** formula la interpolación como un problema de optimización convexa que equilibra dos objetivos contrapuestos: fidelidad a las observaciones (primer término) y suavidad de la señal reconstruida sobre el grafo (segundo término):

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \underbrace{\|\mathbf{M} \odot (\mathbf{x} - \mathbf{y})\|_2^2}_{\text{fidelidad a datos}} + \alpha \cdot \underbrace{\mathbf{x}^\top \mathbf{L} \mathbf{x}}_{\text{suavidad espacial}}, \quad (2.5)$$

donde $\mathbf{M} \in \{0, 1\}^N$ es la máscara binaria que indica qué canales están observados, $\odot$ denota el producto elemento a elemento, e $\mathbf{y}$ contiene los valores observados (con ceros en las posiciones faltantes). El parámetro α controla el compromiso: $\alpha \rightarrow 0$ fuerza el ajuste exacto a los datos (posiblemente inestable si hay pocas observaciones), mientras que $\alpha \rightarrow \infty$ impone una suavidad extrema (la solución tiende a una constante).

La solución admite una expresión de forma cerrada, $\hat{\mathbf{x}} = (\text{diag}(\mathbf{M}) + \alpha \mathbf{L})^{-1}(\mathbf{M} \odot \mathbf{y})$, cuya matriz a invertir es simétrica y definida positiva para $\alpha > 0$, garantizando existencia y unicidad de la solución.

El **método de muestreo en grafos** adopta una perspectiva diferente: en lugar de minimizar una función de costo, asume que la señal es de banda limitada en el grafo —su GFT tiene soporte en los primeros K autovalores— y busca la señal de banda limitada que interpola exactamente los valores observados. La reconstrucción es conceptualmente análoga al teorema de muestreo de Shannon-Nyquist en el dominio del grafo.

2.3.4. Regularización Espacio-Temporal: TRSS

La limitación fundamental de los métodos anteriores es que tratan cada instante de tiempo de forma independiente. En realidad, las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento: el potencial de membrana no cambia instantáneamente, sino que evoluciona de forma continua. La Regularización Temporal de Suavidad de Sobolev (TRSS, por sus siglas en inglés) [7] incorpora esta realidad fisiológica mediante un término adicional de penalización temporal.

En lugar de interpolar la señal de grafo $\mathbf{x}_t$ para cada t por separado, TRSS formula un problema conjunto sobre toda la matriz espacio-temporal $\mathbf{X} \in \mathbb{R}^{N \times T}$:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{X}} \underbrace{\|\mathbf{M} \odot (\mathbf{X} - \mathbf{Y})\|_F^2}_{\text{fidelidad}} + \alpha \cdot \underbrace{\text{tr}(\mathbf{X}^\top \mathbf{L} \mathbf{X})}_{\text{suavidad espacial}} + \beta \cdot \underbrace{\|\mathbf{X} \mathbf{D}_t\|_F^2}_{\text{suavidad temporal}}, \quad (2.6)$$

donde $\|\cdot\|_F$ denota la norma de Frobenius. El tercer término merece una atención detallada, ya que constituye la innovación central del método. El operador $\mathbf{D}_t \in \mathbb{R}^{T \times (T-1)}$ es la matriz de diferencias finitas hacia adelante, definida como $(\mathbf{D}_t)_{t,t} = -1$, $(\mathbf{D}_t)_{t+1,t} = 1$ y cero en el resto. Al aplicar este operador, $\mathbf{X} \mathbf{D}_t \in \mathbb{R}^{N \times (T-1)}$ contiene, en cada columna, la diferencia entre instantes consecutivos para cada canal. La norma de Frobenius al cuadrado de este producto es

$$\|\mathbf{XD}_t\|_F^2 = \sum_{i=1}^N \sum_{t=1}^{T-1} (X_{i,t+1} - X_{i,t})^2, \quad (2.7)$$

es decir, la suma de los cambios cuadráticos muestra a muestra a lo largo del tiempo, acumulada sobre todos los canales. Penalizar este término equivale a forzar que la señal reconstruida sea *temporalmente suave*: los cambios abruptos de voltaje entre instantes consecutivos son penalizados, lo que es consistente con la dinámica de integración continua de las membranas neuronales.

Los dos hiperparámetros, α y β , controlan la importancia relativa de las restricciones espacial y temporal. Cuando $\beta = 0$, TRSS se reduce a Tikhonov en grafos aplicado independientemente a cada instante. Cuando $\alpha = 0$, se convierte en un suavizador temporal sin guía espacial. La interacción de ambos términos —como demostrará el estudio de ablación en el Capítulo de Resultados— produce una mejora mayor que la suma de sus efectos individuales.

2.3.5. Mención del Paradigma de Aprendizaje Profundo

Como se anticipó en la introducción, existe un cuerpo creciente de literatura que aborda la imputación de canales EEG mediante redes neuronales profundas: autoencoders convolucionales [2], redes generativas antagónicas para series temporales [25] y Redes Neuronales de Grafos (GNN) que operan directamente sobre la topología de electrodos [5]. Estos métodos quedan fuera del alcance experimental de esta tesis por tres razones de peso: son inherentemente dependientes de los datos de entrenamiento (riesgo de falta de generalización entre poblaciones y equipos), carecen de garantías formales de convergencia e interpretabilidad (propiedades críticas en contexto clínico), y su costo computacional de entrenamiento es órdenes de magnitud superior al de los métodos algorítmicos aquí considerados.

2.4. Análisis del Mecanismo Interno de la Interpolación por Splines Esféricos en MNE-Python

Esta sección constituye un aporte original de la presente tesis: la documentación en formato académico de las mejoras de ingeniería que hacen de la implementación de *spherical splines* en MNE-Python una referencia inesperadamente competitiva. La información presentada se obtuvo mediante inspección directa del código fuente de MNE-Python

[9, 10] y no está documentada explícitamente en ningún artículo académico previo.

2.4.1. Formulación Original de Perrin y colaboradores

El artículo fundacional de Perrin y colaboradores [20] formula la interpolación como la solución de un sistema lineal aumentado:

$$\begin{bmatrix} \mathbf{G} + \lambda \mathbf{I} & \mathbf{T} \\ \mathbf{T}^\top & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{c} \\ \mathbf{d} \end{bmatrix} = \begin{bmatrix} \mathbf{V}_{\text{obs}} \\ \mathbf{0} \end{bmatrix}, \quad (2.8)$$

donde $\mathbf{G} \in \mathbb{R}^{M \times M}$ es la matriz de Gram que evalúa la función de Green para todos los pares de electrodos observados, $\mathbf{T}$ es una matriz de aumentación con las coordenadas de cada electrodo, y λ es un parámetro de regularización fijo, típicamente 10^{-5} . Una vez resuelto el sistema, el potencial en cualquier posición se estima como $\hat{V}(\mathbf{r}) = \sum_i c_i g_m(\mathbf{r}, \mathbf{r}_i) + d_0 + d_1 x + d_2 y + d_3 z$.

2.4.2. Las Seis Mejoras de Ingeniería Incorporadas en MNE-Python

La implementación en MNE-Python extiende el algoritmo original con las siguientes mejoras.

1. Normalización de coordenadas a esfera unitaria. MNE no utiliza las coordenadas crudas de los electrodos. Las centra —restando la media espacial— y las escala para que todos los puntos queden sobre o dentro de una esfera unitaria: $\mathbf{p}'_i = (\mathbf{p}_i - \bar{\mathbf{p}}) / \max_j \|\mathbf{p}_j - \bar{\mathbf{p}}\|_2$. Esta normalización elimina la dependencia de las unidades físicas, garantiza el buen condicionamiento numérico de $\mathbf{G}$ y asegura que los argumentos de la función de Green caigan en $[0, \pi]$, donde los polinomios de Legendre están bien comportados.

2. Uso global de canales buenos. A diferencia de los métodos de k vecinos más cercanos, el *spherical spline* utiliza todos los M canales observados para estimar cada canal faltante. En un montaje de 64 canales con 2 canales malos, cada reconstrucción se beneficia de la información de 62 electrodos. Esta redundancia es la razón principal del rendimiento en regímenes de baja pérdida: cuando la correlación entre canales supera 0.9 para electrodos adyacentes, utilizar todos ellos con la ponderación adecuada es óptimo en el sentido de mínima varianza del estimador bayesiano con información previa de suavidad espacial.

3. Regularización diagonal adaptativa. MNE añade un término $\varepsilon \mathbf{I}$ a la matriz del sistema, pero el valor se escala según la traza: $\varepsilon = 10^{-6} \cdot \text{tr}(\mathbf{G})/M$. Esta adaptación garantiza que la regularización sea proporcional a la escala de los datos, protegiendo contra la singularidad numérica incluso con electrodos casi colineales.

4. Aumentación del sistema con restricciones lineales. MNE generaliza la aumentación original incluyendo explícitamente un término constante c_0 junto con las coordenadas espaciales, forzando $\sum_i c_i = 0$ y $\sum_i c_i x_i = \sum_i c_i y_i = \sum_i c_i z_i = 0$. Estas restricciones garantizan la unicidad de la solución.

5. Pseudoinversa con tolerancia adaptativa. Cuando la matriz del sistema es numéricamente singular, MNE recurre a una pseudoinversa con tolerancia τ proporcional a la norma de la matriz: $\Sigma_{ii}^+ = 1/\sigma_i$ si $\sigma_i > \tau \cdot \sigma_{\text{máx}}$, y cero en caso contrario. Esto permite obtener una solución de mínima norma incluso en casos degenerados.

6. Mecanismo de reintento automático. MNE verifica la calidad de la reconstrucción: si los canales interpolados resultan numéricamente nulos —falla silenciosa del resolutor—, el sistema reintenta la interpolación con parámetros por defecto. Esta red de seguridad previene que una configuración patológica produzca resultados inválidos sin advertencia.

2.4.3. Implicaciones para la Evaluación Comparativa

Estas seis mejoras transforman un algoritmo teóricamente simple en un estimador notablemente robusto, con tres consecuencias directas para esta tesis. Primero, no es válido comparar contra implementaciones simplificadas de Perrin —la diferencia en SNR puede ser de 3 a 8 dB—. Segundo, la ventaja real de TRSS en regímenes favorables es menor de lo que sugiere la literatura. Tercero, el punto de cruce donde TRSS demuestra su valor está en la pérdida contigua severa, no en la pérdida aleatoria moderada que evalúan la mayoría de los estudios previos.

2.4.4. ¿Por Qué Funciona Tan Bien? Los Tres Pilares de la Robustez

La robustez de MNE no es accidental, sino que descansa sobre tres pilares complementarios.

Desde el punto de vista **físico**, el modelo de cabeza esférica con polinomios de Legendre es una solución regularizada de la ecuación de Laplace en una esfera conductora. No es

una heurística: es el modelo de propagación más simple que captura la física esencial de la conducción volumétrica. Cuando la información previa es correcta —y la suavidad espacial del EEG en el cuero cabelludo es un hecho físico bien documentado—, los métodos bayesianos simples superan a alternativas más complejas.

Desde el punto de vista **estadístico**, MNE implementa implícitamente un estimador bayesiano con información previa de suavidad espacial. En el régimen de alta redundancia —muchos canales, correlación inter-canal superior a 0.9—, este estimador alcanza la mínima varianza. Los métodos de pocos vecinos descartan información de canales distantes que, aunque débilmente correlacionados, todavía transportan señal útil.

Desde el punto de vista **informacional**, el EEG de cuero cabelludo exhibe una redundancia espacial muy alta debido al filtrado paso-bajo de la conducción volumétrica. En este régimen, los métodos globales que utilizan toda la información disponible superan a los métodos locales que la descartan. Este principio —cuando las características son altamente redundantes, usar todas con la regularización apropiada es mejor que una selección agresiva— está bien establecido en teoría de la información.

2.4.5. Cuándo Fallan los Splines Esféricos

A pesar de su robustez, la interpolación por *spherical splines* es vulnerable cuando su información previa espacial deja de ser válida. Esto ocurre bajo pérdida contigua severa (30 % a 40 % de canales fallando en una misma región): no hay suficientes electrodos buenos en la vecindad para interpolar con precisión, y el espacio de superficies espacialmente suaves consistentes con las pocas observaciones es demasiado grande. Es precisamente en este régimen donde TRSS obtiene su ventaja, porque la información previa temporal —controlada por β — proporciona la restricción adicional que MNE no posee.

2.5. Síntesis del Marco Teórico

La Tabla 2.1 resume las seis familias metodológicas evaluadas en esta tesis, sus principios matemáticos subyacentes y sus fortalezas y debilidades relativas según la teoría.

Tabla 2.1: Familias de métodos de interpolación evaluados: principio matemático, fortalezas y limitaciones según el marco teórico.

Familia	Principio	Fortaleza	Limitación
Geométrica	Distancia euclidiana + superficie esférica	Velocidad, simplicidad	Ignora dinámica temporal
Estadística	Descomposición en fuentes latentes	Separación de artefactos	Requiere datos completos para entrenar
GSP-Tikhonov	Suavidad espacial en grafo	Topología flexible	Independiente por instante
GSP-Muestreo	Banda limitada en el grafo	Fundamentos de muestreo	Sensible a selección de K
TRSS	Suavidad espacio-temporal conjunta	Preservación morfológica	Costo computacional elevado
MNE-Python	Splines + mejoras de ingeniería	Robusta en regímenes favorables	Colapso bajo pérdida contigua

Capítulo 3

Metodología

Este capítulo describe el diseño metodológico de la investigación: los tres conjuntos de datos, los dieciocho algoritmos implementados, los protocolos de simulación de canales faltantes, las métricas de evaluación y el motor de optimización bayesiana. La metodología sigue el principio de que una evaluación comparativa solo es justa cuando todos los métodos —incluyendo las referencias— son llevados a su máximo rendimiento empírico.

3.1. Conjuntos de Datos

La evaluación se realizó sobre tres bases de datos EEG públicas que cubren un espectro diverso de densidades de montaje, paradigmas experimentales y poblaciones. Esta heterogeneidad es deliberada: un método que solo funciona en condiciones ideales de laboratorio tiene una utilidad clínica limitada. La Tabla 3.1 resume las características clave de cada conjunto.

3.1.1. PhysioNet EEG Motor Movement/Imagery

Esta base de datos [8, 22] contiene registros EEG de 109 sujetos realizando tareas motoras reales e imaginadas. Cada registro incluye 64 canales según el sistema internacional 10–10, muestreados a 160 Hz. Para esta tesis se utilizaron exclusivamente los segmentos de reposo con ojos abiertos, de 60 segundos por sujeto, con el fin de evitar que las modulaciones relacionadas con la tarea motora introdujeran variabilidad no controlada en la evaluación de los métodos de interpolación.

Tabla 3.1: Características de los tres conjuntos de datos experimentales.

Propiedad	PhysioNet	BCI IV 2a	MNE Sample
Canales	64	22	60
Sistema	10–10	10–20	10–20 ext.
Frecuencia (Hz)	160	250	600
Sujetos	109	9	1
Paradigma	Reposo	Imag. motora	Auditivo

3.1.2. BCI Competition IV – Dataset 2a

Este conjunto [3] es uno de los más utilizados en la investigación de interfaces cerebro-computador. Contiene registros de 9 sujetos realizando imaginación motora de cuatro clases (mano izquierda, mano derecha, pies y lengua) con 22 canales EEG según el sistema 10–20, muestreados a 250 Hz. Se extrajeron segmentos de 2 segundos posteriores al estímulo de todos los ensayos, generando un total de 2592 ensayos de 500 muestras cada uno.

3.1.3. MNE Sample

El conjunto de datos de ejemplo distribuido con MNE-Python [9] contiene registros de un experimento de procesamiento auditivo y visual. Se utilizó exclusivamente la componente EEG: 60 canales según el sistema 10–20 extendido, muestreados a 600 Hz. Se extrajeron épocas de 0.7 segundos alrededor de estímulos auditivos, generando 72 ensayos de 420 muestras cada uno.

3.1.4. Justificación de la Heterogeneidad

Estos tres conjuntos cubren el espacio de variabilidad que un método de interpolación debe manejar en la práctica: desde 22 canales (típico en clínica ambulatoria) hasta 64 (típico en investigación), con frecuencias de muestreo entre 160 y 600 Hz, y paradigmas que incluyen reposo continuo, imaginación motora y potenciales evocados auditivos.

3.2. Protocolos de Simulación de Canales Faltantes

Se definieron dos modos de pérdida que reflejan escenarios clínicos reales. El **modo aleatorio** selecciona un porcentaje p de los canales al azar, modelando fallas esporádicas

e independientes (secado del gel, desprendimiento mecánico de electrodos individuales). El **modo contiguo** selecciona un canal semilla al azar y marca como faltantes los p canales más cercanos a él en distancia euclidiana, modelando fallas catastróficas localizadas (saturación de un amplificador que afecta un bloque de electrodos adyacentes).

Para cada modo se evaluaron cuatro niveles de severidad: $p \in \{10\%, 20\%, 30\%, 40\%\}$ del total de canales. Cada condición experimental (conjunto de datos, modo y severidad) se evaluó con 5 semillas aleatorias, generando diferentes patrones de canales faltantes. El total de escenarios evaluados fue de $3 \times 2 \times 4 \times 5 = 120$.

3.3. Métodos de Interpolación

Se implementaron dieciocho métodos organizados en seis familias. La Tabla 3.2 presenta la lista completa.

Tabla 3.2: Lista completa de los dieciocho métodos de interpolación implementados, organizados por familia metodológica.

Familia	Métodos
Geométrica	Vecino más cercano, Distancia inversa, RBF, Spherical splines
Estadística	Lineal, PCA, ICA
GSP-Tikhonov	k-NN gaussiano, Distancia completa, Correlación funcional, Distancia inversa
GSP-Muestreo	Banda limitada, Mínimos cuadrados
TRSS	Grafo gaussiano, Grafo de correlación
Referencia	MNE-Python (defecto), MNE-Python (Optuna)

Es importante destacar que los *spherical splines* se implementaron en dos variantes: una implementación propia siguiendo la formulación original de Perrin [20] y la función `mne.io.Raw.interpolate\_bads()` de MNE-Python con parámetros por defecto y optimizados. Esta distinción es metodológicamente crucial, ya que —como se documentó en el Capítulo 2— la implementación de MNE incorpora mejoras de ingeniería que la hacen sustancialmente más robusta.

Tabla 3.3: Batería de métricas de evaluación: definición, categoría y dirección de optimalidad ($\uparrow$ = mayor es mejor, $\downarrow$ = menor es mejor).

Métrica	Definición	Categoría	Dirección
MAE	Error absoluto medio $\frac{1}{N} \sum_i x_i - \hat{x}_i $	Amplitud	$\downarrow$
RMSE	Raíz del error cuadrático medio	Amplitud	$\downarrow$
SNR	Relación señal-ruido $10 \log_{10}(\ x\ ^2 / \ x - \hat{x}\ ^2)$	Amplitud	$\uparrow$
DTW	<i>Dynamic Time Warping</i> : distancia con deformación temporal	Morfológica	$\downarrow$
LSD	Distancia Espectral Logarítmica (promedio sobre bandas)	Espectral	$\downarrow$
Coherencia	Correlación lineal en el dominio de la frecuencia	Espectral	$\uparrow$

3.4. Métricas de Evaluación

La calidad de interpolación se evaluó mediante seis métricas organizadas en tres categorías. Ninguna métrica individual captura todos los aspectos relevantes para la utilidad clínica de la señal reconstruida, por lo que la batería completa es necesaria. La Tabla 3.3 presenta la definición, interpretación y dirección de optimalidad de cada métrica.

Las métricas de **amplitud** (MAE, RMSE, SNR) cuantifican el error de reconstrucción muestra a muestra. El MAE es menos sensible a valores atípicos que el RMSE; el SNR normaliza el error por la energía de la señal original, facilitando la comparación entre conjuntos de datos con distintas escalas de amplitud.

La métrica de **fidelidad morfológica** (DTW) permite deformaciones no lineales del eje temporal para alinear rasgos morfológicos correspondientes. Es particularmente relevante para ERPs, donde un desplazamiento de pocos milisegundos en la latencia de un pico es clínicamente insignificante pero severamente penalizado por el RMSE.

Las métricas de **preservación espectral** (LSD, Coherencia) cuantifican la distorsión del espectro de potencia y la correlación en el dominio de la frecuencia entre la señal original y la reconstruida. Son las que mejor predicen la utilidad clínica de la señal interpolada, ya que muchos biomarcadores EEG —como la potencia relativa en bandas específicas o la coherencia interhemisférica— dependen de la estructura fina del espectro.

3.5. Motor de Optimización Bayesiana: Optuna

Un aspecto metodológico central de esta tesis es la optimización imparcial de hiperparámetros para todos los métodos. Se utilizó Optuna [1] con muestreo TPE (*Tree-structured Parzen Estimator*), que modela $p(\text{hiperparámetros} \mid \text{desempeño})$ y selecciona el próximo

Tabla 3.4: Espacios de búsqueda de hiperparámetros por familia metodológica.

Familia	Parámetros	Escala
GSP (grafo)	$\sigma \in [0,01, 1,0], k \in \{3, 5, 7, 10, 15, 20\}$	Lineal
TRSS	$\alpha \in [10^{-4}, 10^2], \beta \in [10^{-3}, 10^3]$	Logarítmica
Splines propios	$m \in \{2, 3, 4\}, \lambda \in [10^{-8}, 10^{-2}]$	Mixta
MNE (Optuna)	$m \in \{2, 3, 4\}, \lambda \in [10^{-8}, 10^{-2}]$	Mixta

punto a evaluar maximizando la probabilidad de mejora esperada.

Los espacios de búsqueda se definieron de manera diferenciada para cada familia, como se detalla en la Tabla 3.4.

Se ejecutaron 30 intentos independientes por cada método de grafo (suficientes para que el TPE converja a una región de alto desempeño), 10 intentos con NSGA-II multiobjetivo para los *spherical splines* (optimizando MAE y SNR simultáneamente), y barridos de grilla fina para TRSS (dado su mayor costo computacional, que impide un gran número de evaluaciones). En total se exploraron más de quince mil configuraciones paramétricas.

3.6. Protocolo de Validación Confirmatoria

Como fase experimental independiente —diseñada para no contaminar los resultados exploratorios— se ejecutó una validación donde TRSS, con hiperparámetros congelados tras la optimización, se comparó directamente contra `mne.io.Raw.interpolate\_bads()` con parámetros por defecto. Para cada escenario se computó la diferencia pareada en cada métrica, y la significancia se evaluó mediante la prueba de Wilcoxon para muestras pareadas con corrección de Benjamini-Hochberg para comparaciones múltiples. Se reportaron medianas de mejora relativa, intervalos de confianza bootstrap al 95 % (1000 remuestreos estratificados por conjunto de datos) y tasas de victoria por escenario.

3.7. Arquitectura del Sistema Experimental

El sistema se organiza en cinco módulos independientes con responsabilidades bien definidas. El módulo de **datos** implementa adaptadores específicos para cada conjunto que exponen una interfaz común. El módulo de **simulación de daños** recibe los datos crudos y retorna una máscara binaria para los canales faltantes, preservando la semilla para trazabilidad. El módulo de **interpolación** contiene las implementaciones de los dieciocho




Figura 3.1: Degradación del SNR en función del porcentaje de canales perdidos para BCI IV 2a (22 canales, modo contiguo). TRSS mantiene un SNR superior a 15 dB incluso al 40 % de pérdida, mientras que los métodos geométricos caen por debajo de 10 dB. La curva ilustra el punto de cruce alrededor del 20 %.

métodos, cada uno como una clase que expone el método `interpolate(X, mask) -> X_hat`. El módulo de **evaluación** calcula las seis métricas sobre pares de señal original y reconstruida. Finalmente, el módulo de **optimización** define los espacios de búsqueda de Optuna y orquesta los intentos, implementando funciones de retorno para detección temprana de convergencia y puntos de control para recuperación ante fallas.

La separación estricta entre fases exploratoria y confirmatoria —los resultados de una nunca se usaron para ajustar hiperparámetros de la otra— es una decisión de diseño fundamental que previene la contaminación circular que vicia muchas evaluaciones comparativas en la literatura.

Capítulo 4

Arquitectura del Sistema y Trazabilidad

Este capítulo documenta la arquitectura de software y el mecanismo de trazabilidad que vincula cada resultado cuantitativo con su artefacto computacional de origen. La reproducibilidad no es un subproducto casual de la investigación, sino una propiedad que debe diseñarse explícitamente en la arquitectura del sistema.

4.1. Arquitectura Modular

El sistema se organiza en cinco módulos independientes, cada uno con una responsabilidad única y una interfaz explícita. Esta separación permite probar cada módulo de forma aislada, reemplazar implementaciones sin afectar al resto del sistema, y ejecutar experimentos en paralelo sin riesgo de interferencia.

El módulo de **datos** contiene adaptadores específicos para PhysioNet, BCI Competition IV 2a y MNE Sample, todos exponiendo una interfaz común `load\_epochs()` $\rightarrow$ `(X, info)`. La estandarización en esta interfaz es la primera línea de defensa contra diferencias espurias debidas al preprocesamiento. El módulo de **simulación de daños** implementa los protocolos aleatorio y contiguo descritos en el Capítulo 3, recibiendo los datos crudos y retornando una máscara binaria junto con la semilla que la generó —garantizando reproducibilidad determinista—.

El módulo de **interpolación** contiene las dieciocho implementaciones, cada una como una clase que hereda de una clase base abstracta con el método `interpolate(X, mask)` $\rightarrow$ `X\_hat`. Esta interfaz forzada es una decisión arquitectónica deliberada: ningún método

recibe más información que los demás, eliminando la posibilidad de ventajas espurias por acceso diferencial a metadatos o configuraciones. El módulo de **evaluación** calcula las seis métricas definidas en la Tabla 3.3 sobre pares de señal original y reconstruida. El módulo de **optimización** define los espacios de búsqueda de Optuna y orquesta los intentos con registro estructurado de métricas intermedias, puntos de control y detección temprana de convergencia.




Figura 4.1: Comparación global del rendimiento de los métodos de interpolación en el conjunto PhysioNet (64 canales). Las barras muestran el valor promedio de cada métrica tras la optimización con Optuna. Nótese la ventaja de TRSS en SNR y DTW frente a las referencias geométricas.

4.2. Flujo de Datos y Cadena de Trazabilidad

Cada ejecución del sistema sigue una cadena determinista de transformaciones: (1) carga de la configuración experimental desde un archivo estructurado, (2) carga de los datos crudos mediante el adaptador correspondiente, (3) simulación de daño con semilla fija, (4) interpolación con el método e hiperparámetros especificados, (5) evaluación con las

seis métricas, (6) registro de resultados en formato estructurado con metadatos completos.

Cada ejecución recibe un identificador único generado como un resumen criptográfico (SHA-256) de la tupla completa de parámetros: conjunto de datos, modo de pérdida, severidad, semilla, método e hiperparámetros. Este identificador se incrusta en los nombres de los archivos de resultados y permite tres operaciones críticas: verificar que dos ejecuciones con la misma configuración producen resultados idénticos, rastrear cualquier número reportado en esta tesis hasta su archivo de origen, y detectar contaminación entre fases experimentales (si un resultado de la fase confirmatoria tiene un identificador de la fase exploratoria, se detecta inmediatamente).

4.3. Gestión de Artefactos Experimentales

Los resultados de cada experimento se almacenan en una jerarquía estandarizada: `results/<dataset>/<mode>/<severity>/<method>/`. Cada ejecución preserva: el archivo de métricas agregadas en formato JSON, las señales reconstruidas en formato NumPy comprimido, la máscara de canales faltantes, una copia inmutable de la configuración utilizada, y los tiempos de ejecución por etapa. El código fuente del sistema está versionado con Git, y cada conjunto de resultados está asociado a una etiqueta (tag) específica del repositorio.

Tabla 4.1: Tipos de artefactos generados por el sistema y su función.

Artefacto	Formato	Función
Configuración de ejecución	YAML	Registro inmutable de parámetros
Métricas agregadas	JSON	Resultados de las seis métricas
Señal reconstruida	NPZ	Salida verificable bit a bit
Máscara de daño	NPZ	Trazabilidad de canales faltantes
Tiempos de ejecución	JSON	Perfil de eficiencia

4.4. Decisiones de Diseño Significativas

Tres decisiones arquitectónicas merecen mención explícita por su impacto en la validez de los resultados. La primera es la **separación estricta de fases**: los datos de la fase exploratoria (optimización con Optuna) nunca se utilizaron para ajustar hiperparámetros de la fase confirmatoria (validación contra MNE), y viceversa. La segunda es la **interfaz común forzada** para los dieciocho métodos, que elimina ventajas espurias por diferencias

en preprocesamiento o formato de datos: todos los métodos reciben exactamente los mismos argumentos y retornan exactamente el mismo tipo de dato. La tercera es la **inmutabilidad de los datos originales**: una vez cargados, los datos crudos nunca se modifican; todos los métodos operan sobre copias y las métricas siempre comparan contra la misma referencia.

Tabla 4.2: Ejemplos de trazabilidad entre afirmaciones del documento y artefactos computacionales.

Afirmación	Artefacto	Verificación
TRSS supera a MNE en SNR	<code>results/*/nearby/*/trss/</code>	Diferencia de SNR
15K configuraciones exploradas	<code>optuna_study.db</code>	Conteo de trials de Optuna
MNE 50–100× más rápido	<code>results/*/timing.json</code>	Comparación de tiempos

Capítulo 5

Diseño Experimental

Este capítulo formaliza el diseño experimental: variables independientes, dependientes y controladas, protocolo de validación, plan de análisis estadístico y preguntas de investigación. El diseño sigue el principio de que cada experimento debe estar explícitamente vinculado a una pregunta de investigación y a una hipótesis, y que la significancia estadística debe establecerse con rigor antes de interpretar cualquier patrón.

5.1. Variables del Experimento

Como **variables independientes** se definen: el método de interpolación (18 niveles), el conjunto de datos (PhysioNet, BCI IV 2a, MNE Sample), el modo de pérdida (aleatorio, contiguo), la severidad de la pérdida (10 %, 20 %, 30 %, 40 %) y la semilla aleatoria (5 réplicas por condición, como variable de bloque).

Las **variables dependientes** son las seis métricas de evaluación: MAE, RMSE, SNR, DTW, LSD y Coherencia, cuyas definiciones precisas se presentaron en la Tabla 3.3.

Como **variables controladas** se fijan: las versiones exactas de todas las bibliotecas de software (documentadas en el Apéndice de Reproducibilidad), el hardware de ejecución, las semillas globales de NumPy y PyTorch, y el preprocesamiento —idéntico para todos los métodos: filtro pasabanda Butterworth de orden 4 entre 0.5 y 45 Hz, referencia promedio común, y segmentación en épocas de igual duración.

5.2. Preguntas de Investigación por Experimento

La Tabla 5.1 vincula cada pregunta de investigación con el experimento diseñado para responderla y la evidencia esperada según las hipótesis H1 y H2.

Tabla 5.1: Relación entre hipótesis, preguntas de investigación, experimentos y evidencia esperada.

Hipótesis	Pregunta	Experimento	Evidencia
H1	¿Supera TRSS a las referencias?	Comparación global de familias	TRSS do
H1	¿Es la mejora sinérgica?	Ablación α/β	$\alpha + \beta > \alpha$
H1	¿Preserva ERPs?	Series temporales N100/P300	Amplitud
H2	¿Es MNE equivalente en régimen favorable?	Validación confirmatoria	Equivalen
H2	¿Cuál es el punto de cruce?	Curvas de degradación	Cruce en
–	¿Qué métrica discrimina mejor?	Radar multi-métrico	DTW y I

5.3. Plan de Análisis Estadístico

Para todas las comparaciones entre métodos se utilizan pruebas no paramétricas (Wilcoxon signed-rank para muestras pareadas), ya que las métricas de error no siguen distribuciones normales (confirmado mediante la prueba de Shapiro-Wilk sobre los resultados agregados). Dado el alto número de comparaciones —6 métricas $\times$ 18 métodos $\times$ 120 escenarios—, se aplica la corrección de Benjamini-Hochberg para controlar la tasa de falsos descubrimientos (FDR) al 5 %. Se reportan tanto los valores p originales como los ajustados.

Además de la significancia estadística, se reporta el tamaño del efecto mediante la correlación biserial por rangos (para Wilcoxon) y la mejora relativa mediana. Los intervalos de confianza se calculan mediante remuestreo bootstrap jerárquico (1000 remuestreos) que respeta la estructura anidada de los datos: escenarios $\supset$ réplicas.

Para la comparación TRSS vs. MNE en la fase confirmatoria, se emplea un diseño de medidas repetidas: cada escenario produce una diferencia pareada en cada métrica. La hipótesis nula H_0 es que la mediana de las diferencias es cero (equivalencia); la alternativa H_1 es que es distinta de cero. La significancia se evalúa con Wilcoxon signed-rank y se reporta la tasa de victoria (fracción de escenarios donde TRSS supera a MNE) estratificada por dataset, modo y severidad.

5.4. Control de Calidad Experimental

Antes de cualquier análisis, se ejecutaron verificaciones automáticas de consistencia para garantizar la integridad de los datos: (1) todos los archivos de resultados contienen las seis métricas esperadas, (2) ningún identificador de ejecución aparece duplicado con resultados diferentes, (3) las máscaras de canales faltantes coinciden exactamente con la semilla y configuración especificadas, (4) las ejecuciones donde el método produjo valores no numéricos en alguna métrica fueron excluidas, (5) las ejecuciones donde el tiempo de ejecución excedió 10 minutos por intento fueron marcadas y analizadas por separado, y (6) las ejecuciones donde la reconstrucción resultó idéntica a la entrada (falla silenciosa del resolutor) fueron excluidas. Estos criterios se aplicaron uniformemente a todos los métodos sin excepción.




Figura 5.1: Mapa de calor del RMSE para todos los métodos en MNE Sample. Cada fila corresponde a un método y cada columna a una combinación de modo y nivel de pérdida. Los tonos oscuros indican menor error. La columna de la derecha (pérdida contigua al 40 %) muestra el contraste más marcado entre TRSS y las referencias geométricas.

5.5. Síntesis del Diseño

El diseño experimental de esta tesis se distingue de la literatura previa en cuatro aspectos: (1) todos los métodos, incluyendo las referencias clásicas, fueron optimizados con el mismo motor de optimización bayesiana, (2) se incorporó una validación confirmatoria independiente contra la implementación industrial MNE-Python, (3) la evaluación abarca métricas de amplitud, morfología y espectro, y (4) los escenarios de pérdida incluyen tanto fallas aleatorias como contiguas en un rango de severidades clínicamente relevante.

Bibliografia

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019.
- [2] Hubert Banville, Omar Chehab, Aapo Hyvärinen, Denis-Alexander Engemann, and Alexandre Gramfort. Uncovering the structure of clinical EEG signals with self-supervised learning. *Journal of Neural Engineering*, 18(4):046020, 2021. doi: 10.1088/1741-2552/abca18.
- [3] Clemens Brunner, Robert Leeb, Gernot R. Müller-Putz, Alois Schlögl, and Gert Pfurtscheller. BCI Competition IV – Dataset 2a. Graz University of Technology, 2008. URL <https://www.bbci.de/competition/iv/>.
- [4] György Buzsáki. Rhythms of the brain. 2006. doi: 10.1093/acprof:oso/9780195301069.001.0001.
- [5] Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. Convolutional neural networks on graphs with fast localized spectral filtering. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 29, pages 3844–3852, 2016.
- [6] Arnaud Delorme and Scott Makeig. Eeglab: An open source toolbox for analysis of single-trial eeg dynamics including independent component analysis. *Journal of Neuroscience Methods*, 134(1):9–21, 2004. doi: 10.1016/j.jneumeth.2003.10.009.
- [7] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans. Reconstruction of time-varying graph signals via sobolev smoothness. *IEEE Transactions on Signal and Information Processing over Networks*, 8:201–214, 2022. doi: 10.1109/TSIPN.2022.3156886.
- [8] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng,

- and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23): e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215.
- [9] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A Engemann, Daniel Strohmeier, Christian Brodbeck, Roman Goj, Mainak Jas, Teon Brooks, Lauri Parkkonen, et al. Meg and eeg data analysis with mne-python. *Frontiers in neuroscience*, 7:267, 2013.
- [10] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Lauri Parkkonen, and Matti S. Hämäläinen. MNE software for processing MEG and EEG data. *NeuroImage*, 86:446–460, 2014. doi: 10.1016/j.neuroimage.2013.10.027.
- [11] Aapo Hyvärinen and Erkki Oja. Independent component analysis: Algorithms and applications. *Neural Networks*, 13(4-5):411–430, 2000. doi: 10.1016/S0893-6080(00)00026-5.
- [12] Ian T. Jolliffe. *Principal Component Analysis*. Springer, 2nd edition, 2002. doi: 10.1007/b98835.
- [13] Tzyy-Ping Jung, Scott Makeig, Martin J. McKeown, Anthony J. Bell, Te-Won Lee, and Terrence J. Sejnowski. Imaging brain dynamics using independent component analysis. *Proceedings of the IEEE*, 89(7):1107–1122, 2001. doi: 10.1109/5.939827.
- [14] Chun-Hung Lai, Yi-Ming Chen, and Wen-Chieh Liao. A controlled study of the eeg during the performance of neurofeedback. *Clinical EEG and Neuroscience*, 36(4): 219–225, 2005.
- [15] Fabien Lotte, Laurent Bougrain, Andrzej Cichocki, Maureen Clerc, Marco Congedo, Alain Rakotomamonjy, and Florian Yger. A review of classification algorithms for eeg-based brain–computer interfaces: A 10 year update. *Journal of Neural Engineering*, 15(3):031005, 2018. doi: 10.1088/1741-2552/aab2f2.
- [16] Steven J. Luck. *An Introduction to the Event-Related Potential Technique*. MIT Press, 2nd edition, 2014.
- [17] S. K. Narang and A. Ortega. Signal processing techniques for interpolation in graph structured data. In *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5445–5449, 2013. doi: 10.1109/ICASSP.2013.6638704.

- [18] Paul L. Nunez and Ramesh Srinivasan. *Electric Fields of the Brain: The Neurophysics of EEG*. Oxford University Press, 2nd edition, 2006. doi: 10.1093/acprof:oso/9780195050387.001.0001.
- [19] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst. Graph signal processing: Overview, challenges, and applications. *Proceedings of the IEEE*, 106(5):808–828, 2018. doi: 10.1109/JPROC.2018.2820126.
- [20] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier. Spherical splines for scalp potential and current density mapping. *Electroencephalography and Clinical Neurophysiology*, 72(2):184–187, 1989. doi: 10.1016/0013-4694(89)90180-6.
- [21] Carlos Saldivia, Alejandro Weinstein, and Matías Zañartu. Trss vs. Spherical Splines: A reproducible benchmark for EEG channel interpolation under missing-data scenarios. *In Preparation*, 2026. Manuscript in preparation. Results derived from this thesis.
- [22] Gerwin Schalk, Dennis J. McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R. Wolpaw. BCI2000: A general-purpose brain-computer interface (BCI) system. *IEEE Transactions on Biomedical Engineering*, 51(6):1034–1043, 2004. doi: 10.1109/TBME.2004.827072.
- [23] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst. The emerging field of signal processing on graphs. *IEEE Signal Processing Magazine*, 30(3):83–98, 2013. doi: 10.1109/MSP.2012.2235192.
- [24] Olaf Sporns, Giulio Tononi, and Rolf Kötter. The human connectome: A structural description of the human brain. *PLoS Computational Biology*, 1(4):e42, 2005. doi: 10.1371/journal.pcbi.0010042.
- [25] Jinsung Yoon, Daniel Jarrett, and Mihaela van der Schaar. Time-series generative adversarial networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 32, 2019.