

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INGENIERÍA ELECTRÓNICA

Reconstrucción de Canales EEG Faltantes Mediante Procesamiento de Señales en Grafos con Regularización Temporal

Tesis de grado presentada por

Carlos Saldivia Heinz

Como requisito parcial para optar al grado de

Magíster en Ciencias de la Ingeniería

Director de Tesis: Alejandro Weinstein, Ph.D.

Co-Director de Tesis: Matías Zañartu, Ph.D.

Valparaíso, Chile, Junio de 2026

Resumen

La electroencefalografía (EEG) constituye una herramienta fundamental en neurociencia clínica y experimental, pero sufre de la pérdida frecuente de canales debido a fallas de contacto, artefactos de movimiento o saturación de amplificadores. La interpolación de estos canales faltantes es un paso crítico del preprocesamiento, y tradicionalmente se ha abordado mediante métodos geométricos como los *spherical splines*, implementados en bibliotecas de referencia como MNE-Python. Sin embargo, estos métodos operan exclusivamente en el dominio espacial, ignorando la dinámica temporal de las señales. Esta tesis presenta una evaluación comparativa reproducible y exhaustiva de dieciocho métodos de interpolación de canales EEG, geométricos, estadísticos y basados en Procesamiento de Señales en Grafos (GSP), bajo un protocolo experimental riguroso. El diseño incluye tres bases de datos heterogéneas (PhysioNet de 64 canales, BCI Competition IV 2a de 22 canales y MNE Sample de 60 canales), ciento veinte escenarios de pérdida que combinan modos aleatorio y contiguo con severidades del 10 % al 40 %, y una batería de seis métricas que cubren error de amplitud (MAE, RMSE, SNR), fidelidad morfológica (DTW) y preservación espectral (LSD, Coherencia). Para garantizar una comparación justa, todos los métodos —incluyendo las referencias clásicas— fueron optimizados mediante Optuna con más de quince mil configuraciones paramétricas exploradas, y se incorporó una validación confirmatoria contra la implementación comunitaria de referencia de MNE-Python.

Los resultados muestran una conclusión condicional. En la evaluación confirmatoria balanceada, TRSS fijo mejora la mediana de MAE en 12.4 % frente a MNE-Python, alcanza una tasa de victoria de 72.0 % y mejora NRMSE en 13.9 %. La ventaja aumenta en pérdidas agrupadas o periféricas severas, donde la continuidad temporal compensa la pérdida de información espacial local. No obstante, MNE-Python conserva ventajas importantes: obtiene mejor LSD global, es sustancialmente más rápido y supera a TRSS en señales espacialmente suaves. Se concluye que TRSS es preferible cuando la reconstrucción precisa bajo pérdida no trivial es prioritaria, mientras que MNE sigue siendo la opción

robusta para preprocesamiento estándar, análisis espectral sensible a LSD y restricciones de tiempo.

La totalidad del código, las configuraciones experimentales, los registros de optimización y los artefactos de resultados se preservan en el repositorio del proyecto, lo que garantiza la trazabilidad completa de los hallazgos.

Palabras clave: EEG, canales faltantes, interpolación, Procesamiento de Señales en Grafos (GSP), regularización temporal, TRSS, spherical splines, MNE-Python, optimización bayesiana, Optuna, evaluación comparativa reproducible.

Abstract

Electroencephalography (EEG) is a cornerstone tool in clinical and experimental neuroscience, yet it frequently suffers from channel loss due to contact failures, motion artifacts, or amplifier saturation. Interpolating these missing channels is a critical preprocessing step, traditionally addressed through geometric methods such as spherical splines, implemented in reference libraries like MNE-Python. However, these methods operate exclusively in the spatial domain, ignoring the brain’s true functional connectivity and the temporal dynamics of the signals.

This thesis presents a reproducible and exhaustive benchmark comparing eighteen EEG channel interpolation methods —geometric, statistical, and Graph Signal Processing (GSP)-based— under a rigorous experimental protocol. The design encompasses three heterogeneous databases (64-channel PhysioNet, 22-channel BCI Competition IV 2a, and 60-channel MNE Sample), 120 loss scenarios combining random and contiguous modes at severities from 10 % to 40 %, and a battery of six metrics covering amplitude error (MAE, RMSE, SNR), morphological fidelity (DTW), and spectral preservation (LSD, Coherence). To ensure a fair comparison, all methods —including classical baselines— were optimized via Optuna with over 15,000 parametric configurations explored, and a confirmatory validation against MNE-Python’s community reference implementation was incorporated.

The results support a conditional conclusion. In the balanced confirmatory evaluation, fixed TRSS improves median MAE by 12.4 % over MNE-Python, reaches a 72.0 % win rate, and improves NRMSE by 13.9 %. The advantage grows under grouped or peripheral severe losses, where temporal continuity compensates for missing local spatial information. Nevertheless, MNE-Python retains important advantages: it achieves better global LSD, is substantially faster, and outperforms TRSS on spatially smooth signals. We conclude that TRSS is preferable when accurate reconstruction under non-trivial channel loss is the priority, whereas MNE remains the robust choice for standard preprocessing, LSD-sensitive spectral analysis, and time-constrained pipelines.

All code, experimental configurations, optimization logs, and result artifacts are preserved in the project repository, ensuring full traceability of the findings.

Keywords: EEG, missing channels, interpolation, Graph Signal Processing (GSP), temporal regularization, TRSS, spherical splines, MNE-Python, Bayesian optimization, Optuna, reproducible benchmark.

Índice general

1. Introducción	1
1.1. Contexto General y Planteamiento del Problema	1
1.2. Limitaciones de los Enfoques Tradicionales	2
1.3. El Advenimiento del Procesamiento de Señales en Grafos	3
1.4. La Brecha en la Literatura y la Motivación del Trabajo	4
1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?	5
1.5. Objetivos	5
1.5.1. Objetivo General	5
1.5.2. Objetivos Específicos	5
1.6. Preguntas de Investigación	6
1.7. Alcance y Aportes de la Investigación	6
1.8. Estructura de la Tesis	7
2. Marco Teórico y Estado del Arte	8
2.1. Fundamentos Neurofisiológicos de la Señal EEG	8
2.1.1. Generación y Propagación	8
2.1.2. Bandas de Frecuencia y Potenciales Relacionados a Eventos	10
2.2. Procesamiento de Señales en Grafos	10
2.2.1. Definiciones Fundamentales	10
2.2.2. Laplaciano, Suavidad y Transformada de Fourier en Grafos	11
2.2.3. Construcción de Grafos para EEG	11
2.3. Estado del Arte en Interpolación de Señales Biomédicas	14

2.3.1. Métodos Geométricos y Estadísticos	14
2.3.2. Métodos Basados en GSP	15
2.3.3. Regularización Espacio-Temporal: TRSS	15
2.4. Mecanismo Interno de la Interpolación en MNE-Python	16
2.4.1. Formulación Original y sus Seis Mejoras	16
2.4.2. Los Tres Pilares de la Robustez	17
3. Metodología	19
3.1. Conjuntos de Datos	19
3.2. Protocolos de Simulación de Canales Faltantes	20
3.3. Construcción de Grafos	21
3.4. Métodos de Interpolación	22
3.5. Métricas de Evaluación	23
3.6. Optimización Bayesiana con Optuna	23
3.7. Arquitectura del Sistema Experimental	24
3.7.1. Trazabilidad y Gestión de Artefactos	24
3.8. Diseño Experimental	26
3.9. Protocolo de Validación Comparativa	26
3.10. Control de Calidad	27
3.11. Síntesis del Diseño	27
4. Resultados	28
4.1. Relación entre Fases Experimentales	28
4.2. Inventario de Evidencia Experimental	29
4.3. Comparación Pareada TRSS–MNE	31
4.4. Estratificación por Conjunto de Datos	34
4.5. Efecto del Patrón y Severidad de Pérdida	35
4.6. Componente Temporal de TRSS	36
4.7. Preservación Morfológica y Espectral	38
4.8. Tiempo de Cómputo y Complejidad	40

4.9. Síntesis de Resultados	41
5. Discusión	42
5.1. Validación Matizada de las Hipótesis	42
5.2. Por Qué MNE-Python Sigue Siendo una Referencia Fuerte	43
5.3. Mecanismo de la Regularización Temporal	43
5.4. Heterogeneidad de Escenarios y Frontera de Decisión	44
5.5. Costo Computacional e Implementación	44
5.6. Implicaciones para la Práctica EEG	45
5.7. Limitaciones del Estudio	46
5.7.1. Amenazas a la Validez	47
5.8. Lecciones Metodológicas	47

Índice de figuras

2.1. Generación de la señal EEG y manifestaciones relevantes	9
2.2. Conceptos fundamentales de GSP	12
2.3. Descomposición del operador TRSS	16
3.1. Flujo metodológico de evaluación	19
3.2. Diagrama de bloques de la arquitectura	24
3.3. Cadena de trazabilidad experimental	25
4.1. Compromiso entre precisión y tiempo de cómputo en la evaluación confirmatoria. TRSS desplaza el MAE hacia valores menores, pero se ubica a la derecha de MNE en la escala logarítmica de tiempo, lo que evidencia el costo computacional de la regularización temporal.	30
4.2. Portafolio visual de métricas TRSS–MNE	32
4.3. Distribución de NRMSE en la evaluación confirmatoria balanceada. La figura complementa la comparación mediana de la Tabla 4.4: TRSS desplaza la distribución hacia menor error relativo, pero la superposición entre cajas muestra que la mejora no es uniforme en todos los estratos.	33
4.4. Mejoras medianas de TRSS frente a MNE con intervalos bootstrap al 95 %. Las barras positivas favorecen a TRSS; las barras negativas favorecen a MNE o indican mayor tiempo de ejecución de TRSS. El gráfico muestra simultáneamente la ganancia en MAE/NRMSE y las dos advertencias principales: LSD y costo temporal.	33
4.5. Mejora mediana de MAE de TRSS fijo frente a MNE por conjunto de datos. La señal sintética suave actúa como control negativo: cuando se cumple fuertemente el supuesto de suavidad espacial, MNE puede ser superior.	35

4.6. Mapa de calor de mejora mediana de MAE para TRSS fijo frente a MNE. Cada celda muestra la mejora mediana y, debajo, la tasa de victoria. La ventaja crece cuando la pérdida elimina información espacial local, especialmente en patrones cercanos o periféricos de alta severidad.	36
4.7. Ablación del componente temporal: mejora mediana de TRSS completo frente a TRSS sin término temporal. La contribución temporal es consistente dentro de la familia TRSS, aunque su magnitud es menor que las diferencias entre familias de métodos.	37
4.8. Ejemplo cualitativo de reconstrucción temporal bajo pérdida cercana severa. La figura ilustra la diferencia morfológica que las métricas agregadas capturan de forma resumida.	38
4.9. Comparación espectral multi-método. La preservación de potencia por banda no siempre coincide con la mejora de MAE, por lo que LSD se reporta como dimensión independiente y no como consecuencia automática del error de amplitud.	39
4.10. Distribución de tiempos por caso en la evaluación confirmatoria. La diferencia de costo es consistente: TRSS mejora varias métricas de reconstrucción, pero MNE conserva una ventaja clara en velocidad.	40
5.1. Mapa de decisión práctica MNE–TRSS	46

Índice de tablas

2.1. Familias de métodos: principio matemático, fortalezas y limitaciones. . .	18
3.1. Características de los tres conjuntos de datos experimentales.	20
3.2. Estrategias de construcción de grafos. La columna «Fase» indica si el grafo se usó en la fase exploratoria (E), comparativa (C) o ambas (E+C). . . .	21
3.3. Métodos de interpolación implementados y evaluados.	22
3.4. Métricas de evaluación. La notación $\mathcal{F}$ denota el conjunto de canales faltantes, x_i la señal real y $\hat{x}_i$ la reconstrucción.	23
3.5. Espacios de búsqueda de hiperparámetros.	24
3.6. Artefactos generados por el sistema experimental.	25
3.7. Relación entre preguntas de investigación, experimentos y evidencia esperada.	26
4.1. Relación entre fases experimentales y evidencia usada en los capítulos prácticos.	29
4.2. Resumen global del benchmark confirmatorio balanceado contra MNE-Python. Las métricas de error se calculan solo sobre canales artificialmente ocultos. El oráculo usa verdad de terreno para seleccionar hiperparámetros y se reporta únicamente como cota superior no desplegable.	30
4.3. Comparación robusta TRSS–MNE	31
4.4. Portafolio completo de métricas confirmatorias para TRSS fijo frente a MNE. La mejora mediana positiva favorece a TRSS después de ajustar la dirección de cada métrica; valores negativos favorecen a MNE.	32

4.5. Estratificación por conjunto de datos para TRSS fijo frente a MNE en MAE. La ventaja no es homogénea: TRSS mejora en datos reales y en el régimen sintético rugoso, pero pierde cuando la señal sintética satisface fuertemente el supuesto de suavidad espacial.	34
4.6. Escenarios representativos para TRSS fijo frente a MNE en MAE. La mejora aumenta en pérdidas agrupadas o periféricas de alta severidad, mientras que escenarios de pocos canales cercanos pueden producir empate práctico.	35
4.7. Complejidad computacional e implementación observada. N es el número de canales, T el número de muestras temporales, E el número de aristas del grafo y K el número de iteraciones del resolvidor.	40
5.1. Guía práctica de selección entre MNE y TRSS a partir de los resultados experimentales.	45

Capítulo 1

Introducción

1.1. Contexto General y Planteamiento del Problema

La electroencefalografía (EEG) ha sido, durante décadas, una de las herramientas fundamentales de la neurociencia clínica y experimental. Su alta resolución temporal —en el orden de los milisegundos—, su naturaleza no invasiva y su costo relativamente bajo frente a técnicas como la resonancia magnética funcional o la tomografía por emisión de positrones la han consolidado como el estándar para estudiar la dinámica cerebral en tiempo real [3]. Sus aplicaciones abarcan el diagnóstico de epilepsia y trastornos del sueño, la investigación en neurociencia cognitiva y el desarrollo de interfaces cerebro-computador para comunicación asistida y neurorrehabilitación.

Ahora bien, la adquisición de EEG es un proceso frágil. En la práctica clínica y de investigación, la pérdida parcial o total de información en uno o más electrodos es frecuente. Estas fallas pueden deberse al aumento de la impedancia de contacto por transpiración o secado del gel conductor, a fallas en el amplificador como la saturación de voltaje, a movimientos bruscos del paciente que desconectan los sensores, o simplemente al descarte deliberado de canales que presentan una relación señal-ruido inaceptablemente baja durante la etapa de preprocesamiento [16].

La pérdida de canales no es un problema cosmético: compromete la integridad de todo análisis posterior. La ausencia de información espacial distorsiona la topografía de la señal, afecta la localización de fuentes neuronales y altera biomarcadores electrofisiológicos como los Potenciales Relacionados a Eventos (ERP) y la Densidad Espectral de Potencia (PSD) [14]. En sistemas modernos de aprendizaje automático aplicados a interfaces cerebro-computador, la pérdida impredecible de canales cambia la dimensionalidad de

entrada de los clasificadores y obliga, con frecuencia, a descartar ensayos completos de datos clínicamente valiosos [13]. La interpolación precisa de estos canales es, por tanto, un paso ineludible del flujo de preprocesamiento, y su calidad condiciona directamente la validez de cualquier conclusión neurofisiológica o clínica posterior.

1.2. Limitaciones de los Enfoques Tradicionales

Históricamente, el problema de la interpolación de canales EEG ha sido abordado mediante métodos espaciales o estadísticos. El enfoque más extendido y utilizado por defecto en bibliotecas de análisis como EEGLAB [4] o MNE-Python [7, 8] es la interpolación por *spherical splines* [18]. Este método, junto con otros enfoques basados en distancia euclidiana como la interpolación por vecinos más cercanos o las funciones de base radial, asume que la cabeza humana es una esfera conductora perfecta y estima el voltaje del canal faltante proyectando geométricamente los voltajes de los electrodos circundantes sobre dicha superficie.

Aunque estos métodos son rápidos y matemáticamente elegantes, adolecen de una limitación fundamental: operan estrictamente en el dominio espacial estático para cada instante de tiempo individual. Al hacerlo, ignoran dos realidades neurofisiológicas esenciales. En primer lugar, la distribución espacial del potencial eléctrico en el cuero cabelludo no es isotrópica ni homogénea: la conducción volumétrica a través de tejidos de distinta conductividad —cuero cabelludo, cráneo, líquido cefalorraquídeo— distorsiona el campo de manera no uniforme, de modo que un modelo esférico simplificado no captura completamente esta heterogeneidad [16]. En segundo lugar, las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento. Al reconstruir un canal muestra por muestra de forma aislada, los métodos puramente espaciales son incapaces de preservar la dinámica de alta frecuencia, generando trazos con ruido de fase y distorsiones en los picos transitorios [12]. Los métodos estadísticos de descomposición, Análisis de Componentes Independientes (ICA) y Análisis de Componentes Principales (PCA), proyectan las señales observadas sobre fuentes latentes y reconstruyen el canal perdido a partir de esa proyección [10]. Sin embargo, cuando varios canales contiguos fallan simultáneamente, estos métodos tienden a inyectar ruido global o a perder los picos transitorios locales que definen la morfología fina de los ERP.

1.3. El Advenimiento del Procesamiento de Señales en Grafos

Para superar estas limitaciones, en los últimos años ha emergido con fuerza el marco del Procesamiento de Señales en Grafos (GSP, por sus siglas en inglés) [17, 22]. El GSP ofrece una perspectiva natural y poderosa para lidiar con datos que residen en dominios irregulares no euclidianos. En lugar de modelar la cabeza como un espacio continuo tridimensional, GSP modela la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un nodo ($\mathcal{V}$), las aristas ($\mathcal{E}$) definen qué pares de electrodos están conectados, y la matriz de pesos ($\mathbf{W}$) cuantifica la intensidad de cada conexión. Las relaciones de similitud o distancia fisiológica entre electrodos se codifican en $\mathbf{W}$ mediante núcleos de distancia gaussianos o basados en correlación. Bajo este paradigma, el voltaje medido en un instante se interpreta como una señal de grafo, y conceptos clásicos como la Transformada de Fourier, el filtrado paso-bajo y el muestreo se trasladan al dominio del grafo mediante el operador Laplaciano $\mathbf{L}$. La intuición es simple: las señales en nodos fuertemente conectados tienden a ser similares. Al minimizar una función de costo que penaliza las variaciones abruptas sobre la topología del grafo, los datos faltantes se reconstruyen con mayor fidelidad que usando solo la distancia euclidiana [15].

Una extensión aún más avanzada es la regularización espacio-temporal. Trabajos recientes han introducido enfoques como la Regularización Temporal de Suavidad de Sobolev (TRSS, por sus siglas en inglés) [5], que optimiza conjuntamente la topología espacial y la derivada temporal de la señal. Al penalizar saltos bruscos en el tiempo de forma simultánea a los saltos en el espacio, TRSS impone restricciones fisiológicas reales: las neuronas no cambian su potencial de membrana instantáneamente, sino que obedecen dinámicas de integración continua. Esta restricción dual —espacial y temporal— es lo que la teoría predice como el factor diferencial frente a los métodos puramente espaciales.

Aunque existen enfoques de aprendizaje profundo para imputación de series temporales y representación de señales, esta tesis no los incorpora como línea experimental. La razón es metodológica: el objetivo es comparar métodos algorítmicos sin entrenamiento —geométricos, estadísticos, GSP y regularización espacio-temporal— bajo un protocolo controlado y trazable. Incluir modelos entrenables requeriría particiones de entrenamiento, validación externa y análisis de generalización que exceden el alcance de este trabajo.

1.4. La Brecha en la Literatura y la Motivación del Trabajo

A pesar del potencial teórico de los algoritmos GSP y TRSS, su validación empírica en la literatura de señales biomédicas presenta limitaciones metodológicas relevantes. Se identifican tres brechas que motivan el diseño experimental de esta tesis.

El primer problema es que los estudios que proponen nuevos algoritmos GSP suelen compararse contra *spherical splines* usando las configuraciones por defecto de los paquetes de software, sin realizar una búsqueda rigurosa de hiperparámetros para los métodos de referencia. Esto puede inflar artificialmente las ventajas del método propuesto y distorsionar la percepción del verdadero estado del arte [19]. El segundo problema es que la mayoría de los trabajos restringe su evaluación a métricas de error de amplitud global —como el RMSE o el MAE— y aplica escenarios de desconexión simples, tales como la remoción de canales aleatorios aislados en bases de datos pequeñas. Rara vez se investiga el impacto morfológico de la reconstrucción mediante métricas temporales como el *Dynamic Time Warping* o espectrales como la Distancia Espectral Logarítmica. El tercer problema es la escasez de comparaciones contra implementaciones comunitarias maduras. En particular, la interpolación de MNE-Python incorpora más de una década de refinamientos de ingeniería —normalización de coordenadas, regularización diagonal adaptativa, aumentación del sistema con restricciones lineales, pseudoinversa con tolerancia adaptativa y un mecanismo de reintento automático— que la hacen sustancialmente más robusta que una implementación ingenua de *spherical splines*. Ignorar esta implementación equivale a comparar contra un método de referencia debilitado artificialmente.

La motivación concreta de este trabajo nace directamente de estas brechas. El objetivo no es diseñar desde cero un nuevo marco teórico matemático, sino someter a la frontera del conocimiento actual —métodos geométricos, GSP y regularización temporal— a una evaluación empírica rigurosa, exhaustiva y justa. Al utilizar Optuna [1] para explorar configuraciones comparables en múltiples conjuntos de datos, esta tesis busca identificar el punto de cruce práctico entre el paradigma clásico y el paradigma de grafos: cuándo basta una referencia madura como MNE-Python y cuándo la regularización espacio-temporal aporta valor adicional.

1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?

Una pregunta recurrente que emerge del análisis preliminar —y que motiva una sección dedicada en el marco teórico de esta tesis— es por qué la función de interpolación de MNE-Python produce resultados tan competitivos, incluso frente a métodos teóricamente superiores como TRSS. La respuesta, que se desarrolla en profundidad en el Capítulo 2, reside en que la implementación de MNE no es una simple transcripción del artículo original de Perrin y colaboradores [18], sino que incorpora un conjunto de mejoras de ingeniería acumuladas durante más de diez años de desarrollo como código abierto.

Estas mejoras —normalización de coordenadas a esfera unitaria, uso global de canales, regularización diagonal adaptativa, aumentación del sistema con restricciones lineales, pseudoinversa con tolerancia adaptativa y reintento automático— no aparecen descritas en la literatura académica, pero están presentes en el código fuente de MNE. Son las responsables de que un método formulado en 1989 siga siendo hoy una referencia competitiva. Esta tesis dedica una sección completa del marco teórico (Capítulo 2) a documentar estos mecanismos, y una validación comparativa independiente (Capítulo 4) a cuantificar la brecha real entre TRSS y MNE.

1.5. Objetivos

1.5.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales EEG basados en GSP con regularización temporal frente a las referencias geométricas bajo un marco experimental riguroso, reproducible y optimizado mediante optimización bayesiana.

1.5.2. Objetivos Específicos

- **OE1 — Sistema unificado de evaluación.** Implementar dieciocho métodos de interpolación en un sistema modular con interfaz común, definir protocolos de pérdida aleatoria y contigua (10 %–40 %), e integrar Optuna para la optimización imparcial de todos los algoritmos (más de 15 000 configuraciones exploradas).
- **OE2 — Evaluación multi-métrica y fisiológica.** Cuantificar el desempeño

mediante seis métricas primarias (MAE, RMSE, SNR, DTW, LSD, Coherencia) sobre tres conjuntos de datos y 120 escenarios de pérdida, y analizar la preservación morfológica y espectral mediante métricas auxiliares, visualizaciones temporales y potencia por banda.

- **OE3 — Trazabilidad y reproducibilidad.** Generar un repositorio de artefactos computacionales —código, configuraciones, registros de optimización y resultados— que garantice la trazabilidad completa de cada afirmación cuantitativa hasta el archivo que la origina.

1.6. Preguntas de Investigación

En lugar de formular la evaluación como una prueba de hipótesis estadística, esta tesis organiza el análisis en torno a dos preguntas comparativas:

P1. ¿En qué condiciones la regularización espacio-temporal mejora la reconstrucción de canales EEG faltantes frente a referencias geométricas y a MNE-Python?

P2. ¿Qué compromiso práctico existe entre precisión de reconstrucción, fidelidad espectral y tiempo de cómputo al elegir entre TRSS y MNE-Python?

Estas preguntas se responden mediante comparaciones pareadas, estratificación por escenario y análisis multi-métrico; no se interpreta la tesis como aceptación o rechazo de hipótesis nulas.

1.7. Alcance y Aportes de la Investigación

El alcance de este trabajo abarca la ejecución computacional a gran escala del sistema de evaluación sobre tres conjuntos de datos, ciento veinte escenarios de falla y dieciocho métodos de interpolación. A diferencia de las evaluaciones acotadas que predominan en la literatura, aquí se consolidan miles de ensayos EEG bajo más de quince mil configuraciones paramétricas exploradas mediante Optuna.

Para garantizar la reproducibilidad, la ejecución se ancla en un registro exhaustivo de corridas experimentales que fija explícitamente las combinaciones de conjuntos de datos, modos de pérdida, semillas, tipos de grafo y familias de métodos. Este diseño evita las

evaluaciones improvisadas y permite trazar cada afirmación cuantitativa reportada en los capítulos posteriores hasta el artefacto experimental que la origina, según se detalla en el Apéndice D.

Los aportes principales se articulan en cuatro ejes. Primero, se proporciona evidencia empírica pareada de que TRSS mejora métricas de amplitud y ajuste temporal frente a referencias geométricas en regímenes difíciles, una vez que todos los métodos han sido optimizados. Segundo, se muestra que bajo pérdida contigua severa (30 % o más de los canales) la restricción temporal puede compensar la pérdida de información espacial local. Tercero, se documentan en formato académico los mecanismos de ingeniería que convierten a MNE-Python en una referencia inesperadamente competitiva. Cuarto, se entrega un sistema unificado en Python, rastreado y reproducible para ejecutar interpolaciones GSP con optimización bayesiana automatizada sobre datos EEG.

1.8. Estructura de la Tesis

Para desarrollar el análisis propuesto, el resto del documento se organiza de la siguiente manera. El Capítulo 2 presenta los fundamentos neurofisiológicos del EEG, los pilares matemáticos del Procesamiento de Señales en Grafos —incluyendo el Laplaciano, la Transformada de Fourier en Grafos y la construcción de grafos—, el estado del arte en interpolación de señales biomédicas, y los mecanismos internos de la función de interpolación de MNE-Python. El Capítulo 3 integra la metodología completa: conjuntos de datos, protocolos de simulación, métodos de interpolación, métricas, arquitectura del sistema experimental, trazabilidad de artefactos, diseño experimental y plan de análisis comparativo. El Capítulo 4 expone los hallazgos empíricos, incluyendo comparativas globales de error, curvas de degradación por pérdida creciente, visualizaciones temporales representativas, comparación espectral mediante PSD, el estudio de descomposición de componentes de TRSS y la validación contra MNE-Python. El Capítulo 5 ofrece una discusión crítica sobre las causas metodológicas de los resultados obtenidos, interpreta los mecanismos subyacentes y transparenta las limitaciones del estudio. Finalmente, el Capítulo 6 sintetiza las conclusiones, evalúa el cumplimiento de los objetivos y sugiere vías de investigación futura.

Los apéndices complementan el documento con derivaciones matemáticas completas (Apéndice A), tablas extensas de resultados (Apéndice B), el protocolo de reproducibilidad (Apéndice C), el inventario de artefactos computacionales (Apéndice D) y una adaptación de las tablas del documento original de tesis para referencia histórica (Apéndice E).

Capítulo 2

Marco Teórico y Estado del Arte

Este capítulo presenta los fundamentos sobre los que se construye la investigación: principios neurofisiológicos del EEG, bases matemáticas del Procesamiento de Señales en Grafos, estado del arte en interpolación de señales biomédicas, y los mecanismos internos que convierten a la implementación de MNE-Python en una referencia comunitaria sólida.

2.1. Fundamentos Neurofisiológicos de la Señal EEG

2.1.1. Generación y Propagación

La señal de voltaje EEG registrada en el cuero cabelludo resulta de la actividad sincronizada de grandes poblaciones de neuronas piramidales en la corteza cerebral [3]. Estas neuronas, orientadas perpendicularmente a la superficie cortical, generan dipolos de corriente ante potenciales postsinápticos. La suma espacial de estos dipolos —se requieren entre diez mil y cien mil neuronas sincronizadas para producir una señal detectable [16]— constituye la fuente primaria del EEG.

La señal de voltaje generada en la corteza atraviesa desde su origen hasta los electrodos de superficie múltiples capas de conductividad variable: líquido cefalorraquídeo, meninges, cráneo (aproximadamente ochenta veces menos conductor que el cuero cabelludo) y cuero cabelludo [16]. Esta conducción volumétrica actúa como un filtro espacial paso-bajo que suaviza la distribución de potencial y limita la resolución espacial efectiva del EEG a unos dos o tres centímetros. La Figura 2.1(a) ilustra este proceso de propagación desde la corteza hasta el cuero cabelludo, y la Figura 2.1(b) muestra la configuración del campo eléctrico generado por un dipolo cortical.




Figura 2.1: Generación de la señal EEG y manifestaciones relevantes para la interpolación de canales. (a) Propagación desde fuentes corticales hasta electrodos de superficie a través de capas con conductividad distinta, representadas sobre una referencia de cabeza. (b) Campo idealizado de un dipolo cortical y sus líneas de potencial. (c) Ejemplo esquemático de ERP con componentes N100, P200 y P300, cuya morfología debe preservarse al interpolar. (d) Topografía de electrodos con canales observados y canales fallados sobre una cabeza con orientación anatómica. Esquema de elaboración propia basado en la descripción neurofísica de [16] y en la nomenclatura ERP de [14].

2.1.2. Bandas de Frecuencia y Potenciales Relacionados a Eventos

La señal EEG se caracteriza por su contenido oscilatorio en bandas de frecuencia asociadas a estados funcionales específicos: delta (0.5–4 Hz, sueño profundo), theta (4–8 Hz, procesamiento de memoria), alpha (8–13 Hz, reposo vigil), beta (13–30 Hz, procesamiento activo) y gamma (30–100 Hz, procesamiento perceptual de alto nivel) [3]. La preservación de la estructura espectral en cada banda es un criterio fundamental para evaluar la calidad de cualquier interpolación.

Los Potenciales Relacionados a Eventos (ERP) son fluctuaciones de voltaje sincronizadas con un estímulo sensorial, motor o cognitivo, obtenidas mediante promediación coherente de múltiples ensayos [14]. Componentes como N100, P300 y N400 constituyen biomarcadores electrofisiológicos cuya preservación morfológica —amplitud de pico, latencia y distribución topográfica— es uno de los criterios de evaluación más exigentes para cualquier método de interpolación. La Figura 2.1(c) muestra un ejemplo de forma de onda ERP con sus componentes principales, y la Figura 2.1(d) ilustra la topografía de canales buenos y fallados.

2.2. Procesamiento de Señales en Grafos

El Procesamiento de Señales en Grafos (GSP) [17, 22] extiende los conceptos del procesamiento clásico de señales a dominios irregulares representados por grafos.

2.2.1. Definiciones Fundamentales

Un grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$ consiste en N nodos $\mathcal{V} = \{v_1, \dots, v_N\}$ —los electrodos—, un conjunto de aristas $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ que define qué electrodos están conectados, y una matriz de pesos $\mathbf{W} \in \mathbb{R}^{N \times N}$ simétrica que especifica con qué intensidad: $W_{ij} > 0$ si existe arista entre i y j , y $W_{ij} = 0$ en caso contrario. La distinción entre $\mathcal{E}$ y $\mathbf{W}$ es relevante porque $\mathcal{E}$ define la topología (pares conectados) mientras que $\mathbf{W}$ codifica la fuerza de cada conexión; en grafos densos pueden coincidir, pero en grafos sparse como k-NN difieren.

Una señal de grafo en el instante t es el vector $\mathbf{x}_t \in \mathbb{R}^N$ de voltajes en los N electrodos. La matriz $\mathbf{X} \in \mathbb{R}^{N \times T}$ contiene T instantes temporales de la ventana de análisis EEG.

2.2.2. Laplaciano, Suavidad y Transformada de Fourier en Grafos

La matriz Laplaciana se define como $\mathbf{L} = \mathbf{D} - \mathbf{W}$, con $D_{ii} = \sum_j W_{ij}$. La forma cuadrática

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{i,j} W_{ij} (x_i - x_j)^2 \quad (2.1)$$

cuantifica la variación total del vector de voltajes $\mathbf{x} \in \mathbb{R}^N$ sobre el grafo: valores pequeños indican que nodos fuertemente conectados tienen valores similares —la señal es *suave*—. Esta propiedad es el pilar de la interpolación GSP: la mejor reconstrucción minimiza $S(\mathbf{x})$ sujeta a coincidir con los canales observados. La Ecuación 2.1 es la base de todos los métodos de regularización en grafos discutidos en este capítulo.

$\mathbf{L}$ admite la descomposición espectral $\mathbf{L} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$, donde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$ contiene los autovalores ordenados $0 = \lambda_1 \leq \dots \leq \lambda_N$, y $\mathbf{U}$ es la matriz ortogonal de autovectores. Los λ_k actúan como frecuencias en el grafo: valores pequeños corresponden a modos de variación lenta, valores grandes a modos de variación rápida (Figura 2.2b).

La Transformada de Fourier en Grafos (GFT) se define como $\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}$. Una señal es *de banda limitada* si $\hat{x}_k = 0$ para $k > K$, con $K \ll N$. La suavidad en el dominio espectral es $S(\mathbf{x}) = \sum_k \lambda_k \hat{x}_k^2$, penalizando los modos de alta frecuencia proporcionalmente a su autovalor. En este contexto, una reconstrucción regularizada es la estimación de los canales faltantes que conserva los canales observados y minimiza simultáneamente una penalización de variación sobre el grafo.

La Figura 2.2(a) muestra el grafo de electrodos, la Figura 2.2(b) separa explícitamente los autovalores del Laplaciano de la energía modal ilustrativa, y la Figura 2.2(c) resume la reconstrucción regularizada como compromiso entre datos observados y suavidad espacial.

2.2.3. Construcción de Grafos para EEG

La elección del grafo subyacente es una decisión metodológica de primer orden: un mismo algoritmo de interpolación GSP produce resultados distintos según el grafo sobre el que opera. En este trabajo se implementaron y evaluaron diez estrategias de construcción de grafos, organizadas en tres categorías según la fuente de información que utilizan.

Grafos geométricos (basados en distancia). Utilizan exclusivamente las posiciones físicas de los electrodos, lo que los hace inmunes a la presencia de canales faltantes y deterministas por construcción:




Figura 2.2: Conceptos fundamentales de GSP aplicados a EEG. (a) Los electrodos forman un grafo ponderado sobre una topografía de cabeza; las aristas codifican cercanía espacial. (b) El espectro del Laplaciano ordena los modos desde variación suave hasta variación rápida. La curva azul muestra autovalores, mientras que la curva naranja ilustra que la energía de una señal suave tiende a concentrarse en modos bajos. (c) La reconstrucción regularizada estima los canales faltantes combinando fidelidad a los canales observados y suavidad inducida por el grafo.

- **k-NN no ponderado (knn)**. Conecta cada electrodo a sus k vecinos más próximos con pesos binarios $\{0, 1\}$. Es el grafo más simple y sirve como línea base estructural.
- **k-NN gaussiano (knng)**. Extiende el anterior ponderando cada arista con $W_{ij} = \exp(-\|\mathbf{p}_i - \mathbf{p}_j\|_2^2 / 2\sigma^2)$, donde $\mathbf{p}_i \in \mathbb{R}^3$ es el vector de coordenadas 3D del electrodo i según el sistema 10–20 o 10–10, σ controla la escala de decaimiento y k determina la dispersión.
- **k-NN gaussiano variable (vknng)**. Similar al knng pero con k_i adaptativo según la densidad local de electrodos: en regiones densas (e.g., zona occipital en montajes 10–10) usa menos vecinos, y en regiones dispersas usa más. El parámetro α controla la sensibilidad a la densidad local.
- **ε -ball (epsilon_ball)**. Conecta todos los pares cuya distancia es menor que un umbral ε , con pesos $\{0, 1\}$. A diferencia de k-NN, el grado de cada nodo es variable y depende de la densidad local.
- **Distancia completa gaussiana (gaussian)**. Conecta todos los pares de electrodos con el núcleo gaussiano, generando una matriz densa. No requiere el parámetro k y captura interacciones de largo alcance, aunque puede introducir ruido de conexiones débiles.
- **Conectividad total inversa (fully_connected_inverse_distance)**. Usa $W_{ij} = 1/d_{ij}$, generando un grafo denso donde la influencia decae linealmente con la distancia.

Grafos basados en correlación funcional. Utilizan la serie temporal observada para cuantificar similitud entre electrodos. La construcción es $W_{ij} = |\rho_{ij}|$, donde ρ_{ij} es el coeficiente de correlación de Pearson entre los electrodos i y j , calculado solo con canales disponibles. Este criterio es informativo para exploración, pero introduce circularidad si se usa para confirmar desempeño: el grafo queda parcialmente determinado por las mismas señales sobre las que luego se evalúa la reconstrucción. Por esta razón, los grafos de correlación se usaron solo en la fase de cribado y no sostienen las conclusiones comparativas principales. **Grafos data-driven (aprendidos desde los datos).** No requieren especificar un núcleo ni sus parámetros; la estructura del grafo emerge de las señales mismas:

- **Kalofolias (kalofolias)**. Formula el aprendizaje del grafo como optimización convexa que minimiza la variación de la señal observada con restricciones de grado positivo [11]. Se implementó una versión propia con descenso de gradiente proyectado sobre la función objetivo de log-grados más regularización de Frobenius.
- **NNK (nnk)**. Regresión de kernel no-negativa que selecciona automáticamente los vecinos relevantes para cada nodo resolviendo un problema NNLS (*Non-Negative Least*

Squares) local, sin necesidad de especificar k [21].

- **AEW (Adaptive Edge Weighting)**. Optimización conjunta de pesos y topología mediante el algoritmo AEW [21], que alterna entre actualización de pesos vía descenso de gradiente y proyección sobre restricciones de grado.

Los grafos data-driven se evaluaron en la fase exploratoria pero no se incluyeron en la fase comparativa por dos razones: su mayor costo computacional ($O(N^3)$ en el caso de Kalofolias) y la dificultad de garantizar reproducibilidad determinista entre ejecuciones. Su impacto sobre TRSS se propone como trabajo futuro.

2.3. Estado del Arte en Interpolación de Señales Biomédicas

2.3.1. Métodos Geométricos y Estadísticos

El método más establecido es el de *spherical splines* [18], que modela el potencial sobre el cuero cabelludo como una función suave sobre una esfera. El potencial estimado en una posición $\mathbf{r}$ es $\hat{V}(\mathbf{r}) = c_0 + \sum_{i=1}^M c_i g_m(\mathbf{r}, \mathbf{r}_i)$, donde M es el número de canales observados, g_m es la función de Green del operador pseudo-laplaciano de orden m sobre la esfera y los coeficientes se obtienen resolviendo un sistema lineal aumentado. En una forma regularizada, el bloque principal del sistema puede escribirse como $(\mathbf{G} + \lambda \mathbf{I})\mathbf{c} + c_0 \mathbf{1} = \mathbf{v}$, donde $G_{ij} = g_m(\mathbf{r}_i, \mathbf{r}_j)$ y λ estabiliza el ajuste. Así, m controla la rigidez de la superficie y λ regula el compromiso entre ajuste y suavidad. Junto a los splines esféricos, se implementaron y evaluaron otros métodos de la familia geométrica. La **interpolación por distancia inversa** (IDW) estima el canal faltante como promedio ponderado de los canales observados, con pesos $w_i = 1/d_i^p$ donde d_i es la distancia euclidiana al canal faltante y p controla la velocidad de decaimiento. La **interpolación por vecino más cercano** asigna al canal faltante el valor del canal observado más próximo. Las **funciones de base radial** (RBF) generalizan el enfoque usando núcleos gaussianos o multicuádricos y han sido aplicadas explícitamente a reconstrucción de EEG [9]. La **interpolación lineal** estima por triangulación sobre las posiciones 2D/3D de los electrodos. Estos métodos comparten la propiedad de operar exclusivamente en el dominio espacial, ignorando la estructura temporal de la señal.

Entre los métodos estadísticos, el **Análisis de Componentes Independientes (ICA)** [10] se utilizó en dos variantes: una implementación propia con FastICA y la

implementación de MNE-Python (ICA-MNE) con algoritmo Picard. ICA proyecta las señales observadas sobre fuentes independientes, elimina componentes artefactuales y reconstruye los canales faltantes desde el espacio de fuentes. Su inclusión se justifica porque es el método estándar de la comunidad EEG para remoción de artefactos, y evaluar su capacidad de reconstruir canales completamente ausentes —no solo corregir canales ruidosos— es una pregunta metodológica relevante. Sin embargo, ICA requiere la estimación de la matriz de mezcla sobre datos completos y su desempeño se degrada cuando la pérdida de canales es severa y contigua, por lo que se reservó para la fase exploratoria. El **Análisis de Componentes Principales (PCA)** se menciona aquí como contexto histórico pero no se evaluó experimentalmente por su desempeño consistentemente inferior en pruebas preliminares.

2.3.2. Métodos Basados en GSP

La **regularización de Tikhonov en grafos** formula la interpolación como un problema de optimización convexa:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \|\mathbf{M} \odot (\mathbf{x} - \mathbf{y})\|_2^2 + \alpha \cdot \mathbf{x}^\top \mathbf{L} \mathbf{x}, \quad (2.2)$$

donde $\mathbf{M} \in \{0, 1\}^N$ es la máscara binaria de canales observados (con $M_i = 1$ si el canal i está observado y $M_i = 0$ si está faltante), $\odot$ denota el producto Hadamard (multiplicación elemento a elemento entre dos matrices o vectores del mismo tamaño), y α controla el compromiso entre fidelidad a los datos y suavidad espacial. La Ecuación 2.2 admite solución cerrada $\hat{\mathbf{x}} = (\text{diag}(\mathbf{M}) + \alpha \mathbf{L})^{-1}(\mathbf{M} \odot \mathbf{y})$. El **método de muestreo en grafos** asume que la señal es de banda limitada y busca la señal de banda limitada que interpola exactamente los valores observados.

2.3.3. Regularización Espacio-Temporal: TRSS

La Regularización Temporal de Suavidad de Sobolev (TRSS) [5] incorpora la continuidad temporal de las señales neuronales mediante un término adicional de penalización. El problema conjunto sobre la matriz espacio-temporal $\mathbf{X} \in \mathbb{R}^{N \times T}$ es

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{X}} \|\mathbf{M} \odot (\mathbf{X} - \mathbf{Y})\|_F^2 + \alpha \cdot \text{tr}(\mathbf{X}^\top \mathbf{L} \mathbf{X}) + \beta \cdot \|\mathbf{X} \mathbf{D}_t\|_F^2, \quad (2.3)$$

donde $\mathbf{D}_t \in \mathbb{R}^{T \times (T-1)}$ es la matriz de diferencias finitas con $(\mathbf{D}_t)_{t,t} = -1$, $(\mathbf{D}_t)_{t+1,t} = 1$, y $\|\mathbf{X} \mathbf{D}_t\|_F^2 = \sum_{i=1}^N \sum_{t=1}^{T-1} (X_{i,t+1} - X_{i,t})^2$ penaliza los cambios abruptos muestra a muestra. β

controla la suavidad temporal: $\beta = 0$ reduce TRSS a Tikhonov independiente por instante; $\alpha = 0$ lo convierte en un suavizador temporal sin guía espacial. La interacción de ambos términos se evalúa empíricamente mediante el estudio de descomposición de componentes del Capítulo 4. La Figura 2.3 descompone visualmente la contribución de cada término en la Ecuación 2.3.




Figura 2.3: Descomposición del operador TRSS. La reconstrucción combina fidelidad a los canales observados, suavidad espacial inducida por el Laplaciano del grafo y suavidad temporal inducida por diferencias finitas. El término temporal no agrega información externa: restringe el espacio de soluciones admisibles mediante D_t .

2.4. Mecanismo Interno de la Interpolación en MNE-Python

Esta sección documenta las mejoras de ingeniería —no descritas en la literatura académica— que convierten a la implementación de *spherical splines* en MNE-Python [7, 8] en una referencia sólida. La información se obtuvo mediante inspección directa del código fuente.

2.4.1. Formulación Original y sus Seis Mejoras

El artículo de Perrin [18] formula la interpolación como un sistema lineal aumentado en el que la regularización se incorpora al bloque de Green, de manera análoga a $(\mathbf{G} + \lambda \mathbf{I})\mathbf{c}$. La formulación original ya utiliza todos los canales observados para estimar cada canal faltante; por tanto, la ventaja de MNE-Python no proviene de usar más canales que Perrin, sino de una implementación numéricamente robusta y bien integrada al flujo M/EEG. MNE-Python incorpora las siguientes decisiones de ingeniería:

1. **Normalización a esfera unitaria.** Las coordenadas de electrodos $\mathbf{p}_i$ se centran y escalan: $\mathbf{p}'_i = (\mathbf{p}_i - \bar{\mathbf{p}}) / \max_j \|\mathbf{p}_j - \bar{\mathbf{p}}\|_2$. Esto elimina la dependencia de unidades físicas y mejora el condicionamiento numérico.
2. **Uso global preservado.** Igual que la formulación de Perrin, todos los M canales observados contribuyen a cada estimación. En un montaje de 64 canales con 2 canales malos, la reconstrucción aprovecha 62 electrodos; esto la diferencia de métodos locales como vecino más cercano o k-NN con k pequeño, no de Perrin.
3. **Regularización adaptativa.** El regularizador efectivo se escala según la matriz de Green $\mathbf{G}$: $\varepsilon = 10^{-6} \cdot \text{tr}(\mathbf{G})/M$. Aquí ε cumple el papel numérico de λ en el sistema regularizado.
4. **Aumentación con restricciones lineales.** Se fuerzan $\sum_i c_i = 0$ y condiciones análogas para las coordenadas, garantizando unicidad.
5. **Pseudoinversa con tolerancia adaptativa.** Ante matrices numéricamente singulares, se usa una pseudoinversa con umbral proporcional a la norma.
6. **Reintento automático.** Si la reconstrucción produce valores nulos, el sistema reintenta con parámetros por defecto.

Estas mejoras transforman un algoritmo teóricamente simple en un estimador notablemente robusto. La implicación para esta tesis es clara: no es válido comparar contra implementaciones simplificadas de Perrin; la referencia debe ser MNE-Python mismo.

2.4.2. Los Tres Pilares de la Robustez

Desde el punto de vista **físico**, el modelo de cabeza esférica —cuya solución involucra polinomios de Legendre como base ortogonal natural para la ecuación de Laplace en coordenadas esféricas— es una solución regularizada de dicha ecuación: no es una heurística sino el modelo más simple que captura la física de la conducción volumétrica. Cuando la información previa es correcta —y la suavidad espacial del EEG es un hecho físico bien documentado—, los métodos con restricciones físicas simples superan a alternativas más complejas.

Desde el punto de vista **estadístico**, la regularización de MNE puede interpretarse como un estimador penalizado con una preferencia explícita por superficies suaves. No se afirma que MNE implemente un modelo bayesiano completo; la analogía relevante es que la penalización actúa como información previa de suavidad espacial. En el régimen de alta redundancia espacial típico del EEG de cuero cabelludo, este estimador penalizado aprovecha una propiedad física real de la señal. Desde el punto de vista **informacional**,

el EEG de cuero cabelludo exhibe redundancia espacial alta por el filtrado paso-bajo de la conducción volumétrica. Los métodos globales, que utilizan todos los canales observados, extraen más información que los métodos locales que restringen la estimación a un subconjunto de vecinos, como el vecino más cercano o k-NN con k pequeño. La Tabla 2.1 resume las familias de métodos discutidas en esta sección, indicando su principio matemático, fortaleza principal y limitación característica.

Tabla 2.1: Familias de métodos: principio matemático, fortalezas y limitaciones.

Familia	Principio	Fortaleza	Limitación
Geométrica	Distancia + superficie esférica	Velocidad, simplicidad	Ignora dinámica temporal
Estadística	Descomposición en fuentes (ICA)	Separa artefactos	Requiere datos completos
GSP-Tikhonov	Suavidad espacial en grafo	Topología flexible	Independiente por instante
GSP-Muestreo	Banda limitada en grafo	Fundamento de muestreo	Sensible a selección de K
TRSS	Suavidad espacio-temporal	Preserva morfología	Costo computacional alto
MNE-Python	Splines + mejoras ing.	Robusta en rég. favorable	Pierde precisión bajo pérdida contigua

Capítulo 3

Metodología

Este capítulo integra el diseño metodológico completo: conjuntos de datos, protocolos de simulación de canales faltantes, construcción de grafos, algoritmos de interpolación, métricas de evaluación, motor de optimización bayesiana, arquitectura del sistema experimental, trazabilidad de artefactos, diseño experimental y protocolo de validación comparativa. La Figura 3.1 resume el flujo metodológico completo.




Figura 3.1: Flujo metodológico de evaluación con control pareado. Cada método se aplica sobre los mismos conjuntos de datos, máscaras de pérdida y semillas; luego se calculan métricas de reconstrucción y costo antes de comparar los métodos por escenario pareado.

3.1. Conjuntos de Datos

La evaluación se realizó sobre tres bases de datos EEG públicas que cubren un espectro diverso de densidades de electrodos, paradigmas y poblaciones (Tabla 3.1).

PhysioNet [6, 20] contiene 64 canales (10–10) a 160 Hz de 109 sujetos. Se usaron segmentos de reposo con ojos abiertos (60 s por sujeto). **BCI Competition IV 2a** [2] aporta 22 canales (10–20) a 250 Hz de 9 sujetos en tareas de imaginación motora de cuatro clases. Se extrajeron 2592 ensayos de 2 s. **MNE Sample** [7] corresponde a un registro de un sujeto; de ese registro se seleccionaron 60 canales EEG a 600 Hz y 72

Tabla 3.1: Características de los tres conjuntos de datos experimentales.

Dataset	Canales	Sistema	Frec. (Hz)	Sujetos	Paradigma
PhysioNet	64	10–10	160	109	Reposo
BCI IV 2a	22	10–20	250	9	Imag. motora
MNE Sample	60	10–20 ext.	600	1	Auditivo

ensayos de 0.7 s alrededor de estímulos auditivos.

Estos tres conjuntos cubren el espacio de variabilidad real: desde 22 canales (clínica ambulatoria) hasta 64 (investigación), con frecuencias de 160 a 600 Hz y paradigmas de reposo, imaginación motora y potenciales evocados.

3.2. Protocolos de Simulación de Canales Faltantes

La evaluación de métodos de interpolación requiere conocer la señal verdadera (*ground truth*) para cuantificar el error de reconstrucción. La estrategia adoptada consiste en simular la pérdida sobre canales que sí están presentes y cuya señal real se conoce: se selecciona un subconjunto de canales, se oculta su señal (máscara de falta), se aplica el método de interpolación para estimar dicha señal, y se compara la estimación con la señal original oculta. Esta estrategia —estándar en la literatura de imputación de señales fisiológicas— permite calcular métricas de error exactas sobre datos reales sin requerir registros simultáneos de referencia.

Se definieron dos modos de pérdida de canales. El **modo aleatorio** selecciona un porcentaje p de canales al azar, modelando fallas esporádicas (secado del gel, desprendimiento de electrodos). El **modo contiguo** selecciona un canal semilla y marca como faltantes los p canales más cercanos en distancia euclidiana, modelando fallas catastróficas localizadas (saturación de amplificador).

Para cada modo se evaluaron cuatro severidades ($p \in \{10\%, 20\%, 30\%, 40\%\}$) con 5 semillas aleatorias, generando $3 \times 2 \times 4 \times 5 = 120$ escenarios. La semilla determina qué canales específicos se marcan como faltantes y se preserva para garantizar que todos los métodos se evalúen sobre exactamente las mismas máscaras.

3.3. Construcción de Grafos

Los métodos basados en GSP requieren un grafo subyacente que define la topología de conectividad entre electrodos. La construcción del grafo es una decisión metodológica independiente del algoritmo de interpolación: un mismo método puede operar sobre distintos grafos, y un mismo grafo puede alimentar distintos algoritmos.

Se implementaron diez estrategias de construcción de grafos, organizadas según la fuente de información que utilizan (Tabla 3.2). La nomenclatura entre paréntesis corresponde al identificador usado en el código del repositorio.

Tabla 3.2: Estrategias de construcción de grafos. La columna «Fase» indica si el grafo se usó en la fase exploratoria (E), comparativa (C) o ambas (E+C).

Estrategia	Tipo	Descripción	Fase
knn	Geométrico	k-NN no ponderado (k vecinos, pesos binarios)	E
knng	Geométrico	k-NN con kernel gaussiano (k , σ)	E+C
vknn	Geométrico	k-NN variable según densidad local (α)	E
epsilon_ball	Geométrico	ε -ball (todos los pares con $d < \varepsilon$)	E
gaussian	Geométrico	Distancia completa con kernel gaussiano (σ)	E+C
inv_distance	Geométrico	Conectividad total con $W_{ij} = 1/d_{ij}$	E
correlation	Correlación	$W_{ij} = \rho_{ij} $ (solo fase exploratoria)	E
kalofolias	Data-driven	Optimización de log-grads + regularización Frobenius	E
nnk	Data-driven	Regresión de kernel no-negativa (NNLS local)	E
aw	Data-driven	<i>Adaptive Edge Weighting</i>	E

Los grafos geométricos operan exclusivamente sobre las posiciones físicas de los electrodos, lo que los hace inmunes a canales faltantes y deterministas. Las posiciones se obtuvieron desde los montajes disponibles en MNE-Python: PhysioNet se estandarizó con el montaje `standard\_1005`; BCI IV 2a se mapeó a los 22 nombres de canal del montaje 10–20 extendido; y MNE Sample usó las coordenadas incluidas en el archivo `sample\_audvis\_raw.fif`. Cuando un canal no tenía coordenada explícita, el sistema lo marcó como caso a revisar y evitó usarlo para conclusiones fuertes. Los grafos de correlación funcional se usaron únicamente en la fase de exploración inicial (*screening*), donde

era necesario evaluar un gran número de combinaciones método×grafo; se descartaron para la fase comparativa porque la correlación se estima sobre las mismas señales que luego se reconstruyen, introduciendo circularidad metodológica. Los grafos data-driven se evaluaron en la fase exploratoria pero no pasaron a la fase comparativa por su mayor costo computacional y menor reproducibilidad determinista. Los grafos knng y gaussian fueron los únicos que avanzaron a la fase comparativa, por su balance entre expresividad y reproducibilidad.

3.4. Métodos de Interpolación

Se implementaron dieciocho métodos de interpolación organizados en cuatro familias (Tabla 3.3). La nomenclatura de familias es consistente a lo largo de todo el documento.

Tabla 3.3: Métodos de interpolación implementados y evaluados.

Familia	Métodos	Fase
Geométrica	Vecino más cercano, Distancia inversa (IDW), RBF, Spherical splines, Lineal	E
Estadística	ICA (FastICA), ICA-MNE (Picard)	E
GSP	Tikhonov en grafos, Banda limitada (BGSRP), Suavizado en grafos, TV en grafos, GTT (graph-time Tikhonov)	E
TRSS	Regularización espacio-temporal de Soble	E+C
Referencia	MNE-Python (defecto), MNE-Python (Optuna)	E+C

Es metodológicamente crucial distinguir entre la implementación propia de *spherical splines* y la de MNE-Python, que incorpora mejoras de ingeniería documentadas en el Capítulo 2. Los métodos GSP (Tikhonov, BGSRP, TV, GTT) y TRSS se evaluaron sobre múltiples grafos de la Sección 3.3, generando variantes por método según el grafo subyacente. Los métodos geométricos y estadísticos se evaluaron en la fase exploratoria; solo TRSS y MNE-Python (en sus variantes por defecto y optimizada) avanzaron a la fase comparativa.

3.5. Métricas de Evaluación

Se emplearon seis métricas primarias organizadas en tres categorías, más el tiempo de cómputo como métrica complementaria (Tabla 3.4). Ninguna métrica individual captura todos los aspectos relevantes; por ello se reportan de forma independiente en los resultados.

Tabla 3.4: Métricas de evaluación. La notación $\mathcal{F}$ denota el conjunto de canales faltantes, x_i la señal real y $\hat{x}_i$ la reconstrucción.

Categoría	Métrica	Símbolo	Dirección
Amplitud	Error absoluto medio: $\frac{1}{ \mathcal{F} } \sum_{i \in \mathcal{F}} x_i - \hat{x}_i $	MAE	↓
	Raíz del error cuadrático medio: $\sqrt{\frac{1}{ \mathcal{F} } \sum_{i \in \mathcal{F}} (x_i - \hat{x}_i)^2}$	RMSE	↓
	Relación señal-ruido: $10 \log_{10}(\ x_{\mathcal{F}}\ ^2 / \ x_{\mathcal{F}} - \hat{x}_{\mathcal{F}}\ ^2)$	SNR	↑
Morfológica	<i>Dynamic Time Warping</i> : $\text{DTW}(x, \hat{x})$	DTW	↓
Espectral	Distancia Espectral Logarítmica: $\sqrt{\frac{1}{B} \sum_b (\log S_x(b) - \log S_{\hat{x}}(b))^2}$	LSD	↓
	Coherencia: $ S_{x\hat{x}}(f) ^2 / (S_{xx}(f) S_{\hat{x}\hat{x}}(f))$	Coh.	↑
Temporal	Tiempo de cómputo por caso (s)	t	↓

Las métricas de **amplitud** cuantifican el error muestra a muestra sobre los canales faltantes. El **DTW** permite deformaciones no lineales del eje temporal, relevante para segmentos con transitorios. Las métricas **espectrales** (LSD, Coherencia) cuantifican la distorsión del espectro de forma independiente del error de amplitud. El **tiempo de cómputo** se reporta como dimensión complementaria porque la mejora en precisión de reconstrucción debe sopesarse contra el costo computacional adicional.

3.6. Optimización Bayesiana con Optuna

Para garantizar una comparación justa, todos los algoritmos fueron optimizados mediante Optuna [1] con muestreo TPE (*Tree-structured Parzen Estimator*). El TPE modela las distribuciones de configuraciones con buen y mal desempeño y guía la búsqueda hacia regiones prometedoras, siendo más eficiente que una búsqueda aleatoria o de grilla para espacios de alta dimensionalidad.

Los espacios de búsqueda se definieron por familia (Tabla 3.5). Se ejecutaron 30 intentos por método de grafo, 10 intentos con NSGA-II multiobjetivo para *spherical splines*, y barridos de grilla fina para TRSS. En total se exploraron más de quince mil configuraciones

paramétricas distintas.

Tabla 3.5: Espacios de búsqueda de hiperparámetros.

Familia	Parámetros	Escala	Estrategia
GSP (grafo)	$\sigma \in [0,01, 1,0]$, $k \in \{3, 5, 7, 10, 15, 20\}$	Lineal	TPE (30 intentos)
TRSS	$\alpha \in [10^{-4}, 10^2]$, $\beta \in [10^{-3}, 10^3]$	Log	Grilla fina
Splines propios	$m \in \{2, 3, 4\}$, $\lambda \in [10^{-8}, 10^{-2}]$	Mixta	NSGA-II (10 intentos)
MNE (Optuna)	$m \in \{2, 3, 4\}$, $\lambda \in [10^{-8}, 10^{-2}]$	Mixta	NSGA-II (10 intentos)

3.7. Arquitectura del Sistema Experimental

El sistema se organiza en cinco módulos con interfaces explícitas que operan en cadena (Figura 3.2). El módulo de **datos** expone una interfaz común para los tres conjuntos. El módulo de **simulación de daños** genera máscaras binarias con semilla trazable. El módulo de **métodos** combina la construcción de grafos —diez estrategias que producen **W** y **L**— con las dieciocho implementaciones de interpolación bajo una interfaz unificada. El módulo de **evaluación** calcula las métricas primarias y complementarias, y el módulo de **artefactos/optimización** orquesta Optuna en la fase exploratoria y registra resultados trazables para la fase comparativa.




Figura 3.2: Diagrama de bloques de la arquitectura del sistema experimental. Cinco módulos con interfaces explícitas operan en cadena. La figura distingue fase exploratoria y fase comparativa, indicando que los resultados comparativos no reabren la búsqueda de hiperparámetros.

3.7.1. Trazabilidad y Gestión de Artefactos

En experimentos computacionales a gran escala (18 métodos, 120 escenarios, más de 15 000 configuraciones), la gestión sistemática de artefactos resuelve tres problemas

concretos. Primero, **auditoría**: cada número reportado debe poder rastrearse hasta el archivo que lo origina; sin trazabilidad es imposible distinguir un hallazgo real de un error de transcripción. Segundo, **control de contaminación**: las fases exploratoria y comparativa deben mantenerse físicamente separadas para que resultados exploratorios no influyan inadvertidamente en decisiones posteriores. Tercero, **reproducibilidad**: un tercero con acceso al repositorio (<https://github.com/csaldivia/Tesis-GSP-EEG>) puede re-ejecutar cualquier subconjunto del experimento.

Cada ejecución recibe un identificador único (SHA-256 de la tupla completa de parámetros) y preserva: configuración inmutable (YAML), métricas agregadas (JSON), señales reconstruidas en formato NPZ (NumPy comprimido), máscara de daño, y tiempos de ejecución (Tabla 3.6). El código está versionado con Git y cada conjunto de resultados está asociado a un *commit hash* específico. La Figura 3.3 ilustra la cadena de trazabilidad desde el texto hasta el script generador.




Figura 3.3: Cadena de trazabilidad experimental. Cada afirmación cuantitativa se vincula con la tabla o figura correspondiente, el archivo de datos asociado y el script que generó el resultado.

Tabla 3.6: Artefactos generados por el sistema experimental.

Artefacto	Formato	Función
Configuración	YAML	Registro inmutable de parámetros
Métricas	JSON	Resultados de las métricas requeridas
Señal reconstruida	NPZ (NumPy)	Salida verificable bit a bit
Máscara de daño	NPZ (NumPy)	Trazabilidad de canales faltantes
Tiempos	JSON	Perfil de eficiencia computacional

3.8. Diseño Experimental

El diseño experimental se resume en la Tabla 3.7, que vincula cada pregunta de investigación con el experimento diseñado para responderla y la evidencia esperada. La lógica central es pareada: dos métodos se comparan sobre la misma señal, la misma máscara de canales ocultos y la misma semilla, evitando que diferencias del caso experimental contaminen la comparación.

Tabla 3.7: Relación entre preguntas de investigación, experimentos y evidencia esperada.

Pregunta	Experimento	Evidencia esperada
P1: ¿Cuándo mejora TRSS?	Comparación global de familias	Reducción de error y ajuste temporal en pérdida agrupada o severa
P1: ¿Aporta el término temporal?	Descomposición α/β	Diferencia observable entre TRSS completo y TRSS sin temporalidad
P1: ¿Preserva morfología temporal?	Series temporales y DTW	Menor distorsión temporal en escenarios representativos
P2: ¿Cuándo conviene MNE?	Comparación TRSS vs. MNE	MNE gana o empata en pérdida baja, señales suaves o restricciones de tiempo
P2: ¿Dónde está el punto de cruce?	Curvas por patrón y severidad	Frontera de uso dependiente de severidad, patrón y métrica

Las **variables independientes** son: método de interpolación, conjunto de datos, modo de pérdida, severidad y semilla (5 réplicas). Las **variables dependientes** son las métricas de la Sección 3.5. Las **variables controladas** incluyen: versiones exactas de todas las bibliotecas, semillas globales, preprocesamiento idéntico (filtro Butterworth 0.5–45 Hz, referencia promedio común, segmentación uniforme), y hardware de ejecución (CPU Intel Core i7-13700H, 32 GB RAM, sin aceleración GPU).

3.9. Protocolo de Validación Comparativa

La validación comparativa es una fase independiente que responde a una necesidad metodológica concreta: los resultados de la fase exploratoria (barridos de 15 000 configuraciones) no deben usarse como evidencia principal porque el riesgo de sobreajuste es alto. Un método que obtuvo buenos resultados porque sus hiperparámetros se ajustaron extensivamente sobre los datos de prueba no demuestra superioridad general; demuestra

capacidad de ajuste al protocolo exploratorio. La fase comparativa reduce este riesgo al congelar los hiperparámetros de TRSS tras la optimización exploratoria y evaluarlo sobre una partición independiente, contra MNE-Python con parámetros por defecto.

La fase se diseñó con 100 estratos definidos por régimen de señal, patrón de pérdida y severidad, con tres semillas por estrato (300 casos pareados). Los regímenes incluyen señales reales y controles sintéticos suave/rugoso. El diseño es de medidas repetidas: cada caso comparte la misma señal y máscara, por lo que las diferencias se atribuyen al método bajo las condiciones del protocolo. El análisis reporta diferencias pareadas, medianas por estrato, tasas de victoria e intervalos de incertidumbre vía bootstrap jerárquico (1000 remuestreos), sin convertir la decisión metodológica en una prueba de hipótesis nula.

3.10. Control de Calidad

Antes de cualquier análisis se ejecutaron verificaciones automáticas: todas las ejecuciones contienen las métricas requeridas, ningún identificador duplicado con resultados diferentes, las máscaras coinciden con la semilla, y se excluyen ejecuciones con valores no numéricos, tiempo excesivo (>10 min) o reconstrucción idéntica a la entrada.

3.11. Síntesis del Diseño

El diseño experimental de esta tesis se distingue de la literatura previa en cuatro aspectos: todos los métodos fueron optimizados con el mismo motor bayesiano; se incorporó una comparación independiente contra MNE-Python; la evaluación abarca métricas de amplitud, morfología y espectro; y los escenarios incluyen pérdida aleatoria y contigua en un rango de severidades clínicamente relevante. La arquitectura modular, la separación estricta de fases y la trazabilidad completa de artefactos garantizan que las conclusiones sean auditables y reproducibles.

Capítulo 4

Resultados

Este capítulo presenta la evidencia experimental que sostiene la parte práctica de la tesis. La exposición separa cuatro niveles de análisis: primero, la relación entre la fase exploratoria amplia y la fase confirmatoria; segundo, el resumen global de la evaluación contra MNE-Python; tercero, la estratificación por conjunto de datos y tipo de pérdida; cuarto, el costo computacional y el estudio de descomposición del componente temporal que permiten interpretar cuándo la regularización temporal aporta valor. Esta organización evita una lectura de superioridad universal y permite formular una decisión práctica: TRSS es útil en regímenes difíciles de reconstrucción, mientras que MNE-Python sigue siendo una referencia fuerte en escenarios favorables y en tiempo de cómputo.

4.1. Relación entre Fases Experimentales

La tesis contiene dos niveles de evidencia que conviene no mezclar. La fase exploratoria implementó el universo amplio de métodos descrito en la metodología y permitió seleccionar familias competitivas. La fase confirmatoria, en cambio, restringió la inferencia principal a una comparación pareada TRSS–MNE, porque esa es la prueba más exigente para la contribución práctica: comparar la regularización espacio–temporal contra la implementación comunitaria de referencia que un usuario real usaría en un flujo M/EEG. La Tabla 4.1 resume la relación entre fases experimentales.

Los datos sintéticos de la fase confirmatoria no reemplazan a los conjuntos reales; cumplen un rol de control. El régimen sintético suave funciona como control negativo para TRSS: si una señal satisface fuertemente la suavidad espacial, MNE debería ser difícil de superar. El régimen sintético rugoso actúa como control positivo para escenarios donde la

Tabla 4.1: Relación entre fases experimentales y evidencia usada en los capítulos prácticos.

Fase	Alcance verificable	Uso principal
Implementación y cribado	18 métodos; 14 con micro-benchmark	Cobertura metodológica y descarte inicial.
Optimización final	5 finalistas, 3 bases reales, 210 filas	Selección de familias competitivas.
Confirmatoria TRSS–MNE	100 estratos, 300 pares, 11 variantes, 3300 evaluaciones	Inferencia principal de capítulos 6–8.
Ablación temporal	3 variantes, 2 bases, 240 evaluaciones	Aporte del término temporal.

información espacial aislada es insuficiente. Esta separación permite explicar por qué el presente capítulo reporta 100 estratos confirmatorios y 300 casos pareados, mientras que los capítulos metodológicos documentan el barrido exploratorio de 120 escenarios sobre tres bases reales.

4.2. Inventario de Evidencia Experimental

La evaluación confirmatoria se realizó sobre 300 casos pareados y 3300 evaluaciones crudas. Cada par compara una variante de TRSS y MNE-Python sobre la misma señal, la misma máscara de canales ocultos y la misma semilla. Del total de evaluaciones, 2700 corresponden a variantes de TRSS usadas para sensibilidad, calibración u oráculo de grilla; las conclusiones desplegadas se basan en TRSS fijo, TRSS calibrado y MNE. Las métricas se calcularon únicamente sobre los canales artificialmente ocultos, de modo que los valores reportados miden reconstrucción de información faltante y no ajuste sobre canales observados.

La Tabla 4.2 resume el resultado global, y la Figura 4.1 muestra el compromiso entre precisión y tiempo de cómputo. El método MNE spline tiene el menor tiempo mediano por caso y el menor valor medio de LSD. TRSS fijo reduce la mediana de MAE de $1,13 \times 10^{-5}$ a $8,46 \times 10^{-6}$, mejora NRMSE medio de 0.804 a 0.604, aumenta la correlación media de 0.808 a 0.860 y eleva R^2 medio de 0.010 a 0.508. La variante calibrada mejora levemente MAE y NRMSE, pero empeora LSD respecto de TRSS fijo. El oráculo, que selecciona hiperparámetros usando la verdad de terreno, solo entrega una ganancia marginal adicional; por tanto, se utiliza como cota superior no desplegable y no como método comparable en condiciones reales.

Tabla 4.2: Resumen global del benchmark confirmatorio balanceado contra MNE-Python. Las métricas de error se calculan solo sobre canales artificialmente ocultos. El oráculo usa verdad de terreno para seleccionar hiperparámetros y se reporta únicamente como cota superior no desplegable.

Método	MAE med. ↓	NRMSE ↓	SNR ↑	LSD ↓	Corr. ↑	R^2 ↑	Tiempo med. (s) ↓
MNE spline	$1,13 \times 10^{-5}$	0.804	8.42	0.789	0.808	0.010	0.0090
TRSS fijo	$8,46 \times 10^{-6}$	0.604	9.34	0.811	0.860	0.508	0.1214
TRSS calibrado	$8,31 \times 10^{-6}$	0.589	9.00	0.863	0.860	0.531	0.0845
TRSS oráculo	$8,11 \times 10^{-6}$	0.570	9.12	0.852	0.865	0.571	0.0808




Figura 4.1: Compromiso entre precisión y tiempo de cómputo en la evaluación confirmatoria. TRSS desplaza el MAE hacia valores menores, pero se ubica a la derecha de MNE en la escala logarítmica de tiempo, lo que evidencia el costo computacional de la regularización temporal.

4.3. Comparación Pareada TRSS–MNE

La Tabla 4.3 reporta la comparación pareada con prueba de Wilcoxon, intervalos de confianza bootstrap jerárquicos y tamaño del efecto. En TRSS fijo, la mejora mediana de MAE frente a MNE es 12.4 % con intervalo al 95 % entre 7.8 % y 17.4 %, tasa de victoria de 72.0 % y $q_{BH} = 1,0 \times 10^{-22}$. NRMSE muestra un patrón similar: mejora mediana de 13.9 %, tasa de victoria de 70.3 % y efecto pareado positivo. La correlación mejora de manera más pequeña en magnitud porcentual, pero de forma consistente en los pares evaluados.

El resultado espectral es distinto. En LSD, donde menor es mejor, TRSS fijo presenta una mejora mediana negativa de -2.3 % y una tasa de victoria de 40.7 %. La variante calibrada acentúa este deterioro, con -9.6 % de mejora mediana y 26.0 % de tasa de victoria. Este hallazgo es central para la interpretación de la tesis: TRSS no domina todas las métricas. Su ventaja se concentra en error de amplitud, NRMSE, correlación y ajuste temporal, mientras que MNE conserva fortaleza en una métrica espectral global.

Tabla 4.3: Comparación robusta de TRSS frente a MNE-Python. La mejora mediana positiva favorece a TRSS; en tiempo, valores negativos indican mayor costo computacional de TRSS. Los intervalos son bootstrap jerárquicos al 95 %.

Método	Métrica	Mej. (%)	IC95 (%)	Victoria (%)	q_{BH}	Efecto
TRSS fijo	MAE	+12.4	[+7.8, +17.4]	72.0	$1,0 \times 10^{-22}$	0.66
TRSS fijo	NRMSE	+13.9	[+6.4, +19.3]	70.3	$2,5 \times 10^{-22}$	0.65
TRSS fijo	LSD	-2.3	[-4.0, -0.2]	40.7	0.003	-0.20
TRSS fijo	Correlación	+0.8	[+0.3, +2.0]	68.7	$5,8 \times 10^{-21}$	0.63
TRSS fijo	Tiempo	-1004.1	[-1072.8, -934.0]	0.3	$9,0 \times 10^{-49}$	-0.99
TRSS calibrado	MAE	+12.0	[+6.9, +18.7]	70.0	$1,8 \times 10^{-20}$	0.62
TRSS calibrado	NRMSE	+13.4	[+6.6, +20.5]	69.3	$3,4 \times 10^{-21}$	0.63
TRSS calibrado	LSD	-9.6	[-13.4, -6.5]	26.0	$5,8 \times 10^{-17}$	-0.56
TRSS calibrado	Correlación	+0.6	[+0.2, +1.6]	63.7	$5,2 \times 10^{-15}$	0.52
TRSS calibrado	Tiempo	-825.9	[-876.1, -731.3]	1.3	$9,0 \times 10^{-49}$	-0.99

La Tabla 4.4 amplía la lectura a todas las métricas confirmatorias disponibles para TRSS fijo, y la Figura 4.2 presenta el portafolio visual correspondiente. La Figura 4.3 complementa con la distribución de NRMSE, y la Figura 4.4 muestra las mejoras medianas con intervalos bootstrap. El patrón es coherente: TRSS mejora MAE, RMSE, NRMSE, DTW, SNR, coherencia, correlación y R^2 después de ajustar la dirección de cada métrica. La excepción relevante es LSD, que favorece a MNE, y el tiempo de cómputo, donde MNE domina claramente. Esta tabla evita seleccionar solo métricas favorables y muestra de forma transparente el perfil completo de ventajas y pérdidas.

Tabla 4.4: Portafolio completo de métricas confirmatorias para TRSS fijo frente a MNE. La mejora mediana positiva favorece a TRSS después de ajustar la dirección de cada métrica; valores negativos favorecen a MNE.

Métrica	Mej. (%)	IC95 (%)	Victoria (%)	q_{BH}	Efecto
MAE	+12.4	[+7.8, +17.4]	72.0	$1,0 \times 10^{-22}$	0.66
RMSE	+13.9	[+6.4, +19.3]	70.3	$4,1 \times 10^{-22}$	0.65
NRMSE	+13.9	[+6.4, +19.3]	70.3	$2,5 \times 10^{-22}$	0.65
DTW	+9.8	[+5.5, +12.7]	71.0	$9,6 \times 10^{-21}$	0.63
SNR	+3.7	[+0.9, +9.6]	61.0	$3,6 \times 10^{-9}$	0.40
LSD	-2.3	[-4.0, -0.2]	40.7	0.003	-0.20
Coherencia	+0.2	[0.0, +0.5]	58.3	$7,6 \times 10^{-7}$	0.33
Correlación	+0.8	[+0.3, +2.0]	68.7	$5,8 \times 10^{-21}$	0.63
R^2	+16.9	[+3.4, +52.8]	70.3	$5,1 \times 10^{-23}$	0.67
Tiempo	-1004.1	[-1072.8, -934.0]	0.3	$9,0 \times 10^{-49}$	-0.99




Figura 4.2: Portafolio visual de métricas para TRSS fijo frente a MNE. El panel izquierdo muestra métricas de calidad con valores positivos favorables a TRSS y negativos favorables a MNE; el panel derecho separa el costo temporal para que la diferencia de escala no comprima las métricas de precisión.




Figura 4.3: Distribución de NRMSE en la evaluación confirmatoria balanceada. La figura complementa la comparación mediana de la Tabla 4.4: TRSS desplaza la distribución hacia menor error relativo, pero la superposición entre cajas muestra que la mejora no es uniforme en todos los estratos.




Figura 4.4: Mejoras medianas de TRSS frente a MNE con intervalos bootstrap al 95 %. Las barras positivas favorecen a TRSS; las barras negativas favorecen a MNE o indican mayor tiempo de ejecución de TRSS. El gráfico muestra simultáneamente la ganancia en MAE/NRMSE y las dos advertencias principales: LSD y costo temporal.

La comparación de tiempo confirma que la mejora de reconstrucción no es gratuita. TRSS fijo presenta una mejora mediana de tiempo de -1004.1 %, con tasa de victoria de solo 0.3 %. Interpretado operacionalmente, MNE es la opción rápida y determinística para preprocesamiento rutinario, mientras que TRSS debe reservarse para escenarios donde la fidelidad de reconstrucción compensa el costo adicional.

4.4. Estratificación por Conjunto de Datos

El promedio global oculta una heterogeneidad importante. La Tabla 4.5 muestra que TRSS fijo mejora MAE en MNE Sample, PhysioNet S1, PhysioNet S2 y el régimen sintético rugoso, como se visualiza en la Figura 4.5. La mejora mediana alcanza 22.6 % en MNE Sample, 21.5 % en el régimen sintético rugoso y 9.5–12.2 % en PhysioNet. En contraste, el régimen sintético suave favorece a MNE: TRSS gana solo en 20.0 % de los casos y la mejora mediana es -12.7 %.

Tabla 4.5: Estratificación por conjunto de datos para TRSS fijo frente a MNE en MAE. La ventaja no es homogénea: TRSS mejora en datos reales y en el régimen sintético rugoso, pero pierde cuando la señal sintética satisface fuertemente el supuesto de suavidad espacial.

Conjunto de datos	n	Tasa victoria	Mejora mediana	MAE MNE / TRSS
MNE Sample	60	81.7 %	+22.6 %	$2,34 \times 10^{-5}$ / $1,82 \times 10^{-5}$
Sintético rugoso	60	100.0 %	+21.5 %	$7,47 \times 10^{-6}$ / $5,82 \times 10^{-6}$
PhysioNet S2	60	73.3 %	+12.2 %	$1,18 \times 10^{-5}$ / $1,02 \times 10^{-5}$
PhysioNet S1	60	85.0 %	+9.5 %	$1,73 \times 10^{-5}$ / $1,67 \times 10^{-5}$
Sintético suave	60	20.0 %	-12.7 %	$1,81 \times 10^{-6}$ / $2,06 \times 10^{-6}$

Este control negativo es útil. Si TRSS hubiera superado también al caso sintético suave, el resultado podría interpretarse como una ventaja numérica artificial del protocolo. La pérdida frente a MNE en ese régimen muestra que el diseño experimental conserva sensibilidad para detectar escenarios donde el modelo espacial clásico es suficiente o preferible.




Figura 4.5: Mejora mediana de MAE de TRSS fijo frente a MNE por conjunto de datos. La señal sintética suave actúa como control negativo: cuando se cumple fuertemente el supuesto de suavidad espacial, MNE puede ser superior.


4.5. Efecto del Patrón y Severidad de Pérdida

La estratificación por patrón de canales ocultos confirma la interpretación condicional. La Tabla 4.6 y la Figura 4.6 muestran que la mayor ventaja de TRSS aparece en pérdidas cercanas o agrupadas de alta severidad. En pérdida cercana al 30 %, la mejora mediana de MAE es 41.2 %; al 40 %, la mejora es 40.8 % y la tasa de victoria alcanza 86.7 %. En pérdida periférica al 40 %, la mejora mediana es 31.6 %. En cambio, con solo dos canales cercanos ocultos, el resultado se aproxima a empate práctico.

Tabla 4.6: Escenarios representativos para TRSS fijo frente a MNE en MAE. La mejora aumenta en pérdidas agrupadas o periféricas de alta severidad, mientras que escenarios de pocos canales cercanos pueden producir empate práctico.

Patrón	Severidad	n	Victoria	Mejora	MAE MNE/TRSS (10^{-5})
Cercano/agrupado	40 %	15	86.7 %	+40.8 %	1.83 / 1.16
Cercano/agrupado	30 %	15	80.0 %	+41.2 %	1.67 / 1.04
Borde/periférico	40 %	15	80.0 %	+31.6 %	2.11 / 1.32
Borde/periférico	10 %	15	73.3 %	+23.2 %	1.73 / 1.19
Alta varianza	40 %	15	80.0 %	+10.1 %	1.12 / 1.05
Alta varianza	10 %	15	80.0 %	+16.1 %	1.20 / 1.03
Aleatorio	40 %	15	80.0 %	+13.0 %	1.12 / 0.96
Cercano/agrupado	2 canales	15	46.7 %	0.0 %	0.76 / 0.70

El patrón observado coincide con la intuición del modelo. MNE usa una información previa espacial global; cuando los canales buenos circundantes son abundantes, esa información previa es suficiente. TRSS agrega una restricción temporal que se vuelve



Cada celda: primera línea = mejora mediana; segunda línea = tasa de victoria

Figura 4.6: Mapa de calor de mejora mediana de MAE para TRSS fijo frente a MNE. Cada celda muestra la mejora mediana y, debajo, la tasa de victoria. La ventaja crece cuando la pérdida elimina información espacial local, especialmente en patrones cercanos o periféricos de alta severidad.

más valiosa cuando el vecindario espacial del canal faltante deja de contener información suficiente.

4.6. Componente Temporal de TRSS

La descomposición del componente temporal compara TRSS completo contra una variante sin término temporal. La Figura 4.7 muestra que el término temporal produce mejoras modestas pero consistentes: aproximadamente 0.7 % en MAE/RMSE, 1.5 % en DTW y 6.4 % en LSD frente a TRSS sin temporalidad, con tasa de victoria de 100 % en las métricas de error incluidas en el análisis. La interpretación correcta no es que el término temporal convierta por sí solo a TRSS en dominante frente a cualquier método espacial, sino que estabiliza la solución espacio-temporal y reduce degradaciones específicas dentro de la propia familia TRSS.

Este resultado matiza la hipótesis principal. La ventaja práctica de TRSS no proviene de un único componente que domine todas las métricas, sino de la combinación entre una representación espacial suficientemente informativa, una restricción temporal que estabiliza la trayectoria y una selección de hiperparámetros que evita sobre-suavizar la señal. Por esa razón, la comparación contra MNE debe leerse junto con el estudio de descomposición: TRSS es más fuerte en reconstrucción de amplitud y correlación, pero




Figura 4.7: Ablación del componente temporal: mejora mediana de TRSS completo frente a TRSS sin término temporal. La contribución temporal es consistente dentro de la familia TRSS, aunque su magnitud es menor que las diferencias entre familias de métodos.

MNE conserva ventajas espectrales y computacionales.

4.7. Preservación Morfológica y Espectral

Además de las métricas agregadas, las visualizaciones de series temporales y espectros permiten revisar si la reconstrucción conserva estructuras fisiológicas interpretables. La Figura 4.8 muestra un caso representativo de pérdida cercana severa en MNE Sample. En este régimen, la reconstrucción puramente espacial tiende a suavizar o desplazar transitorios, mientras que TRSS conserva mejor la morfología temporal de los segmentos evaluados. Esta observación no reemplaza las pruebas estadísticas, pero ayuda a interpretar por qué MAE, NRMSE y correlación mejoran en escenarios difíciles.




Figura 4.8: Ejemplo cualitativo de reconstrucción temporal bajo pérdida cercana severa. La figura ilustra la diferencia morfológica que las métricas agregadas capturan de forma resumida.

La Figura 4.9 resume el comportamiento espectral en una comparación multi-método. La lectura conjunta con la Tabla 4.3 es importante: TRSS puede preservar mejor la forma temporal local y, simultáneamente, no dominar LSD global frente a MNE. Esta aparente tensión refleja que las métricas responden a propiedades distintas de la señal reconstruida.




Figura 4.9: Comparación espectral multi-método. La preservación de potencia por banda no siempre coincide con la mejora de MAE, por lo que LSD se reporta como dimensión independiente y no como consecuencia automática del error de amplitud.

4.8. Tiempo de Cómputo y Complejidad

La Tabla 4.7 resume la diferencia de implementación, y la Figura 4.10 muestra la distribución de tiempos por caso. MNE resuelve un sistema espacial regularizado y lo aplica a las muestras temporales; su costo de preparación depende cúbicamente del número de canales, pero el número de canales en EEG es moderado y la operación resultante es muy eficiente. TRSS opera sobre un grafo espacio-temporal y requiere iteraciones del resolutor, de modo que el costo escala con el número de aristas, muestras temporales e iteraciones.

Tabla 4.7: Complejidad computacional e implementación observada. N es el número de canales, T el número de muestras temporales, E el número de aristas del grafo y K el número de iteraciones del resolutor.

Método	Operación dominante	Complejidad asintótica orientativa	Mediana (s/caso)
MNE spline	Sistema global regularizado y aplicación a muestras	$O(N^3) + O(NT)$	0.0090
TRSS fijo	Iteraciones sobre grafo espacio-temporal disperso	$O(K(ET + NT))$	0.1214
TRSS calibrado	Igual a TRSS fijo más selección de hiperparámetros	$O(HK(ET + NT))$	0.0845




Figura 4.10: Distribución de tiempos por caso en la evaluación confirmatoria. La diferencia de costo es consistente: TRSS mejora varias métricas de reconstrucción, pero MNE conserva una ventaja clara en velocidad.

La implicancia práctica es directa. Si el flujo de procesamiento exige latencia mínima, repetición masiva o uso interactivo, MNE es la opción de referencia. Si el análisis se realiza fuera de línea y la pérdida de canales amenaza la validez de las métricas fisiológicas posteriores, TRSS puede justificarse por su ganancia en reconstrucción.

4.9. Síntesis de Resultados

Los resultados sostienen una conclusión condicional. TRSS fijo mejora de manera estadísticamente robusta MAE, NRMSE y correlación frente a MNE-Python en el benchmark confirmatorio balanceado, con tasas de victoria cercanas al 70–72 %. La ventaja es mayor cuando la pérdida es agrupada, periférica o severa, y desaparece o se invierte cuando la señal cumple fuertemente el supuesto de suavidad espacial. MNE conserva dos ventajas decisivas: menor LSD en el promedio global y menor tiempo de cómputo.

Por tanto, las hipótesis se respaldan con matices. H1 queda respaldada para las métricas primarias de reconstrucción de canales ocultos y para los regímenes difíciles de pérdida, pero no autoriza afirmar dominancia universal de TRSS. H2 queda respaldada como ventaja práctica o empate operativo de MNE, especialmente en señales suaves, baja pérdida espacial y restricciones de tiempo. La contribución práctica de la tesis es precisamente identificar esta frontera de decisión con evidencia pareada, no reemplazar una regla de uso por otra igual de rígida.

Capítulo 5

Discusión

Este capítulo interpreta los resultados del Capítulo 4 y los conecta con las hipótesis, el diseño experimental y las decisiones de implementación. La discusión se organiza alrededor de una idea central: la regularización temporal aporta valor real, pero su utilidad depende del régimen de pérdida, de la métrica de interés y del presupuesto computacional disponible.

5.1. Validación Matizada de las Hipótesis

La hipótesis H1 planteaba que la regularización espacio-temporal debía mejorar la reconstrucción de canales EEG faltantes en regímenes difíciles. La evidencia respalda esta hipótesis para las métricas primarias de reconstrucción. TRSS fijo mejora la mediana de MAE en 12.4 % frente a MNE, con intervalo bootstrap al 95 % entre 7.8 % y 17.4 %, y alcanza una tasa de victoria de 72.0 %. NRMSE muestra una mejora mediana de 13.9 % y tasa de victoria de 70.3 %. Estos resultados son estadísticamente robustos y no dependen de comparar contra una implementación débil, sino contra la interpolación estándar de MNE-Python.

Sin embargo, H1 no debe leerse como dominancia universal. La métrica LSD favorece a MNE en la comparación global: TRSS fijo obtiene una mejora mediana negativa de -2.3 % y gana solo en 40.7 % de los pares. La variante calibrada empeora aún más LSD. Esto indica que mejorar error de amplitud y correlación no garantiza preservar mejor la estructura espectral global. Por tanto, H1 queda validada para reconstrucción de canales ocultos en términos de amplitud y ajuste temporal, pero no para toda métrica ni para todo escenario.

La hipótesis H2 proponía ventaja práctica o empate operativo de MNE en regímenes favorables. Los resultados la respaldan con claridad. En el caso sintético suave, TRSS gana solo en 20.0% de los casos y presenta una mejora mediana de MAE de -12.7%. En escenarios de pocos canales ocultos, el resultado se aproxima a empate práctico. Además, MNE mantiene una ventaja computacional sustancial. H2 no es una excepción marginal: define el límite práctico de uso de TRSS.

5.2. Por Qué MNE-Python Sigue Siendo una Referencia Fuerte

Una lectura superficial podría interpretar que un método basado en GSP y regularización temporal debería superar sin dificultad a una spline esférica. Los resultados muestran lo contrario: MNE-Python es una referencia difícil porque combina un modelo físico razonable con ingeniería numérica robusta. La spline esférica explota la suavidad espacial inducida por la conducción volumétrica, utiliza información global de todos los canales buenos y resuelve un problema determinístico bien condicionado para los tamaños típicos de montajes EEG.

Esta fortaleza explica el resultado del régimen sintético suave. Cuando la señal satisface fuertemente el supuesto de suavidad espacial, agregar temporalidad puede introducir un sesgo innecesario o una regularización excesiva. En ese caso, la simplicidad del modelo espacial no es una debilidad sino una ventaja. La comparación confirma que el método propuesto no debe evaluarse solo contra implementaciones internas simplificadas; debe contrastarse contra herramientas maduras de la comunidad.

5.3. Mecanismo de la Regularización Temporal

El término temporal de TRSS no debe interpretarse como una fuente adicional independiente de información, sino como una restricción sobre el espacio de soluciones admisibles cuando la información espacial observada resulta insuficiente. En pérdida agrupada o periférica severa, la interpolación espacial enfrenta una ambigüedad: varias superficies suaves pueden ser compatibles con los canales observados. La continuidad temporal reduce esa ambigüedad al exigir trayectorias compatibles con la evolución de la señal.

La descomposición del componente temporal muestra que TRSS completo mejora a TRSS sin temporalidad de forma consistente, pero con magnitudes moderadas en MAE y

RMSE. El efecto es más visible en DTW y LSD dentro de la familia TRSS, lo que sugiere que la penalización temporal actúa principalmente estabilizando la forma de la trayectoria, no reduciendo de manera masiva el error puntual. Esta interpretación es compatible con los resultados globales: TRSS mejora reconstrucción de canales ocultos, pero MNE puede conservar ventaja en LSD porque su prior espacial global es muy eficiente para señales suavemente distribuidas.

5.4. Heterogeneidad de Escenarios y Frontera de Decisión

La estratificación por dataset y patrón de pérdida es más informativa que el promedio global. En pérdidas cercanas del 30–40 %, TRSS alcanza mejoras medianas cercanas al 41 % en MAE. En pérdidas periféricas al 40 %, la mejora mediana es 31.6 %. Estos son los escenarios donde la información espacial local se degrada y la regularización temporal compensa la ausencia de electrodos vecinos confiables.

En contraste, cuando se ocultan pocos canales o la señal es sintéticamente suave, MNE puede empatar o ganar. Esta frontera de decisión tiene valor práctico: evita recomendar un método más costoso cuando el método estándar es suficiente. La contribución de la tesis no es reemplazar MNE por TRSS en todo flujo de preprocesamiento, sino identificar cuándo la estructura espacio-temporal justifica el costo adicional. La Tabla 5.1 resume la guía práctica de selección y la Figura 5.1 presenta el mapa de decisión conceptual.

5.5. Costo Computacional e Implementación

La diferencia de tiempo es una limitación práctica y no solo una nota secundaria. MNE alcanza una mediana de 0.0090 segundos por caso en la evaluación confirmatoria, mientras que TRSS fijo alcanza 0.1214 segundos y TRSS calibrado 0.0845 segundos. La comparación pareada de tiempo favorece a MNE casi siempre. Aunque las latencias absolutas de TRSS siguen siendo sub-segundo por ventana en este protocolo, la diferencia se amplifica cuando se procesan estudios completos, validaciones cruzadas o búsquedas de hiperparámetros.

Desde el punto de vista algorítmico, esta diferencia es esperable. MNE explota un problema espacial de tamaño moderado. TRSS incorpora estructura temporal y requiere iteraciones sobre un operador espacio-temporal. La regularización temporal aumenta la expresividad del modelo, pero también eleva el costo. Por ello, una implementación práctica

de TRSS debería priorizar matrices dispersas, factorizaciones reutilizables, criterios de convergencia temprana y paralelización por ventanas o por sujetos.

5.6. Implicaciones para la Práctica EEG

Los resultados permiten proponer una guía de uso. MNE-Python debe mantenerse como opción por defecto cuando la pérdida de canales es baja, el montaje es denso, se requiere procesamiento rápido, el análisis posterior es principalmente espectral o se necesita un flujo estandarizado y reproducible con mínima calibración. Esta recomendación no es conservadora por costumbre; está respaldada por el rendimiento de MNE en LSD, tiempo y señales suavemente distribuidas.

TRSS se justifica cuando la pérdida es severa, agrupada o periférica; cuando el objetivo es reconstruir canales ocultos con bajo error de amplitud; cuando la morfología temporal de los segmentos reconstruidos afecta métricas posteriores; o cuando el procesamiento se realiza fuera de línea y el costo computacional adicional es aceptable. En estos casos, la regularización temporal aporta una fuente de información que MNE no modela explícitamente.

Tabla 5.1: Guía práctica de selección entre MNE y TRSS a partir de los resultados experimentales.

Condición de uso	Método preferible	Justificación
Pocos canales malos en montaje denso	MNE	Rapidez, robustez y prior espacial suficiente
Pérdida agrupada o periférica severa	TRSS	La continuidad temporal compensa pérdida de información espacial local
Análisis espectral sensible a LSD	MNE o validación caso a caso	MNE conserva ventaja global en LSD
Reconstrucción fuera de línea con prioridad en MAE/NRMSE	TRSS	Mejora pareada robusta en métricas de reconstrucción
Flujo clínico con restricción de latencia	MNE	Menor costo y comportamiento determinístico




Figura 5.1: Mapa de decisión práctica entre MNE y TRSS. El eje horizontal representa la severidad y agrupamiento de la pérdida; el eje vertical representa la prioridad de precisión temporal-amplitud frente a latencia y preservación espectral global. La frontera es conceptual y resume la evidencia del Capítulo 4: no existe dominancia universal, sino un régimen de uso preferente.

5.7. Limitaciones del Estudio

El estudio utiliza ocultamiento artificial de canales completos a partir de registros considerados válidos. Esta estrategia permite calcular error de reconstrucción contra una verdad de terreno, pero no cubre todos los casos clínicos: en la práctica, un canal malo puede contener saturación, ruido muscular, deriva lenta o artefactos intermitentes, no solo ausencia de señal. La respuesta de cada método frente a canales contaminados podría diferir de la respuesta frente a canales eliminados.

La fase confirmatoria incluye escenarios balanceados y repetibles, pero no agota la diversidad de montajes, referencias, filtros y poblaciones clínicas. La elección de referencia común, el filtrado previo y la duración de las ventanas pueden cambiar la estructura espacial y temporal que los métodos explotan. Además, las métricas evaluadas miden calidad de señal reconstruida, no impacto directo en tareas posteriores como clasificación BCI, detección de eventos, estimación de conectividad o localización de fuentes.

La optimización de hiperparámetros se trató con cuidado, pero sigue siendo una fuente de riesgo metodológico. El oráculo demuestra que existe un techo de rendimiento, pero no es desplegable. La variante calibrada reduce parte de esta preocupación, aunque no elimina la necesidad de reglas de selección robustas para datos nuevos. Finalmente, el

costo de TRSS puede ser aceptable en análisis fuera de línea, pero requiere optimización adicional antes de recomendarlo para procesamiento en tiempo real.

5.7.1. Amenazas a la Validez

Desde la validez interna, la amenaza principal es la dependencia entre observaciones: los 300 casos confirmatorios no son 300 sujetos independientes, sino combinaciones de regímenes, máscaras y semillas. Por esta razón se usaron comparaciones pareadas y bootstrap estratificado, y las conclusiones se formulan como evidencia experimental dentro del protocolo, no como una estimación poblacional clínica definitiva. Desde la validez externa, el estudio cubre bases y controles relevantes, pero no representa todos los montajes, equipos, referencias, poblaciones ni patologías. Desde la validez de constructo, MAE, NRMSE, DTW y LSD miden propiedades de reconstrucción de señal; no prueban por sí solas mejora en diagnóstico, clasificación BCI o localización de fuentes. Desde la validez estadística, la corrección BH y los tamaños de efecto reducen el riesgo de falsos descubrimientos, pero no sustituyen una validación independiente con nuevos registros y canales realmente dañados.

5.8. Lecciones Metodológicas

La primera lección es que las referencias deben optimizarse y documentarse con el mismo rigor que el método propuesto. Comparar TRSS solo contra una spline propia simplificada habría producido una conclusión demasiado optimista. La inclusión de MNE-Python obliga a reconocer un régimen donde la referencia clásica es difícil de superar.

La segunda lección es que una evaluación multi-métrica cambia la conclusión. MAE, NRMSE, correlación, LSD y tiempo no son intercambiables. Un método puede mejorar reconstrucción puntual y empeorar fidelidad espectral; otro puede ser menos preciso en promedio y más útil por su costo y estabilidad. La tesis gana solidez porque reporta estas tensiones en lugar de ocultarlas.

La tercera lección es que la contribución práctica se expresa mejor como una frontera de uso. La pregunta no es si TRSS es siempre mejor que MNE, sino bajo qué condiciones la información temporal adicional justifica el costo computacional y el riesgo de calibración. Esa pregunta es más útil para usuarios reales de EEG que una afirmación absoluta de dominancia.

Bibliografía

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019.
- [2] Clemens Brunner, Robert Leeb, Gernot R. Müller-Putz, Alois Schlögl, and Gert Pfurtscheller. BCI Competition IV – Dataset 2a. Graz University of Technology, 2008. URL <https://www.bbc.de/competition/iv/>.
- [3] György Buzsáki. Rhythms of the brain. 2006. doi: 10.1093/acprof:oso/9780195301069.001.0001.
- [4] Arnaud Delorme and Scott Makeig. Eeglab: An open source toolbox for analysis of single-trial eeg dynamics including independent component analysis. *Journal of Neuroscience Methods*, 134(1):9–21, 2004. doi: 10.1016/j.jneumeth.2003.10.009.
- [5] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans. Reconstruction of time-varying graph signals via sobolev smoothness. *IEEE Transactions on Signal and Information Processing over Networks*, 8:201–214, 2022. doi: 10.1109/TSIPN.2022.3156886.
- [6] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215.
- [7] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Roman Goj, Mainak Jas, Teon Brooks, Lauri Parkkonen, and Matti Hämäläinen. MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, 7:267, 2013. doi: 10.3389/fnins.2013.00267.

- [8] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Lauri Parkkonen, and Matti S. Hämäläinen. MNE software for processing MEG and EEG data. *NeuroImage*, 86:446–460, 2014. doi: 10.1016/j.neuroimage.2013.10.027.
- [9] Janin Jäger, Alexander Klein, Martin Buhmann, and Wolfgang Skrandies. Reconstruction of electroencephalographic data using radial basis functions. *Clinical Neurophysiology*, 127(4):1978–1983, 2016. doi: 10.1016/j.clinph.2016.01.003.
- [10] Tzyy-Ping Jung, Scott Makeig, Martin J. McKeown, Anthony J. Bell, Te-Won Lee, and Terrence J. Sejnowski. Imaging brain dynamics using independent component analysis. *Proceedings of the IEEE*, 89(7):1107–1122, 2001. doi: 10.1109/5.939827.
- [11] Vassilis Kalofolias. How to learn a graph from smooth signals, 2016. URL <http://arxiv.org/abs/1601.02513>.
- [12] Chun-Hung Lai, Yi-Ming Chen, and Wen-Chieh Liao. A controlled study of the eeg during the performance of neurofeedback. *Clinical EEG and Neuroscience*, 36(4): 219–225, 2005.
- [13] Fabien Lotte, Laurent Bougrain, Andrzej Cichocki, Maureen Clerc, Marco Congedo, Alain Rakotomamonjy, and Florian Yger. A review of classification algorithms for eeg-based brain–computer interfaces: A 10 year update. *Journal of Neural Engineering*, 15(3):031005, 2018. doi: 10.1088/1741-2552/aab2f2.
- [14] Steven J. Luck. *An Introduction to the Event-Related Potential Technique*. MIT Press, 2nd edition, 2014.
- [15] S. K. Narang and A. Ortega. Signal processing techniques for interpolation in graph structured data. In *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5445–5449, 2013. doi: 10.1109/ICASSP.2013.6638704.
- [16] Paul L. Nunez and Ramesh Srinivasan. *Electric Fields of the Brain: The Neurophysics of EEG*. Oxford University Press, 2nd edition, 2006. doi: 10.1093/acprof:oso/9780195050387.001.0001.
- [17] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst. Graph signal processing: Overview, challenges, and applications. *Proceedings of the IEEE*, 106(5):808–828, 2018. doi: 10.1109/JPROC.2018.2820126.

-
- [18] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier. Spherical splines for scalp potential and current density mapping. *Electroencephalography and Clinical Neurophysiology*, 72(2):184–187, 1989. doi: 10.1016/0013-4694(89)90180-6.
 - [19] Carlos Saldivia, Alejandro Weinstein, and Matías Zañartu. Trss vs. Spherical Splines: A reproducible benchmark for EEG channel interpolation under missing-data scenarios. *In Preparation*, 2026. Manuscript in preparation. Results derived from this thesis.
 - [20] Gerwin Schalk, Dennis J. McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R. Wolpaw. BCI2000: A general-purpose brain-computer interface (BCI) system. *IEEE Transactions on Biomedical Engineering*, 51(6):1034–1043, 2004. doi: 10.1109/TBME.2004.827072.
 - [21] S. Shekkizhar and A. Ortega. Graph construction from data by non-negative kernel regression. In *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 3892–3896, 2020. doi: 10.1109/ICASSP40776.2020.9054425.
 - [22] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst. The emerging field of signal processing on graphs. *IEEE Signal Processing Magazine*, 30(3):83–98, 2013. doi: 10.1109/MSP.2012.2235192.