

**Reconstrucción de Canales EEG Faltantes mediante
Procesamiento de Señales en Grafos con
Regularización Temporal** Evaluación comparativa reproducible,

optimización bayesiana de hiperparámetros y validación fisiológica
multi-métrica Tesis presentada para optar al grado de

Magíster en Ciencias de la Ingeniería por

Carlos Saldivia Universidad Técnica Federico Santa María

Departamento de Ingeniería Electrónica Valparaíso, Chile, Mayo de 2026

Resumen

La electroencefalografía (EEG) constituye una herramienta fundamental en neurociencia clínica y experimental, pero sufre de la pérdida frecuente de canales debido a fallas de contacto, artefactos de movimiento o saturación de amplificadores. La interpolación de estos canales faltantes es un paso crítico del preprocesamiento, y tradicionalmente se ha abordado mediante métodos geométricos como los *spherical splines*, implementados en bibliotecas de referencia como MNE-Python. Sin embargo, estos métodos operan exclusivamente en el dominio espacial, ignorando la conectividad funcional real del cerebro y la dinámica temporal de las señales.

Esta tesis presenta una evaluación comparativa reproducible y exhaustiva de dieciocho métodos de interpolación de canales EEG —geométricos, estadísticos y basados en Procesamiento de Señales en Grafos (GSP)— bajo un protocolo experimental riguroso. El diseño incluye tres bases de datos heterogéneas (PhysioNet de 64 canales, BCI Competition IV 2a de 22 canales y MNE Sample de 60 canales), ciento veinte escenarios de pérdida que combinan modos aleatorio y contiguo con severidades del 10 % al 40 %, y una batería de seis métricas que cubren error de amplitud (MAE, RMSE, SNR), fidelidad morfológica (DTW) y preservación espectral (LSD, Coherencia). Para garantizar una comparación justa, todos los métodos —incluyendo las referencias clásicas— fueron optimizados mediante Optuna con más de quince mil configuraciones paramétricas exploradas, y se incorporó una validación confirmatoria contra la implementación industrial de MNE-Python.

Los resultados revelan que la regularización temporal marca un punto de inflexión decisivo: los métodos de la familia TRSS (*Temporal Regularized Sobolev Smoothness*) superan consistentemente a las referencias geométricas y a los métodos GSP puramente espaciales, con ganancias de 5 a 10 dB en SNR bajo pérdida severa contigua del 40 %. El análisis del mecanismo subyacente muestra que esta ventaja no proviene de una mejor representación espacial, sino de la restricción de continuidad temporal que actúa como información previa de naturaleza fisiológica. No obstante, en regímenes favorables —montajes densos, pérdida aleatoria igual o inferior al 20 %—, MNE-Python iguala o

supera a TRSS en preservación espectral, siendo además entre 50 y 100 veces más rápido. Se concluye que TRSS es el método preferido cuando la preservación morfológica bajo pérdida severa es prioritaria, mientras que MNE sigue siendo la opción óptima para entornos con pérdida moderada y restricciones de tiempo real.

La totalidad del código, las configuraciones experimentales, los registros de optimización y los artefactos de resultados están disponibles en un repositorio abierto que garantiza la reproducibilidad completa de los hallazgos.

Palabras clave: EEG, canales faltantes, interpolación, Procesamiento de Señales en Grafos (GSP), regularización temporal, TRSS, spherical splines, MNE-Python, optimización bayesiana, Optuna, evaluación comparativa reproducible.

Abstract

Electroencephalography (EEG) is a cornerstone tool in clinical and experimental neuroscience, yet it frequently suffers from channel loss due to contact failures, motion artifacts, or amplifier saturation. Interpolating these missing channels is a critical preprocessing step, traditionally addressed through geometric methods such as spherical splines, implemented in reference libraries like MNE-Python. However, these methods operate exclusively in the spatial domain, ignoring the brain’s true functional connectivity and the temporal dynamics of the signals.

This thesis presents a reproducible and exhaustive benchmark comparing eighteen EEG channel interpolation methods —geometric, statistical, and Graph Signal Processing (GSP)-based— under a rigorous experimental protocol. The design encompasses three heterogeneous databases (64-channel PhysioNet, 22-channel BCI Competition IV 2a, and 60-channel MNE Sample), 120 loss scenarios combining random and contiguous modes at severities from 10 % to 40 %, and a battery of six metrics covering amplitude error (MAE, RMSE, SNR), morphological fidelity (DTW), and spectral preservation (LSD, Coherence). To ensure a fair comparison, all methods —including classical baselines— were optimized via Optuna with over 15,000 parametric configurations explored, and a confirmatory validation against MNE-Python’s industrial implementation was incorporated.

Results reveal that temporal regularization is a decisive turning point: TRSS-family methods (*Temporal Regularized Sobolev Smoothness*) consistently outperform geometric baselines and purely spatial GSP methods, with gains of 5 to 10 dB in SNR under severe contiguous loss (40 %). Analysis of the underlying mechanism shows this advantage stems not from better spatial representation, but from the temporal continuity constraint acting as a complementary physiological prior. Nevertheless, under favorable regimes (dense montages, random loss at or below 20 %), MNE-Python matches or surpasses TRSS in spectral preservation while being 50 to 100 times faster. We conclude that TRSS is the preferred method when morphological preservation under severe loss is paramount, whereas MNE remains the optimal choice for settings with moderate loss and real-time

constraints.

All code, experimental configurations, optimization logs, and result artifacts are available in an open repository ensuring full reproducibility of the findings.

Keywords: EEG, missing channels, interpolation, Graph Signal Processing (GSP), temporal regularization, TRSS, spherical splines, MNE-Python, Bayesian optimization, Optuna, reproducible benchmark.

Índice general

1. Introducción	1
1.1. Contexto General y Planteamiento del Problema	1
1.2. Limitaciones de los Enfoques Tradicionales	2
1.3. El Advenimiento del Procesamiento de Señales en Grafos	3
1.3.1. Mención del Paradigma de Aprendizaje Profundo	3
1.4. La Brecha en la Literatura y la Motivación del Trabajo	4
1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?	5
1.5. Cronología del Proyecto	6
1.5.1. Fase 1 — Selección de Métodos y Revisión del Estado del Arte . .	6
1.5.2. Fase 2 — Implementación del Sistema de Experimentación	6
1.5.3. Fase 3 — Barrido Exploratorio Inicial	7
1.5.4. Fase 4 — Selección Fina y Diseño del Espacio de Búsqueda	7
1.5.5. Fase 5 — Optimización Bayesiana con Optuna	7
1.5.6. Fase 6 — Validación Confirmatoria contra MNE-Python	8
1.5.7. Fase 7 — Ablación y Documentación	8
1.6. Objetivos	8
1.6.1. Objetivo General	8
1.6.2. Objetivos Específicos	8
1.7. Hipótesis de Trabajo	9
1.8. Alcance y Aportes de la Investigación	9
1.9. Estructura de la Tesis	10

1.10. Tesis, Contribución y Criterio de Lectura	11
2. Marco Teórico	12
2.1. Fundamentos Neurofisiológicos de la Señal EEG	12
2.1.1. Generación y Propagación	12
2.1.2. Bandas de Frecuencia y Potenciales Relacionados a Eventos . . .	13
2.2. Procesamiento de Señales en Grafos	14
2.2.1. Definiciones Fundamentales	14
2.2.2. Laplaciano, Suavidad y Transformada de Fourier en Grafos	15
2.2.3. Construcción de Grafos para EEG	15
2.3. Estado del Arte en Interpolación de Señales Biomédicas	16
2.3.1. Métodos Geométricos y Estadísticos	16
2.3.2. Métodos Basados en GSP	16
2.3.3. Regularización Espacio-Temporal: TRSS	16
2.3.4. Paradigma de Aprendizaje Profundo	17
2.4. Mecanismo Interno de la Interpolación en MNE-Python	17
2.4.1. Formulación Original y sus Seis Mejoras	17
2.4.2. Los Tres Pilares de la Robustez	18
2.4.3. Regímenes de Falla	18
3. Metodología	20
3.1. Conjuntos de Datos	20
3.2. Protocolos de Simulación de Canales Faltantes	21
3.3. Métodos de Interpolación	21
3.4. Métricas de Evaluación	21
3.5. Optimización Bayesiana con Optuna	22
3.6. Protocolo de Validación Confirmatoria	23
3.7. Arquitectura del Sistema	23
4. Arquitectura del Sistema y Trazabilidad	24
4.1. Arquitectura Modular	24

4.2. Cadena de Trazabilidad	24
4.3. Gestión de Artefactos	25
4.4. Decisiones de Diseño	25
5. Diseño Experimental	26
5.1. Variables del Experimento	26
5.2. Preguntas de Investigación	26
5.3. Plan de Análisis Estadístico	27
5.3.1. Prueba de Wilcoxon para muestras pareadas	27
5.3.2. Corrección de Benjamini-Hochberg para comparaciones múltiples	28
5.3.3. Tamaño del efecto e intervalos de confianza	28
5.3.4. Protocolo de la fase confirmatoria	29
5.4. Control de Calidad	29
5.5. Síntesis del Diseño	29

Índice de figuras

2.1. Generación de la señal EEG por poblaciones neuronales corticales y su propagación hasta los electrodos de superficie. La conducción volumétrica a través del cráneo actúa como un filtro espacial paso-bajo. Adaptado de [17].	13
2.2. Conceptos fundamentales de GSP. (a) Electrodo como nodo de un grafo con pesos W_{ij} . (b) Descomposición espectral del Laplaciano: autovalores λ_k como frecuencias en el grafo. (c) Flujo de reconstrucción: la señal original sufre pérdida de canales y GSP la reconstruye minimizando la variación sobre el grafo.	14

Índice de tablas

2.1. Familias de métodos: principio matemático, fortalezas y limitaciones. . .	19
3.1. Características de los tres conjuntos de datos experimentales.	20
3.2. Métodos de interpolación por familia.	21
3.3. Métricas de evaluación: definición, categoría y dirección ($\uparrow$ mayor es mejor, $\downarrow$ menor es mejor).	22
3.4. Espacios de búsqueda de hiperparámetros.	22
4.1. Artefactos generados por el sistema experimental.	25
4.2. Ejemplos de trazabilidad entre afirmaciones y artefactos.	25
5.1. Relación entre hipótesis, experimentos y evidencia esperada.	27

Capítulo 1

Introducción

1.1. Contexto General y Planteamiento del Problema

La electroencefalografía (EEG) ha sido, durante décadas, una de las herramientas fundamentales de la neurociencia clínica y experimental. Su alta resolución temporal —en el orden de los milisegundos—, su naturaleza no invasiva y su costo relativamente bajo frente a técnicas como la resonancia magnética funcional o la tomografía por emisión de positrones la han consolidado como el estándar para estudiar la dinámica cerebral en tiempo real [4]. Sus aplicaciones abarcan el diagnóstico de epilepsia y trastornos del sueño, la investigación en neurociencia cognitiva y el desarrollo de interfaces cerebro-computador para comunicación asistida y neurorrehabilitación.

Ahora bien, la adquisición de EEG es un proceso frágil. En la práctica clínica y de investigación, la pérdida parcial o total de información en uno o más electrodos es moneda corriente. Estas fallas pueden deberse al aumento de la impedancia de contacto por transpiración o secado del gel conductor, a fallas en el amplificador como la saturación de voltaje, a movimientos bruscos del paciente que desconectan los sensores, o simplemente al descarte deliberado de canales que presentan una relación señal-ruido inaceptablemente baja durante la etapa de preprocesamiento [17].

La pérdida de canales no es un problema cosmético: compromete la integridad de todo análisis posterior. La ausencia de información espacial distorsiona la topografía de la señal, afecta la localización de fuentes neuronales y altera biomarcadores electrofisiológicos como los Potenciales Relacionados a Eventos (ERP) y la Densidad Espectral de Potencia (PSD) [15]. En sistemas modernos de aprendizaje automático aplicados a interfaces cerebro-computador, la pérdida impredecible de canales cambia la dimensionalidad de entrada

de los clasificadores y obliga, con frecuencia, a descartar ensayos completos de datos clínicamente valiosos [14]. La interpolación precisa de estos canales es, por tanto, un paso ineludible del flujo de preprocesamiento, y su calidad condiciona directamente la validez de cualquier conclusión neurofisiológica o clínica posterior.

1.2. Limitaciones de los Enfoques Tradicionales

Históricamente, el problema de la interpolación de canales EEG ha sido abordado mediante métodos espaciales o estadísticos. El enfoque más extendido y utilizado por defecto en bibliotecas de análisis como EEGLAB [6] o MNE-Python [9, 10] es la interpolación por *spherical splines* [19]. Este método, junto con otros enfoques basados en distancia euclidiana como la interpolación por vecinos más cercanos o las funciones de base radial, asume que la cabeza humana es una esfera conductora perfecta y estima el voltaje del canal faltante proyectando geométricamente los voltajes de los electrodos circundantes sobre dicha superficie.

Aunque estos métodos son rápidos y matemáticamente elegantes, adolecen de una limitación fundamental: operan estrictamente en el dominio espacial estático para cada instante de tiempo individual. Al hacerlo, ignoran dos realidades neurofisiológicas esenciales. En primer lugar, la conectividad funcional real del cerebro no es isotrópica: la actividad eléctrica sigue rutas anatómicas complejas que no siempre se correlacionan con la distancia física en el cuero cabelludo, de modo que un modelo esférico resulta una simplificación excesiva [23]. En segundo lugar, las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento. Al reconstruir un canal muestra por muestra de forma aislada, los métodos puramente espaciales son incapaces de preservar la dinámica de alta frecuencia, generando trazos con ruido de fase y distorsiones en los picos transitorios [13].

Los métodos estadísticos de descomposición —Análisis de Componentes Independientes (ICA) y Análisis de Componentes Principales (PCA)— proyectan las señales observadas sobre fuentes latentes y reconstruyen el canal perdido a partir de esa proyección [12]. Sin embargo, cuando varios canales contiguos fallan simultáneamente, estos métodos tienden a inyectar ruido global o a perder los picos transitorios locales que definen la morfología fina de los ERP.

1.3. El Advenimiento del Procesamiento de Señales en Grafos

Para superar estas limitaciones, en los últimos años ha emergido con fuerza el marco del Procesamiento de Señales en Grafos (GSP, por sus siglas en inglés) [18, 22]. El GSP ofrece una perspectiva natural y poderosa para lidiar con datos que residen en dominios irregulares no euclidianos. En lugar de modelar la cabeza como un espacio continuo tridimensional, GSP modela la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un nodo y las relaciones de similitud o distancia fisiológica entre ellos se codifican en las aristas mediante núcleos de distancia gaussianos o basados en correlación.

Bajo este paradigma, el voltaje medido en un instante se interpreta como una señal de grafo, y conceptos clásicos como la Transformada de Fourier, el filtrado paso-bajo y el muestreo se trasladan al dominio del grafo mediante el operador Laplaciano $\mathbf{L}$. La intuición es simple: las señales en nodos fuertemente conectados tienden a ser similares. Al minimizar una función de costo que penaliza las variaciones abruptas sobre la topología del grafo, los datos faltantes se reconstruyen con mayor fidelidad que usando solo la distancia euclidiana [16].

Una extensión aún más avanzada es la regularización espacio-temporal. Trabajos recientes han introducido enfoques como la Regularización Temporal de Suavidad de Sobolev (TRSS, por sus siglas en inglés) [7], que optimiza conjuntamente la topología espacial y la derivada temporal de la señal. Al penalizar saltos bruscos en el tiempo de forma simultánea a los saltos en el espacio, TRSS impone restricciones fisiológicas reales: las neuronas no cambian su potencial de membrana instantáneamente, sino que obedecen dinámicas de integración continua. Esta restricción dual —espacial y temporal— es lo que la teoría predice como el factor diferencial frente a los métodos puramente espaciales.

1.3.1. Mención del Paradigma de Aprendizaje Profundo

Es pertinente mencionar que existe un cuerpo creciente de literatura que aborda la interpolación de señales EEG mediante redes neuronales profundas, incluyendo arquitecturas como autoencoders convolucionales [2], redes generativas antagónicas para imputación de series temporales [24], y más recientemente Redes Neuronales de Grafos que operan directamente sobre la topología de electrodos [5]. Estos enfoques han mostrado resultados prometedores en escenarios controlados, beneficiándose de la capacidad de las redes pro-

fundas para aprender representaciones latentes complejas a partir de grandes volúmenes de datos.

No obstante, estos métodos presentan limitaciones que motivan su exclusión deliberada del alcance de esta tesis. En primer lugar, son inherentemente dependientes de los datos de entrenamiento, lo que introduce riesgos de falta de generalización al transferir modelos entre poblaciones, equipos o paradigmas experimentales distintos. En segundo lugar, carecen de garantías formales de convergencia y de interpretabilidad sobre el mecanismo de interpolación, una propiedad crítica en contextos clínicos donde cada decisión debe ser trazable y justificable. En tercer lugar, su costo computacional de entrenamiento es órdenes de magnitud superior al de los métodos algorítmicos aquí considerados. Por estas razones, la presente investigación se circunscribe exclusivamente a métodos algorítmicos con fundamento matemático explícito —geométricos, estadísticos y basados en GSP— cuya operación no requiere entrenamiento y cuyas propiedades de convergencia y regularización son analíticamente caracterizables.

1.4. La Brecha en la Literatura y la Motivación del Trabajo

A pesar de la inmensa promesa teórica de los algoritmos GSP y TRSS, su validación empírica en la literatura de señales biomédicas sufre de una preocupante fragmentación metodológica. Se identifican tres problemas graves en las evaluaciones comparativas publicadas hasta la fecha.

El primer problema es que los estudios que proponen nuevos algoritmos GSP suelen compararse contra *spherical splines* usando las configuraciones por defecto de los paquetes de software, sin realizar una búsqueda rigurosa de hiperparámetros para los métodos de referencia. Esto infla artificialmente las ventajas del método propuesto y distorsiona la percepción del verdadero estado del arte [20]. El segundo problema es que la gran mayoría de los trabajos restringen su evaluación a métricas de error de amplitud global —como el RMSE o el MAE— y aplican escenarios de desconexión irreales, tales como la remoción de canales aleatorios aislados en bases de datos pequeñas. Rara vez se investiga el impacto morfológico de la reconstrucción mediante métricas temporales como el *Dynamic Time Warping* o espectrales como la Distancia Espectral Logarítmica, que constituyen los verdaderos predictores de la utilidad clínica de la señal interpolada. El tercer problema, y quizás el más grave desde el punto de vista metodológico, es la ausencia

casi total de comparaciones contra implementaciones de referencia industrial. En particular, la implementación de interpolación de MNE-Python incorpora más de una década de refinamientos de ingeniería —normalización de coordenadas, regularización diagonal adaptativa, aumentación del sistema con restricciones lineales, pseudoinversa con tolerancia adaptativa y un mecanismo de reintento automático— que la hacen sustancialmente más robusta que una implementación ingenua de *spherical splines*. Ignorar esta implementación equivale a comparar contra un método de referencia debilitado artificialmente.

La motivación concreta de este trabajo nace directamente de estas brechas. El objetivo no es diseñar desde cero un nuevo marco teórico matemático, sino someter a la frontera del conocimiento actual —métodos geométricos, GSP y regularización temporal— a la evaluación empírica más rigurosa, exhaustiva y justa posible. Al utilizar el sistema moderno de optimización bayesiana Optuna [1] para llevar todos los algoritmos a su máximo límite empírico bajo protocolos evaluados en múltiples conjuntos de datos, esta tesis busca revelar el verdadero punto de cruce entre el paradigma clásico y el paradigma de grafos.

1.4.1. La pregunta central: ¿por qué funciona tan bien la interpolación de MNE-Python?

Una pregunta recurrente que emerge del análisis preliminar —y que motiva una sección dedicada en el marco teórico de esta tesis— es por qué la función de interpolación de MNE-Python produce resultados tan competitivos, incluso frente a métodos teóricamente superiores como TRSS. La respuesta, que se desarrolla en profundidad en el Capítulo 2, reside en que la implementación de MNE no es una simple transcripción del artículo original de Perrin y colaboradores [19], sino que incorpora un conjunto de mejoras de ingeniería acumuladas durante más de diez años de desarrollo como código abierto.

Estas mejoras —normalización de coordenadas a esfera unitaria, uso global de canales, regularización diagonal adaptativa, aumentación con restricciones lineales, pseudoinversa con tolerancia adaptativa y reintento automático— no aparecen descritas en la literatura académica, pero están presentes en el código fuente de MNE. Son las responsables de que un método formulado en 1989 siga siendo hoy una referencia formidable. Esta tesis dedica una sección completa del marco teórico (Capítulo 2) a documentar estos mecanismos, y una validación confirmatoria independiente (Capítulo 6) a cuantificar la brecha real entre TRSS y MNE.

1.5. Cronología del Proyecto

La investigación que sustenta esta tesis no siguió un camino lineal, sino un proceso iterativo de descubrimiento guiado por los resultados experimentales que se iban obteniendo. Documentar esta trayectoria es esencial para comprender las decisiones metodológicas que dieron forma al protocolo final, y se presenta a continuación de manera cronológica.

1.5.1. Fase 1 — Selección de Métodos y Revisión del Estado del Arte

Durante los primeros dos meses se realizó una revisión sistemática de la literatura sobre interpolación de señales en dominios irregulares. Este proceso permitió identificar tres familias metodológicas bien diferenciadas: métodos geométricos o espaciales (*spherical splines*, vecinos más cercanos, funciones de base radial), métodos estadísticos de descomposición (ICA, PCA, interpolación lineal) y métodos basados en GSP (regularización de Tikhonov en grafos, regularización de Sobolev, TRSS). De cada familia se seleccionaron los representantes más citados y con fundamento matemático más sólido, resultando en un total de dieciocho métodos candidatos para implementación y evaluación comparativa.

1.5.2. Fase 2 — Implementación del Sistema de Experimentación

Los siguientes dos meses se dedicaron al desarrollo de un sistema modular en Python que unificara la interfaz de todos los métodos bajo una interfaz de programación común. Cada método recibía una matriz de datos $\mathbf{X} \in \mathbb{R}^{C \times T}$ —con C canales y T muestras temporales— junto con una máscara binaria que indicaba qué canales debían tratarse como faltantes, y entregaba como resultado la matriz reconstruida. En paralelo se implementaron los constructores de grafos necesarios —incluyendo k-NN con pesos gaussianos, grafos de correlación funcional y grafos de distancia completa—, los núcleos de interpolación GSP y el resolutor TRSS con regularización dual mediante los parámetros α y β . Esta fase fue particularmente demandante porque requirió validar que cada implementación propia reprodujera exactamente el comportamiento descrito en su artículo original antes de incorporarla al sistema comparativo.

1.5.3. Fase 3 — Barrido Exploratorio Inicial

Con el sistema funcional, se ejecutó un barrido exploratorio sobre escenarios de pérdida aleatoria al 20% en los tres conjuntos de datos. Los resultados revelaron un hallazgo inesperado que redefiniría el curso de la investigación: TRSS mostraba ventajas muy significativas —del orden de 5 a 15 dB en SNR— sobre las implementaciones propias de *spherical splines*, pero esa brecha se reducía de manera importante al comparar contra la implementación industrial de MNE-Python, que incorpora una década de refinamientos de ingeniería. Este hallazgo fue el disparador de dos decisiones metodológicas cruciales: incluir a MNE como referencia confirmatoria independiente en una fase separada del experimento, y diseñar el resto del protocolo para distinguir nítidamente entre resultados exploratorios y confirmatorios.

1.5.4. Fase 4 — Selección Fina y Diseño del Espacio de Búsqueda

Los resultados del barrido permitieron descartar con confianza los métodos claramente inferiores —como la interpolación lineal o el vecino más cercano sin ponderación— y concentrar los recursos de optimización en los métodos con desempeño prometedor. Para cada familia se definió un espacio de búsqueda de hiperparámetros diferenciado: la escala del núcleo gaussiano σ y el número de vecinos k para los métodos de grafo, los coeficientes de regularización espacial α y temporal β para TRSS, y el orden del spline m junto con la regularización λ para los *spherical splines*.

1.5.5. Fase 5 — Optimización Bayesiana con Optuna

Durante los siguientes dos meses se integró Optuna con muestreo TPE (*Tree-structured Parzen Estimator*) como motor de optimización [1]. Se ejecutaron treinta intentos independientes por cada método de grafo, diez intentos con el algoritmo multiobjetivo NSGA-II para los *spherical splines*, y barridos de grilla fina para TRSS dado su mayor costo computacional. En total se evaluaron más de quince mil configuraciones paramétricas distintas. Esta fase constituye el núcleo experimental de la tesis: sus resultados son los que se reportan en el Capítulo 6.

1.5.6. Fase 6 — Validación Confirmatoria contra MNE-Python

En una fase independiente —diseñada para no contaminar los resultados exploratorios— se ejecutó una validación donde TRSS, con sus hiperparámetros congelados tras la optimización de la fase anterior, se comparó directamente contra la implementación de referencia de MNE-Python utilizando los parámetros por defecto que cualquier usuario de MNE obtendría sin ajuste adicional. Esta validación se estratificó por conjunto de datos, modo de pérdida y severidad, y empleó pruebas estadísticas pareadas —Wilcoxon signed-rank con corrección de Benjamini-Hochberg para comparaciones múltiples— con el fin de establecer significancia estadística de manera rigurosa.

1.5.7. Fase 7 — Ablación y Documentación

La fase final consistió en un estudio de ablación para cuantificar la contribución relativa de cada componente de TRSS —el término espacial α frente al término temporal β —, la generación sistemática de todas las figuras y tablas que aparecen en este documento, y la redacción de la tesis propiamente dicha.

1.6. Objetivos

1.6.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales EEG basados en GSP con regularización temporal frente a las referencias geométricas —incluida MNE-Python— bajo un marco experimental riguroso, reproducible y optimizado mediante optimización bayesiana.

1.6.2. Objetivos Específicos

- **OE1 — Sistema unificado de evaluación.** Implementar dieciocho métodos de interpolación en un sistema modular con interfaz común, definir protocolos de pérdida aleatoria y contigua (10 %–40 %), e integrar Optuna para la optimización imparcial de todos los algoritmos (más de 15 000 configuraciones exploradas).
- **OE2 — Evaluación multi-métrica y fisiológica.** Cuantificar el desempeño mediante seis métricas (MAE, RMSE, SNR, DTW, LSD, Coherencia) sobre tres conjuntos de datos y 120 escenarios de pérdida, y verificar el impacto en la preserva-

ción de ERPs (N100, P300) y de la estructura espectral en las bandas de frecuencia naturales del EEG.

- **OE3 — Trazabilidad y reproducibilidad.** Generar un repositorio abierto de artefactos computacionales —código, configuraciones, registros de optimización y resultados— que garantice la trazabilidad completa de cada afirmación cuantitativa hasta el archivo que la origina.

1.7. Hipótesis de Trabajo

H1 — Hipótesis principal. La regularización espacio-temporal (TRSS) permite reconstruir canales EEG faltantes con mayor precisión y robustez que los métodos geométricos, no solo en error de amplitud sino en la preservación de la morfología de ERPs y de la densidad espectral, especialmente bajo pérdida contigua severa.

H2 — Hipótesis de equivalencia condicional. En regímenes favorables —montajes densos (≥ 60 canales), pérdida aleatoria $\leq 20\%$ —, MNE-Python iguala o supera a TRSS en preservación espectral, siendo entre 50 y 100 veces más rápido sin un sacrificio clínico significativo.

1.8. Alcance y Aportes de la Investigación

El alcance de este trabajo abarca la ejecución computacional a gran escala del sistema de evaluación sobre tres conjuntos de datos, ciento veinte escenarios de falla y dieciocho métodos de interpolación. A diferencia de las evaluaciones acotadas que predominan en la literatura, aquí se consolidan miles de ensayos EEG bajo más de quince mil configuraciones paramétricas exploradas mediante Optuna.

Para garantizar la reproducibilidad, la ejecución se ancla en un registro exhaustivo de corridas experimentales que fija explícitamente las combinaciones de conjuntos de datos, modos de pérdida, semillas, tipos de grafo y familias de métodos. Este diseño evita las evaluaciones improvisadas y permite trazar cada afirmación cuantitativa reportada en los capítulos posteriores hasta el artefacto experimental que la origina, según se detalla en el Apéndice D.

Los aportes principales se articulan en cuatro ejes. Primero, se proporciona evidencia estadística de que TRSS supera consistentemente a las referencias geométricas en fidelidad

morfológica y espectral una vez que todos los métodos han sido optimizados. Segundo, se revela que bajo pérdida contigua severa (30 % o más de los canales) las referencias geométricas colapsan, mientras que la restricción temporal de TRSS preserva la trayectoria fisiológica. Tercero, se documentan por primera vez en formato académico las seis mejoras de ingeniería que convierten a MNE-Python en una referencia inesperadamente robusta. Cuarto, se entrega un sistema unificado en Python, rastreable y de código abierto para ejecutar interpolaciones GSP con optimización bayesiana automatizada sobre datos EEG.

1.9. Estructura de la Tesis

Para desarrollar el análisis propuesto, el resto del documento se organiza de la siguiente manera. El Capítulo 2 presenta los fundamentos neurofisiológicos del EEG, los pilares matemáticos del Procesamiento de Señales en Grafos —incluyendo el Laplaciano, la Transformada de Fourier en Grafos y la construcción de grafos—, el estado del arte en interpolación de señales biomédicas, y una sección dedicada al análisis detallado del mecanismo interno de la función de interpolación de MNE-Python. El Capítulo 3 detalla el protocolo experimental: los tres conjuntos de datos empleados, el modelado matemático de los dieciocho algoritmos evaluados, los métodos de simulación de daños y la arquitectura del motor de optimización bayesiana. El Capítulo 4 documenta la arquitectura de software del sistema experimental, la trazabilidad entre módulos y la gestión de artefactos. El Capítulo 5 formaliza el diseño experimental: variables independientes, dependientes y controladas, el protocolo de validación y el plan de análisis estadístico. El Capítulo 6 expone los hallazgos empíricos, incluyendo comparativas globales de error, curvas de degradación por pérdida creciente, preservación de ERPs y PSD, el estudio de ablación de TRSS y la validación confirmatoria contra MNE-Python. El Capítulo 7 ofrece una discusión crítica sobre las causas metodológicas de los resultados obtenidos, interpreta los mecanismos subyacentes y transparenta las limitaciones del estudio. Finalmente, el Capítulo 8 sintetiza las conclusiones, valora el cumplimiento de las hipótesis y sugiere vías de investigación futura.

Los apéndices complementan el documento con derivaciones matemáticas completas (Apéndice A), tablas extensas de resultados (Apéndice B), el protocolo de reproducibilidad (Apéndice C), el inventario de artefactos computacionales (Apéndice D) y una adaptación de las tablas del documento original de tesis para referencia histórica (Apéndice E).

1.10. Tesis, Contribución y Criterio de Lectura

La tesis que organiza este documento sostiene que la reconstrucción de canales EEG faltantes debe evaluarse como un problema simultáneamente espacial, temporal y espectral. En consecuencia, una evaluación basada únicamente en métricas de error de amplitud como el MAE o el RMSE no es suficiente para decidir si una interpolación es útil en aplicaciones neurofisiológicas reales, porque estas métricas son insensibles a las distorsiones de fase y a la preservación de la estructura fina del espectro de frecuencias.

Esta investigación adopta una posición deliberadamente conservadora y transparente: los resultados favorables a TRSS se reportan solo cuando pueden trazarse a artefactos reproducibles; las limitaciones se explicitan con honestidad; y se reconoce sin ambages que la implementación de MNE-Python constituye una referencia formidable en sus regímenes de operación óptimos.

La contribución central puede sintetizarse en una sola oración: *esta tesis establece una evaluación comparativa reproducible y justa para la reconstrucción de canales EEG, demostrando que la regularización temporal sobre grafos —en particular TRSS— mejora sensiblemente la fidelidad morfológica y espectral bajo escenarios de pérdida severa, incluso después de haber optimizado rigurosamente todos los métodos de referencia, incluyendo la implementación industrial MNE-Python, y documenta por primera vez en formato académico los mecanismos de ingeniería que hacen de esta última una referencia inesperadamente competitiva.*

Capítulo 2

Marco Teórico

Este capítulo presenta los fundamentos sobre los que se construye la investigación: principios neurofisiológicos del EEG, bases matemáticas del Procesamiento de Señales en Grafos, estado del arte en interpolación de señales biomédicas, y un análisis detallado de los mecanismos internos que convierten a la implementación de *spherical splines* en MNE-Python en una referencia inesperadamente competitiva.

2.1. Fundamentos Neurofisiológicos de la Señal EEG

2.1.1. Generación y Propagación

La señal EEG registrada en el cuero cabelludo resulta de la actividad sincronizada de grandes poblaciones de neuronas piramidales en la corteza cerebral [4]. Estas neuronas, orientadas perpendicularmente a la superficie cortical, generan dipolos de corriente ante potenciales postsinápticos. La suma espacial de estos dipolos —se requieren entre diez mil y cien mil neuronas sincronizadas para producir una señal detectable— constituye la fuente primaria del EEG.

La señal atraviesa desde la corteza hasta los electrodos múltiples capas de conductividad variable: líquido cefalorraquídeo, meninges, cráneo (aproximadamente ochenta veces menos conductor que el cuero cabelludo) y cuero cabelludo [17]. Esta conducción volumétrica actúa como un filtro espacial paso-bajo que suaviza la distribución de potencial y limita la resolución espacial efectiva del EEG a unos dos o tres centímetros (Figura 2.1).




Figura 2.1: Generación de la señal EEG por poblaciones neuronales corticales y su propagación hasta los electrodos de superficie. La conducción volumétrica a través del cráneo actúa como un filtro espacial paso-bajo. Adaptado de [17].

2.1.2. Bandas de Frecuencia y Potenciales Relacionados a Eventos

La señal EEG se caracteriza por su contenido oscilatorio en bandas de frecuencia asociadas a estados funcionales específicos: delta (0.5–4 Hz, sueño profundo), theta (4–8 Hz, procesamiento de memoria), alpha (8–13 Hz, reposo vigil), beta (13–30 Hz, procesamiento activo) y gamma (30–100 Hz, procesamiento perceptual de alto nivel) [4]. La preservación de la estructura espectral en cada banda es un criterio fundamental para evaluar la calidad de cualquier interpolación.

Los Potenciales Relacionados a Eventos (ERP) son fluctuaciones de voltaje sincronizadas con un estímulo sensorial, motor o cognitivo, obtenidas mediante promediación coherente de múltiples ensayos [15]. Componentes como N100, P300 y N400 constituyen biomarcadores electrofisiológicos cuya preservación morfológica —amplitud de pico, latencia y distribución topográfica— es uno de los criterios de evaluación más exigentes para cualquier método de interpolación.


2.2. Procesamiento de Señales en Grafos

El Procesamiento de Señales en Grafos (GSP) [18, 22] extiende los conceptos del procesamiento clásico de señales a dominios irregulares representados por grafos.


2.2.1. Definiciones Fundamentales

Un grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$ consiste en N nodos $\mathcal{V} = \{v_1, \dots, v_N\}$ —los electrodos—, aristas $\mathcal{E}$ que representan conectividad, y una matriz de pesos $\mathbf{W} \in \mathbb{R}^{N \times N}$ simétrica con $W_{ij} > 0$ si existe arista entre i y j . Una señal de grafo en el instante t es el vector $\mathbf{x}_t \in \mathbb{R}^N$ de voltajes en los N electrodos. La matriz $\mathbf{X} \in \mathbb{R}^{N \times T}$ contiene T instantes temporales.

(a) Grafo de electrodos



(b) Espectro del Laplaciano



(c) Flujo de reconstrucción GSP




Figura 2.2: Conceptos fundamentales de GSP. (a) Electrodos como nodos de un grafo con pesos W_{ij} . (b) Descomposición espectral del Laplaciano: autovalores λ_k como frecuencias en el grafo. (c) Flujo de reconstrucción: la señal original sufre pérdida de canales y GSP la reconstruye minimizando la variación sobre el grafo.

2.2.2. Laplaciano, Suavidad y Transformada de Fourier en Grafos

La matriz Laplaciana se define como $\mathbf{L} = \mathbf{D} - \mathbf{W}$, con $D_{ii} = \sum_j W_{ij}$. La forma cuadrática

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{i,j} W_{ij} (x_i - x_j)^2 \quad (2.1)$$

cuantifica la variación total de $\mathbf{x}$ sobre el grafo: valores pequeños indican que nodos fuertemente conectados tienen valores similares —la señal es *suave*—. Esta propiedad es el pilar de la interpolación GSP: la mejor reconstrucción minimiza $S(\mathbf{x})$ sujeta a coincidir con los canales observados.

$\mathbf{L}$ admite la descomposición espectral $\mathbf{L} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$, donde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$ contiene los autovalores ordenados $0 = \lambda_1 \leq \dots \leq \lambda_N$, y $\mathbf{U}$ es la matriz ortogonal de autovectores. Los λ_k actúan como frecuencias en el grafo: valores pequeños corresponden a modos de variación lenta, valores grandes a modos de variación rápida (Figura 2.2b).

La Transformada de Fourier en Grafos (GFT) se define como $\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}$. Una señal es *de banda limitada* si $\hat{x}_k = 0$ para $k > K$, con $K \ll N$. La suavidad en el dominio espectral es $S(\mathbf{x}) = \sum_k \lambda_k \hat{x}_k^2$, penalizando los modos de alta frecuencia proporcionalmente a su autovalor.

2.2.3. Construcción de Grafos para EEG

Se implementan tres estrategias. El **grafo k-NN gaussiano** conecta cada electrodo a sus k vecinos más próximos en distancia euclidiana, con pesos $W_{ij} = \exp(-\|\mathbf{p}_i - \mathbf{p}_j\|_2^2 / 2\sigma^2)$. El **grafo de correlación funcional** usa $W_{ij} = |\rho_{ij}|$, el valor absoluto de la correlación de Pearson entre las series temporales, capturando conectividad funcional. El **grafo de distancia completa** conecta todos los pares con el núcleo gaussiano, generando una matriz densa.

2.3. Estado del Arte en Interpolación de Señales Biomédicas

2.3.1. Métodos Geométricos y Estadísticos

El método más establecido es el de *spherical splines* [19], que modela el potencial sobre el cuero cabelludo como una función suave sobre una esfera. El potencial estimado en una posición $\mathbf{r}$ es $\hat{V}(\mathbf{r}) = c_0 + \sum_{i=1}^M c_i g_m(\mathbf{r}, \mathbf{r}_i)$, donde g_m es la función de Green del operador pseudo-laplaciano de orden m sobre la esfera, y los coeficientes c_i se obtienen resolviendo un sistema lineal aumentado. El parámetro m controla la rigidez de la superficie y λ regula el compromiso ajuste-suavidad.

Los métodos estadísticos —PCA e ICA— proyectan las señales observadas sobre fuentes latentes y reconstruyen el canal perdido desde esa proyección [11, 12]. Sin embargo, requieren la estimación previa de la matriz de mezcla sobre datos completos y fallan cuando la pérdida de canales es severa y contigua.

2.3.2. Métodos Basados en GSP

La **regularización de Tikhonov en grafos** formula la interpolación como un problema de optimización convexa:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \|\mathbf{M} \odot (\mathbf{x} - \mathbf{y})\|_2^2 + \alpha \cdot \mathbf{x}^\top \mathbf{L} \mathbf{x}, \quad (2.2)$$

donde $\mathbf{M}$ es la máscara binaria de canales observados y α controla el compromiso entre fidelidad a los datos y suavidad espacial. La solución cerrada es $\hat{\mathbf{x}} = (\text{diag}(\mathbf{M}) + \alpha \mathbf{L})^{-1} (\mathbf{M} \odot \mathbf{y})$. El **método de muestreo en grafos** asume que la señal es de banda limitada y busca la señal de banda limitada que interpola exactamente los valores observados.

2.3.3. Regularización Espacio-Temporal: TRSS

La Regularización Temporal de Suavidad de Sobolev (TRSS) [7] incorpora la continuidad temporal de las señales neuronales mediante un término adicional de penalización. El problema conjunto sobre la matriz espacio-temporal $\mathbf{X} \in \mathbb{R}^{N \times T}$ es

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{X}} \|\mathbf{M} \odot (\mathbf{X} - \mathbf{Y})\|_F^2 + \alpha \cdot \text{tr}(\mathbf{X}^\top \mathbf{L} \mathbf{X}) + \beta \cdot \|\mathbf{X} \mathbf{D}_t\|_F^2, \quad (2.3)$$

donde $\mathbf{D}_t \in \mathbb{R}^{T \times (T-1)}$ es la matriz de diferencias finitas con $(\mathbf{D}_t)_{t,t} = -1$, $(\mathbf{D}_t)_{t+1,t} = 1$, y $\|\mathbf{X}\mathbf{D}_t\|_F^2 = \sum_{i=1}^N \sum_{t=1}^{T-1} (X_{i,t+1} - X_{i,t})^2$ penaliza los cambios abruptos muestra a muestra. β controla la suavidad temporal: $\beta = 0$ reduce TRSS a Tikhonov independiente por instante; $\alpha = 0$ lo convierte en un suavizador temporal sin guía espacial. La interacción de ambos términos produce una mejora mayor que la suma de sus efectos individuales (sinergia que se verifica en el Capítulo de Resultados).

2.3.4. Paradigma de Aprendizaje Profundo

Existe un cuerpo creciente de literatura sobre imputación de canales EEG mediante redes neuronales: autoencoders convolucionales [2], redes generativas antagónicas [24] y Redes Neuronales de Grafos [5]. Estos métodos quedan fuera del alcance experimental de esta tesis por tres razones: dependencia de datos de entrenamiento (riesgo de falta de generalización), ausencia de garantías formales de convergencia e interpretabilidad, y costo computacional de entrenamiento órdenes de magnitud superior.

2.4. Mecanismo Interno de la Interpolación en MNE-Python

Esta sección documenta las mejoras de ingeniería —no descritas en la literatura académica— que convierten a la implementación de *spherical splines* en MNE-Python [9, 10] en una referencia inesperadamente competitiva. La información se obtuvo mediante inspección directa del código fuente.

2.4.1. Formulación Original y sus Seis Mejoras

El artículo de Perrin [19] formula la interpolación como un sistema lineal aumentado con regularización fija $\lambda \approx 10^{-5}$. MNE-Python extiende este algoritmo con las siguientes mejoras:

1. **Normalización a esfera unitaria.** Las coordenadas se centran y escalan: $\mathbf{p}'_i = (\mathbf{p}_i - \bar{\mathbf{p}}) / \max_j \|\mathbf{p}_j - \bar{\mathbf{p}}\|_2$. Esto elimina la dependencia de unidades físicas y garantiza el buen condicionamiento numérico.
2. **Uso global de canales.** Todos los M canales observados contribuyen a cada estimación, no solo los vecinos más cercanos. En un montaje de 64 canales con 2 malos, la

reconstrucción aprovecha 62 electrodos.

3. **Regularización adaptativa.** El término de regularización se escala según la traza: $\varepsilon = 10^{-6} \cdot \text{tr}(\mathbf{G})/M$.
4. **Aumentación con restricciones lineales.** Se fuerzan $\sum_i c_i = 0$ y condiciones análogas para las coordenadas, garantizando unicidad.
5. **Pseudoinversa con tolerancia adaptativa.** Ante matrices numéricamente singulares, se usa una pseudoinversa con umbral proporcional a la norma.
6. **Reintento automático.** Si la reconstrucción produce valores nulos, el sistema reintenta con parámetros por defecto.

Estas mejoras transforman un algoritmo teóricamente simple en un estimador notablemente robusto. La implicación para esta tesis es clara: no es válido comparar contra implementaciones simplificadas de Perrin; la referencia debe ser MNE-Python mismo.

2.4.2. Los Tres Pilares de la Robustez

Desde el punto de vista **físico**, el modelo de cabeza esférica con polinomios de Legendre es una solución regularizada de la ecuación de Laplace: no es una heurística sino el modelo más simple que captura la física de la conducción volumétrica. Cuando la información previa es correcta —y la suavidad espacial del EEG es un hecho físico bien documentado—, los métodos bayesianos simples superan a alternativas más complejas.

Desde el punto de vista **estadístico**, MNE implementa implícitamente un estimador bayesiano con información previa de suavidad espacial que, en el régimen de alta redundancia (correlación inter-canal $> 0,9$), alcanza la mínima varianza.

Desde el punto de vista **informacional**, el EEG de cuero cabelludo exhibe redundancia espacial muy alta por el filtrado paso-bajo de la conducción volumétrica. Los métodos globales que usan toda la información disponible superan a los locales que la descartan.

2.4.3. Regímenes de Falla

Los *spherical splines* son vulnerables cuando su información previa espacial deja de ser válida: bajo pérdida contigua severa (30–40 % de canales en una misma región), no hay suficientes electrodos buenos en la vecindad para interpolar con precisión. Es en este régimen donde TRSS obtiene su ventaja, porque la información previa temporal proporciona la restricción adicional que MNE no posee.

Tabla 2.1: Familias de métodos: principio matemático, fortalezas y limitaciones.

Familia	Principio	Fortaleza	Limitación
Geométrica	Distancia + superficie esférica	Velocidad, simplicidad	Ignora dinámica temporal
Estadística	Descomposición en fuentes	Separa artefactos	Requiere datos completos
GSP-Tikhonov	Suavidad espacial en grafo	Topología flexible	Independiente por instante
GSP-Muestreo	Banda limitada en grafo	Fundamento de muestreo	Sensible a selección de K
TRSS	Suavidad espacio-temporal	Preserva morfología	Costo computacional alto
MNE-Python	Splines + mejoras ing.	Robusta en rég. favorable	Colapso bajo pérdida continua

Capítulo 3

Metodología

Este capítulo describe el diseño metodológico: conjuntos de datos, algoritmos, protocolos de simulación de canales faltantes, métricas de evaluación y motor de optimización bayesiana.

3.1. Conjuntos de Datos

La evaluación se realizó sobre tres bases de datos EEG públicas que cubren un espectro diverso de densidades, paradigmas y poblaciones (Tabla 3.1).

Tabla 3.1: Características de los tres conjuntos de datos experimentales.

Propiedad	PhysioNet	BCI IV 2a	MNE Sample
Canales	64	22	60
Sistema	10–10	10–20	10–20 ext.
Frecuencia (Hz)	160	250	600
Sujetos	109	9	1
Paradigma	Reposo	Imag. motora	Auditivo

PhysioNet [8, 21] contiene 64 canales (10–10) a 160 Hz de 109 sujetos. Se usaron segmentos de reposo con ojos abiertos (60 s por sujeto). **BCI Competition IV 2a** [3] aporta 22 canales (10–20) a 250 Hz de 9 sujetos en tareas de imaginación motora de cuatro clases. Se extrajeron 2592 ensayos de 2 s. **MNE Sample** [9] contiene 60 canales (10–20 ext.) a 600 Hz con 72 ensayos de 0.7 s alrededor de estímulos auditivos.

Estos tres conjuntos cubren el espacio de variabilidad real: desde 22 canales (clínica ambulatoria) hasta 64 (investigación), con frecuencias de 160 a 600 Hz y paradigmas de

reposo, imaginación motora y potenciales evocados.

3.2. Protocolos de Simulación de Canales Faltantes

Se definieron dos modos de pérdida. El **modo aleatorio** selecciona un porcentaje p de canales al azar, modelando fallas esporádicas (secado del gel, desprendimiento de electrodos). El **modo contiguo** selecciona un canal semilla y marca como faltantes los p canales más cercanos en distancia euclidiana, modelando fallas catastróficas localizadas (saturación de amplificador).

Para cada modo se evaluaron cuatro severidades ($p \in \{10\%, 20\%, 30\%, 40\%\}$) con 5 semillas aleatorias, generando $3 \times 2 \times 4 \times 5 = 120$ escenarios.

3.3. Métodos de Interpolación

Se implementaron dieciocho métodos organizados en seis familias (Tabla 3.2).

Tabla 3.2: Métodos de interpolación por familia.

Familia	Métodos
Geométrica	Vecino más cercano, Distancia inversa, RBF, Spherical splines
Estadística	Lineal, PCA, ICA
GSP-Tikhonov	k-NN gaussiano, Distancia completa, Correlación funcional, Distancia inversa
GSP-Muestreo	Banda limitada, Mínimos cuadrados
TRSS	Grafo gaussiano, Grafo de correlación
Referencia	MNE-Python (defecto), MNE-Python (Optuna)

Es metodológicamente crucial distinguir entre la implementación propia de *spherical splines* y la de MNE-Python, que incorpora mejoras de ingeniería documentadas en el Capítulo 2.

3.4. Métricas de Evaluación

Se emplearon seis métricas organizadas en tres categorías (Tabla 3.3). Ninguna métrica individual captura todos los aspectos relevantes para la utilidad clínica.

Las métricas de **amplitud** cuantifican el error muestra a muestra. El **DTW** permite deformaciones no lineales del eje temporal, relevante para ERP donde un desplazamiento

Tabla 3.3: Métricas de evaluación: definición, categoría y dirección ($\uparrow$ mayor es mejor, $\downarrow$ menor es mejor).

Métrica	Definición	Cat.	Dir.
MAE	Error absoluto medio $\frac{1}{N} \sum x_i - \hat{x}_i $	Amplitud	$\downarrow$
RMSE	Raíz del error cuadrático medio	Amplitud	$\downarrow$
SNR	$10 \log_{10}(\ x\ ^2 / \ x - \hat{x}\ ^2)$	Amplitud	$\uparrow$
DTW	Dynamic Time Warping (deformación temporal)	Morfológica	$\downarrow$
LSD	Distancia Espectral Logarítmica	Espectral	$\downarrow$
Coherencia	Correlación en dominio de frecuencia	Espectral	$\uparrow$

de pocos milisegundos es clínicamente insignificante pero penalizado por el RMSE. Las métricas **espectrales** (LSD, Coherencia) cuantifican la distorsión del espectro, que es el mejor predictor de utilidad clínica porque biomarcadores como la potencia relativa en bandas dependen de la estructura fina del espectro.

3.5. Optimización Bayesiana con Optuna

Se utilizó Optuna [1] con muestreo TPE para optimizar los hiperparámetros de todos los métodos. Los espacios de búsqueda se definieron por familia (Tabla 3.4). Se ejecutaron 30 intentos por método de grafo, 10 intentos con NSGA-II multiobjetivo para *spherical splines*, y barridos de grilla para TRSS. En total se exploraron más de quince mil configuraciones.

Tabla 3.4: Espacios de búsqueda de hiperparámetros.

Familia	Parámetros	Escala
GSP (grafo)	$\sigma \in [0,01, 1,0], k \in \{3, 5, 7, 10, 15, 20\}$	Lineal
TRSS	$\alpha \in [10^{-4}, 10^2], \beta \in [10^{-3}, 10^3]$	Log
Splines propios	$m \in \{2, 3, 4\}, \lambda \in [10^{-8}, 10^{-2}]$	Mixta
MNE (Optuna)	$m \in \{2, 3, 4\}, \lambda \in [10^{-8}, 10^{-2}]$	Mixta

3.6. Protocolo de Validación Confirmatoria

En una fase independiente, TRSS —con hiperparámetros congelados— se comparó contra MNE-Python con parámetros por defecto. Se computó la diferencia pareada en cada métrica por escenario. La significancia se evaluó con Wilcoxon signed-rank y corrección de Benjamini-Hochberg (FDR 5 %). Se reportan medianas de mejora relativa, intervalos bootstrap al 95 % (1000 remuestreos estratificados) y tasas de victoria.

3.7. Arquitectura del Sistema

El sistema se organiza en cinco módulos: **datos** (adaptadores con interfaz común), **simulación de daños** (protocolos aleatorio y contiguo con semilla trazable), **interpolación** (18 métodos bajo interfaz unificada), **evaluación** (6 métricas) y **optimización** (espacios Optuna con puntos de control). La separación estricta entre fases exploratoria y confirmatoria previene la contaminación circular que vicia muchas evaluaciones comparativas en la literatura.

Capítulo 4

Arquitectura del Sistema y Trazabilidad

Este capítulo documenta la arquitectura de software y el mecanismo de trazabilidad que vincula cada resultado cuantitativo con su artefacto computacional de origen.

4.1. Arquitectura Modular

El sistema se organiza en cinco módulos con interfaces explícitas, lo que permite probar cada módulo de forma aislada y ejecutar experimentos en paralelo sin interferencia.

El módulo de **datos** expone una interfaz común para los tres conjuntos. El módulo de **simulación de daños** retorna la máscara binaria junto con la semilla que la generó, garantizando reproducibilidad determinista. El módulo de **interpolación** contiene las dieciocho implementaciones bajo una clase base abstracta con interfaz unificada, eliminando ventajas espurias por acceso diferencial a metadatos. El módulo de **evaluación** calcula las seis métricas. El módulo de **optimización** orquesta Optuna con registro estructurado de métricas intermedias, puntos de control y detección temprana de convergencia.

4.2. Cadena de Trazabilidad

Cada ejecución sigue una cadena determinista: carga de configuración, carga de datos, simulación de daño con semilla fija, interpolación, evaluación con seis métricas, y registro estructurado de resultados con metadatos completos. Cada ejecución recibe un identificador único (SHA-256 de la tupla completa de parámetros) que permite verificar reproducibilidad

bit a bit, rastrear cualquier número reportado hasta su archivo de origen, y detectar contaminación entre fases experimentales.

4.3. Gestión de Artefactos

Los resultados se almacenan en una jerarquía estandarizada por conjunto, modo, severidad y método. Cada ejecución preserva métricas agregadas (JSON), señales reconstruidas (NPZ), máscara de daño, configuración inmutable (YAML) y tiempos de ejecución (Tabla 4.1). El código fuente está versionado con Git, y cada conjunto de resultados está asociado a una etiqueta del repositorio.

Tabla 4.1: Artefactos generados por el sistema experimental.

Artefacto	Formato	Función
Configuración	YAML	Registro inmutable de parámetros
Métricas	JSON	Resultados de las seis métricas
Señal reconstruida	NPZ	Salida verificable bit a bit
Máscara de daño	NPZ	Trazabilidad de canales faltantes
Tiempos	JSON	Perfil de eficiencia computacional

Tabla 4.2: Ejemplos de trazabilidad entre afirmaciones y artefactos.

Afirmación	Artefacto	Verificación
TRSS supera a MNE en SNR	Registros de métricas por escenario	Diferencia de SNR
15K configuraciones	Base de datos Optuna	Conteo de trials
MNE 50–100× más rápido	Registros de tiempo	Comparación de latencias

4.4. Decisiones de Diseño

Tres decisiones arquitectónicas merecen mención explícita. La **separación estricta de fases** (resultados exploratorios nunca se usaron para ajustar la fase confirmatoria) previene contaminación circular. La **interfaz común forzada** elimina ventajas espurias por diferencias en preprocesamiento. La **inmutabilidad de datos originales** garantiza que las diferencias observadas sean atribuibles exclusivamente a los algoritmos de interpolación.

Capítulo 5

Diseño Experimental

Este capítulo formaliza el diseño experimental: variables, protocolo de validación, plan de análisis estadístico y preguntas de investigación.

5.1. Variables del Experimento

Como **variables independientes** se definen: método de interpolación (18 niveles), conjunto de datos (PhysioNet, BCI IV 2a, MNE Sample), modo de pérdida (aleatorio, contiguo), severidad (10 %, 20 %, 30 %, 40 %) y semilla aleatoria (5 réplicas por condición, como variable de bloque).

Las **variables dependientes** son las seis métricas definidas en la Tabla 3.3: MAE, RMSE, SNR, DTW, LSD y Coherencia.

Como **variables controladas** se fijan: versiones exactas de todas las bibliotecas (documentadas en el Apéndice de Reproducibilidad), hardware de ejecución, semillas globales, y preprocesamiento idéntico para todos los métodos (filtro Butterworth 0.5–45 Hz, referencia promedio común, segmentación en épocas de igual duración).

5.2. Preguntas de Investigación

La Tabla 5.1 vincula cada pregunta con el experimento diseñado para responderla y la evidencia esperada según las hipótesis H1 (TRSS supera a referencias geométricas) y H2 (MNE es equivalente en regímenes favorables).

Tabla 5.1: Relación entre hipótesis, experimentos y evidencia esperada.

Hipótesis y pregunta	Experimento	Evidencia esperada
H1: ¿Supera TRSS a las referencias?	Comparación global de familias	TRSS domina en pérdida continua >20 %
H1: ¿Es la mejora sinérgica?	Ablación α/β	Efecto superaditivo
H1: ¿Preserva ERPs?	Series temporales N100/P300	Amplitud y latencia conservadas al 40 %
H2: ¿Equivalencia en régimen favorable?	Validación confirmatoria TRSS vs. MNE	Equivalencia estadística en pérdida ≤ 20 %
H2: ¿Punto de cruce?	Curvas de degradación por severidad	Cruce en 15–20 %

5.3. Plan de Análisis Estadístico

La elección de las pruebas estadísticas no es arbitraria, sino que responde a las propiedades de los datos y a los objetivos de la evaluación comparativa. A continuación se justifica cada decisión.

5.3.1. Prueba de Wilcoxon para muestras pareadas

Se emplea la prueba de rangos con signo de Wilcoxon como prueba principal de comparación entre métodos. Esta decisión descansa sobre tres fundamentos.

No normalidad de las métricas de error. La prueba de Shapiro-Wilk sobre los resultados agregados rechaza la hipótesis de normalidad con $p < 0,05$ para MAE, RMSE, DTW y LSD. La desviación es particularmente severa en LSD, donde la cola derecha—reconstrucciones de muy baja calidad en escenarios de pérdida extrema— genera una asimetría positiva marcada. Bajo estas condiciones, la prueba t de Student produce valores p no confiables. La prueba de Wilcoxon, en contraste, solo asume que las diferencias son independientes y provienen de una distribución simétrica bajo H_0 , condiciones mucho más débiles y razonables para nuestros datos.

Diseño de medidas repetidas. Cada escenario produce una observación pareada para cada par de métodos A y B , pues ambos operan sobre la misma señal original y la misma máscara de canales faltantes. La prueba de Wilcoxon explota esta estructura: para cada escenario i se calcula la diferencia $d_i = \text{métrica}_A(i) - \text{métrica}_B(i)$, se ordenan los valores absolutos $|d_i|$ asignando rangos R_i , y se computa el estadístico $W = \sum_{i:d_i > 0} R_i$. Bajo H_0 (mediana de diferencias igual a cero), W sigue una distribución conocida. Para tamaños muestrales grandes ($n > 50$), la distribución de W se aproxima mediante una

normal con media $\mu_W = n(n+1)/4$ y varianza $\sigma_W^2 = n(n+1)(2n+1)/24$, aplicando corrección de continuidad para variables discretas.

Eficiencia y robustez. La prueba de Wilcoxon tiene una eficiencia relativa asintótica del 95 % respecto a la prueba t bajo normalidad, pero es sustancialmente más potente bajo desviaciones de la normalidad. En otras palabras, incluso en el peor caso la pérdida de potencia es mínima, mientras que en el caso típico de nuestras métricas —asimétricas y con colas pesadas— la ganancia es considerable.

5.3.2. Corrección de Benjamini-Hochberg para comparaciones múltiples

El diseño experimental genera un número elevado de pruebas simultáneas: 6 métricas $\times$ 18 métodos producen 153 comparaciones por par, que multiplicadas por estratificaciones (3 conjuntos de datos, 2 modos, 4 severidades) superan el millar. Si cada prueba usara $\alpha = 0,05$, la probabilidad de al menos un falso positivo sería $1 - 0,95^k$, que para $k = 1000$ es prácticamente 1. En otras palabras, sin corrección, el experimento garantiza hallar diferencias “significativas” incluso donde no existen.

Para controlar este problema se emplea la corrección de Benjamini-Hochberg (BH), que controla la tasa de falsos descubrimientos (FDR): la proporción esperada de falsos positivos entre todos los rechazos. A diferencia de la corrección de Bonferroni —que controla la tasa de error por familia (FWER, $\text{FWER} \leq m \cdot \alpha$) dividiendo α entre m pruebas y es excesivamente conservadora para estudios con muchas comparaciones—, BH adapta el umbral a la distribución observada de los valores p . El procedimiento es: para m pruebas independientes con valores p ordenados $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$, se encuentra el mayor índice k que satisface $p_{(k)} \leq \frac{k}{m} \cdot \alpha$, y se rechazan $H_{(1)}, \dots, H_{(k)}$.

Se reportan los valores p originales y los ajustados por BH, fijando $\alpha = 0,05$ (FDR al 5 %). Para las comparaciones planificadas de la fase confirmatoria (TRSS vs. MNE), no se aplica corrección por ser hipótesis predefinidas, pero se reporta el tamaño del efecto para contextualizar la magnitud de cualquier diferencia detectada.

5.3.3. Tamaño del efecto e intervalos de confianza

La significancia estadística indica si una diferencia observada es improbable bajo la hipótesis nula, pero no cuantifica la magnitud de esa diferencia. Una diferencia de 0.001 en MAE puede ser estadísticamente significativa con suficientes escenarios, pero clínicamente

irrelevante. Para complementar la significancia se reportan dos medidas de tamaño del efecto: la correlación biserial por rangos $r = 1 - 2U/(n_1 n_2)$ para comparaciones no pareadas, y la mejora relativa mediana $\Delta = \text{mediana}((B - A)/|A|)$ para comparaciones pareadas. Adicionalmente, todos los estimadores puntuales se acompañan de intervalos de confianza al 95 % calculados mediante remuestreo bootstrap jerárquico con 1000 remuestreos que respetan la estructura anidada de los datos (escenarios $\supset$ réplicas). Este método no asume ninguna distribución paramétrica y produce intervalos asimétricos que reflejan fielmente la incertidumbre de los estimadores.

5.3.4. Protocolo de la fase confirmatoria

Para la comparación TRSS vs. MNE-Python en la fase confirmatoria, se emplea un diseño de medidas repetidas: cada uno de los 120 escenarios produce una diferencia pareada d_i en cada métrica. La hipótesis nula H_0 es que la mediana de las diferencias es cero (equivalencia entre métodos). La alternativa H_1 es bilateral. La significancia se evalúa con Wilcoxon signed-rank, y se reporta la tasa de victoria (fracción de escenarios donde TRSS supera a MNE) estratificada por conjunto de datos, modo de pérdida y severidad. Esta estratificación es fundamental porque, como predice la hipótesis H2, la ventaja de TRSS no es uniforme sino condicional al régimen de pérdida.

5.4. Control de Calidad

Antes de cualquier análisis se ejecutaron verificaciones automáticas: (1) todos los archivos contienen las seis métricas, (2) ningún identificador aparece duplicado con resultados diferentes, (3) las máscaras de canales faltantes coinciden con la semilla especificada, (4) se excluyen ejecuciones con valores no numéricos, tiempo excesivo (>10 min) o reconstrucción idéntica a la entrada (falla silenciosa). Estos criterios se aplicaron uniformemente a todos los métodos.

5.5. Síntesis del Diseño

El diseño experimental de esta tesis se distingue de la literatura previa en cuatro aspectos: todos los métodos —incluyendo referencias— fueron optimizados con el mismo motor bayesiano; se incorporó una validación confirmatoria independiente contra la implementación de referencia MNE-Python; la evaluación abarca métricas de amplitud,

morfología y espectro; y los escenarios incluyen pérdida aleatoria y contigua en un rango de severidades clínicamente relevante.

Bibliografia

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019.
- [2] Hubert Banville, Omar Chehab, Aapo Hyvärinen, Denis-Alexander Engemann, and Alexandre Gramfort. Uncovering the structure of clinical EEG signals with self-supervised learning. *Journal of Neural Engineering*, 18(4):046020, 2021. doi: 10.1088/1741-2552/abca18.
- [3] Clemens Brunner, Robert Leeb, Gernot R. Müller-Putz, Alois Schlögl, and Gert Pfurtscheller. BCI Competition IV – Dataset 2a. Graz University of Technology, 2008. URL <https://www.bbci.de/competition/iv/>.
- [4] György Buzsáki. Rhythms of the brain. 2006. doi: 10.1093/acprof:oso/9780195301069.001.0001.
- [5] Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. Convolutional neural networks on graphs with fast localized spectral filtering. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 29, pages 3844–3852, 2016.
- [6] Arnaud Delorme and Scott Makeig. Eeglab: An open source toolbox for analysis of single-trial eeg dynamics including independent component analysis. *Journal of Neuroscience Methods*, 134(1):9–21, 2004. doi: 10.1016/j.jneumeth.2003.10.009.
- [7] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans. Reconstruction of time-varying graph signals via sobolev smoothness. *IEEE Transactions on Signal and Information Processing over Networks*, 8:201–214, 2022. doi: 10.1109/TSIPN.2022.3156886.
- [8] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng,

- and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23): e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215.
- [9] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A Engemann, Daniel Strohmeier, Christian Brodbeck, Roman Goj, Mainak Jas, Teon Brooks, Lauri Parkkonen, et al. Meg and eeg data analysis with mne-python. *Frontiers in neuroscience*, 7:267, 2013.
- [10] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Lauri Parkkonen, and Matti S. Hämäläinen. MNE software for processing MEG and EEG data. *NeuroImage*, 86:446–460, 2014. doi: 10.1016/j.neuroimage.2013.10.027.
- [11] Ian T. Jolliffe. *Principal Component Analysis*. Springer, 2nd edition, 2002. doi: 10.1007/b98835.
- [12] Tzyy-Ping Jung, Scott Makeig, Martin J. McKeown, Anthony J. Bell, Te-Won Lee, and Terrence J. Sejnowski. Imaging brain dynamics using independent component analysis. *Proceedings of the IEEE*, 89(7):1107–1122, 2001. doi: 10.1109/5.939827.
- [13] Chun-Hung Lai, Yi-Ming Chen, and Wen-Chieh Liao. A controlled study of the eeg during the performance of neurofeedback. *Clinical EEG and Neuroscience*, 36(4): 219–225, 2005.
- [14] Fabien Lotte, Laurent Bougrain, Andrzej Cichocki, Maureen Clerc, Marco Congedo, Alain Rakotomamonjy, and Florian Yger. A review of classification algorithms for eeg-based brain–computer interfaces: A 10 year update. *Journal of Neural Engineering*, 15(3):031005, 2018. doi: 10.1088/1741-2552/aab2f2.
- [15] Steven J. Luck. *An Introduction to the Event-Related Potential Technique*. MIT Press, 2nd edition, 2014.
- [16] S. K. Narang and A. Ortega. Signal processing techniques for interpolation in graph structured data. In *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5445–5449, 2013. doi: 10.1109/ICASSP.2013.6638704.
- [17] Paul L. Nunez and Ramesh Srinivasan. *Electric Fields of the Brain: The Neurophysics of EEG*. Oxford University Press, 2nd edition, 2006. doi: 10.1093/acprof:oso/9780195050387.001.0001.

- [18] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst. Graph signal processing: Overview, challenges, and applications. *Proceedings of the IEEE*, 106(5):808–828, 2018. doi: 10.1109/JPROC.2018.2820126.
- [19] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier. Spherical splines for scalp potential and current density mapping. *Electroencephalography and Clinical Neurophysiology*, 72(2):184–187, 1989. doi: 10.1016/0013-4694(89)90180-6.
- [20] Carlos Saldivia, Alejandro Weinstein, and Matías Zañartu. Trss vs. Spherical Splines: A reproducible benchmark for EEG channel interpolation under missing-data scenarios. *In Preparation*, 2026. Manuscript in preparation. Results derived from this thesis.
- [21] Gerwin Schalk, Dennis J. McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R. Wolpaw. BCI2000: A general-purpose brain-computer interface (BCI) system. *IEEE Transactions on Biomedical Engineering*, 51(6):1034–1043, 2004. doi: 10.1109/TBME.2004.827072.
- [22] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst. The emerging field of signal processing on graphs. *IEEE Signal Processing Magazine*, 30(3):83–98, 2013. doi: 10.1109/MSP.2012.2235192.
- [23] Olaf Sporns, Giulio Tononi, and Rolf Kötter. The human connectome: A structural description of the human brain. *PLoS Computational Biology*, 1(4):e42, 2005. doi: 10.1371/journal.pcbi.0010042.
- [24] Jinsung Yoon, Daniel Jarrett, and Mihaela van der Schaar. Time-series generative adversarial networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 32, 2019.