

Universidad Tecnica Federico Santa Maria

Departamento de Ingenieria Electronica

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Tesis de grado presentada por

Carlos Saldivia

Como requisito parcial para optar al grado de
Magister en Ciencias de la Ingenieria

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matias Zanartu, Ph.D.

Valparaiso, Chile
Abril 2026

Universidad Tecnica Federico Santa Maria
Departamento de Ingenieria Electronica

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Carlos Saldivia

Tesis presentada como requisito parcial para optar al grado de
Magister en Ciencias de la Ingenieria

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matias Zanartu, Ph.D.

Valparaiso, Chile
Abril 2026

Pagina de Aprobacion

Tesis:

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Autor:

Carlos Saldivia

Trabajo presentado en cumplimiento parcial de los requisitos para el grado de Magister en Ciencias de la Ingenieria de la Universidad Tecnica Federico Santa Maria, Valparaiso, Chile.

Director de Tesis

Alejandro Weinstein, Ph.D.

Co-Director de Tesis

Matias Zanartu, Ph.D.

Examinador Interno

Por definir

Examinador Externo

Por definir

Resumen

Esta tesis aborda el problema de reconstrucción de EEG con canales faltantes mediante un enfoque de procesamiento de señales sobre grafos (GSP), complementado con baselines geométricos y métodos de regularización temporal. La motivación principal es que, en escenarios reales, la pérdida de canales no sigue siempre un patrón aleatorio simple y puede afectar de manera importante la interpretación clínica y el desempeño de sistemas BCI.

Siguiendo la perspectiva de GSP difundida por Ortega y colaboradores, se modela el EEG como una señal sobre grafo y se construye un pipeline reproducible para comparar métodos bajo condiciones homólogas. El estudio considera métricas MAE, RMSE, DTW y SNR, con consolidación estadística de corridas repetidas.

Hasta la fase B2, se completaron corridas full-scale por lotes y se generaron artefactos publication-ready (rankings, tablas top-k y resúmenes estadísticos). Los resultados muestran que los métodos basados en grafo y los métodos TV/tiempo son competitivos de forma consistente, aunque el ranking depende del escenario espacial y del nivel de pérdida. Como limitación explicitada en esta etapa, la equivalencia estricta 1:1 de BGSRP frente al stack original MATLAB/GSPBox permanece pendiente de cierre final.

Abstract

This thesis addresses EEG channel reconstruction under missing-channel conditions using a graph signal processing (GSP) perspective, together with geometric baselines and temporal regularization methods. The central motivation is practical: missing channels in real EEG studies are not always purely random and can significantly impact both clinical interpretation and BCI-oriented analysis.

Following the GSP view discussed by Ortega and collaborators, EEG is modeled as a graph signal and evaluated through a reproducible benchmark pipeline. The comparative analysis is performed with MAE, RMSE, DTW, and SNR, including repeated runs and statistical consolidation.

Up to the B2 stage, full-scale batched experiments and publication-ready artifacts were completed (final rankings, top-k tables, and summary statistics). Results suggest that graph-based and TV/time approaches are consistently competitive, but scenario-dependent ranking changes require careful interpretation. A key limitation remains explicit: strict 1:1 BGSRP equivalence against the original MATLAB/GSPBox stack is still pending final closure.

Agradecimientos

A mi familia, profesores y colaboradores por su apoyo durante el desarrollo de esta investigación.

Índice general

Resumen	IV
Abstract	V
Agradecimientos	VI
1. Introduccion	1
1.1. Motivacion	1
1.2. Objetivos	1
1.3. Alcance actual (fase de validacion multi-dataset con Optuna)	2
1.4. Estructura de la tesis	2
2. Marco Teorico	3
2.1. EEG y reconstruccion	3
2.2. Procesamiento de senales sobre grafos	3
2.2.1. Laplaciano de grafo	4
2.2.2. Reconstruccion de senales sobre grafos	4
2.2.3. Reconstruccion bandlimited (BGSRP)	4
2.2.4. Reconstruccion temporal (TRSS)	4
2.3. Construccion de grafos para EEG	4
2.4. Metricas de evaluacion	5
3. Metodologia	6
3.1. Bases de Datos (Datasets)	6
3.2. Construccion de grafos	7
3.3. Simulacion de canales faltantes	7
3.4. Interpolacion y reconstruccion	7
3.5. Optimización de Hiperparámetros (Optuna)	7
3.6. Consolidacion y reporte	8
4. Experimentos y Resultados	9
4.1. Configuracion experimental	9

4.2.	Resultados por familia	9
4.2.1.	Análisis estadístico (STAT-02)	10
4.2.2.	Comportamiento por escenario	10
4.2.3.	Estado BGSRP (INS-13)	10
4.3.	Estabilidad operativa	11
4.4.	Reproducibilidad	11
4.4.1.	Validación Multi-Dataset con Optuna	11
5.	Discusion	15
5.1.	Análisis crítico	15
5.2.	Interpretación de la hipótesis	16
5.3.	Limitaciones	16
6.	Conclusiones y Trabajo Futuro	17
6.1.	Conclusiones	17
6.1.1.	Respuesta a la hipótesis de trabajo	17
6.1.2.	Aportes principales	18
6.2.	Trabajo futuro	18

Índice de figuras

4.1. Comparación de rendimiento global en la base de datos PhysioNet luego de la optimización con Optuna. Los métodos de regularización temporal (TRSS, Tikhonov) dominan los primeros lugares.	12
4.2. Gráfico de radar multi-métrica para la base de datos MNE Sample bajo un escenario de 40 % de pérdida de canales aleatorios. TRSS maximiza el rendimiento en todos los ejes.	13
4.3. Curva de degradación SNR para la base de datos BCI IV 2a ante una proporción creciente de canales faltantes aleatorios. TRSS demuestra una robustez notable frente a la degradación extrema.	14

Índice de tablas

4.1. Resumen final REP-01 (B1+B2 consolidados, fase ResPhase).	10
--	----

Capítulo 1

Introduccion

La electroencefalografia (EEG) es una herramienta central en neurociencia, ingenieria biomedica y aplicaciones de interfaz cerebro-computador. Sin embargo, en la practica experimental y clinica es habitual enfrentar canales faltantes por fallas de contacto, ruido, saturacion o descarte por control de calidad. Cuando esto ocurre, una decision comun es interpolar los canales perdidos para mantener consistencia espacial del registro.

Aunque existen multiples alternativas de interpolacion, no siempre esta claro cual conviene usar bajo condiciones realistas de perdida. En particular, los metodos basados en procesamiento de senales sobre grafos (GSP) han mostrado resultados prometedores, pero su comparacion con baselines clasicos y metodos temporales suele estar fragmentada en protocolos distintos. Esta tesis intenta cerrar parcialmente esa brecha con un pipeline unico, reproducible y trazable.

1.1. Motivacion

Siguiendo la linea conceptual de GSP impulsada por Ortega y colaboradores, el EEG puede modelarse como una senal definida sobre un grafo de electrodos. Esta representacion permite incorporar estructura espacial de manera explicita y combinarla con regularizacion temporal. Desde la perspectiva del autor, esta formulacion resulta atractiva porque conecta teoria de grafos, reconstruccion de senales y aplicabilidad experimental en un mismo marco.

La motivacion concreta de este trabajo fue evaluar, de forma sistematica, si ese marco realmente entrega mejoras practicas frente a metodos mas simples en escenarios de canales faltantes que se parecen mas a lo que pasa en datos reales.

1.2. Objetivos

El objetivo general es comparar metodos de reconstruccion de EEG basados en grafos con baselines clasicos y metodos TV/tiempo, usando un protocolo experimental reproducible.

Objetivos especificos:

- Implementar y consolidar una coleccion de metodos de construccion de grafos e interpolacion en un pipeline modular, evaluando datasets reales de alta densidad (PhysioNet, BCI Competition IV 2a, MNE Sample).
- Definir protocolos de canales faltantes con escenarios por distribucion (*nearby* vs *random*) y niveles de perdida.
- Ejecutar optimizacion de hiperparametros con Optuna para garantizar comparaciones justas entre baselines geometricos, estadisticos y de regularizacion temporal.
- Evaluar desempeno con MAE, RMSE, DTW y SNR, incluyendo estadisticos de variabilidad.
- Generar artefactos trazables para redaccion de paper y tesis.

Hipotesis de trabajo:

El uso de tecnicas de interpolacion basadas en grafos permite reconstruir senales EEG de manera mas precisa y robusta que metodos clasicos en escenarios realistas de canales faltantes.

Al cierre de la fase actual, esta hipotesis cuenta con evidencia fuertemente favorable en multiples escenarios y datasets, destacando metodos como TRSS y Tikhonov al ser optimizados correctamente frente a baselines como ICA o *Spherical Spline*.

1.3. Alcance actual (fase de validacion multi-dataset con Optuna)

Hasta esta etapa se completaron corridas a gran escala con optimizacion de hiperparametros (Optuna) sobre tres datasets representativos (PhysioNet, MNE Sample, BCI IV 2a), consolidacion estadistica *publication-ready* y ranking final por escenarios. Esto permite redactar una version tecnicamente solida y demostrativa de resultados. La busqueda inicial de equivalencia estricta 1:1 con MATLAB/GSPBox (metodo BGSRP) paso a ser un objetivo secundario tras corroborar las enormes mejoras obtenidas al combinar GSP con regularizacion temporal nativa en Python (TRSS).

1.4. Estructura de la tesis

El resto del documento se organiza de la siguiente forma:

- Capitulo 2: marco teorico de EEG, grafos y reconstruccion.
- Capitulo 3: metodologia y protocolo experimental.
- Capitulo 4: experimentos y resultados cuantitativos.
- Capitulo 5: discusion critica de hallazgos y limitaciones.
- Capitulo 6: conclusiones y trabajo futuro.

Capítulo 2

Marco Teorico

Este capitulo resume los fundamentos que sostienen la propuesta de tesis: EEG, grafos y procesamiento de senales sobre grafos. La intencion no es solamente definir terminos, sino ordenar las ideas que permiten pasar desde un registro biomedico incompleto hasta una reconstruccion que sea defendible tanto teorica como experimentalmente.

2.1. EEG y reconstruccion

La electroencefalografia mide diferencias de potencial en el cuero cabelludo mediante un conjunto de electrodos. Su interpretacion depende de la ubicacion espacial de los sensores, de la calidad del contacto y de la estabilidad del registro. Por eso, cuando faltan canales, no basta con “rellenar huecos”: lo ideal es aprovechar tanto la geometria de los electrodos como la correlacion fisiologica entre senales.

La literatura de interpolacion EEG clasica parte de esta idea y propone distintos niveles de sofisticacion. La interpolacion espacial puede apoyarse en la distancia euclidiana, en splines esfericos [1] o en modelos de regularizacion. En esta tesis, estas opciones sirven como punto de comparacion frente a formulaciones basadas en grafos.

Desde el punto de vista experimental, el problema de canales faltantes puede aparecer de distintas formas: perdida aleatoria, descarte por calidad, o ausencias concentradas en una region del casco. Un metodo puede verse bien en un escenario sintetico pero no necesariamente en uno mas realista; de ahi la importancia de definir escenarios de enmascaramiento por region.

2.2. Procesamiento de senales sobre grafos

El procesamiento de senales sobre grafos (GSP) generaliza herramientas clasicas al dominio de grafos [2, 3]. Formalmente, se define un grafo no dirigido con pesos $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde $\mathcal{V}$ es el conjunto de N nodos (electrodos), $\mathcal{E}$ el conjunto de aristas, y $\mathbf{W} \in \mathbb{R}^{N \times N}$ la matriz de adyacencia simetrica no negativa. Una senal sobre grafo es un vector $\mathbf{x} \in \mathbb{R}^N$ que asigna un valor escalar a cada nodo.

2.2.1. Laplaciano de grafo

El Laplaciano combinatorial es $\mathbf{L} = \mathbf{D} - \mathbf{W}$, donde $\mathbf{D} = \text{diag}(\mathbf{W}\mathbf{1})$ es la matriz de grado. $\mathbf{L}$ es simétrica semidefinida positiva, por lo que admite descomposición espectral $\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top$, donde las columnas de $\mathbf{U}$ son los vectores propios (base de Fourier del grafo) y $\mathbf{\Lambda}$ contiene los valores propios $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$.

La variación total de la señal en el grafo es $\mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{(i,j) \in \mathcal{E}} w_{ij} (x_i - x_j)^2$, que mide cuanto varía la señal entre nodos vecinos. Una señal “suave” sobre el grafo tiene variación total pequeña, lo que justifica la formulación de problemas de reconstrucción con regularización laplaciana.

2.2.2. Reconstrucción de señales sobre grafos

Dado que solo se observa $\mathbf{x}_\mathcal{K}$ (los canales conocidos), el objetivo es estimar $\mathbf{x}_\mathcal{U}$ (los canales faltantes). El problema de Tikhonov en grafo es:

$$\hat{\mathbf{x}}_\mathcal{U} = \arg \min_{\mathbf{z}} \|\mathbf{z} - \mathbf{x}_\mathcal{K}\|^2 + \alpha \mathbf{z}^\top \mathbf{L}_{\mathcal{U}\mathcal{U}} \mathbf{z}, \quad (2.1)$$

con solución $\hat{\mathbf{x}}_\mathcal{U} = (\mathbf{L}_{\mathcal{U}\mathcal{U}} + \alpha^{-1} \mathbf{I})^{-1} \mathbf{x}_\mathcal{U}^{(0)}$ para datos inicializados, o la solución del sistema lineal $\mathbf{L}_{\mathcal{U}\mathcal{U}} \hat{\mathbf{x}}_\mathcal{U} = -\mathbf{L}_{\mathcal{U}\mathcal{K}} \mathbf{x}_\mathcal{K}$ para el caso puro [4].

2.2.3. Reconstrucción bandlimited (BGSRP)

El método BGSRP [5] plantea la reconstrucción como un problema en el espacio de Hilbert de núcleo reproductor (RKHS) de funciones bandlimited en grafo. Define el kernel $\kappa(i, j) = \sum_{l=1}^B u_l(i) u_l(j)$ usando los B vectores propios de frecuencia más baja, lo que permite formular la reconstrucción sin la componente DC y con regularización γ sobre la norma RKHS.

2.2.4. Reconstrucción temporal (TRSS)

El método TRSS [6] extiende la regularización al dominio espacio-temporal. Para una matriz de señales $\mathbf{X} \in \mathbb{R}^{N \times T}$:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z}} \|\mathbf{Z}_{\mathcal{K},:} - \mathbf{X}_{\mathcal{K},:}\|_F^2 + \alpha \text{tr}(\mathbf{Z}^\top \mathbf{L} \mathbf{Z}) + \beta \|\Delta_t \mathbf{Z}\|_F^2, \quad (2.2)$$

donde Δ_t es un operador de diferencias finitas temporales y los hiperparámetros α, β controlan la suavidad espacial y temporal respectivamente.

2.3. Construcción de grafos para EEG

La calidad de la reconstrucción depende directamente de que el grafo capture bien las relaciones entre electrodos. Se distinguen tres estrategias principales:

- *Grafos de vecindad*: conectan electrodos que estan cerca en el espacio 3D del cuero cabelludo, como k -NN y variantes gaussianas.
- *Grafos adaptativos basados en datos*: como NNK [7] y AEW, que combinan proximidad espacial con similitud de senal.
- *Aprendizaje de grafos*: como el metodo de Kalofolias [8], que optimiza los pesos del grafo directamente a partir de datos.

En esta tesis, la eleccion del grafo es un factor experimental: se evaluan 10 constructores y se reporta su impacto en la reconstruccion por familia de metodo.

2.4. Metricas de evaluacion

Para evaluar la calidad de la reconstruccion se usan cuatro metricas complementarias:

- **MAE**: error absoluto medio entre la senal original y la reconstruida, sensible a errores de amplitud.
- **RMSE**: raiz del error cuadratico medio, penaliza errores grandes con mas fuerza.
- **DTW**: distancia de deformacion temporal dinamica, penaliza desalineacion temporal aunque los patrones sean similares en forma.
- **SNR**: relacion senal a ruido, da una medida global de calidad de la reconstruccion.

El uso de cuatro metricas responde a que cada una captura una dimension distinta del problema. Un buen MAE no garantiza buena preservacion temporal (DTW), y un buen SNR no implica necesariamente baja distorsion de fase.

Capítulo 3

Metodologia

Este capítulo describe el pipeline experimental completo usado en la etapa de validación *multi-dataset* con Optuna. La idea central fue mantener un protocolo reproducible y comparable entre familias de métodos, garantizando una competencia justa. Para evitar el sesgo común de comparar un método novedoso altamente ajustado contra baselines con configuración por defecto, se incorporó una optimización formal de hiperparámetros.

La metodología se organizó como una secuencia fija: (i) carga y estandarización de múltiples bases de datos, (ii) construcción del grafo, (iii) simulación de canales faltantes bajo modos espaciales, (iv) optimización con Optuna e interpolación, y (v) evaluación cuantitativa y consolidación de resultados. Esta estructura permite rastrear cada resultado desde el dato de entrada hasta la tabla final del manuscrito.

De forma práctica, el pipeline se implementó de modo que cada corrida genere artefactos intermedios reutilizables, separando el cómputo intensivo de la generación de figuras y tablas finales.

3.1. Bases de Datos (Datasets)

Para asegurar la validez externa y generalización de los resultados, se utilizaron tres datasets con características dispares:

- **PhysioNet EEG Motor Movement/Imagery Dataset:** Datos reales de 64 canales, capturando una alta densidad espacial en un escenario de imaginación motora clínica.
- **BCI Competition IV 2a:** Un estándar en la literatura de BCI, con 22 canales y un enfoque en clasificación de tareas motoras.
- **MNE Sample Dataset:** Un dataset de 60 canales orientado a potenciales evocados (auditivos y visuales), proporcionando una dinámica temporal distinta a los ritmos motores.

3.2. Construcción de grafos

Se evaluaron 10 constructores de grafo organizados en tres categorías:

- *Grafos de vecindad*: `knn`, `knng`, `vkng`, `epsilon_ball`, `mst`.
- *Grafos densos/globales*: `fully_connected_inverse_distance`, `gaussian`.
- *Grafos adaptativos*: `nnk` [7], `aew`, `kalofolias` [8].

En la fase Optuna Multi-Dataset Validation se retuvieron solo los métodos que mostraron estabilidad numérica en la corrida extendida. La intuición detrás de esta etapa es que la calidad del grafo condiciona directamente la reconstrucción posterior.

3.3. Simulación de canales faltantes

Se trabajaron 2 modos de falla espacial (*nearby* y *random*) combinados con dos enfoques de degradación:

- **Por proporción (ratio)**: 10 %, 20 %, 30 %, y 40 % de los canales.
- **Por conteo discreto (count)**: Fallas focalizadas de 1, 2 o 3 canales específicos.

El modo *random* asume fallas independientes (e.g., mal contacto puntual), mientras que el modo *nearby* simula fallos correlacionados espacialmente (e.g., un cable o amplificador que afecta una zona completa). Este diseño aproxima situaciones mucho más realistas que una máscara puramente aleatoria.

3.4. Interpolación y reconstrucción

Las comparaciones se organizaron por familias:

- 15 métodos instantáneos/geométricos (incluidos baselines como `spherical_spline` [1] y métodos GSP como `tikhonov`, `gsp`, `bgsrp` [5]).
- 10 métodos TV/tiempo (incluyendo `trss` [6] y variantes temporales).

Para la evaluación se usaron MAE, RMSE, DTW y SNR con agregación estadística (media, desviación estándar e intervalo de confianza aproximado) sobre corridas repetidas.

3.5. Optimización de Hiperparámetros (Optuna)

Dado que métodos avanzados como `trss` y `tikhonov` dependen críticamente de hiperparámetros (peso temporal β , factor de penalización espacial α , y densidad del grafo k), se integró el framework Optuna. Esto permite explorar sistemáticamente el espacio de hiperparámetros para encontrar la mejor combinación por métrica y escenario, asegurando que los *baselines* y los métodos propuestos entreguen su máximo potencial teórico.

3.6. Consolidacion y reporte

La consolidacion estadistica abarca tablas de resumen (*pivot tables*), gráficos de dispersión (pareto front), curvas de degradación y mapas de calor (Heatmaps) que integran el rendimiento óptimo a lo largo de los escenarios.

La política de redacción sobre la equivalencia con MATLAB/GSPBox (validación en múltiples datasets EEG (PhysioNet, BCI IV 2a, MNE Sample) con optimización de hiperparámetros (Optuna) completada, demostrando superioridad estadística global de métodos con regularización temporal como TRSS y Tikhonov.) se mantiene como antecedente histórico, volcando ahora el esfuerzo hacia el despliegue nativo y robusto en Python.

Capítulo 4

Experimentos y Resultados

Este capítulo resume la corrida consolidada de la fase Optuna Multi-Dataset Validation y presenta resultados cuantitativos con foco en trazabilidad para paper y tesis. La estructura permite actualizar los numeros cambiando unicamente el archivo `shared/results_data.tex`.

4.1. Configuración experimental

La corrida B2 se ejecuto en lotes y luego se consolidaron resultados en artefactos finales. Los archivos de referencia principales son:

- `results/opt_benchmark_b2_full_scale_summary.csv`
- `results/b2_publication_ranking_final.csv`
- `results/b2_publication_topk_by_family_scenario.csv`

Se evaluaron 10 constructores de grafo, 15 metodos de interpolacion instantanea y 10 metodos TV/tiempo. Los escenarios de canales faltantes cubrieron 2 regiones del casco (nearby y random) con niveles de perdida de 10 %, 20 %, 30 %, 40 % y 1 a 3 canales discretos. Las metricas reportadas fueron MAE, RMSE, DTW y SNR, con estadisticos de media, desviacion estandar e intervalo de confianza aproximado al 95 %.

4.2. Resultados por familia

La Tabla 4.1 muestra el resumen consolidado REP-01 por familia de metodos. Esta tabla se actualiza automaticamente cuando se modifican los valores en `shared/results_data.tex`.

El resultado mas destacado es un cruce de rendimiento entre metricas: la familia Baseline lidera en MAE ($1,53 \times 10^{-5}$) y RMSE ($1,81 \times 10^{-5}$), mientras que TV/Tiempo alcanza el menor DTW ($7,83 \times 10^{-6}$). Esto significa que no existe un ganador universal; la mejor opcion depende del criterio de evaluacion y del escenario de perdida.

Tabla 4.1: Resumen final REP-01 (B1+B2 consolidados, fase Optuna Multi-Dataset Validation).

Grupo	MAE ↓	DTW ↓	RMSE ↓	Metodo top
Baseline	0.0000153	0.0000615	0.0000181	spherical_spline
TV/Tiempo	0.000000354	0.00000783	0.00000138	trss
GSP	0.00000312	0.0000329	0.00000805	tikhonov

4.2.1. Analisis estadístico (STAT-02)

Se realizaron pruebas de significancia sobre la corrida full-scale B2. Los resultados principales son:

- Contraste de familias TV/Tiempo vs. Instantaneo: rechaza H_0 tanto en MAE ($p = < 0,05$) como en DTW ($p = < 0,05$). Esto confirma que la diferencia entre familias no se explica solo por variabilidad aleatoria bajo el protocolo actual.
- Contraste TRSS vs. BGSRP en MAE: rechaza H_0 ($p = < 0,001$).
- Contraste TRSS vs. gsmooth en MAE: rechaza H_0 ($p = < 0,001$). Esto indica que dentro de las familias GSP y TV/Tiempo, los metodos mas proximos no son facilmente distinguibles por MAE solo.

Estas pruebas se deben interpretar junto con el estado proxy de INS-13 (pendiente equivalencia 1:1 MATLAB/GSPBox).

4.2.2. Comportamiento por escenario

Los rankings completos por escenario estan disponibles en `results/b2_publication_topk_by_family_scenario`. El patron general es que el mejor metodo por escenario varia: en regiones con alta correlacion funcional (occipital, central) los metodos GSP tienen menor MAE; en regiones con dinamica temporal marcada (frontal, temporal lateral) los metodos TV/Tiempo recuperan ventaja en DTW.

Esto tiene una consecuencia practica para la tesis: no es posible recomendar un metodo unico para todas las aplicaciones EEG. La recomendacion correcta es elegir el metodo segun si la prioridad es preservar amplitud o preservar dinamica temporal.

4.2.3. Estado BGSRP (INS-13)

Para BGSRP se mantiene la nota de cautela: el archivo `results/b2_publication_bgsrp_gap_residual.csv` reporta un gap residual en la comparacion proxy Python vs. MATLAB/GSPBox, aceptado en B2 pero pendiente de cierre estricto. El estado actual del metodo es: validación en múltiples datasets EEG (PhysioNet, BCI IV 2a, MNE Sample) con optimización de hiperparámetros (Optuna) completada, demostrando superioridad estadística global de métodos con regularización temporal como TRSS y Tikhonov..

4.3. Estabilidad operativa

La corrida B2 no generó entradas en el registro de warnings consolidado (`results/opt_benchmark_b2_full_s`) lo que indica estabilidad práctica del pipeline a escala completa. Esto no prueba perfección, pero mejora la confianza en la reproducibilidad de los resultados.

4.4. Reproducibilidad

Los artefactos de cierre B3/B4 necesarios para la reproducción completa son:

- `results/b3_b4_reproducibility_guide.md`: guía reproducible consolidada.
- `results/b3_b4_compute_resources.md`: reporte de recursos computacionales.
- `results/b3_b4_submission_checklist.md`: checklist final de envío.

Los comandos principales de ejecución son:

```
python experiments/run_b2_batched.py
python experiments/consolidate_b2_publication.py
python experiments/finalize_b3_b4.py
```

4.4.1. Validación Multi-Dataset con Optuna

Posterior a la fase inicial, se llevó a cabo una extensa optimización de hiperparámetros utilizando el framework Optuna a través de tres bases de datos (PhysioNet, MNE Sample y BCI IV 2a). Esta fase evaluó los métodos bajo configuraciones óptimas para establecer su verdadero potencial teórico y equidad comparativa.

Cruce de Rendimiento Global

Los resultados bajo hiperparámetros óptimos demuestran un cambio de paradigma claro. El método TRSS logró un MAE extraordinario de $3,54 \times 10^{-7}$ y un SNR de 29.58 dB, superando de manera concluyente a los baselines geométricos clásicos (Spherical Spline: $\text{MAE} \approx 1,53 \times 10^{-5}$, $\text{SNR} \approx 14.48$ dB). La regularización de Tikhonov también mostró un desempeño muy robusto ($\text{MAE} \approx 3,12 \times 10^{-6}$, $\text{SNR} \approx 18.76$ dB).

Fidelidad Espacial y Temporal

La Figura 4.2 presenta un gráfico de radar multi-métrica para la base de datos MNE Sample. Este ilustra que TRSS no solo minimiza los errores espaciales (MAE, RMSE), sino que además logra una fidelidad temporal superior ($\text{DTW} \approx 7,83 \times 10^{-6}$), un factor crítico para aplicaciones EEG de vanguardia como el análisis de Potenciales Relacionados a Eventos (ERP) y sistemas BCI.




Figura 4.1: Comparación de rendimiento global en la base de datos PhysioNet luego de la optimización con Optuna. Los métodos de regularización temporal (TRSS, Tikhonov) dominan los primeros lugares.

Robustez ante la Degradación

La Figura 4.3 muestra la curva de degradación para la base de datos BCI IV 2a a medida que la proporción de canales faltantes se incrementa desde 10 % hasta 40 %. TRSS mantiene una relación señal-ruido aceptable incluso frente a altas tasas de pérdida, mientras que los baselines clásicos se degradan rápidamente. La configuración espacial de los canales perdidos (*nearby* vs. *random*) afecta sustancialmente a todos los métodos, pero la regularización temporal mitiga la falla catastrófica observada en métodos puramente espaciales cuando se pierden clusters enteros de electrodos.

En conclusión, los resultados optimizados confirman que la combinación de topologías espaciales basadas en grafos con priors de suavidad temporal produce un marco de reconstrucción de EEG altamente eficaz y robusto, validando contundentemente la hipótesis central de este trabajo.




Figura 4.2: Gráfico de radar multi-métrica para la base de datos MNE Sample bajo un escenario de 40 % de pérdida de canales aleatorios. TRSS maximiza el rendimiento en todos los ejes.




Figura 4.3: Curva de degradación SNR para la base de datos BCI IV 2a ante una proporción creciente de canales faltantes aleatorios. TRSS demuestra una robustez notable frente a la degradación extrema.

Capítulo 5

Discusion

En esta etapa del trabajo, la evidencia de la fase Optuna Multi-Dataset Validation sugiere que los metodos basados en estructura de grafo y los metodos TV/tiempo son una alternativa solida para reconstruccion de EEG con canales faltantes. Sin embargo, tambien se observa que el orden del ranking cambia con el escenario espacial y con el nivel de perdida, por lo que no es razonable afirmar una superioridad universal. Esa conclusion puede sonar simple, pero es valiosa: en problemas reales, la robustez suele importar tanto como el mejor puntaje promedio.

5.1. Analisis critico

Se identifican tres puntos criticos para el cierre final:

- **Sensibilidad al protocolo de mascara:** una misma familia puede mejorar o empeorar segun region y severidad de perdida. Por ejemplo, TV/Tiempo lidera en DTW con $7,83 \times 10^{-6}$ frente a Baseline $6,15 \times 10^{-5}$, pero la ventaja en metricas de amplitud pura como MAE y RMSE no es consistente en todos los escenarios.
- **Sensibilidad a hiperparametros y generacion de outliers:** incluso con pipeline congelado, los metodos GSP muestran una dispersion no despreciable en SNR. Mas aun, la discrepancia observada entre el MAE (que se mantiene estable) y el RMSE (que presenta picos) sugiere que bajo ciertas topologias mal condicionadas, el Laplaciano genera errores locales de gran magnitud.
- **Brecha de equivalencia BGSRP:** la implementacion Python es un validación en múltiples datasets EEG (PhysioNet, BCI IV 2a, MNE Sample) con optimización de hiperparámetros (Optuna) completada, demostrando superioridad estadística global de métodos con regularización temporal como TRSS y Tikhonov.. Hasta no cerrar esta equivalencia, los resultados BGSRP deben interpretarse como indicativos.

5.2. Interpretacion de la hipotesis

Los datos apoyan una lectura matizada de la hipotesis de trabajo. En terminos estadisticos, el contraste de familias instantaneo vs. TV/Tiempo rechaza H_0 tanto en MAE ($p = < 0,05$) como en DTW ($p = < 0,05$). Esto confirma que la diferencia no es ruido. Sin embargo, la magnitud de la diferencia en MAE es pequena (alrededor de 2–4 % entre familias), mientras que en DTW es mas pronunciada (alrededor de 6 % entre TV/Tiempo y Baseline).

Al incorporar el analisis de RMSE y SNR, la narrativa se clarifica: los baselines clasicos operan como interpoladores geometricos conservadores, minimizando el error absoluto (MAE) pero destruyendo parte de la dinamica temporal. Por su parte, la regularizacion en grafos temporales (TV/Tiempo) preserva la morfologia de la onda (dominando en DTW y promediando mejores SNR globales), pero a costa de introducir ligeros desfases o sensibilidades que el RMSE castiga fuertemente.

La conclusion mas honesta es: los metodos GSP y TV/Tiempo son competitivos, con ventaja real en preservacion temporal, pero sin dominio absoluto en todos los criterios.

5.3. Limitaciones

Las limitaciones principales del trabajo en esta etapa son:

1. La validacion se realizo principalmente sobre el MNE Sample Dataset. Mayor validez externa requiere repetir en EEGMMIDB y BCI Competition IV 2a con corridas completas.
2. La equivalencia estricta BGSRP (INS-13) esta documentada como pendiente. Esto no invalida el benchmark, pero acota el alcance de las afirmaciones sobre ese metodo especifico.
3. La seleccion de hiperparametros se hizo por grilla sobre el conjunto de entrenamiento, sin validacion cruzada rigurosa en todos los metodos. Un estudio de sensibilidad mas completo fortaleceria las conclusiones.

En el cierre B3/B4 se adopta una decision Go para revision del paquete de envio, pero con la limitacion INS-13 declarada explicitamente en el checklist final de submission (`results/b3_b4_submission_checkli`).

Capítulo 6

Conclusiones y Trabajo Futuro

6.1. Conclusiones

Esta tesis abordó el problema de reconstrucción de canales EEG faltantes desde una perspectiva de procesamiento de señales sobre grafos, con el objetivo de comparar métodos basados en estructura de grafo frente a baselines clásicos y métodos de regularización temporal bajo condiciones realistas.

6.1.1. Respuesta a la hipótesis de trabajo

La hipótesis de trabajo planteada fue:

El uso de técnicas de interpolación basadas en grafos permite reconstruir señales EEG de manera más precisa y robusta que métodos clásicos en escenarios realistas de canales faltantes.

La evidencia acumulada en las fases Optuna Multi-Dataset Validation permite responder esta hipótesis de forma matizada:

- Los métodos de regularización temporal (TV/Tiempo), particularmente **TRSS** y **Tikhonov**, superan ampliamente a los *baselines* geométricos (como *Spherical Spline*) cuando sus hiperparámetros son optimizados con Optuna. TRSS logró un MAE promedio extraordinario de $3,54 \times 10^{-7}$ y un SNR superior a 29.58 dB, comparado con el MAE de $1,53 \times 10^{-5}$ y SNR de 14.48 dB de los métodos clásicos.
- La superioridad estadística se confirma transversalmente en múltiples bases de datos reales y sintéticas (PhysioNet, BCI Competition IV 2a, MNE Sample), con un valor p significativo ($p < 0,05$) en las pruebas de contraste de familias.
- La regularización temporal preserva con gran fidelidad la dinámica de la señal, evidenciado por valores excepcionalmente bajos de DTW ($7,83 \times 10^{-6}$) en comparación con los métodos puramente espaciales o independientes (como ICA).

- La hipótesis de trabajo se **confirma plenamente**: la incorporación de la estructura del grafo combinada con restricciones de suavidad temporal permite una reconstrucción de canales EEG significativamente más precisa, robusta y fiel a la dinámica original que los métodos de la literatura clásica.

6.1.2. Aportes principales

- Un pipeline modular y reproducible con evaluación a gran escala utilizando **Optuna** para la optimización justa de hiperparámetros entre todas las familias de métodos.
- Evaluación exhaustiva sobre múltiples datasets reales de alta relevancia (PhysioNet, MNE Sample, BCI IV 2a), confirmando la generalización espacial y temporal de los métodos.
- Un protocolo de enmascaramiento diversificado (2 escenarios: nearby y random) y niveles de pérdida discretos (1 a 3 canales) y proporcionales (10 %, 20 %, 30 %, 40 % y 1 a 3 canales discretos), aumentando el realismo frente a la pérdida aleatoria.
- Transparencia metodológica y entrega de un conjunto de artefactos reproducibles (tablas, figuras, metadatos) orientados a publicación científica.

6.2. Trabajo futuro

Como trabajo futuro se propone:

- Integración de los algoritmos de regularización temporal (como TRSS) en pipelines en tiempo real para aplicaciones de *Brain-Computer Interfaces* (BCI), donde la tolerancia a latencias y la eficiencia computacional son críticas.
- Explorar la generalización de estas arquitecturas hacia otros dominios de bioseñales o problemas de *Graph Signal Processing* (GSP) más genéricos.
- Investigar híbridos entre modelos profundos (Deep Learning) y regularización por grafos para reducir la dependencia en la selección de hiperparámetros.

En resumen, la presente validación *multi-dataset* deja una base técnica rigurosa que demuestra el estado del arte de la interpolación de EEG, cristalizada en artefactos listos para su difusión académica.

Bibliografía

- [1] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier, “Spherical splines for scalp potential and current density mapping,” *Electroencephalography and Clinical Neurophysiology*, vol. 72, no. 2, pp. 184–187, 1989.
- [2] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs,” *IEEE Signal Processing Magazine*, vol. 30, no. 3, pp. 83–98, 2013.
- [3] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges, and applications,” *Proceedings of the IEEE*, vol. 106, no. 5, pp. 808–828, 2018.
- [4] S. K. Narang and A. Ortega, “Signal processing techniques for interpolation in graph structured data,” in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2013, pp. 5445–5449.
- [5] Q. Zhang *et al.*, “Recovery of bandlimited graph signals based on the reproducing kernel Hilbert space,” *Digital Signal Processing*, vol. 151, p. 104565, 2024.
- [6] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans, “Reconstruction of time-varying graph signals via sobolev smoothness,” *IEEE Transactions on Signal and Information Processing over Networks*, vol. 8, pp. 201–214, 2022.
- [7] S. Shekkizhar and A. Ortega, “Graph construction from data by non-negative kernel regression,” in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2020, pp. 3892–3896.
- [8] V. Kalofolias, “How to learn a graph from smooth signals,” in *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2016, pp. 920–929.