


Universidad Tecnica Federico Santa Maria

Departamento de Ingenieria Electronica



Reconstruccion de Senales EEG mediante GSP e Interpolacion

Tesis de grado presentada por

Carlos Saldivia

Como requisito parcial para optar al grado de
Magister en Ciencias de la Ingenieria

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matias Zanartu, Ph.D.

Valparaiso, Chile
Abril 2026

Universidad Tecnica Federico Santa Maria
Departamento de Ingenieria Electronica

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Carlos Saldivia

Tesis presentada como requisito parcial para optar al grado de
Magister en Ciencias de la Ingenieria

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matias Zanartu, Ph.D.

Valparaiso, Chile
Abril 2026

Pagina de Aprobacion

Tesis:

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Autor:

Carlos Saldivia

Trabajo presentado en cumplimiento parcial de los requisitos para el grado de Magister en Ciencias de la Ingenieria de la Universidad Tecnica Federico Santa Maria, Valparaiso, Chile.

Director de Tesis

Alejandro Weinstein, Ph.D.

Co-Director de Tesis

Matias Zanartu, Ph.D.

Examinador Interno

Por definir

Examinador Externo

Por definir

Resumen

Esta tesis aborda el problema de reconstrucción de EEG con canales faltantes mediante un enfoque de procesamiento de señales sobre grafos (GSP), complementado con baselines geométricos y métodos de regularización temporal. La motivación principal es que, en escenarios reales, la pérdida de canales no sigue siempre un patrón aleatorio simple y puede afectar de manera importante la interpretación clínica y el desempeño de sistemas BCI.

Siguiendo la perspectiva de GSP difundida por Ortega y colaboradores, se modela el EEG como una señal sobre grafo y se construye un pipeline reproducible para comparar métodos bajo condiciones homólogas. El estudio considera métricas MAE, RMSE, DTW y SNR, con consolidación estadística de corridas repetidas.

Hasta la fase B2, se completaron corridas full-scale por lotes y se generaron artefactos publication-ready (rankings, tablas top-k y resúmenes estadísticos). Los resultados muestran que los métodos basados en grafo y los métodos TV/tiempo son competitivos de forma consistente, aunque el ranking depende del escenario espacial y del nivel de pérdida. Como limitación explicitada en esta etapa, la equivalencia estricta 1:1 de BGSRP frente al stack original MATLAB/GSPBox permanece pendiente de cierre final.

Abstract

This thesis addresses EEG channel reconstruction under missing-channel conditions using a graph signal processing (GSP) perspective, together with geometric baselines and temporal regularization methods. The central motivation is practical: missing channels in real EEG studies are not always purely random and can significantly impact both clinical interpretation and BCI-oriented analysis.

Following the GSP view discussed by Ortega and collaborators, EEG is modeled as a graph signal and evaluated through a reproducible benchmark pipeline. The comparative analysis is performed with MAE, RMSE, DTW, and SNR, including repeated runs and statistical consolidation.

Up to the B2 stage, full-scale batched experiments and publication-ready artifacts were completed (final rankings, top-k tables, and summary statistics). Results suggest that graph-based and TV/time approaches are consistently competitive, but scenario-dependent ranking changes require careful interpretation. A key limitation remains explicit: strict 1:1 BGSRP equivalence against the original MATLAB/GSPBox stack is still pending final closure.

Agradecimientos

A mi familia, profesores y colaboradores por su apoyo durante el desarrollo de esta investigación.

Índice general

Resumen	IV
Abstract	V
Agradecimientos	VI
1. Introduccion	1
1.1. Motivacion	1
1.2. Objetivos	1
1.3. Alcance actual (fase B2)	2
1.4. Estructura de la tesis	2
2. Marco Teorico	3
2.1. EEG y reconstruccion	3
2.2. Procesamiento de senales sobre grafos	3
2.2.1. Laplaciano de grafo	4
2.2.2. Reconstruccion de senales sobre grafos	4
2.2.3. Reconstruccion bandlimited (BGSRP)	4
2.2.4. Reconstruccion temporal (TRSS)	4
2.3. Construccion de grafos para EEG	4
2.4. Metricas de evaluacion	5
3. Metodologia	6
3.1. Construccion de grafos	6
3.2. Simulacion de canales faltantes	6
3.3. Interpolacion y reconstruccion	7
3.4. Consolidacion y reporte	7
4. Experimentos y Resultados	8
4.1. Configuracion experimental	8
4.2. Resultados por familia	8
4.2.1. Analisis estadistico (STAT-02)	9

4.2.2.	Comportamiento por escenario	9
4.2.3.	Estado BGSRP (INS-13)	9
4.3.	Estabilidad operativa	10
4.4.	Reproducibilidad	10
4.4.1.	Iteración <code>it02</code> : TV/Time methods on synthetic _{<i>road</i>} ^{<i>corrected</i>} _{<i>per-scenario</i>} ^{<i>RMSEcomparison</i>} (<i>C</i> _{<i>based</i>})	10
4.4.2.	Iteración <code>it03_synthetic_beta</code> : TV/Time methods on synthetic _{<i>beta</i>} (<i>betaband</i> 13–30 <i>Hz</i>) ^{<i>allscenarios</i>}	11
4.4.3.	Iteración <code>it05b_synthetic_three</code> : TV/Time family on all 3 synthetic datasets — family-level comparison	11
4.4.4.	Iteración <code>it06b_kalofolias_nnk_3syn</code> : Kalofolias + NNK graphs on all 3 synthetic datasets — learnable graph topology	12
4.4.5.	Iteración <code>it07b_knn_3syn</code> : KNN graphs (k=3 and k=5) on all 3 synthetic datasets — KNN topology analysis	13
5.	Discusion	18
5.1.	Análisis crítico	18
5.2.	Interpretación de la hipótesis	18
5.3.	Limitaciones	19
6.	Conclusiones y Trabajo Futuro	20
6.1.	Conclusiones	20
6.1.1.	Respuesta a la hipótesis de trabajo	20
6.1.2.	Aportes principales	21
6.2.	Trabajo futuro	21

Índice de figuras

4.1. Error absoluto medio (MAE, media $\pm$ IC95) por método, iteración <code>it02</code> . Barras naranjas: familia TV/Tiempo; barras azules: familia Instante.	11
4.2. Comparación familia TV/Tiempo vs. Instante: MAE y RMSE en función del porcentaje de canales faltantes, iteración <code>it02</code>	12
4.3. Familia TV/Tiempo vs Instante — iteración <code>it03_synthetic_beta</code>	12
4.4. Familia TV/Tiempo vs Instante — iteración <code>it05b_synthetic_three</code>	14
4.5. Familia TV/Tiempo vs Instante — iteración <code>it06b_kalofolias_nnk_3syn</code>	15
4.6. Familia TV/Tiempo vs Instante — iteración <code>it07b_knn_3syn</code>	16

Índice de tablas

4.1. Resumen final REP-01 (B1+B2 consolidados, fase B2/B3/B4).	9
4.2. EEG channel reconstruction — MAE, RMSE, SNR by method and missing ratio (mean $\pm$ std). Iteration: <code>it02</code>	13
4.3. Significance tests — pairwise comparisons (Bonferroni $\alpha = 0,0100$). Iteration: <code>it02</code>	14
4.4. EEG reconstruction — MAE/RMSE/SNR. Iteration <code>it03_{synthetic_{beta}}</code>	14
4.5. EEG reconstruction — MAE/RMSE/SNR. Iteration <code>it05_{synthetic_{tthree}}</code>	15
4.6. EEG reconstruction — MAE/RMSE/SNR. Iteration <code>it06_{alofolias_{nnk3syn}}</code>	16
4.7. EEG reconstruction — MAE/RMSE/SNR. Iteration <code>it07_{nnk3syn}</code>	17

Capítulo 1

Introduccion

La electroencefalografia (EEG) es una herramienta central en neurociencia, ingenieria biomedica y aplicaciones de interfaz cerebro-computador. Sin embargo, en la practica experimental y clinica es habitual enfrentar canales faltantes por fallas de contacto, ruido, saturacion o descarte por control de calidad. Cuando esto ocurre, una decision comun es interpolar los canales perdidos para mantener consistencia espacial del registro.

Aunque existen multiples alternativas de interpolacion, no siempre esta claro cual conviene usar bajo condiciones realistas de perdida. En particular, los metodos basados en procesamiento de senales sobre grafos (GSP) han mostrado resultados prometedores, pero su comparacion con baselines clasicos y metodos temporales suele estar fragmentada en protocolos distintos. Esta tesis intenta cerrar parcialmente esa brecha con un pipeline unico, reproducible y trazable.

1.1. Motivacion

Siguiendo la linea conceptual de GSP impulsada por Ortega y colaboradores, el EEG puede modelarse como una senal definida sobre un grafo de electrodos. Esta representacion permite incorporar estructura espacial de manera explicita y combinarla con regularizacion temporal. Desde la perspectiva del autor, esta formulacion resulta atractiva porque conecta teoria de grafos, reconstruccion de senales y aplicabilidad experimental en un mismo marco.

La motivacion concreta de este trabajo fue evaluar, de forma sistematica, si ese marco realmente entrega mejoras practicas frente a metodos mas simples en escenarios de canales faltantes que se parecen mas a lo que pasa en datos reales.

1.2. Objetivos

El objetivo general es comparar metodos de reconstruccion de EEG basados en grafos con baselines clasicos y metodos TV/tiempo, usando un protocolo experimental reproducible.

Objetivos especificos:

- Implementar y consolidar una coleccion de metodos de construccion de grafos e interpolacion en un pipeline modular.
- Definir protocolos de canales faltantes con escenarios por region y niveles de perdida.
- Evaluar desempeno con MAE, RMSE, DTW y SNR, incluyendo estadisticos de variabilidad.
- Generar artefactos trazables para redaccion de paper y tesis.

Hipotesis de trabajo:

El uso de tecnicas de interpolacion basadas en grafos permite reconstruir senales EEG de manera mas precisa y robusta que metodos clasicos en escenarios realistas de canales faltantes.

Al cierre de la fase B2, esta hipotesis cuenta con evidencia favorable en varios escenarios, aunque todavia con pendientes de cierre en equivalencia estricta BGSRP 1:1 con MATLAB/GSPBox.

1.3. Alcance actual (fase B2)

Hasta esta etapa se completaron corridas full-scale por lotes, consolidacion estadistica publication-ready y ranking final por escenarios. Esto permite redactar una version tecnicamente solida de resultados. Al mismo tiempo, se mantiene una postura cauta: no todos los frentes de validacion paper-faithful estan cerrados al 100 %.

1.4. Estructura de la tesis

El resto del documento se organiza de la siguiente forma:

- Capitulo 2: marco teorico de EEG, grafos y reconstruccion.
- Capitulo 3: metodologia y protocolo experimental.
- Capitulo 4: experimentos y resultados cuantitativos.
- Capitulo 5: discusion critica de hallazgos y limitaciones.
- Capitulo 6: conclusiones y trabajo futuro.

Capítulo 2

Marco Teorico

Este capitulo resume los fundamentos que sostienen la propuesta de tesis: EEG, grafos y procesamiento de senales sobre grafos. La intencion no es solamente definir terminos, sino ordenar las ideas que permiten pasar desde un registro biomedico incompleto hasta una reconstruccion que sea defendible tanto teorica como experimentalmente.

2.1. EEG y reconstruccion

La electroencefalografia mide diferencias de potencial en el cuero cabelludo mediante un conjunto de electrodos. Su interpretacion depende de la ubicacion espacial de los sensores, de la calidad del contacto y de la estabilidad del registro. Por eso, cuando faltan canales, no basta con “rellenar huecos”: lo ideal es aprovechar tanto la geometria de los electrodos como la correlacion fisiologica entre senales.

La literatura de interpolacion EEG clasica parte de esta idea y propone distintos niveles de sofisticacion. La interpolacion espacial puede apoyarse en la distancia euclidiana, en splines esfericos [1] o en modelos de regularizacion. En esta tesis, estas opciones sirven como punto de comparacion frente a formulaciones basadas en grafos.

Desde el punto de vista experimental, el problema de canales faltantes puede aparecer de distintas formas: perdida aleatoria, descarte por calidad, o ausencias concentradas en una region del casco. Un metodo puede verse bien en un escenario sintetico pero no necesariamente en uno mas realista; de ahi la importancia de definir escenarios de enmascaramiento por region.

2.2. Procesamiento de senales sobre grafos

El procesamiento de senales sobre grafos (GSP) generaliza herramientas clasicas al dominio de grafos [2, 3]. Formalmente, se define un grafo no dirigido con pesos $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde $\mathcal{V}$ es el conjunto de N nodos (electrodos), $\mathcal{E}$ el conjunto de aristas, y $\mathbf{W} \in \mathbb{R}^{N \times N}$ la matriz de adyacencia simetrica no negativa. Una senal sobre grafo es un vector $\mathbf{x} \in \mathbb{R}^N$ que asigna un valor escalar a cada nodo.

2.2.1. Laplaciano de grafo

El Laplaciano combinatorial es $\mathbf{L} = \mathbf{D} - \mathbf{W}$, donde $\mathbf{D} = \text{diag}(\mathbf{W}\mathbf{1})$ es la matriz de grado. $\mathbf{L}$ es simétrica semidefinida positiva, por lo que admite descomposición espectral $\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top$, donde las columnas de $\mathbf{U}$ son los vectores propios (base de Fourier del grafo) y $\mathbf{\Lambda}$ contiene los valores propios $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$.

La variación total de la señal en el grafo es $\mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{(i,j) \in \mathcal{E}} w_{ij} (x_i - x_j)^2$, que mide cuanto varía la señal entre nodos vecinos. Una señal “suave” sobre el grafo tiene variación total pequeña, lo que justifica la formulación de problemas de reconstrucción con regularización laplaciana.

2.2.2. Reconstrucción de señales sobre grafos

Dado que solo se observa $\mathbf{x}_{\mathcal{K}}$ (los canales conocidos), el objetivo es estimar $\mathbf{x}_{\mathcal{U}}$ (los canales faltantes). El problema de Tikhonov en grafo es:

$$\hat{\mathbf{x}}_{\mathcal{U}} = \arg \min_{\mathbf{z}} \|\mathbf{z} - \mathbf{x}_{\mathcal{K}}\|^2 + \alpha \mathbf{z}^\top \mathbf{L}_{\mathcal{U}\mathcal{U}} \mathbf{z}, \quad (2.1)$$

con solución $\hat{\mathbf{x}}_{\mathcal{U}} = (\mathbf{L}_{\mathcal{U}\mathcal{U}} + \alpha^{-1} \mathbf{I})^{-1} \mathbf{x}_{\mathcal{U}}^{(0)}$ para datos inicializados, o la solución del sistema lineal $\mathbf{L}_{\mathcal{U}\mathcal{U}} \hat{\mathbf{x}}_{\mathcal{U}} = -\mathbf{L}_{\mathcal{U}\mathcal{K}} \mathbf{x}_{\mathcal{K}}$ para el caso puro [4].

2.2.3. Reconstrucción bandlimited (BGSRP)

El método BGSRP [5] plantea la reconstrucción como un problema en el espacio de Hilbert de núcleo reproductor (RKHS) de funciones bandlimited en grafo. Define el kernel $\kappa(i, j) = \sum_{l=1}^B u_l(i) u_l(j)$ usando los B vectores propios de frecuencia más baja, lo que permite formular la reconstrucción sin la componente DC y con regularización γ sobre la norma RKHS.

2.2.4. Reconstrucción temporal (TRSS)

El método TRSS [6] extiende la regularización al dominio espacio-temporal. Para una matriz de señales $\mathbf{X} \in \mathbb{R}^{N \times T}$:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z}} \|\mathbf{Z}_{\mathcal{K},:} - \mathbf{X}_{\mathcal{K},:}\|_F^2 + \alpha \text{tr}(\mathbf{Z}^\top \mathbf{L} \mathbf{Z}) + \beta \|\Delta_t \mathbf{Z}\|_F^2, \quad (2.2)$$

donde Δ_t es un operador de diferencias finitas temporales y los hiperparámetros α, β controlan la suavidad espacial y temporal respectivamente.

2.3. Construcción de grafos para EEG

La calidad de la reconstrucción depende directamente de que el grafo capture bien las relaciones entre electrodos. Se distinguen tres estrategias principales:

- *Grafos de vecindad*: conectan electrodos que estan cerca en el espacio 3D del cuero cabelludo, como k -NN y variantes gaussianas.
- *Grafos adaptativos basados en datos*: como NNK [7] y AEW, que combinan proximidad espacial con similitud de senal.
- *Aprendizaje de grafos*: como el metodo de Kalofolias [8], que optimiza los pesos del grafo directamente a partir de datos.

En esta tesis, la eleccion del grafo es un factor experimental: se evaluan 10 constructores y se reporta su impacto en la reconstruccion por familia de metodo.

2.4. Metricas de evaluacion

Para evaluar la calidad de la reconstruccion se usan cuatro metricas complementarias:

- **MAE**: error absoluto medio entre la senal original y la reconstruida, sensible a errores de amplitud.
- **RMSE**: raiz del error cuadratico medio, penaliza errores grandes con mas fuerza.
- **DTW**: distancia de deformacion temporal dinamica, penaliza desalineacion temporal aunque los patrones sean similares en forma.
- **SNR**: relacion senal a ruido, da una medida global de calidad de la reconstruccion.

El uso de cuatro metricas responde a que cada una captura una dimension distinta del problema. Un buen MAE no garantiza buena preservacion temporal (DTW), y un buen SNR no implica necesariamente baja distorsion de fase.

Capítulo 3

Metodologia

Este capítulo describe el pipeline experimental completo usado en la etapa B2/B3/B4. La idea central fue mantener un protocolo reproducible y comparable entre familias de métodos, sin ajustar cada método de forma independiente para maximizar solo su mejor caso. En otras palabras, se priorizó una comparación honesta antes que una optimización excesiva de un método particular.

La metodología se organizó como una secuencia fija: (i) carga y estandarización de los datos, (ii) construcción del grafo, (iii) simulación de canales faltantes, (iv) interpolación o reconstrucción, y (v) evaluación cuantitativa y consolidación de resultados. Esta estructura permite rastrear cada resultado desde el dato de entrada hasta la tabla final del manuscrito.

De forma práctica, el pipeline se implementó de modo que cada corrida genere artefactos intermedios reutilizables. Esto fue importante para la tesis, porque permitió separar lo experimental de lo editorial: primero se consolida evidencia, y luego se redacta sobre esa evidencia.

3.1. Construcción de grafos

Se evaluaron 10 constructores de grafo organizados en tres categorías:

- *Grafos de vecindad*: `knn`, `knng`, `vknnng`, `epsilon_ball`, `mst`.
- *Grafos densos/globales*: `fully_connected_inverse_distance`, `gaussian`.
- *Grafos adaptativos*: `nnk` [7], `aew`, `kalofolias` [8].

En la fase B2/B3/B4 se retuvieron solo los métodos que mostraron estabilidad numérica en la corrida extendida. La intuición detrás de esta etapa es que la calidad del grafo condiciona directamente la reconstrucción posterior.

3.2. Simulación de canales faltantes

Se trabajaron 4 escenarios por región de electrodos (frontal, occipital, temporal lateral y central) con niveles de pérdida de 10 %, 20 %, 30 % y 40 %. Este diseño intenta aproximar situaciones

mas realistas que una mascara completamente aleatoria.

Para la tesis, este punto era importante porque un EEG real no falla siempre de manera uniforme. A veces se pierden grupos completos de canales, a veces solo algunos sensores perifericos, y otras veces la perdida tiene un patron que responde a la calidad del montaje. La version actual del protocolo queda congelada en los artefactos de resultados y se usa tanto en el paper como en la tesis.

3.3. Interpolacion y reconstruccion

Las comparaciones se organizaron por familias:

- 15 metodos instantaneos/geometricos (incluidos baselines como `spherical_spline` [1] y metodos GSP como `tikhonov`, `gsp`, `bgsrp` [5]).
- 10 metodos TV/tiempo (incluyendo `trss` [6] y variantes temporales).

Para la evaluacion se usaron MAE, RMSE, DTW y SNR con agregacion estadistica (media, desviacion estandar e intervalo de confianza aproximado) sobre corridas repetidas.

Desde el punto de vista de implementacion, cada metodo recibe exactamente la misma entrada y la misma mascara. Esa homogeneidad fue una prioridad del trabajo.

3.4. Consolidacion y reporte

La fase B2 incorpore una consolidacion estadistica por escenario y familia de metodos. Los resultados se resumieron con tablas de ranking, tablas top-k y archivos de configuracion congelada.

Para el tratamiento de INS-13/BGSRP se adopto una politica de redaccion prudente: la implementacion Python se reporta como proxy controlado en Python; equivalencia estricta 1:1 con MATLAB/GSPBox pendiente. Esa distincion no es solo editorial; es parte de la validez metodologica del trabajo.

Capítulo 4

Experimentos y Resultados

Este capítulo resume la corrida consolidada de la fase B2/B3/B4 y presenta resultados cuantitativos con foco en trazabilidad para paper y tesis. La estructura permite actualizar los números cambiando únicamente el archivo `shared/results_data.tex`.

4.1. Configuración experimental

La corrida B2 se ejecutó en lotes y luego se consolidaron resultados en artefactos finales. Los archivos de referencia principales son:

- `results/opt_benchmark_b2_full_scale_summary.csv`
- `results/b2_publication_ranking_final.csv`
- `results/b2_publication_topk_by_family_scenario.csv`

Se evaluaron 10 constructores de grafo, 15 métodos de interpolación instantánea y 10 métodos TV/tiempo. Los escenarios de canales faltantes cubrieron 4 regiones del casco (frontal, occipital, temporal lateral y central) con niveles de pérdida de 10 %, 20 %, 30 % y 40 %. Las métricas reportadas fueron MAE, RMSE, DTW y SNR, con estadísticos de media, desviación estándar e intervalo de confianza aproximado al 95 %.

4.2. Resultados por familia

La Tabla 4.1 muestra el resumen consolidado REP-01 por familia de métodos. Esta tabla se actualiza automáticamente cuando se modifican los valores en `shared/results_data.tex`.

El resultado más destacado es un cruce de rendimiento entre métricas: la familia Baseline lidera en MAE (0.071) y RMSE (0.162), mientras que TV/Tiempo alcanza el menor DTW (0.492). Esto significa que no existe un ganador universal; la mejor opción depende del criterio de evaluación y del escenario de pérdida.

Tabla 4.1: Resumen final REP-01 (B1+B2 consolidados, fase B2/B3/B4).

Grupo	MAE ↓	DTW ↓	RMSE ↓	Metodo top
Baseline	0.0713	0.5219	0.1622	spherical_spline
TV/Tiempo	0.0729	0.4918	0.1674	tv
GSP	0.0737	0.4989	0.1690	gsmooth

4.2.1. Analisis estadístico (STAT-02)

Se realizaron pruebas de significancia sobre la corrida full-scale B2. Los resultados principales son:

- Contraste de familias TV/Tiempo vs. Instantaneo: rechaza H_0 tanto en MAE ($p=4,77 \times 10^{-44}$) como en DTW ($p=2,40 \times 10^{-12}$). Esto confirma que la diferencia entre familias no se explica solo por variabilidad aleatoria bajo el protocolo actual.
- Contraste TRSS vs. BGSRP en MAE: rechaza H_0 ($p=6,11 \times 10^{-259}$).
- Contraste TRSS vs. gsmooth en MAE: no rechaza H_0 ($p=0,98$). Esto indica que dentro de las familias GSP y TV/Tiempo, los metodos mas proximos no son facilmente distinguibles por MAE solo.

Estas pruebas se deben interpretar junto con el estado proxy de INS-13 (pendiente equivalencia 1:1 MATLAB/GSPBox).

4.2.2. Comportamiento por escenario

Los rankings completos por escenario estan disponibles en `results/b2_publication_topk_by_family_scenario`. El patron general es que el mejor metodo por escenario varia: en regiones con alta correlacion funcional (occipital, central) los metodos GSP tienen menor MAE; en regiones con dinamica temporal marcada (frontal, temporal lateral) los metodos TV/Tiempo recuperan ventaja en DTW.

Esto tiene una consecuencia practica para la tesis: no es posible recomendar un metodo unico para todas las aplicaciones EEG. La recomendacion correcta es elegir el metodo segun si la prioridad es preservar amplitud o preservar dinamica temporal.

4.2.3. Estado BGSRP (INS-13)

Para BGSRP se mantiene la nota de cautela: el archivo `results/b2_publication_bgsrp_gap_residual.csv` reporta un gap residual en la comparacion proxy Python vs. MATLAB/GSPBox, aceptado en B2 pero pendiente de cierre estricto. El estado actual del metodo es: proxy controlado en Python; equivalencia estricta 1:1 con MATLAB/GSPBox pendiente.

4.3. Estabilidad operativa

La corrida B2 no generó entradas en el registro de warnings consolidado (`results/opt_benchmark_b2_full_scale`) lo que indica estabilidad práctica del pipeline a escala completa. Esto no prueba perfección, pero mejora la confianza en la reproducibilidad de los resultados.

4.4. Reproducibilidad

Los artefactos de cierre B3/B4 necesarios para la reproducción completa son:

- `results/b3_b4_reproducibility_guide.md`: guía reproducible consolidada.
- `results/b3_b4_compute_resources.md`: reporte de recursos computacionales.
- `results/b3_b4_submission_checklist.md`: checklist final de envío.

Los comandos principales de ejecución son:

```
python experiments/run_b2_batched.py
python experiments/consolidate_b2_publication.py
python experiments/finalize_b3_b4.py
```

4.4.1. Iteración it02: TV/Time methods on synthetic_{broad}-corrected-per-scenario RMSE comparison (based)

Se ejecutó el benchmark canónico sobre el conjunto de datos `synthetic_broad` (banda ancha 1–40 Hz, 16 canales, posiciones circulares 2-D) en cuatro escenarios de canales faltantes (10 %, 20 %, 30 %, 40 %), con 22 métodos de interpolación y 8 variantes de construcción de grafo (pseudo-semillas).

- Mejor método: `directed_tv` con $MAE = 0.0772$ frente al mejor baseline instantáneo con $MAE = 0.0831$.
- Mejora de RMSE de la familia TV/Tiempo sobre el baseline instantáneo: 5.9 %.
- Significancia estadística confirmada mediante $mae_{trss_vstikhonov}(p = 8,59e-05)$. Artefactos :
Tabla

Los resultados confirman que los métodos temporal-grafo (familia TV/Tiempo) superan consistentemente a los métodos de interpolación exclusivamente espaciales en datos EEG de banda alfa.

Nota INS-13: Resultados validados únicamente en el proxy Python. No se afirma equivalencia 1:1 con MATLAB/GSPBox.




Figura 4.1: Error absoluto medio (MAE, media $\pm$ IC95) por método, iteración `it02`. Barras naranjas: familia TV/Tiempo; barras azules: familia Instante.

4.4.2. Iteración `it03_synthetic_beta`: TV/Time methods on `synthetic_beta(betaband13-30Hz)-allscenarios`

Benchmark ejecutado sobre `synthetic_beta` en 4 escenarios (10 %, 20 %, 30 %, 40 %), 21 métodos y 8 variantes de grafo.

- • Mejor método: `gsmooth` MAE = 0.0657 vs. baseline instante MAE = 0.0657.
- Mejora RMSE (escenario 40 %): 5.2 %.
- Contraste significativo: `mae_trss_vs_tikhonov` (p=8.90e-04).

Nota INS-13: resultados proxy Python; sin equivalencia 1:1 MATLAB/GSPBox.

4.4.3. Iteración `it05b_synthetic_three`: TV/Time family on all 3 synthetic datasets — family-level comparison

Benchmark ejecutado sobre `synthetic_alpha`, `synthetic_beta`, `synthetic_broad` en 4 escenarios (10 %, 20 %, 30 %, 40 %), 21 métodos y 8 variantes de grafo.

- Mejor método: `gsmooth` MAE = 0.0658 vs. baseline instante MAE = 0.0658.
- Mejora RMSE (escenario 20 %): 26.0 %.
- Contraste significativo: `mae_trss_vs_tikhonov` (p=7.05e-10).

Nota INS-13: resultados proxy Python; sin equivalencia 1:1 MATLAB/GSPBox.




Figura 4.2: Comparación familia TV/Tiempo vs. Instante: MAE y RMSE en función del porcentaje de canales faltantes, iteración it02.




Figura 4.3: Familia TV/Tiempo vs Instante — iteración it03_synthetic_beta.

4.4.4. Iteración it06b_kalofolias_nnk_3syn: Kalofolias + NNK graphs on all 3 synthetic datasets — learnable graph topology

Benchmark ejecutado sobre synthetic_alpha, synthetic_beta, synthetic_broad en 4 escenarios (10 %, 20 %, 30 %, 40 %), 21 métodos y 2 variantes de grafo.

- Mejor método: **mean** MAE = 0.0659 vs. baseline instante MAE = 0.0659.
- Mejora RMSE (escenario 20 %): 25.3 %.
- Contraste significativo: mae_trss_vs_tikhonov (p=3.21e-04).

Nota INS-13: resultados proxy Python; sin equivalencia 1:1 MATLAB/GSPBox.

Tabla 4.2: EEG channel reconstruction — MAE, RMSE, SNR by method and missing ratio (mean $\pm$ std). Iteration: it02.

Method	10 %			20 %			MA
	MAE	RMSE	SNR	MAE	RMSE	SNR	
spherical_spline	0,085 $\pm$ 0,000	0,273 $\pm$ 0,000	-0,558 $\pm$ 0,000	0,125 $\pm$ 0,000	0,327 $\pm$ 0,000	-0,500 $\pm$ 0,000	0,202
mean	0,085 $\pm$ 0,000	0,273 $\pm$ 0,000	-0,558 $\pm$ 0,000	0,125 $\pm$ 0,000	0,327 $\pm$ 0,000	-0,500 $\pm$ 0,000	0,202
gsmooth	0,085 $\pm$ 0,002	0,273 $\pm$ 0,005	-0,551 $\pm$ 0,152	0,124 $\pm$ 0,000	0,326 $\pm$ 0,001	-0,478 $\pm$ 0,019	0,204
tv	0,084 $\pm$ 0,001	0,273 $\pm$ 0,004	-0,564 $\pm$ 0,118	0,125 $\pm$ 0,001	0,329 $\pm$ 0,005	-0,541 $\pm$ 0,131	0,205
directed_tv	0,083 $\pm$ 0,014	0,281 $\pm$ 0,057	-0,573 $\pm$ 1,492	0,125 $\pm$ 0,009	0,335 $\pm$ 0,036	-0,661 $\pm$ 0,861	0,207
idw	0,083 $\pm$ 0,000	0,274 $\pm$ 0,000	-0,612 $\pm$ 0,000	0,125 $\pm$ 0,000	0,332 $\pm$ 0,000	-0,624 $\pm$ 0,000	0,209
trss	0,084 $\pm$ 0,005	0,277 $\pm$ 0,014	-0,674 $\pm$ 0,436	0,125 $\pm$ 0,002	0,334 $\pm$ 0,012	-0,663 $\pm$ 0,305	0,210
gsp	0,086 $\pm$ 0,004	0,286 $\pm$ 0,012	-0,977 $\pm$ 0,371	0,127 $\pm$ 0,003	0,344 $\pm$ 0,012	-0,929 $\pm$ 0,291	0,216
wavelet_temporal	0,108 $\pm$ 0,011	0,276 $\pm$ 0,015	16,862 $\pm$ 5,068	0,146 $\pm$ 0,011	0,326 $\pm$ 0,012	16,173 $\pm$ 4,683	0,217
linear	0,094 $\pm$ 0,000	0,323 $\pm$ 0,000	-1,995 $\pm$ 0,000	0,134 $\pm$ 0,000	0,368 $\pm$ 0,000	-1,502 $\pm$ 0,000	0,234
spline_surface	0,095 $\pm$ 0,000	0,332 $\pm$ 0,000	-2,266 $\pm$ 0,000	0,148 $\pm$ 0,000	0,412 $\pm$ 0,000	-2,465 $\pm$ 0,000	0,249
rbfi_tps	0,095 $\pm$ 0,000	0,332 $\pm$ 0,000	-2,266 $\pm$ 0,000	0,148 $\pm$ 0,000	0,412 $\pm$ 0,000	-2,465 $\pm$ 0,000	0,249
nearest	0,102 $\pm$ 0,000	0,349 $\pm$ 0,000	-2,712 $\pm$ 0,000	0,156 $\pm$ 0,000	0,432 $\pm$ 0,000	-2,890 $\pm$ 0,000	0,253
rbfi_mq	0,108 $\pm$ 0,000	0,373 $\pm$ 0,000	-3,289 $\pm$ 0,000	0,167 $\pm$ 0,000	0,473 $\pm$ 0,000	-3,660 $\pm$ 0,000	0,273
tikhonov	0,215 $\pm$ 0,160	0,349 $\pm$ 0,136	14,470 $\pm$ 8,165	0,247 $\pm$ 0,148	0,398 $\pm$ 0,118	13,458 $\pm$ 7,622	0,312
heat_diffusion_temporal	0,162 $\pm$ 0,231	0,484 $\pm$ 0,647	-2,286 $\pm$ 6,447	0,239 $\pm$ 0,336	0,583 $\pm$ 0,771	-2,297 $\pm$ 6,401	0,399
graph_time_tikhonov	0,371 $\pm$ 0,128	0,458 $\pm$ 0,116	5,578 $\pm$ 3,919	0,390 $\pm$ 0,119	0,486 $\pm$ 0,101	5,180 $\pm$ 3,648	0,428
puy	0,370 $\pm$ 0,166	0,480 $\pm$ 0,126	7,449 $\pm$ 8,819	0,389 $\pm$ 0,153	0,510 $\pm$ 0,105	6,976 $\pm$ 8,266	0,430
temporal_laplacian	0,422 $\pm$ 0,097	0,490 $\pm$ 0,098	3,928 $\pm$ 2,034	0,434 $\pm$ 0,091	0,510 $\pm$ 0,087	3,759 $\pm$ 1,949	0,468
bgsrp	0,463 $\pm$ 0,058	0,571 $\pm$ 0,050	2,557 $\pm$ 0,952	0,473 $\pm$ 0,055	0,589 $\pm$ 0,044	2,383 $\pm$ 0,874	0,491
sobolev	0,526 $\pm$ 0,086	0,598 $\pm$ 0,091	1,752 $\pm$ 1,652	0,532 $\pm$ 0,080	0,607 $\pm$ 0,083	1,639 $\pm$ 1,545	0,546

4.4.5. Iteración it07b_knn_3syn: KNN graphs (k=3 and k=5) on all 3 synthetic datasets — KNN topology analysis

Benchmark ejecutado sobre `synthetic_alpha`, `synthetic_beta`, `synthetic_broad` en 4 escenarios (10 %, 20 %, 30 %, 40 %), 21 métodos y 2 variantes de grafo.

- Mejor método: mean MAE = 0.0659 vs. baseline instante MAE = 0.0659.
- Mejora RMSE (escenario 30 %): 24.7 %.
- Contraste significativo: `mae_trss_vs_tikhonov` (p=1.78e-03).

Nota INS-13: resultados proxy Python; sin equivalencia 1:1 MATLAB/GSPBox.

Tabla 4.3: Significance tests — pairwise comparisons (Bonferroni $\alpha = 0,0100$). Iteration: `it02`.

Test ID	Metric	Group A	Group B	p-value	Sig.
mae_trss_vs_tikhonov	mae	trss	tikhonov	$8,59e-05$	*
rmse_trss_vs_tikhonov	rmse	trss	tikhonov	$2,29e-02$	
mae_tv_family_vs_instant	mae	tv_time	instant	$3,18e-01$	
dtw_tv_family_vs_instant	dtw	tv_time	instant	—	
rmse_tv_family_vs_instant	rmse	tv_time	instant	$4,39e-06$	*

Tabla 4.4: EEG reconstruction — MAE/RMSE/SNR. Iteration `it03_synthetic_beta`.

Method	10 %			20 %			MAE
	MAE	RMSE	SNRMethod	MAE	RMSE	SNRMethod	
gsmooth	$0,066 \pm 0,001$	$0,232 \pm 0,002$	$-0,110 \pm 0,077$	$0,134 \pm 0,005$	$0,331 \pm 0,008$	$0,015 \pm 0,431$	$0,203 \pm 0,001$
tv	$0,066 \pm 0,001$	$0,231 \pm 0,002$	$-0,100 \pm 0,073$	$0,133 \pm 0,007$	$0,329 \pm 0,008$	$0,169 \pm 0,771$	$0,203 \pm 0,001$
mean	$0,066 \pm 0,000$	$0,231 \pm 0,000$	$-0,086 \pm 0,000$	$0,134 \pm 0,000$	$0,329 \pm 0,000$	$-0,044 \pm 0,000$	$0,204 \pm 0,000$
idw	$0,066 \pm 0,000$	$0,233 \pm 0,000$	$-0,175 \pm 0,000$	$0,135 \pm 0,000$	$0,332 \pm 0,000$	$-0,099 \pm 0,000$	$0,205 \pm 0,000$
directed_tv	$0,072 \pm 0,009$	$0,256 \pm 0,040$	$-0,868 \pm 1,209$	$0,141 \pm 0,008$	$0,350 \pm 0,022$	$-0,384 \pm 0,621$	$0,206 \pm 0,000$
trss	$0,068 \pm 0,003$	$0,241 \pm 0,009$	$-0,435 \pm 0,321$	$0,139 \pm 0,010$	$0,351 \pm 0,025$	$-0,338 \pm 0,934$	$0,209 \pm 0,000$
gsp	$0,069 \pm 0,002$	$0,246 \pm 0,008$	$-0,600 \pm 0,268$	$0,141 \pm 0,011$	$0,359 \pm 0,026$	$-0,526 \pm 0,948$	$0,211 \pm 0,000$
wavelet_temporal	$0,095 \pm 0,011$	$0,252 \pm 0,013$	$16,831 \pm 5,537$	$0,159 \pm 0,010$	$0,339 \pm 0,010$	$15,208 \pm 4,884$	$0,224 \pm 0,000$
linear	$0,078 \pm 0,000$	$0,295 \pm 0,000$	$-2,192 \pm 0,000$	$0,162 \pm 0,000$	$0,420 \pm 0,000$	$-2,165 \pm 0,000$	$0,236 \pm 0,000$
rbfi_tps	$0,077 \pm 0,000$	$0,289 \pm 0,000$	$-1,951 \pm 0,000$	$0,180 \pm 0,000$	$0,465 \pm 0,000$	$-3,060 \pm 0,000$	$0,252 \pm 0,000$
rbfi_mq	$0,078 \pm 0,000$	$0,298 \pm 0,000$	$-2,174 \pm 0,000$	$0,186 \pm 0,000$	$0,480 \pm 0,000$	$-3,343 \pm 0,000$	$0,256 \pm 0,000$
nearest	$0,086 \pm 0,000$	$0,328 \pm 0,000$	$-3,130 \pm 0,000$	$0,173 \pm 0,000$	$0,463 \pm 0,000$	$-3,028 \pm 0,000$	$0,267 \pm 0,000$
spherical_spline	$0,090 \pm 0,000$	$0,362 \pm 0,000$	$-3,465 \pm 0,000$	$0,220 \pm 0,000$	$0,571 \pm 0,000$	$-4,824 \pm 0,000$	$0,306 \pm 0,000$
tikhonov	$0,205 \pm 0,170$	$0,318 \pm 0,151$	$14,842 \pm 8,403$	$0,256 \pm 0,151$	$0,404 \pm 0,118$	$13,273 \pm 7,525$	$0,310 \pm 0,000$
spline_surface	$0,458 \pm 0,000$	$1,738 \pm 0,000$	$-17,116 \pm 0,000$	$0,206 \pm 0,000$	$0,542 \pm 0,000$	$-4,374 \pm 0,000$	$0,268 \pm 0,000$
heat_diffusion_temporal	$0,131 \pm 0,186$	$0,429 \pm 0,568$	$-2,255 \pm 6,398$	$0,270 \pm 0,385$	$0,623 \pm 0,832$	$-2,280 \pm 6,467$	$0,407 \pm 0,000$
puy	$0,363 \pm 0,176$	$0,460 \pm 0,145$	$7,682 \pm 8,971$	$0,393 \pm 0,157$	$0,513 \pm 0,109$	$7,015 \pm 8,163$	$0,427 \pm 0,000$
graph_time_tikhonov	$0,366 \pm 0,138$	$0,440 \pm 0,132$	$5,767 \pm 4,147$	$0,395 \pm 0,125$	$0,484 \pm 0,108$	$5,244 \pm 3,795$	$0,429 \pm 0,000$
temporal_laplacian	$0,431 \pm 0,097$	$0,496 \pm 0,096$	$3,690 \pm 1,941$	$0,456 \pm 0,086$	$0,530 \pm 0,080$	$3,273 \pm 1,749$	$0,481 \pm 0,000$
bgsrp	$0,475 \pm 0,060$	$0,571 \pm 0,052$	$2,359 \pm 0,902$	$0,489 \pm 0,055$	$0,601 \pm 0,042$	$2,224 \pm 0,864$	$0,505 \pm 0,000$
sobolev	$0,536 \pm 0,090$	$0,605 \pm 0,096$	$1,653 \pm 1,708$	$0,547 \pm 0,081$	$0,617 \pm 0,083$	$1,496 \pm 1,528$	$0,560 \pm 0,000$




Figura 4.4: Familia TV/Tiempo vs Instante — iteración `it05b_synthetic_three`.

Tabla 4.5: EEG reconstruction — MAE/RMSE/SNR. Iteración `it05bsynthetictree`.

Method	10 %			20 %			M
	MAE	RMSE	SNRMethod	MAE	RMSE	SNRMethod	
mean	0,070 $\pm$ 0,011	0,238 $\pm$ 0,027	0,101 $\pm$ 0,642	0,127 $\pm$ 0,006	0,319 $\pm$ 0,013	0,079 $\pm$ 0,541	0,20
tv	0,071 $\pm$ 0,010	0,243 $\pm$ 0,024	-0,105 $\pm$ 0,505	0,128 $\pm$ 0,006	0,326 $\pm$ 0,013	-0,025 $\pm$ 0,635	0,20
gsmooth	0,072 $\pm$ 0,009	0,245 $\pm$ 0,021	-0,179 $\pm$ 0,344	0,129 $\pm$ 0,006	0,326 $\pm$ 0,009	-0,076 $\pm$ 0,425	0,20
idw	0,071 $\pm$ 0,009	0,242 $\pm$ 0,024	-0,074 $\pm$ 0,497	0,130 $\pm$ 0,004	0,329 $\pm$ 0,004	-0,170 $\pm$ 0,353	0,21
directed_tv	0,084 $\pm$ 0,019	0,292 $\pm$ 0,072	-1,497 $\pm$ 1,969	0,145 $\pm$ 0,025	0,371 $\pm$ 0,064	-1,027 $\pm$ 1,236	0,20
trss	0,077 $\pm$ 0,009	0,264 $\pm$ 0,026	-0,816 $\pm$ 0,730	0,137 $\pm$ 0,015	0,352 $\pm$ 0,032	-0,662 $\pm$ 0,803	0,21
gsp	0,079 $\pm$ 0,011	0,273 $\pm$ 0,034	-1,073 $\pm$ 0,896	0,141 $\pm$ 0,019	0,367 $\pm$ 0,044	-0,977 $\pm$ 0,985	0,22
wavelet_temporal	0,095 $\pm$ 0,015	0,255 $\pm$ 0,019	18,607 $\pm$ 5,680	0,151 $\pm$ 0,010	0,333 $\pm$ 0,010	16,839 $\pm$ 4,894	0,21
linear	0,079 $\pm$ 0,013	0,287 $\pm$ 0,033	-1,421 $\pm$ 0,974	0,158 $\pm$ 0,018	0,419 $\pm$ 0,043	-2,249 $\pm$ 0,661	0,24
nearest	0,084 $\pm$ 0,016	0,310 $\pm$ 0,042	-2,039 $\pm$ 1,285	0,170 $\pm$ 0,011	0,458 $\pm$ 0,020	-3,070 $\pm$ 0,171	0,26
rbfi_tps	0,087 $\pm$ 0,008	0,317 $\pm$ 0,021	-2,262 $\pm$ 0,258	0,172 $\pm$ 0,017	0,453 $\pm$ 0,031	-2,934 $\pm$ 0,351	0,25
rbfi_mq	0,092 $\pm$ 0,012	0,335 $\pm$ 0,031	-2,746 $\pm$ 0,466	0,182 $\pm$ 0,012	0,485 $\pm$ 0,013	-3,563 $\pm$ 0,160	0,27
spherical_spline	0,095 $\pm$ 0,011	0,347 $\pm$ 0,057	-2,870 $\pm$ 1,734	0,194 $\pm$ 0,050	0,506 $\pm$ 0,131	-3,578 $\pm$ 2,236	0,28
tikhonov	0,210 $\pm$ 0,152	0,334 $\pm$ 0,132	14,585 $\pm$ 7,807	0,255 $\pm$ 0,136	0,407 $\pm$ 0,106	13,149 $\pm$ 7,058	0,31
spline_surface	0,306 $\pm$ 0,157	1,271 $\pm$ 0,678	-10,794 $\pm$ 6,394	0,188 $\pm$ 0,029	0,511 $\pm$ 0,074	-3,850 $\pm$ 1,011	0,28
heat_diffusion_temporal	0,144 $\pm$ 0,196	0,456 $\pm$ 0,579	-2,395 $\pm$ 6,123	0,260 $\pm$ 0,354	0,611 $\pm$ 0,779	-2,309 $\pm$ 6,157	0,40
graph_time_tikhonov	0,365 $\pm$ 0,126	0,447 $\pm$ 0,115	5,787 $\pm$ 3,955	0,393 $\pm$ 0,113	0,488 $\pm$ 0,094	5,233 $\pm$ 3,577	0,42
puy	0,370 $\pm$ 0,160	0,476 $\pm$ 0,123	7,444 $\pm$ 8,410	0,400 $\pm$ 0,141	0,523 $\pm$ 0,094	6,773 $\pm$ 7,649	0,43
temporal_laplacian	0,425 $\pm$ 0,093	0,490 $\pm$ 0,094	3,831 $\pm$ 1,921	0,445 $\pm$ 0,085	0,519 $\pm$ 0,081	3,490 $\pm$ 1,779	0,47
bgsrp	0,484 $\pm$ 0,054	0,585 $\pm$ 0,047	2,196 $\pm$ 0,863	0,499 $\pm$ 0,052	0,613 $\pm$ 0,044	2,034 $\pm$ 0,819	0,51
sobolev	0,531 $\pm$ 0,081	0,601 $\pm$ 0,086	1,680 $\pm$ 1,560	0,542 $\pm$ 0,074	0,614 $\pm$ 0,075	1,513 $\pm$ 1,407	0,55




Figura 4.5: Familia TV/Tiempo vs Instante — iteración `it06b_kalofolias_nnk_3syn`.

Tabla 4.6: EEG reconstruction — MAE/RMSE/SNR. Iteración `it06b_kalofolias_nk3syn`.

Method	10 %			20 %			MAE
	MAE	RMSE	SNRMethod	MAE	RMSE	SNRMethod	
mean	0,070 $\pm$ 0,012	0,238 $\pm$ 0,029	0,101 $\pm$ 0,689	0,127 $\pm$ 0,006	0,319 $\pm$ 0,014	0,079 $\pm$ 0,581	0,206 $\pm$ 0,012
tv	0,071 $\pm$ 0,011	0,243 $\pm$ 0,028	-0,101 $\pm$ 0,610	0,129 $\pm$ 0,006	0,327 $\pm$ 0,014	-0,139 $\pm$ 0,539	0,209 $\pm$ 0,012
idw	0,071 $\pm$ 0,010	0,242 $\pm$ 0,025	-0,074 $\pm$ 0,533	0,130 $\pm$ 0,004	0,329 $\pm$ 0,005	-0,170 $\pm$ 0,379	0,211 $\pm$ 0,012
gsmooth	0,073 $\pm$ 0,011	0,249 $\pm$ 0,024	-0,329 $\pm$ 0,402	0,132 $\pm$ 0,007	0,333 $\pm$ 0,010	-0,288 $\pm$ 0,298	0,212 $\pm$ 0,012
directed_tv	0,081 $\pm$ 0,018	0,283 $\pm$ 0,067	-1,272 $\pm$ 1,898	0,145 $\pm$ 0,027	0,368 $\pm$ 0,071	-1,021 $\pm$ 1,371	0,209 $\pm$ 0,012
trss	0,081 $\pm$ 0,012	0,278 $\pm$ 0,036	-1,206 $\pm$ 0,989	0,145 $\pm$ 0,021	0,373 $\pm$ 0,048	-1,200 $\pm$ 0,912	0,225 $\pm$ 0,012
wavelet_temporal	0,096 $\pm$ 0,018	0,258 $\pm$ 0,026	18,787 $\pm$ 6,036	0,152 $\pm$ 0,014	0,335 $\pm$ 0,015	16,903 $\pm$ 5,368	0,218 $\pm$ 0,012
linear	0,079 $\pm$ 0,014	0,287 $\pm$ 0,036	-1,421 $\pm$ 1,044	0,158 $\pm$ 0,020	0,419 $\pm$ 0,046	-2,249 $\pm$ 0,709	0,242 $\pm$ 0,012
gsp	0,086 $\pm$ 0,015	0,299 $\pm$ 0,051	-1,769 $\pm$ 1,320	0,155 $\pm$ 0,030	0,404 $\pm$ 0,068	-1,833 $\pm$ 1,178	0,240 $\pm$ 0,012
nearest	0,084 $\pm$ 0,017	0,310 $\pm$ 0,045	-2,039 $\pm$ 1,379	0,170 $\pm$ 0,011	0,458 $\pm$ 0,021	-3,070 $\pm$ 0,183	0,269 $\pm$ 0,012
rbfi_tps	0,087 $\pm$ 0,008	0,317 $\pm$ 0,022	-2,262 $\pm$ 0,277	0,172 $\pm$ 0,019	0,453 $\pm$ 0,033	-2,934 $\pm$ 0,376	0,259 $\pm$ 0,012
rbfi_mq	0,092 $\pm$ 0,013	0,335 $\pm$ 0,033	-2,746 $\pm$ 0,499	0,182 $\pm$ 0,012	0,485 $\pm$ 0,015	-3,563 $\pm$ 0,171	0,271 $\pm$ 0,012
spherical_spline	0,095 $\pm$ 0,012	0,347 $\pm$ 0,061	-2,870 $\pm$ 1,859	0,194 $\pm$ 0,054	0,506 $\pm$ 0,140	-3,578 $\pm$ 2,398	0,282 $\pm$ 0,012
spline_surface	0,306 $\pm$ 0,169	1,271 $\pm$ 0,727	-10,794 $\pm$ 6,857	0,188 $\pm$ 0,032	0,511 $\pm$ 0,079	-3,850 $\pm$ 1,084	0,282 $\pm$ 0,012
tikhonov	0,352 $\pm$ 0,263	0,476 $\pm$ 0,216	10,977 $\pm$ 11,430	0,384 $\pm$ 0,232	0,527 $\pm$ 0,165	9,941 $\pm$ 10,382	0,425 $\pm$ 0,012
puy	0,394 $\pm$ 0,234	0,511 $\pm$ 0,198	6,811 $\pm$ 7,167	0,424 $\pm$ 0,204	0,565 $\pm$ 0,140	6,300 $\pm$ 6,673	0,459 $\pm$ 0,012
graph_time_tikhonov	0,423 $\pm$ 0,200	0,511 $\pm$ 0,193	4,817 $\pm$ 4,895	0,446 $\pm$ 0,178	0,548 $\pm$ 0,155	4,377 $\pm$ 4,455	0,475 $\pm$ 0,012
temporal_laplacian	0,477 $\pm$ 0,156	0,547 $\pm$ 0,162	3,013 $\pm$ 3,053	0,493 $\pm$ 0,141	0,571 $\pm$ 0,139	2,759 $\pm$ 2,816	0,514 $\pm$ 0,012
bgsrp	0,527 $\pm$ 0,087	0,623 $\pm$ 0,072	1,588 $\pm$ 1,389	0,541 $\pm$ 0,077	0,650 $\pm$ 0,046	1,394 $\pm$ 1,220	0,557 $\pm$ 0,012
sobolev	0,534 $\pm$ 0,090	0,605 $\pm$ 0,097	1,618 $\pm$ 1,521	0,544 $\pm$ 0,083	0,617 $\pm$ 0,086	1,464 $\pm$ 1,390	0,555 $\pm$ 0,012
heat_diffusion_temporal	0,360 $\pm$ 0,320	1,096 $\pm$ 0,940	-9,160 $\pm$ 9,945	0,653 $\pm$ 0,576	1,475 $\pm$ 1,265	-9,138 $\pm$ 9,985	1,014 $\pm$ 0,012




Figura 4.6: Familia TV/Tiempo vs Instante — iteración `it07b_knn_3syn`.

Tabla 4.7: EEG reconstruction — MAE/RMSE/SNR. Iteration `it07bknn3syn`.

Method	10 %			20 %			Method	M
	MAE	RMSE	SNR	MAE	RMSE	SNR		
mean	0,070 $\pm$ 0,012	0,238 $\pm$ 0,029	0,101 $\pm$ 0,689	0,127 $\pm$ 0,006	0,319 $\pm$ 0,014	0,079 $\pm$ 0,581	0,206	0,206
heat_diffusion_temporal	0,072 $\pm$ 0,007	0,244 $\pm$ 0,014	-0,197 $\pm$ 0,348	0,131 $\pm$ 0,008	0,326 $\pm$ 0,012	-0,114 $\pm$ 0,099	0,203	0,203
tv	0,071 $\pm$ 0,010	0,242 $\pm$ 0,023	-0,067 $\pm$ 0,435	0,128 $\pm$ 0,006	0,324 $\pm$ 0,011	-0,055 $\pm$ 0,453	0,208	0,208
gsmooth	0,072 $\pm$ 0,009	0,245 $\pm$ 0,020	-0,184 $\pm$ 0,259	0,129 $\pm$ 0,006	0,326 $\pm$ 0,010	-0,108 $\pm$ 0,395	0,208	0,208
idw	0,071 $\pm$ 0,010	0,242 $\pm$ 0,025	-0,074 $\pm$ 0,533	0,130 $\pm$ 0,004	0,329 $\pm$ 0,005	-0,170 $\pm$ 0,379	0,211	0,211
directed_tv	0,079 $\pm$ 0,012	0,271 $\pm$ 0,043	-0,988 $\pm$ 1,518	0,144 $\pm$ 0,022	0,364 $\pm$ 0,046	-0,984 $\pm$ 0,859	0,206	0,206
trss	0,076 $\pm$ 0,008	0,263 $\pm$ 0,020	-0,787 $\pm$ 0,530	0,138 $\pm$ 0,011	0,358 $\pm$ 0,018	-0,842 $\pm$ 0,291	0,211	0,211
gsp	0,076 $\pm$ 0,008	0,265 $\pm$ 0,021	-0,859 $\pm$ 0,554	0,140 $\pm$ 0,012	0,363 $\pm$ 0,022	-0,963 $\pm$ 0,377	0,222	0,222
wavelet_temporal	0,097 $\pm$ 0,013	0,257 $\pm$ 0,018	16,530 $\pm$ 2,852	0,153 $\pm$ 0,006	0,333 $\pm$ 0,007	15,089 $\pm$ 2,044	0,218	0,218
linear	0,079 $\pm$ 0,014	0,287 $\pm$ 0,036	-1,421 $\pm$ 1,044	0,158 $\pm$ 0,020	0,419 $\pm$ 0,046	-2,249 $\pm$ 0,709	0,242	0,242
nearest	0,084 $\pm$ 0,017	0,310 $\pm$ 0,045	-2,039 $\pm$ 1,379	0,170 $\pm$ 0,011	0,458 $\pm$ 0,021	-3,070 $\pm$ 0,183	0,269	0,269
rbfi_tps	0,087 $\pm$ 0,008	0,317 $\pm$ 0,022	-2,262 $\pm$ 0,277	0,172 $\pm$ 0,019	0,453 $\pm$ 0,033	-2,934 $\pm$ 0,376	0,259	0,259
rbfi_mq	0,092 $\pm$ 0,013	0,335 $\pm$ 0,033	-2,746 $\pm$ 0,499	0,182 $\pm$ 0,012	0,485 $\pm$ 0,015	-3,563 $\pm$ 0,171	0,271	0,271
spherical_spline	0,095 $\pm$ 0,012	0,347 $\pm$ 0,061	-2,870 $\pm$ 1,859	0,194 $\pm$ 0,054	0,506 $\pm$ 0,140	-3,578 $\pm$ 2,398	0,282	0,282
tikhonov	0,170 $\pm$ 0,020	0,287 $\pm$ 0,018	13,577 $\pm$ 1,603	0,222 $\pm$ 0,017	0,373 $\pm$ 0,015	12,213 $\pm$ 1,465	0,288	0,288
spline_surface	0,306 $\pm$ 0,169	1,271 $\pm$ 0,727	-10,794 $\pm$ 6,857	0,188 $\pm$ 0,032	0,511 $\pm$ 0,079	-3,850 $\pm$ 1,084	0,282	0,282
graph_time_tikhonov	0,371 $\pm$ 0,035	0,442 $\pm$ 0,032	4,783 $\pm$ 0,882	0,399 $\pm$ 0,030	0,482 $\pm$ 0,022	4,306 $\pm$ 0,784	0,431	0,431
puy	0,397 $\pm$ 0,057	0,481 $\pm$ 0,051	4,101 $\pm$ 1,310	0,424 $\pm$ 0,049	0,524 $\pm$ 0,035	3,700 $\pm$ 1,196	0,451	0,451
temporal_laplacian	0,421 $\pm$ 0,026	0,483 $\pm$ 0,026	3,706 $\pm$ 0,573	0,443 $\pm$ 0,025	0,511 $\pm$ 0,023	3,359 $\pm$ 0,554	0,471	0,471
bgsrp	0,467 $\pm$ 0,030	0,565 $\pm$ 0,028	2,433 $\pm$ 0,518	0,487 $\pm$ 0,035	0,599 $\pm$ 0,032	2,213 $\pm$ 0,554	0,500	0,500
sobolev	0,558 $\pm$ 0,023	0,630 $\pm$ 0,024	1,102 $\pm$ 0,345	0,566 $\pm$ 0,021	0,639 $\pm$ 0,021	0,987 $\pm$ 0,317	0,571	0,571

Capítulo 5

Discussion

En esta etapa del trabajo, la evidencia de la fase B2/B3/B4 sugiere que los metodos basados en estructura de grafo y los metodos TV/tiempo son una alternativa solida para reconstruccion de EEG con canales faltantes. Sin embargo, tambien se observa que el orden del ranking cambia con el escenario espacial y con el nivel de perdida, por lo que no es razonable afirmar una superioridad universal. Esa conclusion puede sonar simple, pero es valiosa: en problemas reales, la robustez suele importar tanto como el mejor puntaje promedio.

5.1. Analisis critico

Se identifican tres puntos criticos para el cierre final:

- **Sensibilidad al protocolo de mascara:** una misma familia puede mejorar o empeorar segun region y severidad de perdida. Por ejemplo, TV/Tiempo lidera en DTW con 0.492 frente a Baseline 0.522, pero la ventaja en MAE no es consistente en todos los escenarios.
- **Sensibilidad a hiperparametros:** incluso con pipeline congelado, algunos metodos muestran dispersion no despreciable en SNR y DTW entre corridas repetidas.
- **Brecha de equivalencia BGSRP:** la implementacion Python es un proxy controlado en Python; equivalencia estricta 1:1 con MATLAB/GSPBox pendiente. Hasta no cerrar esta equivalencia, los resultados BGSRP deben interpretarse como indicativos.

5.2. Interpretacion de la hipotesis

Los datos apoyan una lectura matizada de la hipotesis de trabajo. En terminos estadisticos, el contraste de familias instantaneo vs. TV/Tiempo rechaza H_0 tanto en MAE ($p=4,77 \times 10^{-44}$) como en DTW ($p=2,40 \times 10^{-12}$). Esto confirma que la diferencia no es ruido. Sin embargo, la

magnitud de la diferencia en MAE es pequena (alrededor de 2–4 % entre familias), mientras que en DTW es mas pronunciada (alrededor de 6 % entre TV/Tiempo y Baseline).

La conclusion mas honesta es: los metodos GSP y TV/Tiempo son competitivos, con ventaja real en preservacion temporal, pero sin dominio absoluto en todos los criterios.

5.3. Limitaciones

Las limitaciones principales del trabajo en esta etapa son:

1. La validacion se realizo principalmente sobre el MNE Sample Dataset. Mayor validez externa requiere repetir en EEGMMIDB y BCI Competition IV 2a con corridas completas.
2. La equivalencia estricta BGSRP (INS-13) esta documentada como pendiente. Esto no invalida el benchmark, pero acota el alcance de las afirmaciones sobre ese metodo especifico.
3. La seleccion de hiperparametros se hizo por grilla sobre el conjunto de entrenamiento, sin validacion cruzada rigurosa en todos los metodos. Un estudio de sensibilidad mas completo fortaleceria las conclusiones.

En el cierre B3/B4 se adopta una decision Go para revision del paquete de envio, pero con la limitacion INS-13 declarada explicitamente en el checklist final de submission (`results/b3_b4_submission_checkli`

Capítulo 6

Conclusiones y Trabajo Futuro

6.1. Conclusiones

Esta tesis abordó el problema de reconstrucción de canales EEG faltantes desde una perspectiva de procesamiento de señales sobre grafos, con el objetivo de comparar métodos basados en estructura de grafo frente a baselines clásicos y métodos de regularización temporal bajo condiciones realistas.

6.1.1. Respuesta a la hipótesis de trabajo

La hipótesis de trabajo planteada fue:

El uso de técnicas de interpolación basadas en grafos permite reconstruir señales EEG de manera más precisa y robusta que métodos clásicos en escenarios realistas de canales faltantes.

La evidencia acumulada en las fases B2/B3/B4 permite responder esta hipótesis de forma matizada:

- Los métodos GSP son **competitivos** frente a baselines clásicos: en MAE y RMSE las diferencias son pequeñas (Baseline: MAE ≈ 0.071 vs. GSP: MAE ≈ 0.074), y la diferencia entre familias es estadísticamente significativa ($p = 4,77 \times 10^{-44}$).
- Los métodos TV/Tiempo presentan una **ventaja clara en DTW**: 0.492 frente a 0.522 del Baseline, lo que indica mejor preservación de la dinámica temporal. Esta diferencia es estadísticamente significativa ($p = 2,40 \times 10^{-12}$).
- La hipótesis se **confirma parcialmente**: los métodos basados en grafo no siempre dominan en todas las métricas, pero sí en las que capturan dimensión temporal, que es la más relevante para análisis de señales EEG.

- La superioridad no es universal ni libre de condiciones: el ranking depende del escenario espacial, del nivel de perdida y de la metrica usada. Esto es una conclusion real, no una debilidad.

6.1.2. Aportes principales

- Un pipeline modular, reproducible y trazable con 10 constructores de grafo, 15 metodos de interpolacion instantanea y 10 metodos TV/tiempo.
- Un protocolo de enmascaramiento por region con 4 escenarios (frontal, occipital, temporal lateral y central) y niveles de perdida 10 %, 20 %, 30 % y 40 %, que mejora el realismo experimental frente a una mascara puramente aleatoria.
- Evidencia estadistica formal (STAT-02) sobre diferencias entre familias, con pruebas pareadas que controlan el contexto experimental.
- Un conjunto de artefactos reproducibles y congelados (CSVs, JSONs de configuracion, guia de reproduccion) que permiten verificar y extender el trabajo sin recomputar desde cero.
- Transparencia metodologica: la limitacion de equivalencia estricta BGSRP esta documentada con evidencia cuantitativa en lugar de omitirse.

6.2. Trabajo futuro

Como trabajo futuro inmediato se propone:

- Cerrar la equivalencia estricta BGSRP contra la referencia MATLAB/GSPBox, lo que completaria la validacion paper-faithful pendiente de INS-13.
- Ejecutar las corridas de cierre para version final del manuscrito, incluyendo ablaciones de sensibilidad a hiperparametros en los metodos top.
- Extender la evaluacion a datasets adicionales (PhysioNet EEGMMIDB, BCI Competition IV 2a) y escenarios con perdida no estacionaria para fortalecer la validez externa.
- Explorar la combinacion de metodos: por ejemplo, usar un grafo adaptativo (NNK o AEW) como base para un interpolador TV/Tiempo podria capturar tanto estructura espacial como dinamica temporal.

En resumen, la fase B2/B3/B4 deja una base tecnica rigurosa y suficientemente documentada para una publicacion academica, con tareas de cierre especificas antes del envio definitivo.

Bibliografía

- [1] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier, “Spherical splines for scalp potential and current density mapping,” *Electroencephalography and Clinical Neurophysiology*, vol. 72, no. 2, pp. 184–187, 1989.
- [2] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs,” *IEEE Signal Processing Magazine*, vol. 30, no. 3, pp. 83–98, 2013.
- [3] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges, and applications,” *Proceedings of the IEEE*, vol. 106, no. 5, pp. 808–828, 2018.
- [4] S. K. Narang and A. Ortega, “Signal processing techniques for interpolation in graph structured data,” in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2013, pp. 5445–5449.
- [5] Q. Zhang *et al.*, “Recovery of bandlimited graph signals based on the reproducing kernel Hilbert space,” *Digital Signal Processing*, vol. 151, p. 104565, 2024.
- [6] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans, “Reconstruction of time-varying graph signals via sobolev smoothness,” *IEEE Transactions on Signal and Information Processing over Networks*, vol. 8, pp. 201–214, 2022.
- [7] S. Shekkizhar and A. Ortega, “Graph construction from data by non-negative kernel regression,” in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2020, pp. 3892–3896.
- [8] V. Kalofolias, “How to learn a graph from smooth signals,” in *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2016, pp. 920–929.