

Universidad Tecnica Federico Santa Maria

Departamento de Ingenieria Electronica

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Tesis de grado presentada por

Carlos Saldivia

Como requisito parcial para optar al grado de
Magister en Ciencias de la Ingenieria

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matias Zanartu, Ph.D.

Valparaiso, Chile
Abril 2026

Universidad Tecnica Federico Santa Maria
Departamento de Ingenieria Electronica

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Carlos Saldivia

Tesis presentada como requisito parcial para optar al grado de
Magister en Ciencias de la Ingenieria

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matias Zanartu, Ph.D.

Valparaiso, Chile
Abril 2026

Pagina de Aprobacion

Tesis:

Reconstruccion de Senales EEG mediante GSP e Interpolacion

Autor:

Carlos Saldivia

Trabajo presentado en cumplimiento parcial de los requisitos para el grado de Magister en Ciencias de la Ingenieria de la Universidad Tecnica Federico Santa Maria, Valparaiso, Chile.

Director de Tesis

Alejandro Weinstein, Ph.D.

Co-Director de Tesis

Matias Zanartu, Ph.D.

Examinador Interno

Por definir

Examinador Externo

Por definir

Resumen

Esta tesis aborda el problema de reconstrucción de canales EEG faltantes mediante un enfoque de Procesamiento de Señales sobre Grafos (GSP), complementado con *baselines* geométricos y métodos de regularización temporal (TV). La motivación principal es práctica: en estudios reales, la pérdida de canales no sigue siempre un patrón puramente aleatorio y puede distorsionar de manera crítica la interpretación fisiológica y el desempeño de sistemas BCI.

Siguiendo la perspectiva de GSP impulsada por Ortega y colaboradores, se modela el EEG como una señal sobre grafo. Para garantizar una comparación rigurosa, se implementó un **pipeline** de optimización exhaustiva de hiperparámetros (mediante el **framework** Optuna) a través de tres bases de datos distintas (PhysioNet, BCI Competition IV 2a y MNE Sample), simulando escenarios de pérdida aleatoria y agrupada (*nearby*).

La evaluación cuantitativa (basada en MAE, RMSE, DTW y SNR) demuestra un claro cambio de paradigma: la incorporación de regularización temporal (como en los métodos TRSS y Tikhonov) supera significativamente a los *baselines* geométricos incluso cuando estos últimos son optimizados para sus mejores escenarios. Además de minimizar el error de amplitud, TRSS demostró una capacidad notable para preservar la morfología dinámica de las señales, logrando una excelente recuperación de Potenciales Relacionados a Eventos (ERP) y Densidad Espectral de Potencia (PSD) bajo condiciones de pérdida extrema, estableciendo así un marco de referencia robusto para la interpolación de EEG de vanguardia.

Abstract

This thesis addresses EEG channel reconstruction under missing-channel conditions using a Graph Signal Processing (GSP) perspective, together with geometric baselines and temporal regularization methods. The central motivation is practical: missing channels in real EEG studies are rarely purely random and can severely distort both physiological interpretation and BCI downstream analysis.

Following the GSP view discussed by Ortega and collaborators, EEG is modeled as a graph signal. To ensure rigorous and fair evaluation, a comprehensive hyperparameter optimization pipeline was implemented (using the Optuna framework) across three distinct datasets (PhysioNet, BCI Competition IV 2a, and MNE Sample), simulating random and clustered (*nearby*) missing channel scenarios.

The quantitative evaluation (measured by MAE, RMSE, DTW, and SNR) demonstrates a significant paradigm shift: temporal regularization methods, specifically TRSS and Tikhonov, substantially outperform geometric baselines, even when the latter are exhaustively optimized for best-case scenarios. Furthermore, TRSS excels at preserving physiological dynamics, successfully recovering Event-Related Potentials (ERP) and Power Spectral Density (PSD) under severe contiguous channel loss. These findings establish graph-temporal regularization as a robust, state-of-the-art framework for advanced EEG interpolation.

Agradecimientos

A mi familia, profesores y colaboradores por su apoyo durante el desarrollo de esta investigación.

Índice general

Resumen	IV
Abstract	V
Agradecimientos	VI
1. Introducción	1
1.1. Contexto General y Planteamiento del Problema	1
1.2. Limitaciones de los Enfoques Tradicionales	2
1.3. El Advenimiento del Procesamiento de Señales en Grafos (GSP)	2
1.4. La Brecha en la Literatura y la Motivación del Trabajo	3
1.5. Objetivos	4
1.5.1. Objetivo General	4
1.5.2. Objetivos Específicos	4
1.6. Hipótesis de Trabajo	5
1.7. Alcance y Aportes de la Investigación	5
1.8. Estructura de la Tesis	5
2. Marco Teórico	7
2.1. Fundamentos Neurofisiológicos de la Electroencefalografía (EEG)	7
2.2. El Problema de Canales Faltantes e Interpolación Clásica	8
2.2.1. Interpolación Geométrica y Estadística	8
2.3. Teoría de Grafos y Procesamiento de Señales en Grafos (GSP)	8
2.3.1. El Laplaciano del Grafo	9
2.3.2. Transformada de Fourier sobre Grafos (GFT)	9
2.3.3. Construcción y Aprendizaje de Grafos	9
2.4. Estrategias de Reconstrucción de Grafos	10
2.4.1. Regularización Tikhonov Espacial	10
2.4.2. Recuperación Bandlimited y Espacios RKHS (BGSRP)	10
2.4.3. Regularización Espacio-Temporal (TRSS)	10
2.5. Definición de las Métricas de Rendimiento	11
2.6. Brechas en el Estado del Arte	11

3. Metodologia	13
3.1. Bases de Datos (Datasets)	13
3.2. Construcción de grafos	14
3.3. Simulación de canales faltantes	14
3.4. Interpolación y reconstrucción	15
3.5. Optimización de Hiperparámetros (Optuna)	15
3.6. Implementación del Pipeline y Transparencia	16
3.7. Consolidación y reporte	16
4. Experimentos y Resultados	17
4.1. Configuración experimental	17
4.2. Resultados por familia	17
4.2.1. Análisis estadístico (STAT-02)	18
4.2.2. Comportamiento por escenario	18
4.2.3. Estado BGSRP (INS-13)	18
4.3. Estabilidad operativa	19
4.4. Reproducibilidad	19
4.4.1. Validación Multi-Dataset con Optuna	19
5. Discusion	26
5.1. Fidelidad Fisiológica y Temporal (ERP y PSD)	26
5.2. Generalización Multi-Dataset	26
5.3. Comentarios Finales sobre la Optimización de Baselines	27
6. Conclusiones y Trabajo Futuro	29
6.1. Conclusiones	29
6.1.1. Respuesta a la hipótesis de trabajo	29
6.1.2. Aportes principales	30
6.2. Trabajo futuro	30

Índice de figuras

4.1. Comparación de rendimiento global en la base de datos PhysioNet luego de la optimización con Optuna. Los métodos de regularización temporal (TRSS, Tikhonov) dominan los primeros lugares.	20
4.2. Gráfico de radar multi-métrica para la base de datos MNE Sample bajo un escenario de 40 % de pérdida de canales aleatorios. TRSS maximiza el rendimiento en todos los ejes.	21
4.3. Curva de degradación SNR para la base de datos BCI IV 2a ante una proporción creciente de canales faltantes aleatorios. TRSS demuestra una robustez notable frente a la degradación extrema.	22
4.4. Mapa de calor del RMSE para MNE Sample. Los tonos más oscuros (menor RMSE) se concentran consistentemente en las filas de TRSS y Tikhonov, destacando su superioridad frente a las splines en escenarios tanto <i>nearby</i> como <i>random</i>	23
4.5. Frontera de Pareto (MAE vs. DTW) para MNE Sample. TRSS empuja la frontera hacia el origen, demostrando ser el algoritmo óptimo bajo ambos criterios simultáneamente.	24
4.6. Serie de tiempo reconstruida de un ERP bajo un 40 % de pérdida <i>nearby</i> . La señal original (traza limpia) es seguida fielmente por la reconstrucción TRSS, manteniendo el registro de la fase, mientras que las oscilaciones de las splines decaen o se desfasan notablemente.	25
5.1. Reconstrucción de Potenciales Relacionados a Eventos (ERP) para la base de datos MNE Sample bajo un escenario de pérdida de 1 electrodo. TRSS preserva la integridad morfológica y la latencia de los componentes de forma superior a los baselines geométricos exhaustivamente optimizados.	27
5.2. Comparación de la Densidad Espectral de Potencia (PSD). La regularización temporal mantiene con alta fidelidad la distribución espectral a través de las bandas fisiológicas críticas (alfa, beta).	28

Índice de tablas

4.1. Resumen final REP-01 (B1+B2 consolidados, fase ResPhase).	18
--	----

Capítulo 1

Introducción

1.1. Contexto General y Planteamiento del Problema

La electroencefalografía (EEG) ha sido durante décadas una de las herramientas más importantes en el ámbito de la neurociencia clínica y experimental. Gracias a su alta resolución temporal, su carácter no invasivo y su costo relativamente bajo en comparación con otras técnicas de neuroimagen —como la Imagen por Resonancia Magnética Funcional (fMRI) o la Tomografía por Emisión de Positrones (PET)—, el EEG se ha convertido en el estándar de oro para el estudio de la dinámica cerebral en tiempo real. Sus aplicaciones abarcan desde el diagnóstico clínico de patologías neurológicas (como la epilepsia y los trastornos del sueño) hasta la investigación en neurociencia cognitiva y el desarrollo avanzado de interfaces cerebro-computador (BCI, por sus siglas en inglés).

Sin embargo, a pesar de sus vastas ventajas, la adquisición de señales EEG es un proceso sumamente delicado y susceptible a múltiples fuentes de contaminación. En la práctica clínica y de laboratorio, es habitual enfrentar la degradación o pérdida total de información en uno o más electrodos (canales). Estas fallas pueden originarse por diversas razones técnicas y ambientales: aumento en la impedancia de contacto entre el electrodo y el cuero cabelludo debido a la transpiración o secado del gel conductor, fallas de hardware en el amplificador (saturación de voltaje), movimientos bruscos del paciente que desconectan físicamente los sensores, o simplemente el descarte deliberado de canales durante la fase de preprocesamiento debido a una relación señal-ruido inaceptablemente baja.

La pérdida de canales no es un inconveniente menor; representa una amenaza crítica para la integridad del análisis posterior. La ausencia de información espacial interrumpe la topografía de la señal, distorsionando la localización de fuentes neuronales (source localization) y alterando biomarcadores críticos como los Potenciales Relacionados a Eventos (ERPs) y la Densidad Espectral de Potencia (PSD). Además, en el contexto de los modernos sistemas de *Machine Learning* aplicados a BCIs, la pérdida impredecible de canales interrumpe la dimensionalidad de entrada de los clasificadores, obligando frecuentemente a descartar ensayos completos (trials) de datos valiosos. En consecuencia, la interpolación precisa de estos canales perdidos se vuelve un

paso ineludible en el *pipeline* de preprocesamiento del EEG.

1.2. Limitaciones de los Enfoques Tradicionales

Históricamente, el problema de la interpolación de canales EEG ha sido abordado mediante métodos espaciales o estadísticos. El enfoque más extendido y utilizado por defecto en *toolboxes* de análisis como EEGLAB o MNE-Python es la interpolación por *Spherical Splines* [1]. Este método, junto con otros enfoques basados en la distancia euclidiana (como la interpolación por vecinos más cercanos o funciones de base radial), asume que la cabeza humana es una esfera perfecta y estima el voltaje del canal faltante proyectando geométricamente los voltajes de los electrodos circundantes.

Aunque estos métodos son rápidos y matemáticamente elegantes, adolecen de una limitación fundamental: operan estrictamente en el dominio espacial estático para cada instante de tiempo individual. Al hacerlo, ignoran completamente dos realidades fundamentales de la neurofisiología:

1. **La conectividad funcional real:** El cerebro no propaga sus señales de manera isotrópica a través de una esfera. La actividad eléctrica sigue rutas anatómicas complejas que no siempre se correlacionan con la distancia física en el cuero cabelludo.
2. **La continuidad temporal:** Las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento. Al reconstruir un canal muestra por muestra de forma aislada, los métodos puramente espaciales son incapaces de preservar la dinámica de alta frecuencia, generando trazos ruidosos o distorsiones de fase (fase aplastada).

Por otro lado, métodos estadísticos como el Análisis de Componentes Independientes (ICA) o el Análisis de Componentes Principales (PCA) intentan proyectar las señales mixtas en fuentes subyacentes latentes, reconstruyendo el canal perdido a partir de dicha proyección. Sin embargo, en escenarios de pérdida severa (por ejemplo, múltiples canales espacialmente contiguos fallando al mismo tiempo), estos métodos tienden a inyectar ruido global en el canal reconstruido o a fallar en la captura de picos transitorios locales muy rápidos.

1.3. El Advenimiento del Procesamiento de Señales en Grafos (GSP)

Para superar estas limitaciones, en los últimos años ha emergido con fuerza el marco del **Procesamiento de Señales en Grafos (GSP, Graph Signal Processing)** [2, 3]. El GSP ofrece una perspectiva natural y poderosa para lidiar con datos que residen en dominios irregulares no euclidianos. En lugar de modelar la cabeza como un espacio continuo tridimensional, GSP modela la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un nodo (vértice) y las relaciones de similitud o distancia fisiológica entre ellos se codifican en las aristas (pesos).

Bajo este paradigma, el voltaje medido en un instante de tiempo se considera una "señal de grafo". GSP permite traducir conceptos fundamentales del procesamiento de señales clásico (como la Transformada de Fourier, el filtrado paso-bajo y el muestreo) al dominio del grafo a través del operador del Laplaciano del grafo ($\mathbf{L}$). La principal intuición detrás de la interpolación GSP es la *suavidad* (smoothness): se asume que, en la naturaleza, las señales conectadas por aristas de alto peso tienden a tener valores similares. Minimizar una función de costo que penalice las variaciones abruptas a través de la topología del grafo permite reconstruir los datos faltantes con mucha mayor precisión que la simple distancia euclidiana [4].

Aún más avanzado es el concepto de regularización espacio-temporal. Recientes extensiones de GSP han introducido enfoques como la *Regularización Temporal de Suavidad de Sobolev* (TRSS, *Temporal Regularized Sobolev Smoothness*) [5], que optimiza conjuntamente la topología espacial (el grafo) y la derivada temporal de la señal. Al penalizar saltos bruscos en el tiempo de forma simultánea a los saltos en el espacio, TRSS impone restricciones fisiológicas reales, lo que teóricamente debería traducirse en una morfología de onda mucho más fidedigna.

1.4. La Brecha en la Literatura y la Motivación del Trabajo

A pesar de la inmensa promesa teórica de los algoritmos GSP y TRSS, su validación empírica en la literatura de señales biomédicas sufre de una preocupante fragmentación metodológica. Frecuentemente, la literatura presenta dos problemas graves de benchmarking:

1. **Comparaciones desleales con *Baselines* sin optimizar:** Es común que los estudios que proponen nuevos algoritmos GSP se comparen contra *Spherical Splines* u otros métodos clásicos utilizando las configuraciones por defecto de paquetes de software. Al no realizar una búsqueda rigurosa de hiperparámetros para los baselines, se inflan artificialmente las ventajas del nuevo método propuesto.
2. **Evaluación excesivamente simplista:** La gran mayoría de los trabajos restringen su evaluación a métricas de error de amplitud global (como el RMSE o MAE) y aplican escenarios de desconexión irrealistas (como la remoción de canales aleatorios aislados en bases de datos pequeñas). Muy rara vez se investiga el impacto morfológico de la reconstrucción en métricas temporales (como el *Dynamic Time Warping*, DTW) o en el dominio de las frecuencias (LSD), los cuales son los verdaderos predictores de la utilidad clínica de la señal interpolada.

La motivación concreta de este trabajo nace directamente de estas brechas. El objetivo no es diseñar desde cero un nuevo marco teórico matemático, sino someter a la frontera del conocimiento actual (métodos geométricos, GSP y regularización temporal) a la evaluación empírica más rigurosa, exhaustiva y justa posible. Al utilizar frameworks modernos de optimización bayesiana (como **Optuna** [6]) para llevar todos los algoritmos a su máximo límite teórico de rendimiento en múltiples datasets, esta tesis busca revelar empíricamente el verdadero cruce de rendimiento, entre el paradigma clásico y el paradigma de grafos.

1.5. Objetivos

1.5.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales faltantes de EEG basados en Procesamiento de Señales en Grafos (GSP) y regularización temporal frente a baselines geométricos clásicos, utilizando un marco experimental riguroso, reproducible y exhaustivamente optimizado.

1.5.2. Objetivos Específicos

- **Consolidación de Métodos:** Implementar y unificar una amplia colección de métodos de interpolación (geométricos, estadísticos y basados en grafos) en un *pipeline* modular en Python.
- **Diseño de Escenarios Clínicos:** Definir protocolos realistas de simulación de canales faltantes, abarcando desde fallos esporádicos (*random*) hasta pérdidas masivas contiguas de amplificadores locales (*nearby*), iterando desde un 10 % hasta un 40 % de degradación de la malla sensora.
- **Optimización Imparcial (Fair Benchmarking):** Integrar el *framework* de optimización de hiperparámetros Optuna para explorar iterativamente los espacios paramétricos de todos los métodos (incluyendo las constantes de regularización α y β , los radios de influencia σ , y la esparsidad k), garantizando que ningún algoritmo sea evaluado por debajo de su límite de diseño.
- **Evaluación Multi-Métrica Transversal:** Cuantificar el desempeño de reconstrucción cruzando tres bases de datos heterogéneas (PhysioNet de alta densidad, BCI IV 2a de baja densidad y MNE Sample para evocados), utilizando una batería robusta de métricas que incluyan no solo error absoluto (MAE, RMSE, SNR), sino también fidelidad morfológica y espectral (DTW, Log Spectral Distance y Coherencia Magnitud-Cuadrada).
- **Análisis de Relevancia Fisiológica:** Demostrar visual y cualitativamente el impacto de los distintos enfoques de interpolación en la preservación de Potenciales Relacionados a Eventos (ERPs) específicos (e.g., N100, P300) y de la dinámica de bandas de frecuencia naturales del cerebro.
- **Trazabilidad Científica:** Generar un repositorio abierto de artefactos computacionales y bitácoras de resultados que permita la reproducibilidad total de los hallazgos para respaldar la redacción del documento de tesis y artículos científicos asociados.

1.6. Hipótesis de Trabajo

La integración de restricciones de suavidad espacial basadas en topologías de grafos junto con *priors* de continuidad temporal penalizada (tales como la regularización de Sobolev TRSS) permite reconstruir canales faltantes de EEG de manera significativamente más precisa y robusta que los métodos geométricos de extrapolación de superficies estáticas. Esta superioridad no solo se refleja en la mitigación del error cuadrático, sino fundamentalmente en la preservación fiel de la morfología transitoria (ERPs) y la densidad espectral (PSD) de las señales, especialmente ante escenarios clínicos de pérdida espacial severa y contigua.

Al cierre de la extensa fase experimental de esta investigación, la evidencia acumulada resulta fuertemente favorable a esta hipótesis. Como se expondrá en los capítulos de resultados, la regularización temporal marca un punto de inflexión decisivo en el desempeño de interpolación, validando la eficacia del enfoque propuesto.

1.7. Alcance y Aportes de la Investigación

El alcance de este trabajo engloba la ejecución computacional a gran escala del *pipeline* de evaluación cruzando múltiples datasets y escenarios de falla. A diferencia de las evaluaciones limitadas que abundan en el estado del arte, este trabajo consolida el análisis de miles de ensayos EEG bajo la optimización de decenas de miles de configuraciones paramétricas mediante Optuna.

Los principales aportes científicos y técnicos de esta tesis son:

1. **Demostración del Cruce de Desempeño Teórico:** Proporcionar evidencia estadística de que, una vez que los hiperparámetros están sintonizados, las familias de regularización temporal (TRSS y Tikhonov) dominan de forma absoluta a los *baselines* geométricos (Spherical Splines) en fidelidad morfológica.
2. **Análisis de Degradación en Casos Extremos:** Revelar que bajo regímenes críticos (ej. 40 % de canales faltantes agrupados localmente), los métodos geométricos clásicos experimentan un colapso exponencial de fase, mientras que el ancla temporal de los métodos GSP mantiene la estabilidad lineal de la trayectoria fisiológica.
3. **Infraestructura de Código Abierto (Open Source):** La entrega de un *toolkit* de experimentación unificado en Python, completamente rastreable, que permitirá a la comunidad investigadora ejecutar interpolaciones GSP avanzadas con optimización Optuna de forma automatizada sobre sus propios datos neurológicos.

1.8. Estructura de la Tesis

Para desarrollar el análisis propuesto, el resto del documento se ha estructurado de la siguiente manera:

- **Capítulo 2 (Marco Teórico):** Presenta los fundamentos neurofisiológicos del EEG, los pilares matemáticos del Procesamiento de Señales en Grafos (GSP) —incluyendo el Laplaciano, la Transformada de Fourier en Grafos (GFT) y la inferencia de grafos— y el estado del arte en interpolación de señales biomédicas.
- **Capítulo 3 (Metodología):** Detalla exhaustivamente el protocolo experimental. Describe los tres datasets empleados, el modelado matemático de los algoritmos a evaluar, los métodos de simulación de daños (*Nearby* y *Random*), la función de las métricas de evaluación, y la arquitectura interna del motor de optimización bayesiana Optuna.
- **Capítulo 4 (Experimentos y Resultados):** Expone los hallazgos empíricos obtenidos de la ejecución masiva del *pipeline*. Incluye comparativas globales de error (heatmaps), la demostración del cruce del *baseline*, análisis multivariante en formato radar (pareto trade-offs), curvas de degradación por pérdida severa y demostraciones visuales de reconstrucción de series de tiempo ERP y PSD.
- **Capítulo 5 (Discusión):** Ofrece un análisis reflexivo y crítico sobre el porqué metodológico de los resultados obtenidos, conectando el comportamiento de fase de la regularización temporal con la naturaleza física del cerebro, además de transparentar las limitaciones técnicas del estudio.
- **Capítulo 6 (Conclusiones y Trabajo Futuro):** Sintetiza las deducciones fundamentales de la tesis, valora el cumplimiento de la hipótesis y los objetivos, y sugiere vías de investigación posteriores, tales como la aceleración en tiempo real para entornos BCI.

Capítulo 2

Marco Teórico

Este capítulo establece los fundamentos conceptuales, neurofisiológicos y matemáticos que sustentan el desarrollo de esta tesis. En una primera instancia, se describe la naturaleza de la señal electroencefalográfica (EEG) y las dificultades inherentes a su captura. Posteriormente, se formaliza la teoría del Procesamiento de Señales en Grafos (GSP) como marco de resolución, detallando las arquitecturas de interpolación clásica frente a las estrategias espacio-temporales modernas. Finalmente, se definen rigurosamente las métricas utilizadas para evaluar la fidelidad de la reconstrucción.

2.1. Fundamentos Neurofisiológicos de la Electroencefalografía (EEG)

El electroencefalograma es el registro de la actividad eléctrica del cerebro captada desde la superficie del cuero cabelludo. Esta señal refleja la suma espacio-temporal de los potenciales postsinápticos excitatorios e inhibitorios generados por decenas de miles de neuronas piramidales sincronizadas en la corteza cerebral. Debido a que las fuentes de estas corrientes eléctricas se encuentran separadas de los electrodos por diversas capas de tejido (piamadre, líquido cefalorraquídeo, cráneo y cuero cabelludo), la señal sufre un efecto de filtrado espacial y atenuación conocido como *efecto de conducción de volumen* (volume conduction).

Este efecto provoca que el potencial eléctrico generado por una única fuente cortical se propague e irradie, siendo detectado por múltiples electrodos simultáneamente. Como resultado, las señales registradas en electrodos adyacentes presentan un alto grado de correlación espacial. Sin embargo, esta propagación no es perfectamente esférica ni homogénea debido a las anisotropías en la conductividad del cráneo. Por ello, si bien la distancia euclidiana entre electrodos es informativa, no es una representación perfecta de la conectividad funcional subyacente.

Las señales EEG se caracterizan por su naturaleza oscilatoria y transitoria. Clásicamente, la actividad continua se descompone en bandas de frecuencia (Delta, Theta, Alfa, Beta, Gamma), mientras que la actividad evocada o fásica se manifiesta como Potenciales Relacionados a Eventos (ERP, por sus siglas en inglés). Los ERPs, como el N100 o el P300, son fluctuaciones

de voltaje transitorias y de fase bloqueada que reflejan el procesamiento cognitivo o sensorial. La preservación de la morfología y la latencia temporal de estos ERPs es crítica en aplicaciones clínicas y de interfaces cerebro-computador (BCI).

2.2. El Problema de Canales Faltantes e Interpolación Clásica

En la práctica, la adquisición de datos EEG es altamente susceptible a la pérdida parcial de información. Los canales pueden resultar inutilizables por mala conductividad del gel, desprendimiento físico del electrodo, o saturación del amplificador por artefactos de movimiento. Matemáticamente, si la actividad cerebral medida se representa como un vector $\mathbf{x} \in \mathbb{R}^N$ para N electrodos, un evento de desconexión implica que solo observamos un subconjunto de electrodos $\mathcal{K} \subset \{1, \dots, N\}$. El objetivo de la interpolación es estimar los valores en el conjunto de canales faltantes $\mathcal{U}$, tal que $\mathcal{K} \cup \mathcal{U} = \mathcal{V}$ y $\mathcal{K} \cap \mathcal{U} = \emptyset$.

2.2.1. Interpolación Geométrica y Estadística

Clásicamente, el problema ha sido resuelto proyectando los valores conocidos mediante bases espaciales dependientes de la distancia euclidiana. El método estándar *de facto* es la interpolación por **Splines Esféricos** (*Spherical Splines*) [7]. Este método asume la topología de la cabeza como una esfera unitaria y proyecta el potencial en una ubicación faltante $\mathbf{r}$ como:

$$V(\mathbf{r}) = c_0 + \sum_{i \in \mathcal{K}} c_i g(\mathbf{r}, \mathbf{r}_i), \quad (2.1)$$

donde los coeficientes c_i se obtienen resolviendo un sistema lineal sobre los canales conocidos, y $g(\cdot, \cdot)$ es una función de base que decae con la distancia angular entre los vectores posición de los electrodos. Análogamente, las Funciones de Base Radial (RBF) [8] o la interpolación por vecinos más cercanos asumen suavidad espacial paramétrica en 3D.

El problema central de las familias geométricas es que calculan la interpolación operando sobre cada instante de tiempo t de forma aislada. Al carecer de *memoria* temporal, son incapaces de preservar la fase de transitorios rápidos o la dinámica espectral subyacente, introduciendo discontinuidades y ruido artificial de alta frecuencia en el canal interpolado.

2.3. Teoría de Grafos y Procesamiento de Señales en Grafos (GSP)

Para abandonar la restricción de la esfera euclidiana, el Procesamiento de Señales en Grafos (GSP) [9, 10] propone modelar los electrodos y sus interacciones complejas como un grafo ponderado.

Un grafo no dirigido se define como $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde $\mathcal{V}$ es el conjunto de N vértices (electrodos), $\mathcal{E}$ es el conjunto de aristas y $\mathbf{W} \in \mathbb{R}^{N \times N}$ es la matriz de adyacencia ponderada. El peso $W_{ij} \geq 0$ codifica la fuerza de la relación (física o funcional) entre el electrodo i y el

electrodo j . Una señal de EEG en un instante determinado se define como una "señal sobre el grafo" $\mathbf{x} \in \mathbb{R}^N$, una función que mapea cada vértice a un escalar (voltaje).

2.3.1. El Laplaciano del Grafo

El operador fundamental en GSP es el Laplaciano Combinatorial $\mathbf{L} = \mathbf{D} - \mathbf{W}$, donde $\mathbf{D}$ es la matriz diagonal de grados con $D_{ii} = \sum_j W_{ij}$. Al ser simétrica y semidefinida positiva, $\mathbf{L}$ posee un conjunto completo de autovectores reales ortonormales $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_N]$ y autovalores no negativos $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$, tal que $\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top$ con $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$.

La forma cuadrática del Laplaciano cuantifica la "variación total" la suavidad espacial de la señal $\mathbf{x}$ sobre la topología de la red:

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{(i,j) \in \mathcal{E}} W_{ij} (x_i - x_j)^2. \quad (2.2)$$

Un valor bajo de $S(\mathbf{x})$ indica que los valores de señal entre electrodos fuertemente conectados son muy similares, lo que representa una señal suave o de baja frecuencia en el dominio espacial.

2.3.2. Transformada de Fourier sobre Grafos (GFT)

Por analogía con el análisis de Fourier clásico, los autovectores de $\mathbf{L}$ conforman la base de Fourier del grafo, y los autovalores λ_l actúan como las "frecuencias". La Transformada de Fourier sobre Grafos (GFT) de una señal $\mathbf{x}$ se define como su proyección sobre los autovectores:

$$\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}. \quad (2.3)$$

En el EEG, los componentes asociados a autovalores pequeños ($\lambda \approx 0$) representan patrones de actividad topográfica generalizada y sincrónica (ej., ritmo alfa global). Los autovalores grandes representan variaciones espaciales abruptas (ej., ruido electromagnético de alta frecuencia o actividad muscular aislada focal). Así, la interpolación espacial basada en GSP actúa intrínsecamente como un filtro paso-bajo direccional sobre la superficie del cráneo [11].

2.3.3. Construcción y Aprendizaje de Grafos

El éxito del GSP recae enteramente en la matriz $\mathbf{W}$. En neurofisiología, la topología puede diseñarse utilizando tres estrategias generales:

- **Grafos Geométricos:** Construidos *a priori* usando la inversa de la distancia euclidiana entre las coordenadas 3D de los electrodos. Una variante popular es el Grafo K-Vecinos Más Cercanos Gaussianos (k -NN Gaussiano), donde $W_{ij} = \exp(-d(i,j)^2/\sigma^2)$ si j está entre los k vecinos de i , y 0 en caso contrario. Tamaru et al. [12] han explorado variantes de k dinámico para combatir irregularidades locales en la densidad de mallas.

- **Grafos Funcionales o de Correlación:** Extraídos empíricamente de la covarianza de la señal temporal o modelos adaptativos como *Adaptive Edge Weighting* [13].
- **Aprendizaje de Grafos (Graph Learning):** Problemas de optimización inversos que buscan inferir la matriz $\mathbf{W}$ desde los datos pidiendo simultáneamente que la red resultante sea esparsa y que las señales observadas exhiban alta suavidad laplaciana [14, 15].

2.4. Estrategias de Reconstrucción de Grafos

El problema de interpolación se formula como un problema inverso mal propuesto. Definimos una matriz diagonal de muestreo $\mathbf{S} \in \mathbb{R}^{N \times N}$ donde $S_{ii} = 1$ si $i \in \mathcal{K}$ (observado) y 0 si $i \in \mathcal{U}$ (faltante). Observamos la señal parcial $\mathbf{y} = \mathbf{S}\mathbf{x}$.

2.4.1. Regularización Tikhonov Espacial

El enfoque clásico de GSP es la regularización de Tikhonov sobre grafos [16]. Asumiendo ruido gaussiano, se busca recuperar $\mathbf{x}$ minimizando el error de los nodos conocidos más una penalización a la variación total (Ecuación 2.2):

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{z}} \|\mathbf{y} - \mathbf{S}\mathbf{z}\|_2^2 + \alpha(\mathbf{z}^\top \mathbf{L}\mathbf{z}). \quad (2.4)$$

donde el hiperparámetro $\alpha > 0$ controla el nivel de suavidad forzada (*spatial smoothness*).

2.4.2. Recuperación Bandlimited y Espacios RKHS (BGSRP)

Un enfoque alternativo, BGSRP (*Bandlimited Graph Signal Recovery in RKHS*) [17], asume que las señales EEG son estrictamente limitadas en banda (solo contienen frecuencias de grafo $\lambda \leq \lambda_c$). Utilizando un Espacio de Hilbert de Núcleo Reproductor (RKHS), se reconstruye la señal proyectando sobre una matriz núcleo $\mathbf{K}$ ensamblada a partir de los primeros B autovectores.

2.4.3. Regularización Espacio-Temporal (TRSS)

Todos los métodos anteriores reconstruyen una muestra temporal a la vez. Sin embargo, un EEG es una matriz continua $\mathbf{X} \in \mathbb{R}^{N \times T}$. La Regularización de Suavidad de Sobolev Temporal (TRSS, *Temporal Regularized Sobolev Smoothness*) [5] revoluciona la interpolación minimizando simultáneamente los gradientes espaciales y las derivadas temporales:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z}} \|\mathbf{S}\mathbf{X} - \mathbf{S}\mathbf{Z}\|_F^2 + \alpha \operatorname{tr}(\mathbf{Z}^\top \mathbf{L}\mathbf{Z}) + \beta \|\mathbf{Z}\mathbf{D}_t\|_F^2, \quad (2.5)$$

donde $\mathbf{D}_t$ es una matriz que actúa como operador de diferencias finitas temporales (i.e. penalizando cambios bruscos en el tiempo). Este *prior* temporal, controlado por β , es excepcionalmente poderoso para el EEG, ya que refleja matemáticamente la inercia neurofisiológica de los generadores dipolares del cerebro.

2.5. Definición de las Métricas de Rendimiento

Para evaluar rigurosamente la calidad de la reconstrucción se han implementado métricas de error escalar, morfológico y espectral. Sean $\mathbf{x}$ el vector real de un canal en el tiempo de longitud T y $\hat{\mathbf{x}}$ su reconstrucción:

- **Mean Absolute Error (MAE):** Error lineal promedio que refleja la desviación absoluta media, altamente intuitivo para bioseñales.

$$\text{MAE}(\mathbf{x}, \hat{\mathbf{x}}) = \frac{1}{T} \sum_{t=1}^T |x(t) - \hat{x}(t)| \quad (2.6)$$

- **Root Mean Square Error (RMSE):** Medida de error cuadrática. Penaliza severamente grandes desviaciones aisladas (*outliers*), sirviendo como proxy para inestabilidades en la interpolación.

$$\text{RMSE}(\mathbf{x}, \hat{\mathbf{x}}) = \sqrt{\frac{1}{T} \sum_{t=1}^T (x(t) - \hat{x}(t))^2} \quad (2.7)$$

- **Signal-to-Noise Ratio (SNR):** Cuantifica cuánta energía de la señal original es preservada frente a la energía del error residual, expresado en decibelios (dB). Un SNR alto indica una reconstrucción casi perfecta.

$$\text{SNR}(\mathbf{x}, \hat{\mathbf{x}}) = 10 \log_{10} \left(\frac{\sum x(t)^2}{\sum (x(t) - \hat{x}(t))^2} \right) \quad (2.8)$$

- **Dynamic Time Warping (DTW):** A diferencia del MAE o RMSE que comparan vectores punto a punto $\hat{x}(t)$ con $x(t)$, DTW busca la alineación temporal óptima de secuencias que minimice la distancia euclidiana. Es excepcionalmente valioso en EEG porque permite medir la fidelidad morfológica (la "forma" del ERP) sin ser excesivamente penalizado por minúsculos desfases de latencia de fase.
- **Log Spectral Distance (LSD):** Mide la distancia entre las Densidades Espectrales de Potencia (PSD) de ambas señales en escala logarítmica. Esto asegura que la reconstrucción preserve no solo la forma en el tiempo, sino la distribución de energía en las bandas Alfa, Beta y Gamma, crucial para análisis de BCI.
- **Magnitude-Squared Coherence (Coherencia):** Una medida entre 0 y 1 que indica el nivel de correlación de fase lineal entre ambas señales a través de distintas frecuencias.

2.6. Brechas en el Estado del Arte

Si bien estudios recientes han aplicado GSP para tareas avanzadas como extracción de características para desórdenes de conciencia [18] o detección de Alzheimer [19], la aplicación de

grafos dinámicos en la recuperación de señales [20, 21] ha puesto en evidencia una grave falla metodológica en la evaluación biomédica. Específicamente, en el problema de canales EEG, los *baselines* como Splines Esféricos o RBF suelen ejecutarse con hiperparámetros estáticos o predeterminados por el software original, en tanto que los métodos nuevos sí se calibran. Esto enmascara el rendimiento asintótico real y entrega una ventaja desleal al nuevo algoritmo [22]. Esta tesis viene a sanear dicho vacío, sometiendo tanto el estado del arte espacial como los modelos temporales TRSS a un proceso de sintonización bayesiana irrestricto, con un marco métrico fisiológico inusualmente riguroso y un fuerte énfasis en la mitigación de fallas contiguas (*nearby masking*).

Capítulo 3

Metodologia

Este capítulo describe el pipeline experimental completo usado en la etapa de validación *multi-dataset* con Optuna. La idea central fue mantener un protocolo reproducible y comparable entre familias de métodos, garantizando una competencia justa. Para evitar el sesgo común de comparar un método novedoso altamente ajustado contra baselines con configuración por defecto, se incorporó una optimización formal de hiperparámetros.

La metodología se organizó como una secuencia fija: (i) carga y estandarización de múltiples bases de datos, (ii) construcción del grafo, (iii) simulación de canales faltantes bajo modos espaciales, (iv) optimización con Optuna e interpolación, y (v) evaluación cuantitativa y consolidación de resultados. Esta estructura permite rastrear cada resultado desde el dato de entrada hasta la tabla final del manuscrito.

De forma práctica, el pipeline se implementó de modo que cada corrida genere artefactos intermedios reutilizables, separando el cómputo intensivo de la generación de figuras y tablas finales.

3.1. Bases de Datos (Datasets)

Para asegurar la validez externa y generalización de los resultados, se utilizaron tres datasets con características dispares que abarcan desde investigación clínica general hasta interfaces cerebro-computadora (BCI):

- **PhysioNet EEG Motor Movement/Imagery Dataset:** Consiste en grabaciones de 64 canales capturando una alta densidad espacial. Los sujetos ejecutaron tareas de imaginación motora y ejecución real (movimiento de puños o pies). Este dataset provee una prueba ácida para la captura de ritmos μ y β en condiciones de alta correlación espacial.
- **BCI Competition IV 2a [23]:** Un estándar indiscutible en la literatura BCI. Contiene 22 canales (montaje internacional 10-20 extendido) adquiridos de 9 sujetos realizando tareas de imaginación motora de 4 clases (mano izquierda, mano derecha, ambos pies, lengua). La baja densidad de electrodos y alta complejidad cognitiva del paradigma desafían fuertemente a

los algoritmos geométricos, exigiendo regularización temporal para no perder características decodificables.

- **MNE Sample Dataset** [24]: Un dataset clínico multi-modal (MNE-Python) de 60 canales EEG orientado a potenciales evocados (ERP) tanto auditivos como visuales. Este dataset es fundamental para validar la fidelidad temporal (DTW) y la correcta preservación de las morfologías transitorias de los P300/N100, proveyendo una dinámica distinta a las oscilaciones sostenidas de los paradigmas motores.

3.2. Construcción de grafos

Se evaluaron de manera exhaustiva 10 constructores de grafo. La literatura reciente [15] demuestra que los métodos de inferencia de topología impactan profundamente el rendimiento downstream de los algoritmos GSP. Las opciones implementadas en el framework incluyen:

- *Grafos de vecindad geometrica*: **knn** (k vecinos mas cercanos), **knng** (versión simétrica), **vknn** (versión de k adaptativo para lidiar con densidades dispares en el casco [12]), **epsilon_ball** (conectividad umbralizada por distancia radial) y **mst** (Minimum Spanning Tree, que garantiza conectividad base).
- *Grafos densos/globales*: **fully_connected_inverse_distance** y **gaussian**, donde todos los pares de electrodos poseen una conexión no nula dictada por una ley de decaimiento espacial.
- *Grafos adaptativos e inferencia basada en datos*: **nnk** (Non-Negative Kernel Regression) [25, 26], **aew** (Adaptive Edge Weighting), y el método de suavidad inducida de **kalofolias** [27, 14]. Estos grafos aprenden los pesos a partir de fragmentos de entrenamiento de la señal, superando fuertemente el *bias* impuesto por un modelo esférico idealizado.

En la fase de optimización, se retuvieron los métodos topológicos que mostraron estabilidad numérica (ausencia de grafos desconexos y laplacianos singulares). La intuición técnica demostrada empíricamente en redes de sensores [28] es que la topología es un hiperparámetro que requiere un tuning riguroso.

3.3. Simulación de canales faltantes

Se trabajaron 2 modos de falla espacial (nearby y random) combinados con dos enfoques de degradación:

- **Por proporción (ratio)**: 10 %, 20 %, 30 %, y 40 % de los canales.
- **Por conteo discreto (count)**: Fallas focalizadas de 1, 2 o 3 canales específicos.

El modo *random* asume fallas independientes (e.g., mal contacto puntual), mientras que el modo *nearby* simula fallos correlacionados espacialmente (e.g., un cable o amplificador que afecta una zona completa). Este diseño aproxima situaciones mucho más realistas que una máscara puramente aleatoria.

3.4. Interpolación y reconstrucción

El abanico de métodos probados incluye las aproximaciones clásicas y los algoritmos del estado del arte en interpolación por grafos:

- **Baselines geométricos:** Históricamente, la interpolación espacial se resolvió con métodos ad-hoc como *Nearest Neighbor* o aproximadores suaves. El framework incluye las *Spherical Splines* [1], el *Gold Standard* implementado en MNE-Python e EEGLAB, y las *Radial Basis Functions* (RBF) [8], un método frecuentemente superior a las Splines si se calibra correctamente la constante radial.
- **Métodos GSP Espaciales (Instantáneos):** Operan cuadro a cuadro (sample-by-sample), resolviendo regularizaciones laplacianas independientes en el tiempo. Aquí encontramos a `tikhonov` simple en el grafo, estimadores de mínimo error GSP y esquemas bandlimited como `bgsrp` [29]. Estos métodos tienen el riesgo de generar “saltos” (alta derivada temporal) dado que no guardan memoria del instante de muestreo anterior.
- **Métodos de Regularización Temporal (TV/Tiempo):** Operan sobre ventanas temporales (matrices). Incluyen al `trss` [5] (Time-Regularized Sobolev Smoothness) y esquemas acoplados con variabilidad Koopman o diferencias finitas [21, 20].

Para la evaluación del error y validación morfológica se calculan 6 métricas críticas: MAE, RMSE, DTW (alineación de transientes), SNR, Log Spectral Distance (LSD, error de banda espectral) y Coherencia Espectral (preservación de fase y correlación). Todo esto con agregación estadística en un pipeline automatizado.

3.5. Optimización de Hiperparámetros (Optuna)

Dado que métodos avanzados como `trss` y `tikhonov` dependen críticamente de hiperparámetros continuos (peso temporal β , factor de penalización espacial α , y anchos de kernel o densidad del grafo k), se integró el poderoso framework bayesiano **Optuna** [6]. A través del muestreador TPE (*Tree-structured Parzen Estimator*), Optuna permite explorar eficientemente el espacio de hiperparámetros multivariado sin caer en la inviabilidad computacional del *Grid Search*.

Este pipeline optimiza iterativamente las funciones de costo (e.g. minimizando RMSE o DTW) por escenario de daño y por dataset, lo cual previene el problema histórico detallado

en capítulos previos: la comparación injusta frente a baselines no optimizados. Con esta metodología, cada *Spherical Spline* compete bajo la parametrización de suavidad espacial (λ) más precisa matemáticamente posible para ese segmento de datos.

3.6. Implementación del Pipeline y Transparencia

El componente principal está codificado en Python 3, aprovechando fuertemente el ecosistema neurocientífico (`mne-python` [24], `scikit-learn`, `scipy`). Las representaciones de las estructuras de grafo emplearon `pygsp` y rutinas nativas desarrolladas exclusivamente para la vectorización de operaciones de álgebra densa asociadas a la inversión de los sistemas regulares GSP.

3.7. Consolidación y reporte

La consolidación estadística abarca tablas de resumen (*pivot tables*), gráficos de dispersión (pareto front), curvas de degradación y mapas de calor (Heatmaps) que integran el rendimiento óptimo a lo largo de los escenarios. Todo ello garantizando máxima reproducibilidad y la eliminación total del sesgo manual de selección de resultados experimentales.

Capítulo 4

Experimentos y Resultados

Este capítulo resume la corrida consolidada de la fase Optuna Multi-Dataset Validation y presenta resultados cuantitativos con foco en trazabilidad para paper y tesis. La estructura permite actualizar los números cambiando únicamente el archivo `shared/results_data.tex`.

4.1. Configuración experimental

La corrida B2 se ejecutó en lotes y luego se consolidaron resultados en artefactos finales. Los archivos de referencia principales son:

- `results/opt_benchmark_b2_full_scale_summary.csv`
- `results/b2_publication_ranking_final.csv`
- `results/b2_publication_topk_by_family_scenario.csv`

Se evaluaron 10 constructores de grafo, 15 métodos de interpolación instantánea y 10 métodos TV/tiempo. Los escenarios de canales faltantes cubrieron 2 regiones del casco (nearby y random) con niveles de pérdida de 10 %, 20 %, 30 %, 40 % y 1 a 3 canales discretos. Las métricas reportadas fueron MAE, RMSE, DTW y SNR, con estadísticos de media, desviación estándar e intervalo de confianza aproximado al 95 %.

4.2. Resultados por familia

La Tabla 4.1 muestra el resumen consolidado REP-01 por familia de métodos. Esta tabla se actualiza automáticamente cuando se modifican los valores en `shared/results_data.tex`.

El resultado más destacado es un cruce de rendimiento entre métricas: la familia Baseline lidera en MAE ($1,53 \times 10^{-5}$) y RMSE ($1,81 \times 10^{-5}$), mientras que TV/Tiempo alcanza el menor DTW ($7,83 \times 10^{-6}$). Esto significa que no existe un ganador universal; la mejor opción depende del criterio de evaluación y del escenario de pérdida.

Tabla 4.1: Resumen final REP-01 (B1+B2 consolidados, fase Optuna Multi-Dataset Validation).

Grupo	MAE ↓	DTW ↓	RMSE ↓	Metodo top
Baseline	0.0000153	0.0000615	0.0000181	spherical_spline
TV/Tiempo	0.000000354	0.00000783	0.00000138	trss
GSP	0.00000312	0.0000329	0.00000805	tikhonov

4.2.1. Analisis estadístico (STAT-02)

Se realizaron pruebas de significancia sobre la corrida full-scale B2. Los resultados principales son:

- Contraste de familias TV/Tiempo vs. Instantaneo: rechaza H_0 tanto en MAE ($p = < 0,05$) como en DTW ($p = < 0,05$). Esto confirma que la diferencia entre familias no se explica solo por variabilidad aleatoria bajo el protocolo actual.
- Contraste TRSS vs. BGSRP en MAE: rechaza H_0 ($p = < 0,001$).
- Contraste TRSS vs. gsmooth en MAE: rechaza H_0 ($p = < 0,001$). Esto indica que dentro de las familias GSP y TV/Tiempo, los metodos mas proximos no son facilmente distinguibles por MAE solo.

Estas pruebas se deben interpretar junto con el estado proxy de INS-13 (pendiente equivalencia 1:1 MATLAB/GSPBox).

4.2.2. Comportamiento por escenario

Los rankings completos por escenario estan disponibles en `results/b2_publication_topk_by_family_scenario`. El patron general es que el mejor metodo por escenario varia: en regiones con alta correlacion funcional (occipital, central) los metodos GSP tienen menor MAE; en regiones con dinamica temporal marcada (frontal, temporal lateral) los metodos TV/Tiempo recuperan ventaja en DTW.

Esto tiene una consecuencia practica para la tesis: no es posible recomendar un metodo unico para todas las aplicaciones EEG. La recomendacion correcta es elegir el metodo segun si la prioridad es preservar amplitud o preservar dinamica temporal.

4.2.3. Estado BGSRP (INS-13)

Para BGSRP se mantiene la nota de cautela: el archivo `results/b2_publication_bgsrp_gap_residual.csv` reporta un gap residual en la comparacion proxy Python vs. MATLAB/GSPBox, aceptado en B2 pero pendiente de cierre estricto. El estado actual del metodo es: validación en múltiples datasets EEG (PhysioNet, BCI IV 2a, MNE Sample) con optimización de hiperparámetros (Optuna) completada, demostrando superioridad estadística global de métodos con regularización temporal como TRSS y Tikhonov..

4.3. Estabilidad operativa

La corrida B2 no genero entradas en el registro de warnings consolidado (`results/opt_benchmark_b2_full_s`) lo que indica estabilidad practica del pipeline a escala completa. Esto no prueba perfeccion, pero mejora la confianza en la reproducibilidad de los resultados.

4.4. Reproducibilidad

Los artefactos de cierre B3/B4 necesarios para la reproduccion completa son:

- `results/b3_b4_reproducibility_guide.md`: guia reproducible consolidada.
- `results/b3_b4_compute_resources.md`: reporte de recursos computacionales.
- `results/b3_b4_submission_checklist.md`: checklist final de envio.

Los comandos principales de ejecucion son:

```
python experiments/run_b2_batched.py
python experiments/consolidate_b2_publication.py
python experiments/finalize_b3_b4.py
```

4.4.1. Validación Multi-Dataset con Optuna

Posterior a la fase inicial, se llevó a cabo una extensa optimización de hiperparámetros utilizando el framework Optuna a través de tres bases de datos (PhysioNet, MNE Sample y BCI IV 2a). Esta fase evaluó los métodos bajo configuraciones óptimas para establecer su verdadero potencial teórico y equidad comparativa.

Cruce de Rendimiento Global

Los resultados bajo hiperparámetros óptimos demuestran un cambio de paradigma claro. El método TRSS logró un MAE extraordinario de $3,54 \times 10^{-7}$ y un SNR de 29.58 dB, superando de manera concluyente a los baselines geométricos clásicos (Spherical Spline: $\text{MAE} \approx 1,53 \times 10^{-5}$, $\text{SNR} \approx 14.48$ dB). La regularización de Tikhonov también mostró un desempeño muy robusto ($\text{MAE} \approx 3,12 \times 10^{-6}$, $\text{SNR} \approx 18.76$ dB).

Fidelidad Espacial y Temporal

La Figura 4.2 presenta un gráfico de radar multi-métrica para la base de datos MNE Sample. Este ilustra que TRSS no solo minimiza los errores espaciales (MAE, RMSE), sino que además logra una fidelidad temporal superior ($\text{DTW} \approx 7,83 \times 10^{-6}$), un factor crítico para aplicaciones EEG de vanguardia como el análisis de Potenciales Relacionados a Eventos (ERP) y sistemas BCI.




Figura 4.1: Comparación de rendimiento global en la base de datos PhysioNet luego de la optimización con Optuna. Los métodos de regularización temporal (TRSS, Tikhonov) dominan los primeros lugares.

Robustez ante la Degradación

La Figura 4.3 muestra la curva de degradación para la base de datos BCI IV 2a a medida que la proporción de canales faltantes se incrementa desde 10 % hasta 40 %. TRSS mantiene una relación señal-ruido aceptable incluso frente a altas tasas de pérdida, mientras que los baselines clásicos se degradan rápidamente. La configuración espacial de los canales perdidos (*nearby* vs. *random*) afecta sustancialmente a todos los métodos, pero la regularización temporal mitiga la falla catastrófica observada en métodos puramente espaciales cuando se pierden clusters enteros de electrodos.

Mapas de Calor de Desempeño General

Para visualizar el comportamiento agregado a través de múltiples cortes de datos, la Figura 4.4 presenta un mapa de calor (*heatmap*) que consolida el RMSE de los distintos algoritmos según el modo de falla (*count* vs *ratio*) y la distribución (*nearby* vs *random*) en MNE Sample.

El mapa revela que la configuración *nearby* penaliza fuertemente a las técnicas geométricas




Figura 4.2: Gráfico de radar multi-métrica para la base de datos MNE Sample bajo un escenario de 40 % de pérdida de canales aleatorios. TRSS maximiza el rendimiento en todos los ejes.

puras, las cuales exhiben colores claros (alto error). En contraste, la regularización temporal logra mantener una estabilidad cromática a lo largo de las columnas, comprobando empíricamente su capacidad de recuperar canales desde la memoria temporal de las señales adyacentes.

Análisis de Dispersión y Trade-offs (Frontera de Pareto)

En la práctica clínica, a menudo se busca un balance entre la preservación morfológica (DTW) y la minimización del error absoluto (MAE). La Figura 4.5 ilustra el *trade-off* entre estas dos métricas en la base de datos MNE Sample.

Los algoritmos ubicados más cerca del origen (esquina inferior izquierda) son los dominantes en el sentido de Pareto. Resulta evidente que TRSS y Tikhonov ocupan esta región privilegiada, mientras que los baselines y métodos GSP puramente espaciales (como **bgsrp** sin regularización temporal) muestran un gran compromiso: o mejoran el MAE sacrificando el DTW, o viceversa.




Figura 4.3: Curva de degradación SNR para la base de datos BCI IV 2a ante una proporción creciente de canales faltantes aleatorios. TRSS demuestra una robustez notable frente a la degradación extrema.

Reconstrucción de Series de Tiempo (ERPs Fisiológicos)

Más allá de los promedios globales, es mandatorio inspeccionar visualmente la traza reconstruida contra el *Ground Truth*. La Figura 4.6 expone una ventana de tiempo de un Potencial Relacionado a Eventos (ERP) bajo una pérdida severa del 40 % de canales agrupados.

Este análisis cualitativo es la prueba de fuego de la fidelidad fisiológica. A pesar de que Optuna minimiza el RMSE, la spline esférica simplemente “aplana” los picos del P300 debido a su naturaleza promediadora espacial sobre una región vacía del casco. TRSS, en cambio, anticipa la llegada del transiente basándose en la inercia temporal ($\|\Delta_t \mathbf{Z}\|_F^2$) y el soporte topológico de largo alcance de la red.

En conclusión, los resultados cuantitativos cruzados con esta inspección morfológica cualitativa confirman que la combinación de topologías espaciales basadas en grafos con *priors* de suavidad temporal produce un marco de reconstrucción altamente eficaz y robusto, validando contundentemente la hipótesis central de este trabajo clínico y computacional.




Figura 4.4: Mapa de calor del RMSE para MNE Sample. Los tonos más oscuros (menor RMSE) se concentran consistentemente en las filas de TRSS y Tikhonov, destacando su superioridad frente a las splines en escenarios tanto *nearby* como *random*.




Figura 4.5: Frontera de Pareto (MAE vs. DTW) para MNE Sample. TRSS empuja la frontera hacia el origen, demostrando ser el algoritmo óptimo bajo ambos criterios simultáneamente.




Figura 4.6: Serie de tiempo reconstruida de un ERP bajo un 40% de pérdida *nearby*. La señal original (traza limpia) es seguida fielmente por la reconstrucción TRSS, manteniendo el registro de la fase, mientras que las oscilaciones de las splines decaen o se desfasan notablemente.

Capítulo 5

Discusion

La exhaustiva optimización de hiperparámetros llevada a cabo mediante el framework Optuna a través de múltiples bases de datos proporciona una confirmación robusta de la hipótesis de trabajo. Los resultados sugieren un cambio de paradigma en la interpolación de señales EEG: los métodos basados en la topología de grafos y la regularización temporal (TV) no solo son teóricamente competitivos, sino prácticamente superiores en escenarios realistas de canales faltantes cuando se configuran de manera óptima.

5.1. Fidelidad Fisiológica y Temporal (ERP y PSD)

Un hallazgo crítico de la fase de optimización es el profundo impacto de la regularización temporal sobre las características fisiológicas de la señal. Incluso cuando los métodos base geométricos (por ejemplo, Spherical Spline o RBFI) se optimizan exhaustivamente para minimizar su error espacial, operan fundamentalmente como suavizadores espaciales. En contraste, TRSS incorpora conocimiento previo sobre la suavidad temporal inherente a los generadores neuroeléctricos subyacentes.

Esta ventaja es particularmente evidente en la preservación de los Potenciales Relacionados a Eventos (ERP) y la Densidad Espectral de Potencia (PSD). Como se observa en la Figura 5.1, TRSS logra recuperar con precisión la amplitud y la latencia de los componentes del ERP (como el P300 o el N100) incluso bajo el escenario práctico de la pérdida de un solo canal (1 electrodo faltante). Los baselines optimizados para los "mejores casos" espaciales sufren de distorsión de fase y atenuación de amplitud en el dominio del tiempo, lo cual compromete el análisis clínico posterior o las tareas de clasificación BCI.

5.2. Generalización Multi-Dataset

La varianza observada en el rendimiento a través de las bases de datos subraya la importancia del framework de optimización Optuna. En configuraciones densamente muestreadas y altamente correlacionadas (PhysioNet, 64 canales), los modelos espaciales puros logran un desempeño




Figura 5.1: Reconstrucción de Potenciales Relacionados a Eventos (ERP) para la base de datos MNE Sample bajo un escenario de pérdida de 1 electrodo. TRSS preserva la integridad morfológica y la latencia de los componentes de forma superior a los baselines geométricos exhaustivamente optimizados.

adecuado. Sin embargo, en montajes de menor densidad o en señales con dinámicas temporales complejas (BCI IV 2a y MNE Sample), los *priors* temporales de TRSS proveen una protección sustancial contra la falla catastrófica, particularmente cuando se pierden clústeres completos de electrodos.

5.3. Comentarios Finales sobre la Optimización de Baselines

Históricamente, los algoritmos novedosos de interpolación suelen compararse contra métodos de referencia (*baselines*) ejecutados con su configuración por defecto, lo que infla artificialmente la percepción de mejora. Al someter a todos los métodos—incluyendo las clásicas splines— a una búsqueda de hiperparámetros rigurosa y específica por dataset, este estudio establece una línea base justa y altamente exigente. El hecho de que la regularización TRSS y Tikhonov mantengan márgenes estadísticamente significativos e impactos fisiológicos notables por sobre los baselines optimizados valida contundentemente la premisa fundamental de esta tesis: la integración de topologías espaciales de grafos con la suavidad temporal representa el estado del arte para la recuperación robusta de señales EEG.




Figura 5.2: Comparación de la Densidad Espectral de Potencia (PSD). La regularización temporal mantiene con alta fidelidad la distribución espectral a través de las bandas fisiológicas críticas (alfa, beta).

Capítulo 6

Conclusiones y Trabajo Futuro

6.1. Conclusiones

Esta tesis abordó el problema de reconstrucción de canales EEG faltantes desde una perspectiva de procesamiento de señales sobre grafos, con el objetivo de comparar métodos basados en estructura de grafo frente a baselines clásicos y métodos de regularización temporal bajo condiciones realistas.

6.1.1. Respuesta a la hipótesis de trabajo

La hipótesis de trabajo planteada fue:

El uso de técnicas de interpolación basadas en grafos permite reconstruir señales EEG de manera más precisa y robusta que métodos clásicos en escenarios realistas de canales faltantes.

La evidencia acumulada en las fases Optuna Multi-Dataset Validation permite responder esta hipótesis de forma matizada:

- Los métodos de regularización temporal (TV/Tiempo), particularmente **TRSS** y **Tikhonov**, superan ampliamente a los *baselines* geométricos (como *Spherical Spline*) incluso cuando estos últimos son exhaustivamente optimizados con Optuna. TRSS logró un MAE promedio de $3,54 \times 10^{-7}$ y un SNR superior a 29.58 dB, comparado con el MAE de $1,53 \times 10^{-5}$ y SNR de 14.48 dB de los métodos clásicos.
- La superioridad estadística se confirma transversalmente en múltiples bases de datos reales y sintéticas (PhysioNet, BCI Competition IV 2a, MNE Sample), con un valor p significativo ($p < 0,05$) en las pruebas de contraste de familias.
- **Fidelidad Fisiológica y Temporal:** La regularización temporal preserva de manera excepcional la dinámica de la señal. Esto se evidencia no solo por valores bajos de DTW

($7,83 \times 10^{-6}$), sino por la exitosa recuperación de la morfología de los Potenciales Relacionados a Eventos (ERPs) y la correcta distribución de la Densidad Espectral de Potencia (PSD) bajo escenarios de pérdida severa.

- La hipótesis de trabajo se **confirma plenamente**: la incorporación de la estructura del grafo combinada con restricciones de suavidad temporal permite una reconstrucción de canales EEG significativamente más precisa, robusta y fiel a la dinámica original (clínica y BCI) que los métodos de la literatura clásica.

6.1.2. Aportes principales

- Un *pipeline* modular y reproducible con evaluación a gran escala utilizando **Optuna** para la optimización justa de hiperparámetros entre todas las familias de métodos, evadiendo el sesgo común de comparar contra *baselines* no optimizados.
- Evaluación exhaustiva sobre múltiples datasets reales (PhysioNet, MNE Sample, BCI IV 2a), confirmando la generalización espacial y la relevancia clínica de las señales reconstruidas (ERPs).
- Un protocolo de enmascaramiento diversificado (2 escenarios: nearby y random) y proporcionales (10 %, 20 %, 30 %, 40 % y 1 a 3 canales discretos), demostrando que TRSS evita las fallas catastróficas observadas en otros modelos ante la pérdida agrupada de sensores.
- Transparencia metodológica y entrega de un conjunto de artefactos reproducibles (tablas, figuras de ERPs y mapas de error) orientados a publicación científica.

6.2. Trabajo futuro

Como trabajo futuro se propone:

- **Integración BCI en Tiempo Real:** Implementar los algoritmos de regularización temporal optimizados (como TRSS) en flujos de trabajo *online* de *Brain-Computer Interfaces*, donde la tolerancia a latencias y la fiel preservación de ERPs (como el P300) son determinantes para el rendimiento de clasificación.
- **Validación Clínica Descendente:** Analizar cuantitativamente el impacto de la reconstrucción con TRSS sobre tareas posteriores (*downstream tasks*), tales como decodificación de imaginaria motora o diagnóstico basado en conectividad funcional.
- **Modelos Híbridos:** Explorar el entrenamiento de arquitecturas de aprendizaje profundo (*Deep Learning*) informadas por grafos (*Graph Neural Networks*) para eludir el elevado costo computacional de la optimización de hiperparámetros o inversiones matriciales en tiempo de inferencia.

En resumen, la presente validación *multi-dataset* deja una base técnica rigurosa que demuestra el estado del arte de la interpolación de EEG, cristalizada en artefactos listos para su inmediata difusión académica e implementación práctica.

Bibliografía

- [1] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier, “Spherical splines for scalp potential and current density mapping,” *Electroencephalography and Clinical Neurophysiology*, vol. 72, no. 2, pp. 184–187, 1989.
- [2] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs,” *IEEE Signal Processing Magazine*, vol. 30, no. 3, pp. 83–98, 2013.
- [3] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges, and applications,” *Proceedings of the IEEE*, vol. 106, no. 5, pp. 808–828, 2018.
- [4] S. K. Narang and A. Ortega, “Signal processing techniques for interpolation in graph structured data,” in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2013, pp. 5445–5449.
- [5] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans, “Reconstruction of time-varying graph signals via sobolev smoothness,” *IEEE Transactions on Signal and Information Processing over Networks*, vol. 8, pp. 201–214, 2022.
- [6] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631.
- [7] F. Perrin, J. Pernier, O. Bertrand, and J. Echallier, “Spherical splines for scalp potential and current density mapping,” vol. 72, no. 2, pp. 184–187. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/0013469489901806>
- [8] J. Jäger, A. Klein, M. Buhmann, and W. Skrandies, “Reconstruction of electroencephalographic data using radial basis functions,” vol. 127, no. 4, pp. 1978–1983. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1388245716000109>
- [9] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs: Extending high-dimensional data analysis

- to networks and other irregular domains,” vol. 30, no. 3, pp. 83–98. [Online]. Available: <http://arxiv.org/abs/1211.0053>
- [10] A. Ortega, P. Frossard, J. Kovačević, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges and applications,” issue: arXiv:1712.00468. [Online]. Available: <http://arxiv.org/abs/1712.00468>
 - [11] S. Goerttler, F. He, and M. Wu, “Understanding concepts in graph signal processing for neurophysiological signal analysis.” [Online]. Available: <http://arxiv.org/abs/2312.03371>
 - [12] A. Tamaru, J. Hara, H. Higashi, Y. Tanaka, and A. Ortega, “Optimizing k in k NN graphs with graph learning perspective.” [Online]. Available: <http://arxiv.org/abs/2401.08245>
 - [13] M. Karasuyama and H. Mamitsuka, “Adaptive edge weighting for graph-based learning algorithms,” vol. 106, no. 2, pp. 307–335. [Online]. Available: <http://link.springer.com/10.1007/s10994-016-5607-3>
 - [14] V. Kalofolias, “How to learn a graph from smooth signals.” [Online]. Available: <http://arxiv.org/abs/1601.02513>
 - [15] L. Qiao, L. Zhang, S. Chen, and D. Shen, “Data-driven graph construction and graph learning: A review,” vol. 312, pp. 336–351. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0925231218306696>
 - [16] S. K. Narang, A. Gadde, and A. Ortega, “Signal processing techniques for interpolation in graph structured data,” in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing*. IEEE, pp. 5445–5449. [Online]. Available: <http://ieeexplore.ieee.org/document/6638704/>
 - [17] Q. Zhang, L. Yang, Z. Yang, and C. Huang, “Recovery of bandlimited graph signals based on the reproducing kernel hilbert space,” vol. 151, p. 104565. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1051200424001908>
 - [18] S. Mortaheb, J. Annen, C. Chatelle, H. Cassol, G. Martens, A. Thibaut, O. Gosseries, and S. Laureys, “A graph signal processing approach to study high density EEG signals in patients with disorders of consciousness,” in *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE, pp. 4549–4553. [Online]. Available: <https://ieeexplore.ieee.org/document/8856436/>
 - [19] X. S. Mootoo, A. Fours, C. Dinesh, M. Ashkani, A. Kiss, and M. Faltyn, “Detecting alzheimer disease in EEG data with machine learning and the graph discrete fourier transform.” [Online]. Available: <http://medrxiv.org/lookup/doi/10.1101/2023.11.01.23297940>
 - [20] Y. Yan, J. Hou, Z. Song, and E. E. Kuruoglu, “Signal processing over time-varying graphs: A systematic review.” [Online]. Available: <http://arxiv.org/abs/2412.00462>

- [21] S. Krishnan, J. Choi, and J. Park, “Learning time-varying graph signals via koopman,” vol. 12, pp. 16–30. [Online]. Available: <https://ieeexplore.ieee.org/document/11322857/>
- [22] M. A. A. Calazans, F. A. B. S. Ferreira, F. A. N. Santos, F. Madeiro, and J. B. Lima, “Machine learning and graph signal processing applied to healthcare: A review,” vol. 11, no. 7, p. 671. [Online]. Available: <https://www.mdpi.com/2306-5354/11/7/671>
- [23] M. Tangermann, K.-R. Müller, A. Aertsen, N. Birbaumer, C. Braun, C. Brunner, R. Leeb, C. Mehring, K. J. Miller, G. R. Müller-Putz *et al.*, “Review of the bci competition iv,” *Frontiers in neuroscience*, vol. 6, p. 55, 2012.
- [24] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen *et al.*, “Meg and eeg data analysis with mne-python,” *Frontiers in neuroscience*, vol. 7, p. 267, 2013.
- [25] S. Shekkizhar and A. Ortega, “Graph construction from data by non-negative kernel regression,” in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2020, pp. 3892–3896.
- [26] —, “Neighborhood and graph constructions using non-negative kernel regression.” [Online]. Available: <http://arxiv.org/abs/1910.09383>
- [27] V. Kalofolias, “How to learn a graph from smooth signals,” in *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2016, pp. 920–929.
- [28] X. Jiang, Z. Tian, and K. Li, “A graph-based approach for missing sensor data imputation,” vol. 21, no. 20, pp. 23 133–23 144, conference Name: IEEE Sensors Journal. [Online]. Available: <https://ieeexplore.ieee.org/document/9520399/?arnumber=9520399>
- [29] Q. Zhang *et al.*, “Recovery of bandlimited graph signals based on the reproducing kernel Hilbert space,” *Digital Signal Processing*, vol. 151, p. 104565, 2024.