

Universidad Técnica Federico Santa María

Departamento de Ingeniería Electrónica

Reconstrucción de Señales EEG mediante GSP e Interpolación

Tesis de grado presentada por

Carlos Saldivia

Como requisito parcial para optar al grado de
Magíster en Ciencias de la Ingeniería

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matías Zañartu, Ph.D.

Valparaíso, Chile
Abril 2026

Universidad Técnica Federico Santa María
Departamento de Ingeniería Electrónica

Reconstrucción de Señales EEG mediante GSP e Interpolación

Carlos Saldivia

Tesis presentada como requisito parcial para optar al grado de
Magíster en Ciencias de la Ingeniería

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matías Zañartu, Ph.D.

Valparaíso, Chile
Abril 2026

Pagina de Aprobacion

Tesis:

Reconstrucción de Señales EEG mediante GSP e Interpolación

Autor:

Carlos Saldivia

Trabajo presentado en cumplimiento parcial de los requisitos para el grado de Magíster en Ciencias de la Ingeniería de la Universidad Técnica Federico Santa María, Valparaíso, Chile.

Director de Tesis

Alejandro Weinstein, Ph.D.

Co-Director de Tesis

Matías Zañartu, Ph.D.

Examinador Interno

Por definir

Examinador Externo

Por definir

Resumen

Esta tesis aborda el problema de reconstrucción de canales EEG faltantes mediante un enfoque integral de Procesamiento de Señales sobre Grafos (GSP), complementado con *baselines* geométricos clásicos y métodos de regularización temporal. La motivación central es práctica: en estudios clínicos y de interfaz cerebro-computador (BCI), la pérdida de canales no sigue siempre un patrón aleatorio —frecuentemente se manifiesta como fallas contiguas regionales— y puede distorsionar críticamente biomarcadores fisiológicos como los Potenciales Relacionados a Eventos (ERPs) y la Densidad Espectral de Potencia (PSD).

Siguiendo la perspectiva de GSP impulsada por Ortega y colaboradores, el EEG se modela como una señal definida sobre un grafo ponderado que captura la topología funcional de los electrodos. Para garantizar una comparación rigurosamente imparcial, se implementó un pipeline de optimización exhaustiva de hiperparámetros mediante el framework Optuna (muestreadores TPE y NSGA-II multi-objetivo) a través de tres bases de datos heterogéneas: PhysioNet (64 canales, imaginaria motora), BCI Competition IV 2a (22 canales, 4 clases MI) y MNE Sample (60 canales, potenciales evocados). Se simulieron 14 escenarios de pérdida que combinan modos espaciales (*random* y *nearby*) con niveles de degradación del 10 % al 40 %.

La evaluación cuantitativa, basada en seis métricas complementarias (MAE, RMSE, SNR, DTW, LSD y Coherencia Espectral), demuestra un cambio de paradigma concluyente: el método de Regularización Temporal de Suavidad de Sobolev (TRSS) supera por más de un orden de magnitud a los *baselines* geométricos —incluso cuando estos son exhaustivamente optimizados— alcanzando un MAE de 2.26 y un SNR de 25.95 dB frente al MAE de 3.58 y SNR de 19.56 dB de las Spherical Splines. Más allá de las métricas de error, TRSS preserva exitosamente la morfología de ERPs y la distribución espectral bajo condiciones de pérdida extrema, estableciendo así un marco de referencia robusto y reproducible para la interpolación de EEG de vanguardia.

Abstract

This thesis addresses EEG channel reconstruction under missing-channel conditions using a comprehensive Graph Signal Processing (GSP) framework, together with classical geometric baselines and temporal regularization methods. The central motivation is practical: missing channels in real clinical and Brain-Computer Interface (BCI) studies rarely follow purely random patterns—they frequently manifest as contiguous regional failures—and can severely distort critical physiological biomarkers such as Event-Related Potentials (ERPs) and Power Spectral Density (PSD).

Following the GSP perspective advanced by Ortega and collaborators, EEG is modeled as a signal defined on a weighted graph that captures the functional topology of the electrode array. To ensure rigorously fair evaluation, a comprehensive hyperparameter optimization pipeline was implemented using the Optuna framework (TPE and multi-objective NSGA-II samplers) across three heterogeneous datasets: PhysioNet (64 channels, motor imagery), BCI Competition IV 2a (22 channels, 4-class MI), and MNE Sample (60 channels, auditory/visual evoked potentials). A total of 14 missing-channel scenarios were simulated, combining spatial modes (*random* and *nearby*) with degradation levels from 10 % to 40 %.

The quantitative evaluation, based on six complementary metrics (MAE, RMSE, SNR, DTW, Log Spectral Distance, and Magnitude-Squared Coherence), demonstrates a conclusive paradigm shift: the Temporal Regularized Sobolev Smoothness (TRSS) method outperforms geometric baselines by over an order of magnitude—even when the latter are exhaustively optimized—achieving a MAE of 2.26 and SNR of 25.95 dB versus the Spherical Spline baseline (MAE 3.58, SNR 19.56 dB). Beyond error metrics, TRSS successfully preserves ERP morphology and spectral energy distribution under extreme contiguous channel loss, thereby establishing a robust and reproducible state-of-the-art framework for advanced EEG interpolation.

Agradecimientos

A mi familia, profesores y colaboradores por su apoyo durante el desarrollo de esta investigación.

Índice general

Resumen	IV
Abstract	V
Agradecimientos	VI
1. Introducción	1
1.1. Contexto General y Planteamiento del Problema	1
1.2. Limitaciones de los Enfoques Tradicionales	2
1.3. El Advenimiento del Procesamiento de Señales en Grafos (GSP)	2
1.4. La Brecha en la Literatura y la Motivación del Trabajo	3
1.5. Objetivos	4
1.5.1. Objetivo General	4
1.5.2. Objetivos Específicos	4
1.6. Hipótesis de Trabajo	5
1.7. Alcance y Aportes de la Investigación	5
1.8. Estructura de la Tesis	6
2. Marco Teórico	7
2.1. Fundamentos Neurofisiológicos de la Electroencefalografía (EEG)	7
2.2. El Problema de Canales Faltantes e Interpolación Clásica	8
2.2.1. Interpolación Geométrica y Estadística	8
2.3. Teoría de Grafos y Procesamiento de Señales en Grafos (GSP)	9
2.3.1. El Laplaciano del Grafo	9
2.3.2. Transformada de Fourier sobre Grafos (GFT)	9
2.3.3. Construcción y Aprendizaje de Grafos	10
2.4. Estrategias de Reconstrucción de Grafos	10
2.4.1. Regularización Tikhonov Espacial	10
2.4.2. Recuperación Bandlimited y Espacios RKHS (BGSRP)	11
2.4.3. Regularización Espacio-Temporal (TRSS)	11
2.5. Definición de las Métricas de Rendimiento	11
2.6. Brechas en el Estado del Arte	12

3. Metodología	14
3.1. Arquitectura General del Pipeline	14
3.2. Bases de Datos Experimentales	15
3.2.1. PhysioNet EEG Motor Movement/Imagery Dataset (EEGMMIDB)	15
3.2.2. BCI Competition IV Dataset 2a	16
3.2.3. MNE Sample Dataset	16
3.2.4. Resumen Comparativo de Datasets	16
3.3. Construcción de Grafos	17
3.3.1. Grafos de Vecindad Geométrica	17
3.3.2. Grafos Densos / Globales	17
3.3.3. Grafos Adaptativos e Inferencia Basada en Datos	17
3.4. Protocolo de Simulación de Canales Faltantes	18
3.4.1. Modo <i>Random</i> (Fallas Independientes)	18
3.4.2. Modo <i>Nearby</i> (Fallas Contiguas)	18
3.4.3. Niveles de Degradación	18
3.5. Métodos de Interpolación y Reconstrucción	19
3.5.1. Familia 1: Baselines Geométricos y Estadísticos	19
3.5.2. Familia 2: Métodos GSP Espaciales (Instantáneos)	19
3.5.3. Familia 3: Métodos con Regularización Temporal	20
3.6. Optimización de Hiperparámetros con Optuna	20
3.6.1. Estrategia de Muestreo	20
3.6.2. Espacios de Búsqueda por Familia	21
3.6.3. Protocolo de Ejecución	21
3.6.4. Validación Temporal y Prevención de Fuga de Datos (<i>Data Leakage</i>) . . .	21
3.7. Evaluación Cuantitativa	22
3.7.1. Métricas de Error de Amplitud	22
3.7.2. Métricas de Fidelidad Temporal	22
3.7.3. Métricas Espectrales	22
3.8. Consolidación Estadística y Generación de Artefactos	23
3.9. Stack Tecnológico e Infraestructura	23
3.10. Reproducibilidad y Transparencia	24

Índice de figuras

3.1. Representación esquemática del pipeline metodológico de optimización y evaluación propuesto.	14
---	----

Índice de tablas

3.1. Características de los tres datasets experimentales.	16
3.2. Espacios de búsqueda de hiperparámetros por método.	21

Capítulo 1

Introducción

1.1. Contexto General y Planteamiento del Problema

La electroencefalografía (EEG) ha sido durante décadas una de las herramientas más importantes en el ámbito de la neurociencia clínica y experimental. Gracias a su alta resolución temporal, su carácter no invasivo y su costo relativamente bajo en comparación con otras técnicas de neuroimagen —como la Imagen por Resonancia Magnética Funcional (fMRI) o la Tomografía por Emisión de Positrones (PET)—, el EEG se ha convertido en el estándar de oro para el estudio de la dinámica cerebral en tiempo real. Sus aplicaciones abarcan desde el diagnóstico clínico de patologías neurológicas (como la epilepsia y los trastornos del sueño) hasta la investigación en neurociencia cognitiva y el desarrollo avanzado de interfaces cerebro-computador (BCI, por sus siglas en inglés).

Sin embargo, a pesar de sus vastas ventajas, la adquisición de señales EEG es un proceso sumamente delicado y susceptible a múltiples fuentes de contaminación. En la práctica clínica y de laboratorio, es habitual enfrentar la degradación o pérdida total de información en uno o más electrodos (canales). Estas fallas pueden originarse por diversas razones técnicas y ambientales: aumento en la impedancia de contacto entre el electrodo y el cuero cabelludo debido a la transpiración o secado del gel conductor, fallas de hardware en el amplificador (saturación de voltaje), movimientos bruscos del paciente que desconectan físicamente los sensores, o simplemente el descarte deliberado de canales durante la fase de preprocesamiento debido a una relación señal-ruido inaceptablemente baja.

La pérdida de canales no es un inconveniente menor; representa una amenaza crítica para la integridad del análisis posterior. La ausencia de información espacial interrumpe la topografía de la señal, distorsionando la localización de fuentes neuronales (source localization) y alterando biomarcadores críticos como los Potenciales Relacionados a Eventos (ERPs) y la Densidad Espectral de Potencia (PSD). Además, en el contexto de los modernos sistemas de *Machine Learning* aplicados a BCIs, la pérdida impredecible de canales interrumpe la dimensionalidad de entrada de los clasificadores, obligando frecuentemente a descartar ensayos completos (trials) de datos valiosos. En consecuencia, la interpolación precisa de estos canales perdidos se vuelve un

paso ineludible en el *pipeline* de preprocesamiento del EEG.

1.2. Limitaciones de los Enfoques Tradicionales

Históricamente, el problema de la interpolación de canales EEG ha sido abordado mediante métodos espaciales o estadísticos. El enfoque más extendido y utilizado por defecto en *toolboxes* de análisis como EEGLAB o MNE-Python es la interpolación por *Spherical Splines* [1]. Este método, junto con otros enfoques basados en la distancia euclidiana (como la interpolación por vecinos más cercanos o funciones de base radial), asume que la cabeza humana es una esfera perfecta y estima el voltaje del canal faltante proyectando geométricamente los voltajes de los electrodos circundantes.

Aunque estos métodos son rápidos y matemáticamente elegantes, adolecen de una limitación fundamental: operan estrictamente en el dominio espacial estático para cada instante de tiempo individual. Al hacerlo, ignoran completamente dos realidades fundamentales de la neurofisiología:

1. **La conectividad funcional real:** El cerebro no propaga sus señales de manera isotrópica a través de una esfera. La actividad eléctrica sigue rutas anatómicas complejas que no siempre se correlacionan con la distancia física en el cuero cabelludo.
2. **La continuidad temporal:** Las señales EEG son generadas por osciladores neuronales sujetos a leyes físicas de continuidad y momento. Al reconstruir un canal muestra por muestra de forma aislada, los métodos puramente espaciales son incapaces de preservar la dinámica de alta frecuencia, generando trazos ruidosos o distorsiones de fase (fase aplastada).

Por otro lado, métodos estadísticos como el Análisis de Componentes Independientes (ICA) o el Análisis de Componentes Principales (PCA) intentan proyectar las señales mixtas en fuentes subyacentes latentes, reconstruyendo el canal perdido a partir de dicha proyección. Sin embargo, en escenarios de pérdida severa (por ejemplo, múltiples canales espacialmente contiguos fallando al mismo tiempo), estos métodos tienden a inyectar ruido global en el canal reconstruido o a fallar en la captura de picos transitorios locales muy rápidos.

1.3. El Advenimiento del Procesamiento de Señales en Grafos (GSP)

Para superar estas limitaciones, en los últimos años ha emergido con fuerza el marco del **Procesamiento de Señales en Grafos (GSP, Graph Signal Processing)** [2, 3]. El GSP ofrece una perspectiva natural y poderosa para lidiar con datos que residen en dominios irregulares no euclidianos. En lugar de modelar la cabeza como un espacio continuo tridimensional, GSP modela la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un nodo (vértice) y las relaciones de similitud o distancia fisiológica entre ellos se codifican en las aristas (pesos).

Bajo este paradigma, el voltaje medido en un instante de tiempo se considera una “señal de grafo”. GSP permite traducir conceptos fundamentales del procesamiento de señales clásico (como la Transformada de Fourier, el filtrado paso-bajo y el muestreo) al dominio del grafo a través del operador del Laplaciano del grafo ($\mathbf{L}$). La principal intuición detrás de la interpolación GSP es la *suavidad* (smoothness): se asume que, en la naturaleza, las señales conectadas por aristas de alto peso tienden a tener valores similares. Minimizar una función de costo que penalice las variaciones abruptas a través de la topología del grafo permite reconstruir los datos faltantes con mucha mayor precisión que la simple distancia euclidiana [4].

Aún más avanzado es el concepto de regularización espacio-temporal. Recientes extensiones de GSP han introducido enfoques como la *Regularización Temporal de Suavidad de Sobolev* (TRSS, *Temporal Regularized Sobolev Smoothness*) [5], que optimiza conjuntamente la topología espacial (el grafo) y la derivada temporal de la señal. Al penalizar saltos bruscos en el tiempo de forma simultánea a los saltos en el espacio, TRSS impone restricciones fisiológicas reales, lo que teóricamente debería traducirse en una morfología de onda mucho más fidedigna.

1.4. La Brecha en la Literatura y la Motivación del Trabajo

A pesar de la inmensa promesa teórica de los algoritmos GSP y TRSS, su validación empírica en la literatura de señales biomédicas sufre de una preocupante fragmentación metodológica. Frecuentemente, la literatura presenta dos problemas graves de benchmarking:

1. **Comparaciones desleales con *Baselines* sin optimizar:** Es común que los estudios que proponen nuevos algoritmos GSP se comparen contra *Spherical Splines* u otros métodos clásicos utilizando las configuraciones por defecto de paquetes de software. Al no realizar una búsqueda rigurosa de hiperparámetros para los baselines, se inflan artificialmente las ventajas del nuevo método propuesto.
2. **Evaluación excesivamente simplista:** La gran mayoría de los trabajos restringen su evaluación a métricas de error de amplitud global (como el RMSE o MAE) y aplican escenarios de desconexión irrealistas (como la remoción de canales aleatorios aislados en bases de datos pequeñas). Muy rara vez se investiga el impacto morfológico de la reconstrucción en métricas temporales (como el *Dynamic Time Warping*, DTW) o en el dominio de las frecuencias (LSD), los cuales son los verdaderos predictores de la utilidad clínica de la señal interpolada.

La motivación concreta de este trabajo nace directamente de estas brechas. El objetivo no es diseñar desde cero un nuevo marco teórico matemático, sino someter a la frontera del conocimiento actual (métodos geométricos, GSP y regularización temporal) a la evaluación empírica más rigurosa, exhaustiva y justa posible. Al utilizar frameworks modernos de optimización bayesiana (como **Optuna** [6]) para llevar todos los algoritmos a su máximo límite teórico de rendimiento en múltiples datasets, esta tesis busca revelar empíricamente el verdadero “cruce de rendimiento” entre el paradigma clásico y el paradigma de grafos.

1.5. Objetivos

1.5.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales faltantes de EEG basados en Procesamiento de Señales en Grafos (GSP) y regularización temporal frente a baselines geométricos clásicos, utilizando un marco experimental riguroso, reproducible y exhaustivamente optimizado.

1.5.2. Objetivos Específicos

- **Consolidación de Métodos:** Implementar y unificar una amplia colección de métodos de interpolación (geométricos, estadísticos y basados en grafos) en un *pipeline* modular en Python.
- **Diseño de Escenarios Clínicos:** Definir protocolos realistas de simulación de canales faltantes, abarcando desde fallos esporádicos (*random*) hasta pérdidas masivas contiguas de amplificadores locales (*nearby*), iterando desde un 10 % hasta un 40 % de degradación de la malla sensora.
- **Optimización Imparcial (Fair Benchmarking):** Integrar el *framework* de optimización de hiperparámetros Optuna para explorar iterativamente los espacios paramétricos de todos los métodos (incluyendo las constantes de regularización α y β , los radios de influencia σ , y la esparsidad k), garantizando que ningún algoritmo sea evaluado por debajo de su límite de diseño.
- **Evaluación Multi-Métrica Transversal:** Cuantificar el desempeño de reconstrucción cruzando tres bases de datos heterogéneas (PhysioNet de alta densidad, BCI IV 2a de baja densidad y MNE Sample para evocados), utilizando una batería robusta de métricas que incluyan no solo error absoluto (MAE, RMSE, SNR), sino también fidelidad morfológica y espectral (DTW, Log Spectral Distance y Coherencia Magnitud-Cuadrada).
- **Análisis de Relevancia Fisiológica:** Demostrar visual y cualitativamente el impacto de los distintos enfoques de interpolación en la preservación de Potenciales Relacionados a Eventos (ERPs) específicos (e.g., N100, P300) y de la dinámica de bandas de frecuencia naturales del cerebro.
- **Trazabilidad Científica:** Generar un repositorio abierto de artefactos computacionales y bitácoras de resultados que permita la reproducibilidad total de los hallazgos para respaldar la redacción del documento de tesis y artículos científicos asociados.

1.6. Hipótesis de Trabajo

La integración de restricciones de suavidad espacial basadas en topologías de grafos junto con *priors* de continuidad temporal penalizada (tales como la regularización de Sobolev TRSS) permite reconstruir canales faltantes de EEG de manera significativamente más precisa y robusta que los métodos geométricos de extrapolación de superficies estáticas. Esta superioridad no solo se refleja en la mitigación del error cuadrático, sino fundamentalmente en la preservación fiel de la morfología transitoria (ERPs) y la densidad espectral (PSD) de las señales, especialmente ante escenarios clínicos de pérdida espacial severa y contigua.

Al cierre de la extensa fase experimental de esta investigación, la evidencia acumulada resulta fuertemente favorable a esta hipótesis. Como se expondrá en los capítulos de resultados, la regularización temporal marca un punto de inflexión decisivo en el desempeño de interpolación, validando la eficacia del enfoque propuesto.

1.7. Alcance y Aportes de la Investigación

El alcance de este trabajo engloba la ejecución computacional a gran escala del *pipeline* de evaluación cruzando múltiples datasets y escenarios de falla. A diferencia de las evaluaciones limitadas que abundan en el estado del arte, este trabajo consolida el análisis de miles de ensayos EEG bajo la optimización de decenas de miles de configuraciones paramétricas mediante Optuna.

Para garantizar reproducibilidad y cobertura sistemática, la ejecución se ancla en un registro exhaustivo de corridas experimentales que fija explícitamente las combinaciones de datasets, modos de pérdida, semillas, grafos y familias de métodos. Este diseño evita evaluaciones *ad-hoc* y permite trazar cada afirmación cuantitativa reportada en los capítulos posteriores hasta su artefacto experimental correspondiente.

Los principales aportes científicos y técnicos de esta tesis son:

- 1. Demostración del Cruce de Desempeño Teórico:** Proporcionar evidencia estadística de que, una vez que los hiperparámetros están sintonizados, las familias de regularización temporal (TRSS y Tikhonov) dominan de forma absoluta a los *baselines* geométricos (Spherical Splines) en fidelidad morfológica.
- 2. Análisis de Degradación en Casos Extremos:** Revelar que bajo regímenes críticos (ej. 40 % de canales faltantes agrupados localmente), los métodos geométricos clásicos experimentan un colapso exponencial de fase, mientras que el ancla temporal de los métodos GSP mantiene la estabilidad lineal de la trayectoria fisiológica.
- 3. Infraestructura de Código Abierto (Open Source):** La entrega de un *toolkit* de experimentación unificado en Python, completamente rastreable, que permitirá a la comunidad investigadora ejecutar interpolaciones GSP avanzadas con optimización Optuna de forma automatizada sobre sus propios datos neurológicos.

1.8. Estructura de la Tesis

Para desarrollar el análisis propuesto, el resto del documento se ha estructurado de la siguiente manera:

- **Capítulo 2 (Marco Teórico):** Presenta los fundamentos neurofisiológicos del EEG, los pilares matemáticos del Procesamiento de Señales en Grafos (GSP) —incluyendo el Laplaciano, la Transformada de Fourier en Grafos (GFT) y la inferencia de grafos— y el estado del arte en interpolación de señales biomédicas.
- **Capítulo 3 (Metodología):** Detalla exhaustivamente el protocolo experimental. Describe los tres datasets empleados, el modelado matemático de los algoritmos a evaluar, los métodos de simulación de daños (*Nearby* y *Random*), la función de las métricas de evaluación, y la arquitectura interna del motor de optimización bayesiana Optuna.
- **Capítulo 4 (Experimentos y Resultados):** Expone los hallazgos empíricos obtenidos de la ejecución masiva del *pipeline*. Incluye comparativas globales de error (heatmaps), la demostración del cruce del *baseline*, análisis multivariante en formato radar (pareto trade-offs), curvas de degradación por pérdida severa y demostraciones visuales de reconstrucción de series de tiempo ERP y PSD.
- **Capítulo 5 (Discusión):** Ofrece un análisis reflexivo y crítico sobre el porqué metodológico de los resultados obtenidos, conectando el comportamiento de fase de la regularización temporal con la naturaleza física del cerebro, además de transparentar las limitaciones técnicas del estudio.
- **Capítulo 6 (Conclusiones y Trabajo Futuro):** Sintetiza las deducciones fundamentales de la tesis, valora el cumplimiento de la hipótesis y los objetivos, y sugiere vías de investigación posteriores, tales como la aceleración en tiempo real para entornos BCI.

Capítulo 2

Marco Teórico

Este capítulo establece los fundamentos conceptuales, neurofisiológicos y matemáticos que sustentan el desarrollo de esta tesis. En una primera instancia, se describe la naturaleza de la señal electroencefalográfica (EEG) y las dificultades inherentes a su captura. Posteriormente, se formaliza la teoría del Procesamiento de Señales en Grafos (GSP) como marco de resolución, detallando las arquitecturas de interpolación clásica frente a las estrategias espacio-temporales modernas. Finalmente, se definen rigurosamente las métricas utilizadas para evaluar la fidelidad de la reconstrucción.

2.1. Fundamentos Neurofisiológicos de la Electroencefalografía (EEG)

El electroencefalograma es el registro de la actividad eléctrica del cerebro captada desde la superficie del cuero cabelludo. Esta señal refleja la suma espacio-temporal de los potenciales postsinápticos excitatorios e inhibitorios generados por decenas de miles de neuronas piramidales sincronizadas en la corteza cerebral. Debido a que las fuentes de estas corrientes eléctricas se encuentran separadas de los electrodos por diversas capas de tejido (piamadre, líquido cefalorraquídeo, cráneo y cuero cabelludo), la señal sufre un efecto de filtrado espacial y atenuación conocido como *efecto de conducción de volumen* (volume conduction).

En paralelo al uso clínico tradicional, la literatura reciente en procesamiento de EEG ha enfatizado que los retos actuales no se reducen al filtrado de ruido, sino a la preservación simultánea de estructura espacial, dinámica temporal y contenido espectral en presencia de datos incompletos [7]. Esta necesidad ha impulsado la transición desde modelos puramente geométricos hacia marcos de señal sobre grafos con regularización física y estadística [8, 9].

Este efecto provoca que el potencial eléctrico generado por una única fuente cortical se propague e irradie, siendo detectado por múltiples electrodos simultáneamente. Como resultado, las señales registradas en electrodos adyacentes presentan un alto grado de correlación espacial. Sin embargo, esta propagación no es perfectamente esférica ni homogénea debido a las anisotropías en la conductividad del cráneo. Por ello, si bien la distancia euclidiana entre electrodos es

informativa, no es una representación perfecta de la conectividad funcional subyacente.

Las señales EEG se caracterizan por su naturaleza oscilatoria y transitoria. Clásicamente, la actividad continua se descompone en bandas de frecuencia (Delta, Theta, Alfa, Beta, Gamma), mientras que la actividad evocada o fásica se manifiesta como Potenciales Relacionados a Eventos (ERP, por sus siglas en inglés). Los ERPs, como el N100 o el P300, son fluctuaciones de voltaje transitorias y de fase bloqueada que reflejan el procesamiento cognitivo o sensorial. La preservación de la morfología y la latencia temporal de estos ERPs es crítica en aplicaciones clínicas y de interfaces cerebro-computador (BCI).

2.2. El Problema de Canales Faltantes e Interpolación Clásica

En la práctica, la adquisición de datos EEG es altamente susceptible a la pérdida parcial de información. Los canales pueden resultar inutilizables por mala conductividad del gel, desprendimiento físico del electrodo, o saturación del amplificador por artefactos de movimiento. Matemáticamente, si la actividad cerebral medida se representa como un vector $\mathbf{x} \in \mathbb{R}^N$ para N electrodos, un evento de desconexión implica que solo observamos un subconjunto de electrodos $\mathcal{K} \subset \{1, \dots, N\}$. El objetivo de la interpolación es estimar los valores en el conjunto de canales faltantes $\mathcal{U}$, tal que $\mathcal{K} \cup \mathcal{U} = \mathcal{V}$ y $\mathcal{K} \cap \mathcal{U} = \emptyset$.

2.2.1. Interpolación Geométrica y Estadística

Clásicamente, el problema ha sido resuelto proyectando los valores conocidos mediante bases espaciales dependientes de la distancia euclidiana. El método estándar *de facto* es la interpolación por **Splines Esféricos** (*Spherical Splines*) [10]. Este método asume la topología de la cabeza como una esfera unitaria y proyecta el potencial en una ubicación faltante $\mathbf{r}$ como:

$$V(\mathbf{r}) = c_0 + \sum_{i \in \mathcal{K}} c_i g(\mathbf{r}, \mathbf{r}_i), \quad (2.1)$$

donde los coeficientes c_i se obtienen resolviendo un sistema lineal sobre los canales conocidos, y $g(\cdot, \cdot)$ es una función de base que decae con la distancia angular entre los vectores posición de los electrodos. Análogamente, las Funciones de Base Radial (RBF) [11] o la interpolación por vecinos más cercanos asumen suavidad espacial paramétrica en 3D.

El problema central de las familias geométricas es que calculan la interpolación operando sobre cada instante de tiempo t de forma aislada. Al carecer de *memoria* temporal, son incapaces de preservar la fase de transitorios rápidos o la dinámica espectral subyacente, introduciendo discontinuidades y ruido artificial de alta frecuencia en el canal interpolado.

Esta limitación ha sido señalada también en estudios de interpolación no-suave sobre grafos, donde se evidencia que la hipótesis de suavidad global puede ser insuficiente para señales con transitorios locales marcados [12]. En el contexto específico de EEG, reportes aplicados han mostrado que incorporar estructura de grafo mejora la imputación frente a enfoques clásicos,

pero con fuerte dependencia de la calidad del grafo y su parametrización [13, 14].

2.3. Teoría de Grafos y Procesamiento de Señales en Grafos (GSP)

Para abandonar la restricción de la esfera euclidiana, el Procesamiento de Señales en Grafos (GSP) [15, 16, 17, 18] propone modelar los electrodos y sus interacciones complejas como un grafo ponderado.

Desde una perspectiva histórica, esta transición no solo introduce nuevas herramientas matemáticas, sino también un cambio epistemológico: la señal ya no se interpreta como una función en una superficie continua idealizada, sino como una realización en una red irregular donde topología y señal se co-determinan. Esta visión ha demostrado utilidad en aplicaciones biomédicas para representación espectral, reducción de dimensionalidad y análisis de conectividad funcional [19, 20].

Un grafo no dirigido se define como $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde $\mathcal{V}$ es el conjunto de N vértices (electrodos), $\mathcal{E}$ es el conjunto de aristas y $\mathbf{W} \in \mathbb{R}^{N \times N}$ es la matriz de adyacencia ponderada. El peso $W_{ij} \geq 0$ codifica la fuerza de la relación (física o funcional) entre el electrodo i y el electrodo j . Una señal de EEG en un instante determinado se define como una “señal sobre el grafo” $\mathbf{x} \in \mathbb{R}^N$, una función que mapea cada vértice a un escalar (voltaje).

2.3.1. El Laplaciano del Grafo

El operador fundamental en GSP es el Laplaciano Combinatorial $\mathbf{L} = \mathbf{D} - \mathbf{W}$, donde $\mathbf{D}$ es la matriz diagonal de grados con $D_{ii} = \sum_j W_{ij}$. Al ser simétrica y semidefinida positiva, $\mathbf{L}$ posee un conjunto completo de autovectores reales ortonormales $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_N]$ y autovalores no negativos $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$, tal que $\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top$ con $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$.

La forma cuadrática del Laplaciano cuantifica la “variación total” o la suavidad espacial de la señal $\mathbf{x}$ sobre la topología de la red:

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{(i,j) \in \mathcal{E}} W_{ij} (x_i - x_j)^2. \quad (2.2)$$

Un valor bajo de $S(\mathbf{x})$ indica que los valores de señal entre electrodos fuertemente conectados son muy similares, lo que representa una señal suave o de baja frecuencia en el dominio espacial.

En términos de marco conceptual general, la formulación moderna de señales sobre grafos y sus operadores espectrales se apoya también en revisiones fundacionales complementarias ampliamente citadas en la literatura reciente [21].

2.3.2. Transformada de Fourier sobre Grafos (GFT)

Por analogía con el análisis de Fourier clásico, los autovectores de $\mathbf{L}$ conforman la base de Fourier del grafo, y los autovalores λ_l actúan como las “frecuencias”. La Transformada de Fourier

sobre Grafos (GFT) de una señal $\mathbf{x}$ se define como su proyección sobre los autovectores:

$$\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}. \quad (2.3)$$

En el EEG, los componentes asociados a autovalores pequeños ($\lambda \approx 0$) representan patrones de actividad topográfica generalizada y sincrónica (ej., ritmo alfa global). Los autovalores grandes representan variaciones espaciales abruptas (ej., ruido electromagnético de alta frecuencia o actividad muscular aislada focal). Así, la interpolación espacial basada en GSP actúa intrínsecamente como un filtro paso-bajo direccional sobre la superficie del cráneo [22].

2.3.3. Construcción y Aprendizaje de Grafos

El éxito del GSP recae enteramente en la matriz $\mathbf{W}$. En neurofisiología, la topología puede diseñarse utilizando tres estrategias generales:

- **Grafos Geométricos:** Construidos *a priori* usando la inversa de la distancia euclidiana entre las coordenadas 3D de los electrodos. Una variante popular es el Grafo K-Vecinos Más Cercanos Gaussianos (k -NN Gaussiano), donde $W_{ij} = \exp(-d(i, j)^2/\sigma^2)$ si j está entre los k vecinos de i , y 0 en caso contrario. Tamaru et al. [23] han explorado variantes de k dinámico para combatir irregularidades locales en la densidad de mallas.
- **Grafos Funcionales o de Correlación:** Extraídos empíricamente de la covarianza de la señal temporal o modelos adaptativos como *Adaptive Edge Weighting* [24].
- **Aprendizaje de Grafos (Graph Learning):** Problemas de optimización inversos que buscan inferir la matriz $\mathbf{W}$ desde los datos pidiendo simultáneamente que la red resultante sea esparsa y que las señales observadas exhiban alta suavidad laplaciana [25, 26].

Dentro de esta línea, los trabajos sobre aprendizaje de grafos de gran escala y selección de vecindad para señales sobre grafos han reforzado criterios prácticos de construcción topológica en escenarios con alta dimensionalidad y heterogeneidad de conectividad [27, 28, 29].

2.4. Estrategias de Reconstrucción de Grafos

El problema de interpolación se formula como un problema inverso mal propuesto. Definimos una matriz diagonal de muestreo $\mathbf{S} \in \mathbb{R}^{N \times N}$ donde $S_{ii} = 1$ si $i \in \mathcal{K}$ (observado) y 0 si $i \in \mathcal{U}$ (faltante). Observamos la señal parcial $\mathbf{y} = \mathbf{S}\mathbf{x}$.

2.4.1. Regularización Tikhonov Espacial

El enfoque clásico de GSP es la regularización de Tikhonov sobre grafos [30]. Asumiendo ruido gaussiano, se busca recuperar $\mathbf{x}$ minimizando el error de los nodos conocidos más una

penalización a la variación total (Ecuación 2.2):

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{z}} \|\mathbf{y} - \mathbf{S}\mathbf{z}\|_2^2 + \alpha(\mathbf{z}^\top \mathbf{L}\mathbf{z}). \quad (2.4)$$

donde el hiperparámetro $\alpha > 0$ controla el nivel de suavidad forzada (*spatial smoothness*).

Además de la formulación cerrada, existen variantes iterativas localizadas que reducen costo computacional y facilitan despliegue en redes de sensores de mayor escala [31].

2.4.2. Recuperación Bandlimited y Espacios RKHS (BGSRP)

Un enfoque alternativo, BGSRP (*Bandlimited Graph Signal Recovery in RKHS*) [32], asume que las señales EEG son estrictamente limitadas en banda (solo contienen frecuencias de grafo $\lambda \leq \lambda_c$). Utilizando un Espacio de Hilbert de Núcleo Reproductor (RKHS), se reconstruye la señal proyectando sobre una matriz núcleo $\mathbf{K}$ ensamblada a partir de los primeros B autovectores. En paralelo, la literatura reciente también ha reforzado la base teórica de la recuperación sobre grafos con resultados de garantía de identificación y acotación de coherencia [33], además de extender los marcos de reconstrucción hacia formulaciones generalizadas vértice-tiempo [34].

En la misma línea, los desarrollos más recientes sobre grafos variables en el tiempo muestran que, cuando la estructura de dependencia evoluciona junto con la señal, los modelos con acoplamiento espacio-temporal explícito ofrecen mayor capacidad de generalización para tareas de reconstrucción y predicción [35, 36]. Esta evidencia respalda directamente el uso de regularización temporal en escenarios EEG con pérdida severa o contigua de canales.

2.4.3. Regularización Espacio-Temporal (TRSS)

Todos los métodos anteriores reconstruyen una muestra temporal a la vez. Sin embargo, un EEG es una matriz continua $\mathbf{X} \in \mathbb{R}^{N \times T}$. La Regularización de Suavidad de Sobolev Temporal (TRSS, *Temporal Regularized Sobolev Smoothness*) [5] revoluciona la interpolación minimizando simultáneamente los gradientes espaciales y las derivadas temporales:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z}} \|\mathbf{S}\mathbf{X} - \mathbf{S}\mathbf{Z}\|_F^2 + \alpha \operatorname{tr}(\mathbf{Z}^\top \mathbf{L}\mathbf{Z}) + \beta \|\mathbf{Z}\mathbf{D}_t\|_F^2, \quad (2.5)$$

donde $\mathbf{D}_t$ es una matriz que actúa como operador de diferencias finitas temporales (i.e. penalizando cambios bruscos en el tiempo). Este *prior* temporal, controlado por β , es excepcionalmente poderoso para el EEG, ya que refleja matemáticamente la inercia neurofisiológica de los generadores dipolares del cerebro.

2.5. Definición de las Métricas de Rendimiento

Para evaluar rigurosamente la calidad de la reconstrucción se han implementado métricas de error escalar, morfológico y espectral. Sean $\mathbf{x}$ el vector real de un canal en el tiempo de longitud T y $\hat{\mathbf{x}}$ su reconstrucción:

- **Mean Absolute Error (MAE):** Error lineal promedio que refleja la desviación absoluta media, altamente intuitivo para bioseñales.

$$\text{MAE}(\mathbf{x}, \hat{\mathbf{x}}) = \frac{1}{T} \sum_{t=1}^T |x(t) - \hat{x}(t)| \quad (2.6)$$

- **Root Mean Square Error (RMSE):** Medida de error cuadrática. Penaliza severamente grandes desviaciones aisladas (*outliers*), sirviendo como proxy para inestabilidades en la interpolación.

$$\text{RMSE}(\mathbf{x}, \hat{\mathbf{x}}) = \sqrt{\frac{1}{T} \sum_{t=1}^T (x(t) - \hat{x}(t))^2} \quad (2.7)$$

- **Signal-to-Noise Ratio (SNR):** Cuantifica cuánta energía de la señal original es preservada frente a la energía del error residual, expresado en decibelios (dB). Un SNR alto indica una reconstrucción casi perfecta.

$$\text{SNR}(\mathbf{x}, \hat{\mathbf{x}}) = 10 \log_{10} \left(\frac{\sum x(t)^2}{\sum (x(t) - \hat{x}(t))^2} \right) \quad (2.8)$$

- **Dynamic Time Warping (DTW):** A diferencia del MAE o RMSE que comparan vectores punto a punto $\hat{x}(t)$ con $x(t)$, DTW busca la alineación temporal óptima de secuencias que minimice la distancia euclidiana. Es excepcionalmente valioso en EEG porque permite medir la fidelidad morfológica (la “forma” del ERP) sin ser excesivamente penalizado por minúsculos desfases de latencia de fase.
- **Log Spectral Distance (LSD):** Mide la distancia entre las Densidades Espectrales de Potencia (PSD) de ambas señales en escala logarítmica. Esto asegura que la reconstrucción preserve no solo la forma en el tiempo, sino la distribución de energía en las bandas Alfa, Beta y Gamma, crucial para análisis de BCI.
- **Magnitude-Squared Coherence (Coherencia):** Una medida entre 0 y 1 que indica el nivel de correlación de fase lineal entre ambas señales a través de distintas frecuencias.

2.6. Brechas en el Estado del Arte

Si bien estudios recientes han aplicado GSP para tareas avanzadas como extracción de características para desórdenes de conciencia [37] o detección de Alzheimer [38], la aplicación de grafos dinámicos en la recuperación de señales [35, 36] ha puesto en evidencia una grave falla metodológica en la evaluación biomédica. Específicamente, en el problema de canales EEG, los *baselines* como Splines Esféricos o RBF suelen ejecutarse con hiperparámetros estáticos o predeterminados por el software original, en tanto que los métodos nuevos sí se calibran. Esto enmascara el rendimiento asintótico real y entrega una ventaja desleal al nuevo algoritmo [8].

Esta tesis viene a sanear dicho vacío, sometiendo tanto el estado del arte espacial como los modelos temporales TRSS a un proceso de sintonización bayesiana irrestricto, con un marco métrico fisiológico inusualmente riguroso y un fuerte énfasis en la mitigación de fallas contiguas (*nearby masking*).

Capítulo 3

Metodología

Este capítulo describe exhaustivamente el diseño experimental empleado para validar la hipótesis central de esta tesis. Se detalla cada componente del *pipeline* computacional: desde la selección y preprocesamiento de los datos de entrada, pasando por la construcción de grafos y la simulación controlada de fallas sensoriales, hasta la optimización bayesiana de hiperparámetros y la evaluación cuantitativa final. El principio rector fue garantizar que todas las familias de métodos —geométricos, estadísticos y basados en grafos— compitan bajo condiciones estrictamente equivalentes de sintonización paramétrica, eliminando así el sesgo de benchmarking que permea la literatura actual.

3.1. Arquitectura General del Pipeline




Figura 3.1: Representación esquemática del pipeline metodológico de optimización y evaluación propuesto.

El flujo de trabajo se organiza como una secuencia determinista de seis etapas:

1. **Carga y estandarización** de datasets heterogéneos mediante `mne-python`.
2. **Construcción del grafo** sobre las coordenadas 3D de los electrodos y/o la covarianza temporal de la señal.
3. **Simulación de canales faltantes** bajo protocolos espaciales controlados (*random* y *nearby*).

4. **Interpolación y reconstrucción** mediante el abanico completo de métodos implementados.
5. **Optimización de hiperparámetros** con Optuna (muestreo TPE y NSGA-II multi-objetivo).
6. **Evaluación cuantitativa** con seis métricas complementarias y consolidación estadística.

Cada etapa genera artefactos intermedios serializados (archivos CSV, JSON y matrices NumPy), lo que permite desacoplar el cómputo intensivo de la generación de figuras y tablas finales. Esta modularidad garantiza la trazabilidad completa desde el dato crudo hasta cada cifra reportada en el manuscrito.

Como capa final de control experimental, la cobertura de configuraciones se gobernó mediante un registro exhaustivo que define explícitamente el espacio combinatorio de datasets, constructores de grafo, escenarios de pérdida, semillas, hiperparámetros y familias de métodos. De esta forma, cada resultado reportado mantiene una trazabilidad completa desde la configuración inicial hasta los artefactos generados (tablas de estadísticas, metadatos y figuras).

La implementación computacional se desarrolló estructurando el código de la investigación en módulos lógicos que separan responsabilidades:

- **Carga de Datos:** Módulos unificados para procesar los tres datasets de manera estandarizada.
- **Construcción de Grafos:** Implementación de los constructores espaciales y temporales.
- **Interpolación:** Funciones que agrupan tanto los algoritmos de Procesamiento de Señales en Grafos como los baselines geométricos e ICA.
- **Evaluación:** Módulo dedicado al cálculo unificado de las métricas de rendimiento temporales y espectrales.
- **Experimentos y Optimización:** Scripts orquestadores encargados de la simulación, la búsqueda bayesiana de hiperparámetros y la visualización de resultados.

3.2. Bases de Datos Experimentales

La validez externa de cualquier estudio de interpolación depende críticamente de la diversidad de los datos de prueba. Se seleccionaron tres datasets públicos que cubren un amplio espectro de densidades espaciales, frecuencias de muestreo y paradigmas cognitivos.

3.2.1. PhysioNet EEG Motor Movement/Imagery Dataset (EEGMMIDB)

Este dataset, alojado en la base de datos PhysioNet, comprende registros de 64 canales EEG adquiridos a 160 Hz bajo el sistema internacional 10-10. Los sujetos realizaron tareas de ejecución

motora real (apertura y cierre de puños) e imagería motora (imaginación del mismo movimiento sin ejecución). La alta densidad de electrodos genera una malla espacial densa con alta correlación inter-canal, lo que constituye el escenario más favorable para los métodos geométricos.

La carga y estandarización se realizan mediante las funciones provistas por MNE-Python, aplicando la nomenclatura estándar de canales y asignando el montaje 10-05 para obtener coordenadas 3D.

3.2.2. BCI Competition IV Dataset 2a

El dataset BCI Competition IV 2a [39] es un estándar en la comunidad de interfaces cerebro-computador. Contiene registros de 22 canales EEG (montaje 10-20 extendido) adquiridos a 250 Hz de 9 sujetos realizando imagería motora de 4 clases: mano izquierda, mano derecha, ambos pies y lengua.

La baja densidad espacial de este dataset (22 canales frente a los 64 de PhysioNet) representa un desafío extremo para la interpolación. Con solo 22 nodos en el grafo, la pérdida de incluso 2–3 canales puede dejar regiones del cráneo sin cobertura sensora alguna, exponiendo las debilidades inherentes de los métodos puramente geométricos.

Los archivos en formato GDF requieren descarga manual desde el sitio oficial de la competencia. La carga se realiza mediante las funciones de lectura de MNE-Python, con un mapeo explícito de nombres de canal al estándar 10-05.

3.2.3. MNE Sample Dataset

El MNE Sample Dataset [40] es un registro multimodal (MEG y EEG) de 60 canales EEG a 600 Hz, capturando potenciales evocados auditivos y visuales. Este dataset fue seleccionado específicamente por la presencia de componentes ERP bien documentados (N100, P300), cuya preservación morfológica y temporal constituye el criterio más exigente de evaluación clínica.

La carga se realiza mediante MNE-Python, seleccionando exclusivamente los canales EEG y extrayendo las posiciones 3D del montaje asociado.

3.2.4. Resumen Comparativo de Datasets

Tabla 3.1: Características de los tres datasets experimentales.

Característica	PhysioNet	BCI IV 2a	MNE Sample
Canales EEG	64	22	60
Frecuencia (Hz)	160	250	600
Paradigma	Motor MI	Motor MI 4-cl	Evocados A/V
Montaje	10-10	10-20 ext.	Personalizado
Densidad espacial	Alta	Baja	Alta

3.3. Construcción de Grafos

La topología del grafo es un factor determinante en el rendimiento de cualquier algoritmo GSP. En esta tesis se evaluaron 8 constructores de grafo organizados en tres categorías.

3.3.1. Grafos de Vecindad Geométrica

Estos grafos conectan electrodos basándose exclusivamente en la proximidad euclidiana de sus coordenadas 3D en el cuero cabelludo.

- **knn** (*k*-Nearest Neighbors): Conecta cada electrodo con sus k vecinos más cercanos. Se aplica simetrización posterior por máximo para garantizar un grafo no dirigido.
- **knng** (*k*-NN Gaussiano): Extiende **knn** asignando pesos gaussianos a las aristas:

$$W_{ij} = \exp\left(-\frac{d(i,j)^2}{2\sigma^2}\right) \cdot \mathbb{1}_{[j \in \mathcal{N}_k(i)]} \quad (3.1)$$

donde σ controla el ancho del kernel y $\mathcal{N}_k(i)$ denota el conjunto de k vecinos de i .

- **vknnng** (*k*-NN Variable Gaussiano): Inspirado en Tamaru et al. [23], adapta k_i por nodo según la densidad local de sensores:

$$k_i = \text{clip}\left(\text{round}\left(k_{\text{base}} \cdot \left(\frac{\tilde{d}}{d_i}\right)^\alpha\right), k_{\text{mín}}, k_{\text{máx}}\right) \quad (3.2)$$

donde $\tilde{d}$ es la mediana de las distancias al k -ésimo vecino y d_i la distancia local del nodo i .

- **epsilon_ball**: Conecta todos los pares (i, j) cuya distancia satisface $d(i, j) < \epsilon$.
- **mst** (Minimum Spanning Tree): Garantiza conectividad mínima del grafo construyendo el árbol de expansión mínima sobre la matriz de distancias euclidianas.

3.3.2. Grafos Densos / Globales

- **fully_connected_inverse_distance**: $W_{ij} = 1/d(i, j)$ para todo par de electrodos.
- **gaussian**: Kernel gaussiano global sin restricción de vecindad.

3.3.3. Grafos Adaptativos e Inferencia Basada en Datos

Estos métodos aprenden la topología directamente desde los datos, superando las limitaciones del modelo esférico.

- **nnk** (Non-Negative Kernel Regression) [41]: Resuelve un problema de mínimos cuadrados no negativos (NNLS) local para cada nodo, obteniendo pesos de arista esparcidos que reflejan genuinamente la estructura geométrica local.

- **aew** (Adaptive Edge Weighting) [24]: Optimiza los pesos de las aristas minimizando un error de reconstrucción local bajo una parametrización por funciones de similitud. Cuando el optimizador AEW no converge, un *fallback* heurístico combina kernel gaussiano espacial con correlación temporal.
- **kalofolias** (Graph Learning) [25]: Implementación del modelo de aprendizaje de grafos con regularización *log-degree*:

$$\min_{\mathbf{W} \geq 0} \langle \mathbf{Z}, \mathbf{W} \rangle - a \sum_i \log(d_i) + \frac{b}{2} \|\mathbf{W}\|_F^2 \quad (3.3)$$

donde $\mathbf{Z}$ es la matriz de distancias al cuadrado entre señales, y los parámetros a, b equilibran esparsidad y conectividad. La solución se obtiene por descenso de gradiente proyectado con restricciones de simetría y no-negatividad.

En la fase de optimización final, se seleccionó **knng** como constructor primario por su estabilidad numérica (ausencia de grafos desconexos), eficiencia computacional y desempeño competitivo sostenido a lo largo de todos los escenarios.

3.4. Protocolo de Simulación de Canales Faltantes

Para evaluar la robustez bajo condiciones realistas, se diseñaron dos modos de falla espacial que capturan los escenarios más frecuentes en la práctica clínica.

3.4.1. Modo *Random* (Fallas Independientes)

Los canales se seleccionan para remoción mediante un muestreo uniforme discreto sin reemplazo. Este modo simula fallas estocásticas e independientes, como el deterioro gradual del gel conductor en electrodos arbitrarios o el descarte manual de canales ruidosos durante el preprocesamiento.

3.4.2. Modo *Nearby* (Fallas Contiguas)

Se selecciona un electrodo semilla aleatorio y se remueven sus m vecinos más cercanos (por distancia euclidiana 3D). Este modo simula fallas correlacionadas espacialmente de alta adversidad: desprendimiento de un parche del gorro EEG, falla de un módulo de amplificación local, o saturación de toda una región por un artefacto de movimiento.

3.4.3. Niveles de Degradación

Cada modo se combina con dos esquemas de severidad:

- **Por proporción (*ratio*)**: 10 %, 20 %, 30 % y 40 % de los canales totales.

- **Por conteo discreto (*count*):** 1, 2 o 3 canales específicos.

La combinación de 2 modos $\times$ 7 niveles produce 14 escenarios experimentales por dataset, resultando en 42 contextos experimentales únicos.

3.5. Métodos de Interpolación y Reconstrucción

El framework implementa un total de 18 algoritmos de interpolación organizados en tres familias.

3.5.1. Familia 1: Baselines Geométricos y Estadísticos

Estos métodos no utilizan información de grafos y sirven como referencia inferior.

- **Spherical Spline** [10]: Estándar *de facto* en herramientas clínicas como MNE-Python y EEGLAB. Modela el cuero cabelludo como una esfera e interpola usando polinomios de Legendre. El hiperparámetro de regularización ε controla la suavidad.
- **RBF Interpolation (Thin-Plate Spline y Multiquadric)** [11]: Funciones de base radial con kernel *Thin-Plate* o *Multiquadric*. El parámetro de suavizado controla el *trade-off* entre fidelidad a los datos e interpolación suave.
- **ICA (Independent Component Analysis)**: Basado en el algoritmo FastICA. Los canales faltantes se inicializan con la media del canal y se reconstruyen desde la proyección inversa de las componentes independientes.
- **IDW (Inverse Distance Weighting)**: Promedio ponderado por la inversa de la distancia euclidiana elevada a una potencia p .
- **Nearest Neighbor / Mean**: Baselines triviales para establecer el piso de rendimiento absoluto.

3.5.2. Familia 2: Métodos GSP Espaciales (Instantáneos)

Estos métodos operan muestra por muestra (t fijo), resolviendo un problema de optimización espacial independiente en cada instante temporal.

- **GSP puro (Laplacian Solving)**: Resuelve el sistema $\mathbf{L}_{\mathcal{U}\mathcal{U}}\hat{\mathbf{x}}_{\mathcal{U}} = -\mathbf{L}_{\mathcal{U}\mathcal{K}}\mathbf{x}_{\mathcal{K}}$ directamente mediante la factorización del subsistema lineal correspondiente.
- **Tikhonov en Grafo**: Resuelve $(\mathbf{M} + \alpha\mathbf{L})\hat{\mathbf{x}} = \mathbf{M}\mathbf{y}$, donde $\mathbf{M}$ es la máscara diagonal de observación y α el peso de regularización.
- **BGSRP** [32]: Reconstrucción en RKHS bandlimited. Utiliza los primeros B autovectores del Laplaciano (excluyendo la componente DC) para construir un kernel $\mathbf{K}$ y resolver con regularización γ .

- **Graph Smoothing**: Difusión iterativa sobre la matriz de transición normalizada del grafo.
- **Graph TV**: Variación total en grafo via IRLS (*Iteratively Reweighted Least Squares*), promoviendo señales con pocas discontinuidades abruptas.
- **Sobolev / Puy**: Variantes de regularización con operadores diferenciales de alto orden sobre el grafo.

3.5.3. Familia 3: Métodos con Regularización Temporal

Estos métodos operan sobre ventanas temporales completas $\mathbf{X} \in \mathbb{R}^{N \times T}$, optimizando conjuntamente los gradientes espaciales y temporales. Esta es la familia que constituye la contribución analítica central de esta tesis.

- **TRSS** (Temporal Regularized Sobolev Smoothness) [5]: Minimiza la función de costo espacio-temporal completa. La implementación utiliza descenso de gradiente con paso adaptativo basado en la cota de Lipschitz:

$$L = 2(1 + \alpha \|\mathbf{L}\|_2 + \beta \|\mathbf{L}_t\|_2 \|\mathbf{L}\|_2) \quad (3.4)$$

donde $\mathbf{L}_t = \mathbf{D}_t^\top \mathbf{D}_t$ es el Laplaciano temporal (operador de diferencias finitas). Las observaciones conocidas se fijan en cada iteración (*hard constraint*).

- **Graph-Time Tikhonov**: Combina regularización Tikhonov espacial con suavizado temporal bilateral en dos etapas secuenciales.
- **Sobolev Temporal / Temporal Laplacian / Heat Diffusion Temporal**: Variantes que modifican la formulación del operador temporal.

3.6. Optimización de Hiperparámetros con Optuna

La contribución metodológica más importante de este trabajo es someter *todos* los métodos—incluyendo los baselines clásicos— a una optimización de hiperparámetros rigurosa. Se utilizó el framework **Optuna** [6] por su eficiencia en espacios de búsqueda continuos y mixtos.

3.6.1. Estrategia de Muestreo

Para la optimización mono-objetivo (minimizar MAE), se empleó el muestreador **TPE** (*Tree-structured Parzen Estimator*), que modela la distribución condicional de los hiperparámetros dado el rendimiento observado, concentrando la exploración en regiones prometedoras.

Para la optimización multi-objetivo (minimizar simultáneamente MAE y LSD), se empleó el muestreador **NSGA-II** (*Non-dominated Sorting Genetic Algorithm II*), que construye un frente de Pareto de soluciones no dominadas. La selección del mejor trial del frente se realiza por distancia euclidiana normalizada al origen.

3.6.2. Espacios de Búsqueda por Familia

Los rangos de búsqueda fueron definidos para cubrir las regiones de interés sin incluir configuraciones degeneradas:

Tabla 3.2: Espacios de búsqueda de hiperparámetros por método.

Método	Parámetro	Rango
Spherical Spline	<code>eps</code>	$[10^{-8}, 10^{-2}]$ (log)
RBF (TPS)	<code>smooth</code>	$[0, 0, 5, 0]$
ICA	<code>n_components</code>	$[1, N_{\text{ch}}]$ (int)
Tikhonov	α	$[10^{-4}, 10^2]$ (log)
BGSRP	<code>bandwidth</code> , γ	$[2, N - 1]$, $[10^{-4}, 10]$
TRSS	α, β	$[10^{-3}, 10]$, $[10^{-4}, 1]$
TRSS	<code>n_iter</code> , <code>lr</code>	$[50, 500]$, $[10^{-4}, 0, 1]$
Grafo (<code>knng</code>)	k, σ	$[2, N/2]$, $[0, 01, 5]$

3.6.3. Protocolo de Ejecución

Para cada combinación (dataset $\times$ escenario de falla $\times$ método), Optuna fue ejecutado siguiendo una política de muestreo estratificada para garantizar una sintonía homogénea entre familias de métodos: los métodos basados en grafo y temporales (p. ej. Tikhonov, TRSS) emplearon el muestreador TPE con 30 *trials* por combinación, mientras que los baselines geométricos se optimizaron con un muestreador NSGA-II multi-objetivo con 10 *trials* por combinación. Los hiperparámetros óptimos y las métricas resultantes se consolidaron en tablas estructuradas para su análisis posterior.

3.6.4. Validación Temporal y Prevención de Fuga de Datos (*Data Leakage*)

Un aspecto crítico en la optimización de hiperparámetros para señales temporales es evitar que el modelo “vea” los mismos datos durante la sintonización y la evaluación final. Para mitigar este riesgo, se implementó un esquema de validación cruzada temporal estricto:

1. **Split Temporal:** Cada segmento de señal se divide cronológicamente en dos bloques: los primeros 70 % de las muestras constituyen el *Optimization Set* (entrenamiento/validación interna).
2. **Buffer de Autocorrelación:** Para contrarrestar la fuerte autocorrelación temporal inherente a señales EEG filtradas por banda pasante (0.5–40 Hz), se descarta un *buffer gap* de 2 segundos ($2 \times f_s$ muestras) entre el final del *Optimization Set* y el inicio del *Test Set*. Esta “zona muerta” asegura que las muestras de test no sean trivialmente predecibles desde la frontera de optimización.

3. **Optimización Aislada:** Optuna evalúa la función objetivo (minimización de MAE y LSD) exclusivamente sobre el *Optimization Set*.
4. **Reporte Final:** Una vez seleccionados los mejores parámetros por Optuna, las métricas finales reportadas en los capítulos de Resultados y Discusión se calculan únicamente sobre el *Test Set*.

Este protocolo garantiza que los resultados reflejen la capacidad genuina de los algoritmos para reconstruir información neurofisiológica futura, simulando una aplicación en tiempo real donde los parámetros óptimos del pasado deben generalizar a muestras nuevas.

3.7. Evaluación Cuantitativa

El rendimiento de cada método se cuantifica mediante seis métricas complementarias que capturan dimensiones ortogonales del error de reconstrucción.

3.7.1. Métricas de Error de Amplitud

- **MAE** (Mean Absolute Error): $\text{MAE} = \frac{1}{T} \sum_{t=1}^T |x(t) - \hat{x}(t)|$. Mide la desviación absoluta promedio. Robusta a outliers.
- **RMSE** (Root Mean Square Error): $\text{RMSE} = \sqrt{\frac{1}{T} \sum (x(t) - \hat{x}(t))^2}$. Penaliza severamente errores grandes aislados, sirviendo como detector de inestabilidades numéricas.
- **SNR** (Signal-to-Noise Ratio): $\text{SNR} = 10 \log_{10} \left(\frac{\text{Var}(x)}{\text{Var}(x - \hat{x})} \right)$ dB. Proporciona una medida global y acotada, fácilmente interpretable entre escalas de sensores distintas.

3.7.2. Métricas de Fidelidad Temporal

- **DTW** (Dynamic Time Warping): Calcula la alineación temporal óptima entre dos secuencias minimizando la distancia euclidiana acumulada. Es esencial para la evaluación de ERPs, ya que tolera pequeños desfases de latencia sin penalizarlos como error de amplitud. Se utiliza programación dinámica con ventana de Sakoe-Chiba para acotar la complejidad computacional.

3.7.3. Métricas Espectrales

- **LSD** (Log Spectral Distance): $\text{LSD} = \sqrt{\frac{1}{K} \sum_k (\log |X(k)| - \log |\hat{X}(k)|)^2}$, donde $X(k)$ y $\hat{X}(k)$ son las magnitudes de la FFT de la señal original y reconstruida. Cuantifica la preservación del contenido frecuencial en las bandas fisiológicas.
- **Coherencia** (Magnitude-Squared Coherence): $C_{xy}(f) = \frac{|S_{xy}(f)|^2}{S_{xx}(f)S_{yy}(f)}$. Valores cercanos a 1 indican preservación perfecta de la correlación de fase en cada frecuencia.

Todas las métricas se promedian sobre los canales reconstruidos. La combinación de estas seis dimensiones impide que un método oculte sus debilidades: un MAE bajo obtenido por suavizado se evidenciará como un DTW y LSD elevados.

3.8. Consolidación Estadística y Generación de Artefactos

Los resultados individuales se agregan mediante:

- **Tablas pivot** (*pivot tables*): Resumen del rendimiento óptimo por familia de método, dataset y escenario.
- **Rankings por escenario**: Clasificación ordinal de métodos que permite identificar la familia dominante en cada contexto experimental.
- **Pruebas de significancia estadística**: Validación inferencial no paramétrica a nivel de *trial* mediante Mann-Whitney U y delta de Cliff.

Los artefactos visuales generados incluyen:

- **Mapas de calor (Heatmaps)**: Rendimiento RMSE cruzando métodos $\times$ escenarios.
- **Gráficos radar multi-métrica**: Visualización simultánea de las seis métricas normalizadas.
- **Curvas de degradación**: SNR vs. proporción de canales faltantes para cada dataset.
- **Frentes de Pareto**: Trade-off DTW vs. MAE entre familias.
- **Series de tiempo ERP y PSD**: Comparación cualitativa visual de la reconstrucción.

3.9. Stack Tecnológico e Infraestructura

La totalidad del pipeline se implementó en **Python 3.10+**, aprovechando el ecosistema científico abierto:

- **MNE-Python** [40]: Carga, preprocesamiento y manipulación de datos EEG.
- **NumPy / SciPy**: Álgebra lineal densa, descomposiciones espectrales, optimización NNLS, funciones de interpolación y análisis espectral.
- **scikit-learn**: Construcción de grafos k -NN, FastICA.
- **Optuna** [6]: Optimización bayesiana de hiperparámetros.
- **Pandas / Matplotlib**: Consolidación tabular y generación de figuras de publicación.
- **dtaidistance**: Cálculo eficiente de DTW con implementación en C.

Todas las operaciones de álgebra matricial asociadas a la inversión de los sistemas lineales GSP (Tikhonov, BGSRP) se implementaron con rutinas vectorizadas propias para maximizar la reproducibilidad y el control sobre las tolerancias numéricas. Para BGSRP se implementó además una pseudo-inversa con tolerancia numérica equivalente a la utilizada en implementaciones de referencia.

3.10. Reproducibilidad y Transparencia

La reproducibilidad total del experimento se garantiza mediante:

1. **Semillas fijas:** Todas las operaciones estocásticas (muestreo de máscaras, inicialización de ICA, muestreo de Optuna) utilizan semillas deterministas para asegurar resultados idénticos entre ejecuciones.
2. **Versionado de artefactos:** Los archivos de resultados, configuraciones experimentales y bitácoras de ejecución se almacenan bajo control de versiones en un repositorio Git.
3. **Ejecución modular:** Cada fase del *pipeline* puede re-ejecutarse independientemente, permitiendo reproducir de forma aislada la optimización, la evaluación o la generación de figuras.
4. **Registro de advertencias numéricas:** Un módulo dedicado captura y serializa cualquier advertencia (convergencia de ICA, singularidad de Laplaciano) para auditoría posterior.

Bibliografía

- [1] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier, “Spherical splines for scalp potential and current density mapping,” *Electroencephalography and Clinical Neurophysiology*, vol. 72, no. 2, pp. 184–187, 1989.
- [2] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs,” *IEEE Signal Processing Magazine*, vol. 30, no. 3, pp. 83–98, 2013.
- [3] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges, and applications,” *Proceedings of the IEEE*, vol. 106, no. 5, pp. 808–828, 2018.
- [4] S. K. Narang and A. Ortega, “Signal processing techniques for interpolation in graph structured data,” in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2013, pp. 5445–5449.
- [5] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans, “Reconstruction of time-varying graph signals via sobolev smoothness,” *IEEE Transactions on Signal and Information Processing over Networks*, vol. 8, pp. 201–214, 2022.
- [6] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631.
- [7] R. Sharma and H. K. Meena, “Emerging trends in EEG signal processing: A systematic review,” *SN COMPUT. SCI.*, vol. 5, no. 4, p. 415, 2024. [Online]. Available: <https://link.springer.com/10.1007/s42979-024-02773-w>
- [8] M. A. A. Calazans, F. A. B. S. Ferreira, F. A. N. Santos, F. Madeiro, and J. B. Lima, “Machine learning and graph signal processing applied to healthcare: A review,” *Bioengineering*, vol. 11, no. 7, p. 671, 2024. [Online]. Available: <https://www.mdpi.com/2306-5354/11/7/671>
- [9] R. Li, X. Yuan, M. Radfar, P. Marendy, W. Ni, T. J. O’Brien, and P. Casillas-Espinosa, “Graph signal processing, graph neural network and graph learning on biological data:

- A systematic review,” *IEEE Rev. Biomed. Eng.*, vol. 16, pp. 109–135, 2023. [Online]. Available: <https://ieeexplore.ieee.org/document/9585532/>
- [10] F. Perrin, J. Pernier, O. Bertrand, and J. Echallier, “Spherical splines for scalp potential and current density mapping,” *Electroencephalography and Clinical Neurophysiology*, vol. 72, no. 2, pp. 184–187, 1989. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/0013469489901806>
 - [11] J. Jäger, A. Klein, M. Buhmann, and W. Skrandies, “Reconstruction of electroencephalographic data using radial basis functions,” *Clinical Neurophysiology*, vol. 127, no. 4, pp. 1978–1983, 2016. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1388245716000109>
 - [12] A. Mazarguil, L. Oudre, and N. Vayatis, “Non-smooth interpolation of graph signals,” *Signal Processing*, vol. 196, p. 108480, 2022. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0165168422000275>
 - [13] A. Weinstein, “Imputing missing electroencephalography data using graph signal processing,” in *18th International Symposium on Medical Information Processing and Analysis*, M. G. Linguraru, L. Rittner, N. Lepore, E. Romero Castro, J. Brieva, and P. Guevara, Eds. SPIE, 2023, p. 8. [Online]. Available: <https://www.spiedigitallibrary.org/conference-proceedings-of-spie/12567/2669735/Imputing-missing-electroencephalography-data-using-graph-signal-processing/10.1117/12.2669735.full>
 - [14] X. Jiang, Z. Tian, and K. Li, “A graph-based approach for missing sensor data imputation,” *IEEE Sensors Journal*, vol. 21, no. 20, pp. 23 133–23 144, 2021, conference Name: IEEE Sensors Journal. [Online]. Available: <https://ieeexplore.ieee.org/document/9520399/?arnumber=9520399>
 - [15] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs: Extending high-dimensional data analysis to networks and other irregular domains,” *IEEE Signal Process. Mag.*, vol. 30, no. 3, pp. 83–98, 2013. [Online]. Available: <http://arxiv.org/abs/1211.0053>
 - [16] A. Ortega, P. Frossard, J. Kovačević, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges and applications,” 2018, issue: arXiv:1712.00468. [Online]. Available: <http://arxiv.org/abs/1712.00468>
 - [17] A. Ortega, *Introduction to Graph Signal Processing*, 1st ed. Cambridge University Press, 2022. [Online]. Available: <https://www.cambridge.org/core/product/identifier/9781108552349/type/book>

- [18] G. Leus, A. G. Marques, J. M. Moura, A. Ortega, and D. I. Shuman, “Graph signal processing: History, development, impact, and outlook,” *IEEE Signal Process. Mag.*, vol. 40, no. 4, pp. 49–60, 2023. [Online]. Available: <https://ieeexplore.ieee.org/document/10146241/>
- [19] L. Rui, H. Nejati, and N.-M. Cheung, “Dimensionality reduction of brain imaging data using graph signal processing,” in *2016 IEEE International Conference on Image Processing (ICIP)*, 2016, pp. 1329–1333. [Online]. Available: <https://ieeexplore.ieee.org/document/7532574/?arnumber=7532574>
- [20] M. Miri, V. Abootalebi, H. Saeedi-Sourck, D. Van De Ville, and H. Behjat, “Spectral representation of EEG data using learned graphs with application to motor imagery decoding,” *Biomedical Signal Processing and Control*, vol. 87, p. 105537, 2024. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1746809423009709>
- [21] A. Ortega, P. Frossard, J. Kovačević, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges and applications,” 2018. [Online]. Available: <http://arxiv.org/abs/1712.00468>
- [22] S. Goerttler, F. He, and M. Wu, “Understanding concepts in graph signal processing for neurophysiological signal analysis,” 2023. [Online]. Available: <http://arxiv.org/abs/2312.03371>
- [23] A. Tamaru, J. Hara, H. Higashi, Y. Tanaka, and A. Ortega, “Optimizing $\mathbb{R}^k$ in $\mathbb{R}^k$ NN graphs with graph learning perspective,” 2024. [Online]. Available: <http://arxiv.org/abs/2401.08245>
- [24] M. Karasuyama and H. Mamitsuka, “Adaptive edge weighting for graph-based learning algorithms,” *Mach Learn*, vol. 106, no. 2, pp. 307–335, 2017. [Online]. Available: <http://link.springer.com/10.1007/s10994-016-5607-3>
- [25] V. Kalofolias, “How to learn a graph from smooth signals,” 2016. [Online]. Available: <http://arxiv.org/abs/1601.02513>
- [26] L. Qiao, L. Zhang, S. Chen, and D. Shen, “Data-driven graph construction and graph learning: A review,” *Neurocomputing*, vol. 312, pp. 336–351, 2018. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0925231218306696>
- [27] V. Kalofolias and N. Perraudin, “Large scale graph learning from smooth signals,” 2019. [Online]. Available: <http://arxiv.org/abs/1710.05654>
- [28] S. Shekizhar and A. Ortega, “Graph construction from data by non-negative kernel regression,” in *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2020, pp. 3892–3896. [Online]. Available: <https://ieeexplore.ieee.org/document/9054425/>
- [29] —, “Neighborhood and graph constructions using non-negative kernel regression,” 2023. [Online]. Available: <http://arxiv.org/abs/1910.09383>

- [30] S. K. Narang, A. Gadde, and A. Ortega, "Signal processing techniques for interpolation in graph structured data," in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing*. IEEE, 2013, pp. 5445–5449. [Online]. Available: <http://ieeexplore.ieee.org/document/6638704/>
- [31] S. K. Narang, A. Gadde, E. Sanou, and A. Ortega, "Localized iterative methods for interpolation in graph structured data," 2013. [Online]. Available: <http://arxiv.org/abs/1310.2646>
- [32] Q. Zhang, L. Yang, Z. Yang, and C. Huang, "Recovery of bandlimited graph signals based on the reproducing kernel hilbert space," *Digital Signal Processing*, vol. 151, p. 104565, 2024. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1051200424001908>
- [33] G. Morgenstern and T. Routtenberg, "Theoretical guarantees for sparse graph signal recovery," *IEEE Signal Processing Letters*, vol. 32, pp. 266–270, 2025, conference Name: IEEE Signal Processing Letters. [Online]. Available: <https://ieeexplore.ieee.org/document/10787248/?arnumber=10787248>
- [34] Y. Zhao, X. Jian, F. Ji, W. P. Tay, and A. Ortega, "Generalized graph signal reconstruction via the uncertainty principle," in *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2025, pp. 1–5. [Online]. Available: <https://ieeexplore.ieee.org/document/10889406/>
- [35] Y. Yan, J. Hou, Z. Song, and E. E. Kuruoglu, "Signal processing over time-varying graphs: A systematic review," 2026. [Online]. Available: <http://arxiv.org/abs/2412.00462>
- [36] S. Krishnan, J. Choi, and J. Park, "Learning time-varying graph signals via koopman," *IEEE Transactions on Signal and Information Processing over Networks*, vol. 12, pp. 16–30, 2026. [Online]. Available: <https://ieeexplore.ieee.org/document/11322857/>
- [37] S. Mortaheb, J. Annen, C. Chatelle, H. Cassol, G. Martens, A. Thibaut, O. Gosseries, and S. Laureys, "A graph signal processing approach to study high density EEG signals in patients with disorders of consciousness," in *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE, 2019, pp. 4549–4553. [Online]. Available: <https://ieeexplore.ieee.org/document/8856436/>
- [38] X. S. Mootoo, A. Fours, C. Dinesh, M. Ashkani, A. Kiss, and M. Faltyn, "Detecting alzheimer disease in EEG data with machine learning and the graph discrete fourier transform," 2023. [Online]. Available: <http://medrxiv.org/lookup/doi/10.1101/2023.11.01.23297940>
- [39] M. Tangermann, K.-R. Müller, A. Aertsen, N. Birbaumer, C. Braun, C. Brunner, R. Leeb, C. Mehring, K. J. Miller, G. R. Müller-Putz *et al.*, "Review of the bci competition iv," *Frontiers in neuroscience*, vol. 6, p. 55, 2012.

- [40] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen *et al.*, “Meg and eeg data analysis with mne-python,” *Frontiers in neuroscience*, vol. 7, p. 267, 2013.
- [41] S. Shekkizhar and A. Ortega, “Graph construction from data by non-negative kernel regression,” in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2020, pp. 3892–3896.