

Universidad Técnica Federico Santa María

Departamento de Ingeniería Electrónica

Reconstrucción de Señales EEG mediante GSP e Interpolación

Tesis de grado presentada por

Carlos Saldivia

Como requisito parcial para optar al grado de
Magíster en Ciencias de la Ingeniería

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matías Zañartu, Ph.D.

Valparaíso, Chile
Abril 2026

Universidad Técnica Federico Santa María
Departamento de Ingeniería Electrónica

Reconstrucción de Señales EEG mediante GSP e Interpolación

Carlos Saldivia

Tesis presentada como requisito parcial para optar al grado de
Magíster en Ciencias de la Ingeniería

Director de Tesis
Alejandro Weinstein, Ph.D.

Co-Director de Tesis
Matías Zañartu, Ph.D.

Valparaíso, Chile
Abril 2026

Pagina de Aprobacion

Tesis:

Reconstrucción de Señales EEG mediante GSP e Interpolación

Autor:

Carlos Saldivia

Trabajo presentado en cumplimiento parcial de los requisitos para el grado de Magíster en Ciencias de la Ingeniería de la Universidad Técnica Federico Santa María, Valparaíso, Chile.

Director de Tesis

Alejandro Weinstein, Ph.D.

Co-Director de Tesis

Matías Zañartu, Ph.D.

Examinador Interno

Por definir

Examinador Externo

Por definir

Resumen

Esta tesis aborda el problema de reconstrucción de canales EEG faltantes mediante un enfoque integral de Procesamiento de Señales sobre Grafos (GSP), complementado con *baselines* geométricos clásicos y métodos de regularización temporal. La motivación central es práctica: en estudios clínicos y de interfaz cerebro-computador (BCI), la pérdida de canales no sigue siempre un patrón aleatorio —frecuentemente se manifiesta como fallas contiguas regionales— y puede distorsionar críticamente biomarcadores fisiológicos como los Potenciales Relacionados a Eventos (ERPs) y la Densidad Espectral de Potencia (PSD).

Siguiendo la perspectiva de GSP impulsada por Ortega y colaboradores, el EEG se modela como una señal definida sobre un grafo ponderado que captura la topología funcional de los electrodos. Para garantizar una comparación rigurosamente imparcial, se implementó un pipeline de optimización exhaustiva de hiperparámetros mediante el framework Optuna (muestreadores TPE y NSGA-II multi-objetivo) a través de tres bases de datos heterogéneas: PhysioNet (64 canales, imaginaria motora), BCI Competition IV 2a (22 canales, 4 clases MI) y MNE Sample (60 canales, potenciales evocados). Se simulieron 14 escenarios de pérdida que combinan modos espaciales (*random* y *nearby*) con niveles de degradación del 10 % al 40 %.

La evaluación cuantitativa, basada en seis métricas complementarias (MAE, RMSE, SNR, DTW, LSD y Coherencia Espectral), demuestra un cambio de paradigma concluyente: el método de Regularización Temporal de Suavidad de Sobolev (TRSS) supera por más de un orden de magnitud a los *baselines* geométricos —incluso cuando estos son exhaustivamente optimizados— alcanzando un MAE de 2.26 y un SNR de 25.95 dB frente al MAE de 3.58 y SNR de 19.56 dB de las Spherical Splines. Más allá de las métricas de error, TRSS preserva exitosamente la morfología de ERPs y la distribución espectral bajo condiciones de pérdida extrema, estableciendo así un marco de referencia robusto y reproducible para la interpolación de EEG de vanguardia.

Abstract

This thesis addresses EEG channel reconstruction under missing-channel conditions using a comprehensive Graph Signal Processing (GSP) framework, together with classical geometric baselines and temporal regularization methods. The central motivation is practical: missing channels in real clinical and Brain-Computer Interface (BCI) studies rarely follow purely random patterns—they frequently manifest as contiguous regional failures—and can severely distort critical physiological biomarkers such as Event-Related Potentials (ERPs) and Power Spectral Density (PSD).

Following the GSP perspective advanced by Ortega and collaborators, EEG is modeled as a signal defined on a weighted graph that captures the functional topology of the electrode array. To ensure rigorously fair evaluation, a comprehensive hyperparameter optimization pipeline was implemented using the Optuna framework (TPE and multi-objective NSGA-II samplers) across three heterogeneous datasets: PhysioNet (64 channels, motor imagery), BCI Competition IV 2a (22 channels, 4-class MI), and MNE Sample (60 channels, auditory/visual evoked potentials). A total of 14 missing-channel scenarios were simulated, combining spatial modes (*random* and *nearby*) with degradation levels from 10 % to 40 %.

The quantitative evaluation, based on six complementary metrics (MAE, RMSE, SNR, DTW, Log Spectral Distance, and Magnitude-Squared Coherence), demonstrates a conclusive paradigm shift: the Temporal Regularized Sobolev Smoothness (TRSS) method outperforms geometric baselines by over an order of magnitude—even when the latter are exhaustively optimized—achieving a MAE of 2.26 and SNR of 25.95 dB versus the Spherical Spline baseline (MAE 3.58, SNR 19.56 dB). Beyond error metrics, TRSS successfully preserves ERP morphology and spectral energy distribution under extreme contiguous channel loss, thereby establishing a robust and reproducible state-of-the-art framework for advanced EEG interpolation.

Agradecimientos

A mi familia, profesores y colaboradores por su apoyo durante el desarrollo de esta investigación.

Índice general

Resumen	IV
Abstract	V
Agradecimientos	VI
1. Introducción	1
1.1. Contexto y Planteamiento del Problema	1
1.2. Antecedentes Específicos y Estado del Arte	2
1.3. La Brecha Metodológica y la Motivación de Este Trabajo	2
1.4. Objetivos	3
1.4.1. Objetivo General	3
1.4.2. Objetivos Específicos	3
1.5. Hipótesis de Trabajo	4
1.6. Alcance y Contribuciones	4
1.7. Estructura del Documento	5
2. Marco Teórico	7
2.1. Fundamentos Neurofisiológicos de la Electroencefalografía	7
2.2. El Problema de Canales Faltantes y los Enfoques de Interpolación	9
2.2.1. Enfoque Geométrico-Espacial	9
2.2.2. Enfoque Estadístico	10
2.3. Procesamiento de Señales en Grafos (GSP)	10
2.3.1. El Laplaciano del Grafo	11
2.3.2. Transformada de Fourier en Grafos (GFT)	11
2.3.3. Construcción y Aprendizaje de Grafos	11
2.4. Métodos de Reconstrucción Basados en GSP	12
2.4.1. Regularización de Tikhonov en Grafos	12
2.4.2. Recuperación Bandlimited en RKHS (BGSRP)	13
2.4.3. Regularización Espacio-Temporal (TRSS)	13
2.5. Métricas de Evaluación	13
2.5.1. Error de Amplitud	14

2.5.2.	Fidelidad Morfológica	14
2.5.3.	Fidelidad Espectral	14
2.6.	Síntesis del Marco Teórico	15
3.	Metodología	16
3.1.	Arquitectura General del Pipeline	16
3.2.	Bases de Datos Experimentales	17
3.2.1.	PhysioNet EEG Motor Movement/Imagery (EEGMMIDB)	17
3.2.2.	BCI Competition IV Dataset 2a	18
3.2.3.	MNE Sample Dataset	18
3.3.	Construcción de Grafos	18
3.3.1.	Grafos de Vecindad Geométrica	18
3.3.2.	Grafos Densos y Aprendidos	18
3.4.	Protocolo de Simulación de Canales Faltantes	19
3.4.1.	Modos de Falla Espacial	19
3.4.2.	Niveles de Severidad	19
3.5.	Métodos de Interpolación	19
3.6.	Optimización de Hiperparámetros con Optuna	20
3.6.1.	Estrategia de Muestreo	20
3.6.2.	Espacios de Búsqueda	21
3.6.3.	Protocolo de Ejecución y Validación Temporal	21
3.7.	Evaluación Cuantitativa	21
3.8.	Matriz Experimental Consolidada	22
3.9.	Consolidación Estadística	22
3.10.	Stack Tecnológico e Infraestructura	22
3.11.	Reproducibilidad	22

Índice de figuras

2.1. Origen neurofisiológico del EEG. (a) Los dipolos corticales generan corrientes que se propagan a través de las capas tisulares hasta los electrodos de superficie; la conducción de volumen suaviza y mezcla las contribuciones. (b) Un dipolo puede modelarse como un par de cargas opuestas cuyo campo se propaga en el medio conductor. (c) La señal registrada combina actividad oscilatoria espontánea (ritmo α) con potenciales evocados transitorios (N100, P300). (d) La distribución espacial instantánea del potencial sobre el cuero cabelludo (topografía) evidencia la alta correlación entre canales adyacentes; los canales fallados (marcados con $\times$) interrumpen esta continuidad.	8
2.2. Conceptos fundamentales del Procesamiento de Señales en Grafos aplicados a EEG. (a) Los electrodos constituyen los vértices $\mathcal{V}$ de un grafo $\mathcal{G}$; las aristas $\mathcal{E}$ conectan canales con alta similitud física o funcional, y los pesos $\mathbf{W}$ cuantifican la fuerza de cada conexión. (b) Una “señal de grafo” $\mathbf{x}$ asigna un valor de voltaje a cada vértice en un instante dado; la suavidad espacial $S(\mathbf{x})$ penaliza las diferencias entre vecinos conectados. (c) La Transformada de Fourier en Grafos (GFT) descompone la señal en componentes frecuenciales sobre la base de autovectores del Laplaciano; las componentes de baja frecuencia corresponden a patrones espaciales suaves (actividad cortical global), mientras que las de alta frecuencia capturan variaciones abruptas (ruido o artefactos focales).	10
3.1. Arquitectura del <i>pipeline</i> metodológico. Las señales crudas se estandarizan y enmascaran según el protocolo de pérdida; los hiperparámetros se optimizan mediante Optuna sobre un conjunto de entrenamiento temporal; un <i>buffer</i> de 2 segundos separa los datos de optimización del conjunto de prueba, sobre el cual se calculan todas las métricas reportadas.	16

Índice de tablas

2.1. Estrategias de construcción de grafos para EEG.	12
2.2. Resumen de familias de métodos de interpolación de canales EEG.	15
3.1. Características de las tres bases de datos experimentales.	17
3.2. Catálogo de métodos de interpolación implementados y evaluados.	20
3.3. Espacios de búsqueda de hiperparámetros.	21
3.4. Matriz experimental consolidada. Cada celda representa una combinación evalua- da bajo optimización bayesiana con separación cronológica estricta entrenamien- to/prueba.	22

Capítulo 1

Introducción

1.1. Contexto y Planteamiento del Problema

La electroencefalografía (EEG) constituye una de las herramientas más consolidadas en el ámbito de la neurociencia clínica y experimental. Su alta resolución temporal —del orden de milisegundos—, su carácter no invasivo y su costo operativo moderado en comparación con otras técnicas de neuroimagen, como la Imagen por Resonancia Magnética Funcional (fMRI) o la Tomografía por Emisión de Positrones (PET), la han posicionado como el método de referencia para el estudio de la dinámica cerebral en tiempo real. Sus aplicaciones abarcan desde el diagnóstico clínico de patologías neurológicas —epilepsia, trastornos del sueño, encefalopatías— hasta la investigación fundamental en neurociencia cognitiva y el desarrollo de interfaces cerebro-computador (BCI, *Brain-Computer Interfaces*) para asistencia motora y comunicación aumentativa.

No obstante, la adquisición de señales EEG es un proceso notablemente frágil. En condiciones reales de laboratorio u hospital, es frecuente enfrentar la degradación o pérdida total de la señal en uno o más electrodos. Las causas son diversas: aumento progresivo de la impedancia de contacto por evaporación del gel conductor, fallas en los amplificadores diferenciales (saturación de voltaje), movimientos del paciente que desplazan físicamente los sensores, o simplemente el descarte deliberado de canales durante la etapa de preprocesamiento automático por presentar una relación señal-ruido inaceptable. En registros de alta densidad (32–256 canales), la probabilidad de que al menos un canal presente datos inválidos en una sesión típica de 30 minutos es cercana a la certeza.

La pérdida de canales no constituye un mero inconveniente cosmético: representa una amenaza concreta para la integridad del análisis neurofisiológico posterior. La ausencia de información espacial interrumpe la distribución topográfica del potencial eléctrico, distorsiona los algoritmos de localización de fuentes (*source localization*), y altera biomarcadores clínicos de primer orden como los Potenciales Relacionados a Eventos (ERPs) y la Densidad Espectral de Potencia (PSD). En el contexto de los sistemas modernos de aprendizaje de máquina aplicados a BCI, la pérdida impredecible de canales modifica la dimensionalidad de los vectores de entrada, forzando el

descarte de ensayos completos de datos cuya adquisición ha demandado tiempo y recursos considerables. En este escenario, la interpolación de canales faltantes deja de ser un paso opcional y se convierte en una necesidad metodológica insoslayable dentro del *pipeline* de preprocesamiento.

1.2. Antecedentes Específicos y Estado del Arte

El problema de la interpolación de canales EEG ha recibido atención sostenida desde la década de 1980, generando una familia diversa de soluciones que pueden agruparse en tres grandes paradigmas.

Paradigma geométrico-espacial. La estrategia más extendida, implementada como opción por defecto en las principales plataformas de análisis —EEGLAB [1], MNE-Python [2], Brainstorm [3]— es la interpolación por *Spherical Splines*, introducida por Perrin et al. [4]. Este método modela la cabeza como una esfera conductora y representa el potencial eléctrico mediante una expansión en polinomios de Legendre. Su solidez numérica y su costo computacional reducido lo han mantenido como estándar *de facto* durante más de tres décadas. Variantes posteriores incluyen funciones de base radial (RBF) con kernel de placa delgada (*Thin-Plate Spline*) y el ponderamiento por distancia inversa (IDW). La limitación transversal de esta familia es que cada muestra temporal se interpola de forma aislada, sin memoria del contexto dinámico de la señal.

Paradigma estadístico. Métodos como el Análisis de Componentes Independientes (ICA) proyectan las señales observadas en un espacio de fuentes latentes estadísticamente independientes, reconstruyendo los canales faltantes desde la proyección inversa [5]. Aunque efectivos para remover artefactos oculares y musculares, su desempeño en interpolación se degrada marcadamente bajo pérdida severa, especialmente cuando los canales afectados son espacialmente contiguos.

Paradigma de Procesamiento de Señales en Grafos (GSP). En la última década, el marco teórico del GSP [6, 7] ha ofrecido una alternativa conceptualmente superior. En lugar de asumir un modelo esférico continuo, GSP representa la red de electrodos como un grafo discreto $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde cada electrodo es un vértice y los pesos W_{ij} codifican relaciones de proximidad física o acoplamiento funcional entre canales. Bajo este paradigma, interpolar un canal faltante equivale a resolver un problema de optimización con restricciones de suavidad sobre la topología del grafo [8, 9]. Extensiones recientes incorporan además regularización temporal —esto es, penalizan cambios abruptos entre muestras consecutivas— a través de formulaciones como la Regularización Temporal de Suavidad de Sobolev (TRSS) [10], que extiende el funcional de costo de Tikhonov clásico con un operador de diferencias finitas temporales que refleja matemáticamente la inercia de los generadores neuronales.

1.3. La Brecha Metodológica y la Motivación de Este Trabajo

Pese a la madurez de estos desarrollos, la literatura especializada exhibe dos déficits metodológicos que comprometen la comparabilidad de los resultados publicados.

En primer lugar, los estudios que proponen nuevos algoritmos de interpolación suelen evaluarlos contra *baselines* ejecutados con sus parámetros por defecto —los que vienen preconfigurados en las bibliotecas de software—, mientras que el método propuesto es cuidadosamente sintonizado. Esta asimetría infla artificialmente la ventaja reportada y oscurece el verdadero techo de rendimiento de los métodos establecidos [11].

En segundo lugar, la evaluación se restringe típicamente a una o dos métricas de error de amplitud global —MAE o RMSE— sobre uno o dos datasets, frecuentemente con simulaciones de pérdida de canales que no reflejan los modos de falla observados en la práctica clínica: la pérdida contigua de múltiples canales por desprendimiento de un parche del gorro EEG o por falla de un módulo de amplificación local. Muy pocos trabajos examinan el impacto sobre la morfología temporal (ERPs) o la preservación del contenido espectral (PSD, coherencia), que son, en última instancia, los predictores de utilidad clínica y científica de la señal interpolada.

La motivación central de esta tesis emerge directamente de estas brechas. El objetivo no es proponer un nuevo algoritmo de interpolación, sino someter a la frontera del conocimiento actual —métodos geométricos clásicos, GSP espacial y GSP con regularización temporal— a la comparación empírica más rigurosa, exhaustiva y justa de la que se tenga registro. Para ello, se emplean herramientas modernas de optimización bayesiana (Optuna [12]) que garantizan que ningún método sea evaluado por debajo de su límite de diseño, sobre un total de tres bases de datos heterogéneas, múltiples protocolos de pérdida realistas y seis métricas que cubren las dimensiones de amplitud, morfología temporal y fidelidad espectral.

1.4. Objetivos

1.4.1. Objetivo General

Comparar el rendimiento espacial, temporal y espectral de los métodos de reconstrucción de canales EEG faltantes basados en Procesamiento de Señales en Grafos (GSP) y regularización temporal frente a *baselines* geométricos clásicos, mediante un marco experimental riguroso, reproducible y con optimización imparcial de hiperparámetros.

1.4.2. Objetivos Específicos

1. **Unificación metodológica.** Implementar y consolidar en un *pipeline* modular en Python una colección amplia de métodos de interpolación —geométricos, estadísticos y basados en grafos con regularización temporal—, garantizando interfaces homogéneas y evaluación estandarizada.
2. **Diseño de escenarios clínicamente representativos.** Definir protocolos de simulación de canales faltantes que abarquen desde fallos esporádicos independientes (*random*) hasta pérdidas masivas y espacialmente contiguas (*nearby*), con niveles progresivos de severidad desde el 10 % hasta el 40 % de los canales totales.

3. **Optimización imparcial (*Fair Benchmarking*).** Integrar el *framework* Optuna con muestreadores TPE y NSGA-II para explorar los espacios paramétricos de *todos* los métodos —incluyendo los *baselines* clásicos—, eliminando el sesgo de comparación contra configuraciones por defecto que permea la literatura.
4. **Evaluación multi-métrica y multi-dominio.** Cuantificar el desempeño de reconstrucción sobre tres bases de datos de distinta densidad espacial y paradigma experimental (PhysioNet EEGMMIDB, BCI Competition IV 2a, MNE Sample), utilizando seis métricas complementarias: MAE, RMSE, SNR, DTW, LSD y Coherencia.
5. **Análisis de relevancia fisiológica.** Demostrar cualitativa y cuantitativamente el impacto de cada familia de métodos sobre la preservación de Potenciales Relacionados a Eventos (N100, P300) y de la densidad espectral en las bandas de interés clínico (Delta, Theta, Alfa, Beta, Gamma).
6. **Trazabilidad y reproducibilidad.** Generar un repositorio de artefactos computacionales —configuraciones, resultados numéricos, bitácoras de ejecución y advertencias— que permita la auditoría completa de cada resultado reportado y su reproducción independiente.

1.5. Hipótesis de Trabajo

La hipótesis que guía esta investigación es la siguiente:

La incorporación de restricciones de suavidad espacial modeladas mediante topologías de grafo, en conjunto con *priors* de continuidad temporal penalizada —tal como los que provee la regularización de Sobolev TRSS—, permite reconstruir canales EEG faltantes con una precisión significativamente superior a la de los métodos geométricos clásicos de extrapolación de superficies. Esta superioridad se manifiesta no solo en la reducción del error de amplitud, sino fundamentalmente en la preservación de la morfología de los potenciales evocados (ERPs) y de la distribución de potencia espectral (PSD), y se acentúa bajo condiciones de pérdida espacial severa y contigua.

Al cierre de la fase experimental de esta investigación —que abarcó cientos de iteraciones sistemáticas y decenas de miles de evaluaciones de interpolación—, la evidencia acumulada es ampliamente favorable a esta hipótesis. Los resultados que se presentan en los Capítulos 4 y 5 muestran que el término de regularización temporal constituye un punto de inflexión en el desempeño de los métodos de reconstrucción, particularmente en los regímenes donde la información espacial se toma crítica.

1.6. Alcance y Contribuciones

El alcance de este trabajo abarca la ejecución computacional a gran escala de un *pipeline* de evaluación comparativa que cruza sistemáticamente tres bases de datos, dos modos de pérdida,

cuatro niveles de severidad, múltiples constructores de grafo y varias familias de métodos de interpolación. En total, el espacio experimental comprende del orden de decenas de miles de configuraciones evaluadas bajo estricto control de semillas y con separación cronológica estricta entre datos de optimización y de prueba.

Las contribuciones principales de esta tesis se articulan en tres ejes:

1. **Evidencia estadística del cruce de desempeño.** Se demuestra que, bajo condiciones de sintonización equitativa, la familia de métodos con regularización temporal —encabezada por TRSS— supera de manera consistente a los *baselines* geométricos en las dimensiones de error de amplitud (MAE, RMSE), fidelidad morfológica (DTW) y preservación espectral (LSD, coherencia), con márgenes que se amplifican al aumentar la severidad de la pérdida.
2. **Caracterización del colapso de los métodos clásicos.** Se documenta empíricamente que, bajo regímenes de pérdida contigua severa (40 % de los canales en una misma región del cuero cabelludo), los métodos puramente espaciales —incluyendo el *Spherical Spline*— experimentan un colapso de fase en el que la señal reconstruida invierte su polaridad o diverge en amplitud, mientras que los métodos con anclaje temporal mantienen trayectorias fisiológicamente plausibles.
3. **Infraestructura de código abierto para la comunidad.** Se entrega un *toolkit* de experimentación unificado en Python, modular, completamente rastreado mediante control de versiones y diseñado para que cualquier investigador pueda reproducir los resultados aquí presentados o extender el *framework* con nuevos métodos, datasets o métricas.

1.7. Estructura del Documento

El resto de esta tesis se organiza de la siguiente manera:

- **Capítulo 2 – Marco Teórico.** Presenta los fundamentos neurofisiológicos de la señal EEG, la teoría matemática del Procesamiento de Señales en Grafos —incluyendo el Laplaciano, la Transformada de Fourier en Grafos, la construcción y el aprendizaje de topologías—, las formulaciones de los métodos de interpolación clásicos y basados en GSP, y la definición formal de las métricas de evaluación.
- **Capítulo 3 – Metodología.** Describe el diseño experimental completo: los tres datasets utilizados y sus características, el *pipeline* computacional, los métodos de construcción de grafos, los protocolos de simulación de canales faltantes, la arquitectura de optimización bayesiana con Optuna, el protocolo de validación temporal con separación estricta entrenamiento/prueba, y la infraestructura de evaluación y consolidación estadística.
- **Capítulo 4 – Experimentos y Resultados.** Expone los hallazgos empíricos organizados en niveles crecientes de especificidad: comparación global de familias, tablas estratificadas

por severidad y modo de pérdida, análisis de preservación de ERPs y PSD, curvas de degradación, y un estudio de ablación que aísla la contribución del término de regularización temporal.

- **Capítulo 5 – Discusión.** Interpreta los resultados a la luz de la hipótesis de trabajo, analiza las causas metodológicas de las diferencias observadas entre familias, discute las implicaciones para la práctica clínica y de investigación, y transparenta las limitaciones del estudio.
- **Capítulo 6 – Conclusiones y Trabajo Futuro.** Sintetiza los hallazgos principales, evalúa el grado de cumplimiento de los objetivos y la hipótesis, y propone direcciones de investigación futura que los resultados de este trabajo habilitan.

Capítulo 2

Marco Teórico

Este capítulo establece los fundamentos conceptuales, neurofisiológicos y matemáticos que sustentan el desarrollo de esta tesis. En una primera instancia, se describe la naturaleza de la señal electroencefalográfica (EEG) y las dificultades inherentes a su captura. Posteriormente, se formaliza la teoría del Procesamiento de Señales en Grafos (GSP) como marco de resolución, detallando las arquitecturas de interpolación clásica frente a las estrategias espacio-temporales modernas. Finalmente, se definen rigurosamente las métricas utilizadas para evaluar la fidelidad de la reconstrucción.

2.1. Fundamentos Neurofisiológicos de la Electroencefalografía

El electroencefalograma es el registro de la actividad eléctrica cerebral captada desde la superficie del cuero cabelludo. Esta señal refleja la suma espacio-temporal de los potenciales postsinápticos excitatorios e inhibitorios generados por decenas de miles de neuronas piramidales sincronizadas en la corteza cerebral [13, 14]. Debido a que las fuentes de estas corrientes se encuentran separadas de los electrodos por múltiples capas de tejido con distintas conductividades —píamadre, líquido cefalorraquídeo, cráneo y cuero cabelludo—, la señal sufre un proceso de filtrado espacial y atenuación conocido como *conducción de volumen* (*volume conduction*), ilustrado conceptualmente en la Figura 2.1.

El efecto de conducción de volumen implica que una única fuente cortical es detectada simultáneamente por múltiples electrodos, generando una alta correlación espacial entre canales adyacentes. Sin embargo, esta propagación no es perfectamente homogénea: las anisotropías en la conductividad del cráneo —cuya resistividad es aproximadamente 80 veces mayor que la del cuero cabelludo y el cerebro [15]— distorsionan la relación entre proximidad física y acoplamiento funcional. Por consiguiente, si bien la distancia euclidiana entre electrodos es informativa, no constituye una representación exhaustiva de la conectividad neurofisiológica subyacente.

Las señales EEG se caracterizan por su naturaleza oscilatoria y transitoria. La actividad continua se descompone convencionalmente en bandas de frecuencia: Delta (0,5–4 Hz), Theta (4–8 Hz), Alfa (8–13 Hz), Beta (13–30 Hz) y Gamma (30–100 Hz). La actividad evocada o




Figura 2.1: Origen neurofisiológico del EEG. (a) Los dipolos corticales generan corrientes que se propagan a través de las capas tisulares hasta los electrodos de superficie; la conducción de volumen suaviza y mezcla las contribuciones. (b) Un dipolo puede modelarse como un par de cargas opuestas cuyo campo se propaga en el medio conductor. (c) La señal registrada combina actividad oscilatoria espontánea (ritmo α) con potenciales evocados transitorios (N100, P300). (d) La distribución espacial instantánea del potencial sobre el cuero cabelludo (topografía) evidencia la alta correlación entre canales adyacentes; los canales fallados (marcados con $\times$) interrumpen esta continuidad.

fásica, por su parte, se manifiesta como Potenciales Relacionados a Eventos (ERPs): fluctuaciones de voltaje de fase bloqueada que reflejan procesamiento cognitivo o sensorial, con componentes bien caracterizados como el N100 (deflexión negativa a los ~ 100 ms post-estímulo) y el P300 (deflexión positiva a los ~ 300 ms). La preservación fiel de la morfología, amplitud y latencia de estos componentes es un requisito crítico para cualquier método de interpolación que aspire a utilidad clínica o científica.

En paralelo al uso clínico tradicional, la literatura reciente en procesamiento de EEG ha enfatizado que los retos actuales trascienden el simple filtrado de ruido: se trata de preservar simultáneamente estructura espacial, dinámica temporal y contenido espectral en presencia de datos incompletos [16]. Esta exigencia ha catalizado la transición desde modelos puramente geométricos hacia marcos de señal sobre grafos con regularización física y estadística [11, 17].

2.2. El Problema de Canales Faltantes y los Enfoques de Interpolación

En la práctica clínica y experimental, la adquisición de EEG es inherentemente vulnerable a la pérdida parcial de información. Los canales pueden resultar inutilizables por degradación de la interfaz electrodo-piel, desprendimiento mecánico, saturación del amplificador o descarte durante el preprocesamiento automatizado. Formalmente, si la actividad cerebral instantánea se representa como un vector $\mathbf{x} \in \mathbb{R}^N$ para N electrodos, un evento de pérdida implica que solo se observa un subconjunto $\mathcal{K} \subset \{1, \dots, N\}$ de canales. El objetivo de la interpolación es estimar los valores en el conjunto complementario $\mathcal{U} = \mathcal{V} \setminus \mathcal{K}$, donde $\mathcal{V}$ es el conjunto de todos los electrodos.

2.2.1. Enfoque Geométrico-Espacial

La solución clásica a este problema consiste en proyectar los valores conocidos mediante funciones de base que dependen exclusivamente de la posición espacial de los electrodos. El método estándar es la interpolación por **Splines Esféricos** [4]. Asumiendo una cabeza modelada como esfera unitaria, el potencial en una ubicación $\mathbf{r}$ se expresa como:

$$V(\mathbf{r}) = c_0 + \sum_{i \in \mathcal{K}} c_i g(\mathbf{r}, \mathbf{r}_i), \quad (2.1)$$

donde los coeficientes c_i se determinan resolviendo un sistema lineal que involucra los canales conocidos y la función de Green $g(\cdot, \cdot)$ —una expansión en polinomios de Legendre que decae con la distancia angular. Métodos emparentados incluyen las Funciones de Base Radial (RBF) con kernel de placa delgada (*Thin-Plate Spline*) [18] y la interpolación por distancia inversa ponderada (IDW).

La limitación estructural de esta familia es que cada instante temporal t se interpola de forma aislada. Al carecer de *memoria* temporal, estos métodos son constitutivamente incapaces de preservar la continuidad fase-temporal de transitorios rápidos o de respetar la coherencia espectral de la señal. La consecuencia práctica es la introducción de discontinuidades artificiales de alta frecuencia en el canal reconstruido, particularmente visibles en las trazas de ERPs y en los espectrogramas.

Esta limitación ha sido documentada en estudios de interpolación no-suave sobre grafos, donde se evidencia que la hipótesis de suavidad espacial global puede ser insuficiente para señales con transitorios locales marcados [19]. En el contexto específico de EEG, trabajos aplicados han mostrado que la incorporación de estructura de grafo mejora la calidad de imputación frente a enfoques puramente geométricos, aunque con una dependencia crítica de la calidad de la topología subyacente y de su parametrización [20, 21].

2.2.2. Enfoque Estadístico

Una vía alternativa consiste en proyectar la matriz de señales observadas $\mathbf{X} \in \mathbb{R}^{N \times T}$ en un espacio latente de menor dimensionalidad mediante Análisis de Componentes Independientes (ICA). El algoritmo FastICA [22] busca una matriz de separación $\mathbf{W}$ tal que las fuentes estimadas $\mathbf{S} = \mathbf{W}\mathbf{X}$ sean estadísticamente independientes. Los canales faltantes se reconstruyen a partir de la proyección inversa de las fuentes. Si bien este enfoque es efectivo para la remoción de artefactos oculares y musculares [5], su rendimiento en tareas de interpolación se ve comprometido cuando la dimensionalidad del espacio de fuentes es comparable o inferior al número de canales perdidos —una situación frecuente en montajes de baja densidad como el BCI IV 2a (22 canales).

2.3. Procesamiento de Señales en Grafos (GSP)

Para superar las restricciones del modelo esférico y de la interpolación muestra-a-muestra, el Procesamiento de Señales en Grafos [6, 7] propone modelar la red de electrodos y sus interacciones como un grafo ponderado. La Figura 2.2 ilustra los conceptos fundamentales de este paradigma.




Figura 2.2: Conceptos fundamentales del Procesamiento de Señales en Grafos aplicados a EEG. (a) Los electrodos constituyen los vértices $\mathcal{V}$ de un grafo $\mathcal{G}$; las aristas $\mathcal{E}$ conectan canales con alta similitud física o funcional, y los pesos $\mathbf{W}$ cuantifican la fuerza de cada conexión. (b) Una “señal de grafo” $\mathbf{x}$ asigna un valor de voltaje a cada vértice en un instante dado; la suavidad espacial $S(\mathbf{x})$ penaliza las diferencias entre vecinos conectados. (c) La Transformada de Fourier en Grafos (GFT) descompone la señal en componentes frecuenciales sobre la base de autovectores del Laplaciano; las componentes de baja frecuencia corresponden a patrones espaciales suaves (actividad cortical global), mientras que las de alta frecuencia capturan variaciones abruptas (ruido o artefactos focales).

Formalmente, un grafo no dirigido se define como $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$, donde $\mathcal{V}$ es el conjunto de N vértices (electrodos), $\mathcal{E}$ es el conjunto de aristas, y $\mathbf{W} \in \mathbb{R}^{N \times N}$ es la matriz de adyacencia ponderada, simétrica y con elementos no negativos. Cada peso W_{ij} codifica la fuerza de acoplamiento entre los electrodos i y j . Una señal EEG en un instante t se define como una función $\mathbf{x} \in \mathbb{R}^N$ que asigna un valor escalar (voltaje) a cada vértice.

2.3.1. El Laplaciano del Grafo

El operador fundamental en GSP es el Laplaciano Combinatorial, definido como:

$$\mathbf{L} = \mathbf{D} - \mathbf{W}, \quad (2.2)$$

donde $\mathbf{D}$ es la matriz diagonal de grados, con $D_{ii} = \sum_{j=1}^N W_{ij}$. La matriz $\mathbf{L}$ es simétrica y semidefinida positiva, por lo que admite una descomposición espectral completa:

$$\mathbf{L} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top, \quad (2.3)$$

donde $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_N]$ contiene los autovectores ortonormales y $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$ los autovalores, ordenados de forma creciente: $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$.

La forma cuadrática del Laplaciano cuantifica la suavidad de la señal $\mathbf{x}$ sobre la topología del grafo:

$$S(\mathbf{x}) = \mathbf{x}^\top \mathbf{L} \mathbf{x} = \frac{1}{2} \sum_{(i,j) \in \mathcal{E}} W_{ij} (x_i - x_j)^2. \quad (2.4)$$

Un valor reducido de $S(\mathbf{x})$ indica que los canales fuertemente conectados presentan voltajes similares —una señal *suave* o de baja frecuencia espacial—, mientras que un valor elevado señala discontinuidades abruptas entre vecinos, típicamente asociadas a ruido o artefactos.

2.3.2. Transformada de Fourier en Grafos (GFT)

Por analogía con el análisis de Fourier clásico —donde las funciones exponenciales complejas son las autofunciones del operador laplaciano unidimensional—, los autovectores de $\mathbf{L}$ constituyen la base de Fourier del grafo, y los autovalores λ_l actúan como *frecuencias generalizadas*. La Transformada de Fourier en Grafos (GFT) de una señal $\mathbf{x}$ se define como:

$$\hat{\mathbf{x}} = \mathbf{U}^\top \mathbf{x}. \quad (2.5)$$

En el contexto del EEG, los componentes asociados a autovalores pequeños ($\lambda \approx 0$) representan patrones de actividad topográfica global y espacialmente sincrónica —como el ritmo alfa occipital—, mientras que los autovalores grandes capturan variaciones espaciales abruptas —como artefactos musculares focales o ruido de electrodo—. La interpolación basada en GSP actúa, en esencia, como un filtro paso-bajo direccional que preserva las componentes espectrales suaves y atenúa las discontinuidades espurias [23].

2.3.3. Construcción y Aprendizaje de Grafos

El desempeño de cualquier método GSP depende críticamente de la calidad de la matriz de adyacencia $\mathbf{W}$. En el dominio EEG, la topología puede definirse mediante tres estrategias complementarias, que se resumen en la Tabla 2.1.

Tabla 2.1: Estrategias de construcción de grafos para EEG.

Estrategia	Principio	Ejemplos
Geométrica <i>a priori</i>	Usa coordenadas 3D de k -NN, k -NN Gaussianos, ϵ -electrodos; no depende de la señal.	ball, MST
Funcional / correlación	Extrae similitud desde la AEW [24], grafos de covarianza temporal de las señales registradas.	lación parcial
Aprendizaje de grafos	Infiere $\mathbf{W}$ resolviendo un problema inverso que balancea esparsidad, suavidad y ajuste a los datos.	Kalofolias [25], NNK [26], la [27]

Dentro de los grafos geométricos, la variante más utilizada en este trabajo es el **k -NN Gaussiano**, que asigna pesos según:

$$W_{ij} = \exp\left(-\frac{d(i,j)^2}{2\sigma^2}\right) \cdot \mathbb{1}_{[j \in \mathcal{N}_k(i)]}, \quad (2.6)$$

donde $d(i,j)$ es la distancia euclidiana 3D entre electrodos, σ controla la escala del kernel, y $\mathcal{N}_k(i)$ denota los k vecinos más cercanos al nodo i . Esta construcción garantiza grafos conexos y esparsos con pesos físicamente interpretables, y ha mostrado desempeño competitivo sostenido en los experimentos de esta tesis.

2.4. Métodos de Reconstrucción Basados en GSP

Una vez definido el grafo, el problema de interpolación se formula como un problema inverso regularizado. Sea $\mathbf{M} \in \mathbb{R}^{N \times N}$ una matriz diagonal de muestreo donde $M_{ii} = 1$ si el canal i está observado y 0 en caso contrario. Se observa la señal parcial $\mathbf{y} = \mathbf{M}\mathbf{x}$, y se desea recuperar $\mathbf{x}$.

2.4.1. Regularización de Tikhonov en Grafos

El enfoque GSP más directo minimiza, para cada instante t , el error cuadrático sobre los canales observados más una penalización a la variación total sobre el grafo [28]:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{z} \in \mathbb{R}^N} \|\mathbf{M}\mathbf{z} - \mathbf{y}\|_2^2 + \alpha \mathbf{z}^\top \mathbf{L}\mathbf{z}, \quad (2.7)$$

cuya solución en forma cerrada es:

$$\hat{\mathbf{x}} = (\mathbf{M} + \alpha \mathbf{L})^{-1} \mathbf{M}\mathbf{y}. \quad (2.8)$$

El hiperparámetro $\alpha > 0$ gobierna el compromiso entre fidelidad a las observaciones ($\alpha \rightarrow 0$) y suavidad espacial impuesta por el grafo ($\alpha \rightarrow \infty$). En el límite de restricción dura ($\alpha \rightarrow \infty$), el problema se reduce a la interpolación armónica clásica sobre el grafo.

2.4.2. Recuperación Bandlimited en RKHS (BGSRP)

Una formulación alternativa es BGSRP (*Bandlimited Graph Signal Recovery in RKHS*) [29], que asume que las señales EEG son aproximadamente limitadas en banda respecto al Laplaciano: $\hat{x}_l = 0$ para $\lambda_l > \lambda_c$. La reconstrucción se realiza en un Espacio de Hilbert de Núcleo Reproductor (RKHS) inducido por un kernel $\mathbf{K}$ construido a partir de los primeros B autovectores. La literatura reciente ha reforzado la base teórica de este enfoque con garantías de identificabilidad basadas en cotas de coherencia espectral [30] y extensiones a formulaciones generalizadas vértice-tiempo [31].

2.4.3. Regularización Espacio-Temporal (TRSS)

La limitación fundamental de los métodos anteriores es que operan sobre cada columna temporal de $\mathbf{X}$ por separado. La **Regularización Temporal de Suavidad de Sobolev** (TRSS, *Temporal Regularized Sobolev Smoothness*) [10] extiende el problema a la matriz espacio-temporal completa $\mathbf{X} \in \mathbb{R}^{N \times T}$:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z} \in \mathbb{R}^{N \times T}} \|\mathbf{MZ} - \mathbf{MX}\|_F^2 + \alpha \operatorname{tr}(\mathbf{Z}^\top \mathbf{LZ}) + \beta \|\mathbf{ZD}_t\|_F^2, \quad (2.9)$$

donde $\|\cdot\|_F$ denota la norma de Frobenius, $\operatorname{tr}(\cdot)$ es la traza, y $\mathbf{D}_t \in \mathbb{R}^{T \times (T-1)}$ es un operador de diferencias finitas de primer orden a lo largo del eje temporal, que satisface $[\mathbf{ZD}_t]_{:,t} = \mathbf{z}_{t+1} - \mathbf{z}_t$. La penalización temporal, controlada por $\beta > 0$, refleja matemáticamente la inercia fisiológica de los generadores dipolares: los potenciales postsinápticos no pueden cambiar abruptamente entre muestras consecutivas, especialmente bajo frecuencias de muestreo típicas de 160–600 Hz.

En los trabajos más recientes sobre grafos variables en el tiempo se ha mostrado que, cuando la estructura de dependencia evoluciona junto con la señal, los modelos con acoplamiento espacio-temporal explícito ofrecen mayor capacidad de generalización para tareas de reconstrucción y predicción [32, 33]. Esta evidencia respalda directamente el uso de regularización temporal en escenarios EEG con pérdida severa o contigua, donde la información espacial por sí sola resulta insuficiente.

2.5. Métricas de Evaluación

La calidad de la reconstrucción se evalúa mediante seis métricas que cubren dimensiones ortogonales del error. En todos los casos, $\mathbf{x}$ denota el vector del canal original de longitud T y $\hat{\mathbf{x}}$ su reconstrucción.

2.5.1. Error de Amplitud

El **Error Absoluto Medio** (MAE) mide la desviación promedio, resultando robusto ante valores atípicos aislados:

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |x(t) - \hat{x}(t)|. \quad (2.10)$$

La **Raíz del Error Cuadrático Medio** (RMSE) penaliza severamente los errores grandes, funcionando como detector de inestabilidades numéricas:

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (x(t) - \hat{x}(t))^2}. \quad (2.11)$$

La **Relación Señal-Ruido** (SNR), expresada en decibelios, ofrece una medida normalizada e interpretable entre escalas de amplitud heterogéneas:

$$\text{SNR} = 10 \log_{10} \left(\frac{\sum_t x(t)^2}{\sum_t (x(t) - \hat{x}(t))^2} \right). \quad (2.12)$$

2.5.2. Fidelidad Morfológica

El **Dynamic Time Warping** (DTW) calcula la alineación temporal óptima entre dos secuencias mediante programación dinámica, minimizando la distancia euclidiana acumulada bajo restricciones de monotonicidad y continuidad. A diferencia del MAE, que penaliza cualquier desfase temporal como error de amplitud, DTW es tolerante a pequeñas variaciones de latencia, lo que lo convierte en la métrica más apropiada para evaluar la preservación de ERPs [34]. La implementación utilizada en esta tesis emplea una ventana de Sakoe-Chiba para acotar la complejidad computacional.

2.5.3. Fidelidad Espectral

La **Distancia Espectral Logarítmica** (LSD) cuantifica la divergencia entre las densidades espectrales de potencia de la señal original y la reconstruida:

$$\text{LSD} = \sqrt{\frac{1}{K} \sum_{k=1}^K (\log |X(f_k)| - \log |\hat{X}(f_k)|)^2}, \quad (2.13)$$

donde $X(f_k)$ es la magnitud de la Transformada Discreta de Fourier en la frecuencia f_k . Un valor bajo de LSD indica que la distribución de energía a través de las bandas fisiológicas ha sido preservada.

La **Coherencia de Magnitud Cuadrada** mide la correlación lineal en el dominio frecuencial:

$$C_{x\hat{x}}(f) = \frac{|S_{x\hat{x}}(f)|^2}{S_{xx}(f) S_{\hat{x}\hat{x}}(f)}, \quad (2.14)$$

donde $S_{ab}(f)$ es la densidad espectral cruzada. La coherencia toma valores en $[0, 1]$; un valor de 1 indica que la señal reconstruida es una transformación lineal perfecta de la original en esa frecuencia, mientras que valores bajos señalan pérdida de información de fase o introducción de ruido no correlacionado.

La combinación de estas seis métricas es deliberada: un MAE bajo obtenido por suavizado de la señal se evidenciará como un DTW y LSD elevados, impidiendo que un método oculte sus deficiencias detrás de un único indicador favorable.

2.6. Síntesis del Marco Teórico

La Tabla 2.2 sintetiza las familias de métodos de interpolación consideradas en este estudio, sus fundamentos matemáticos y sus limitaciones características.

Tabla 2.2: Resumen de familias de métodos de interpolación de canales EEG.

Familia	Métodos representativos	re-Fundamento	Limitación principal
Geométrico-espacial	Spherical Spline, RBF, IDW	Proyección sobre bases radiales dependientes de distancia euclidiana 3D.	Opera sobre muestra; sin memoria temporal.
Estadístico	ICA (FastICA)	Separación ciega de fuentes; reconstrucción desde proyección inversa.	Degradación severa; sujeción a independencia estadística.
GSP instantáneo	Tikhonov, Laplaciano, BGSRP, TV en grafo	Regularización espacial sobre el Laplaciano del grafo, instantáneo.	Ignora continuidad temporal de la señal EEG.
GSP temporal	TRSS, Graph Time Tikhonov, Temporal Laplaciano	Optimización conjunta de gradientes espaciales (α) y temporales (β).	Mayor costo computacional; requiere sintonización de dos hiperparámetros acoplados.

El capítulo siguiente detalla cómo estas familias fueron operacionalizadas dentro de un *pipeline* experimental unificado, y cómo se diseñaron los protocolos de simulación de fallas, la optimización de hiperparámetros y la evaluación cuantitativa para garantizar una comparación justa y reproducible.

Capítulo 3

Metodología

Este capítulo describe exhaustivamente el diseño experimental empleado para validar la hipótesis central de esta tesis. Se detalla cada componente del *pipeline* computacional: desde la selección y preprocesamiento de los datos de entrada, pasando por la construcción de grafos y la simulación controlada de fallas sensoriales, hasta la optimización bayesiana de hiperparámetros y la evaluación cuantitativa final. El principio rector que gobierna cada decisión metodológica es la *imparcialidad comparativa*: todas las familias de métodos —geométricos, estadísticos y basados en grafos— deben competir bajo condiciones estrictamente equivalentes de sintonización paramétrica, eliminando así el sesgo de *benchmarking* que la Sección 1.3 identificó como una debilidad transversal en la literatura.

3.1. Arquitectura General del Pipeline

El flujo de trabajo se organiza como una secuencia de etapas bien definidas, ilustrada en la Figura 3.1.




Figura 3.1: Arquitectura del *pipeline* metodológico. Las señales crudas se estandarizan y enmascaran según el protocolo de pérdida; los hiperparámetros se optimizan mediante Optuna sobre un conjunto de entrenamiento temporal; un *buffer* de 2 segundos separa los datos de optimización del conjunto de prueba, sobre el cual se calculan todas las métricas reportadas.

La implementación computacional se estructuró en módulos independientes que separan responsabilidades:

- **Módulo de datos.** Carga unificada y preprocesamiento de los tres datasets experimenta-

les.

- **Módulo de grafos.** Agrupa los constructores de topologías espaciales, funcionales y aprendidas.
- **Módulo de interpolación.** Reúne los 18 algoritmos implementados, con interfaces homogéneas.
- **Módulo de evaluación.** Centraliza el cálculo de las seis métricas sobre canales reconstruidos.
- **Scripts orquestadores.** Gestionan la simulación de máscaras, la búsqueda bayesiana y la generación de artefactos (CSV, JSON, figuras).

Cada etapa produce artefactos intermedios serializados, desacoplando la ejecución del cómputo intensivo de la generación de tablas y figuras finales, y garantizando trazabilidad completa desde el dato crudo hasta cada cifra reportada.

3.2. Bases de Datos Experimentales

La validez externa del estudio depende de la diversidad de los datos de prueba. Se seleccionaron tres *datasets* públicos que cubren un espectro amplio de densidades espaciales, frecuencias de muestreo y paradigmas experimentales. La Tabla 3.1 resume sus características.

Tabla 3.1: Características de las tres bases de datos experimentales.

Característica	PhysioNet EEGMMIDB	BCI IV 2a	MNE Sample
Canales EEG	64	22	60
Frecuencia de muestreo (Hz)	160	250	600
Paradigma	Motor (MI)	Motor MI 4 clases	Evocados A/V
Montaje	10-10	10-20 ext.	Personalizado
Densidad espacial	Alta	Baja	Alta
Duración típica por ensayo (s)	~160	~6	Variable

3.2.1. PhysioNet EEG Motor Movement/Imagery (EEGMMIDB)

Este *dataset* [35, 36] contiene registros de 64 canales EEG bajo el sistema internacional 10-10, adquiridos a 160 Hz. Los sujetos realizaron tareas de ejecución motora real (apertura y cierre de puños) e imaginiería motora (imaginación del movimiento sin ejecución). La alta densidad de la malla electroencefalográfica genera una fuerte correlación inter-canal, representando el escenario más favorable para los métodos geométricos. La estandarización se realiza mediante MNE-Python [2], asignando el montaje 10-05 para obtener coordenadas 3D precisas.

3.2.2. BCI Competition IV Dataset 2a

Este *dataset* [37] es un estándar en la comunidad de BCI. Contiene 22 canales EEG (montaje 10-20 extendido) a 250 Hz de 9 sujetos realizando imaginación motora de 4 clases (mano izquierda, mano derecha, pies, lengua). Con solo 22 canales, la pérdida de 2–3 electrodos puede dejar regiones enteras del cráneo sin cobertura sensora, exponiendo las limitaciones de los métodos puramente espaciales. Los archivos en formato GDF se descargan del sitio oficial de la competencia y se cargan mediante MNE-Python con mapeo explícito al estándar 10-05.

3.2.3. MNE Sample Dataset

Este registro multimodal (MEG y EEG) [2] incluye 60 canales EEG a 600 Hz con potenciales evocados auditivos y visuales. Su inclusión responde a la presencia de componentes ERP bien documentados (N100, P300), cuya preservación constituye el criterio más exigente de evaluación clínica. La carga se realiza mediante MNE-Python, seleccionando exclusivamente los canales EEG.

3.3. Construcción de Grafos

La topología del grafo determina la calidad de toda reconstrucción GSP posterior. El *pipeline* implementa 8 constructores organizados en tres categorías, aunque tras la fase exploratoria inicial —donde se evaluaron todos sobre los tres *datasets*— se seleccionó el *k*-NN Gaussiano como constructor primario para la optimización final, debido a su estabilidad numérica (ausencia de grafos desconexos), eficiencia computacional y desempeño competitivo sostenido.

3.3.1. Grafos de Vecindad Geométrica

Estos métodos conectan electrodos basándose exclusivamente en la distancia euclidiana 3D. El *k*-NN Gaussiano (*k*-NNG) asigna pesos:

$$W_{ij} = \exp\left(-\frac{d(i, j)^2}{2\sigma^2}\right) \cdot \mathbb{1}_{[j \in \mathcal{N}_k(i)]} \quad (3.1)$$

y se simetriza como $\mathbf{W} \leftarrow \max(\mathbf{W}, \mathbf{W}^\top)$. El *k*-NN Gaussiano Variable [38] adapta k_i por nodo según la densidad local: $k_i = \text{clip}(\text{round}(k_{\text{base}} \cdot (\tilde{d}/d_i)^\alpha), k_{\text{mín}}, k_{\text{máx}})$, donde $\tilde{d}$ es la mediana de las distancias al k -ésimo vecino. Otros constructores incluyen **bola- ϵ** ($W_{ij} = 1$ si $d(i, j) < \epsilon$) y el **Árbol de Expansión Mínima** (MST), que garantiza conectividad mínima.

3.3.2. Grafos Densos y Aprendidos

Se implementaron grafos completamente conectados con pesos de distancia inversa ($W_{ij} = 1/d(i, j)$) y kernel Gaussiano global. En la categoría de aprendizaje, el método **NNK** [26] resuelve un problema de mínimos cuadrados no negativos por nodo, produciendo pesos esparci-

dos que reflejan la geometría local. El método **AEW** [24] optimiza pesos minimizando el error de reconstrucción local, con un mecanismo de respaldo que combina kernel Gaussiano espacial con correlación temporal. El modelo de **Kalofolias** [25] infiere la topología minimizando $\langle \mathbf{Z}, \mathbf{W} \rangle - a \sum_i \log(d_i) + \frac{b}{2} \|\mathbf{W}\|_F^2$, donde $\mathbf{Z}$ es la matriz de distancias cuadráticas entre señales y a, b balancean esparsidad y conectividad.

3.4. Protocolo de Simulación de Canales Faltantes

La validez ecológica del *benchmark* exige que los patrones de pérdida simulados capturen los modos de falla observados en la práctica. Se definieron dos modos espaciales y dos esquemas de severidad.

3.4.1. Modos de Falla Espacial

- **Random (fallas independientes).** Los canales a remover se seleccionan mediante muestreo uniforme sin reemplazo. Simula el deterioro gradual y estocástico de electrodos individuales por secado del gel, acumulación de ruido o descarte manual durante el preprocesamiento.
- **Nearby (fallas contiguas).** Se elige un electrodo semilla al azar y se remueven sus m vecinos más cercanos por distancia euclidiana 3D. Simula eventos de alta adversidad: desprendimiento de un parche del gorro, falla de un módulo de amplificación, o saturación de una región completa por artefacto de movimiento.

3.4.2. Niveles de Severidad

Cada modo se ensaya bajo dos esquemas de cuantificación. El esquema por **proporción** remueve el 10, 20, 30 o 40 % de los canales totales. El esquema por **conteo discreto** remueve 1, 2 o 3 canales específicos —este último es particularmente relevante para la práctica clínica, donde típicamente fallan pocos canales pero de manera concentrada.

La combinación de 2 modos $\times$ (4 proporciones + 3 conteos) produce 14 escenarios por *dataset*, totalizando 42 contextos experimentales únicos.

3.5. Métodos de Interpolación

El *framework* implementa 18 algoritmos de interpolación, organizados en las tres familias descritas en el Capítulo 2. La Tabla 3.2 presenta el catálogo completo.

No todos los métodos de este catálogo fueron sometidos a la fase de optimización exhaustiva. Una fase exploratoria inicial —con hiperparámetros por defecto sobre todos los *datasets* y escenarios— permitió identificar las familias competitivas y descartar aquellas con rendimiento consistentemente inferior o inestabilidad numérica recurrente (por ejemplo, métodos puramente

Tabla 3.2: Catálogo de métodos de interpolación implementados y evaluados.

Familia	Método	Parámetros sintonizables
Geométricos	Spherical Spline [4]	ε (regularización)
	RBF Thin-Plate Spline [18]	Suavizado
	RBF Multiquadric	Suavizado
	IDW (Inverse Distance Weighting)	Potencia p
	Nearest Neighbor / Mean	(sin parámetros)
Estadísticos	ICA (FastICA) [22]	Número de componentes
	ICA-MNE (variante con montaje)	Componentes, método ICA
GSP espaciales	Laplaciano (interpolación armónica)	–
	Tikhonov en grafo	α (suavidad espacial)
	BGSRP [29]	Ancho de banda B, γ
	Graph Smoothing	λ , iteraciones
	Graph TV (IRLS)	λ , iteraciones
	Sobolev	α , orden
	Puy [9]	α
GSP temporales	TRSS [10]	α, β , iteraciones, η
	Graph-Time Tikhonov	α, β
	Temporal Laplacian	α, β , iteraciones
	Sobolev Temporal	α, β , iteraciones

laplacianos sin regularización, o BGSRP bajo pérdida contigua severa). La optimización fina con Optuna se concentró en cinco métodos: Spherical Spline, RBF Thin-Plate, ICA, Tikhonov y TRSS.

3.6. Optimización de Hiperparámetros con Optuna

La contribución metodológica central de este trabajo es la aplicación de optimización bayesiana a *todos* los métodos, incluyendo los *baselines* clásicos. Se utilizó el *framework* **Optuna** [12], seleccionado por su eficiencia en espacios de búsqueda mixtos (continuos, discretos y condicionales) y su integración nativa con Python.

3.6.1. Estrategia de Muestreo

Para la optimización mono-objetivo —minimizar el MAE— se empleó el muestreador **TPE** (*Tree-structured Parzen Estimator*), un modelo probabilístico que estima p (hiperparámetros | rendimiento) utilizando dos densidades de kernel: una para las configuraciones de alto rendimiento y otra para las de bajo rendimiento. El muestreo se concentra en regiones donde la razón de densidades es máxima, logrando una exploración eficiente incluso en espacios de alta dimensionalidad.

Para la optimización multi-objetivo —minimizar simultáneamente MAE y LSD, dos objetivos frecuentemente en conflicto— se utilizó el algoritmo genético **NSGA-II** (*Non-dominated Sorting Genetic Algorithm II*), que construye un frente de Pareto de soluciones no dominadas.

La selección final desde el frente se realizó por distancia euclidiana normalizada al origen de coordenadas en el espacio objetivo.

3.6.2. Espacios de Búsqueda

La Tabla 3.3 define los rangos de búsqueda. Todos los parámetros continuos se muestrean en escala logarítmica dentro de los intervalos especificados, salvo indicación contraria.

Tabla 3.3: Espacios de búsqueda de hiperparámetros.

Método	Parámetro	Rango de búsqueda
Spherical Spline	ε (regularización)	$[10^{-8}, 10^{-2}]$ (log)
RBF (TPS)	Suavizado	$[0, 0, 5, 0]$
ICA	n (componentes)	$[1, N_{\text{ch}}]$ (entero)
Tikhonov	α (suavidad)	$[10^{-4}, 10^2]$ (log)
TRSS	α, β	$[10^{-3}, 10], [10^{-4}, 1]$ (log)
	Iteraciones, tasa de aprendizaje	$[50, 500], [10^{-4}, 0, 1]$ (log)
k -NNG (grafo)	k (vecinos), σ (escala)	$[2, N/2], [0, 01, 5]$

3.6.3. Protocolo de Ejecución y Validación Temporal

La optimización se ejecutó con 30 *trials* por combinación (dataset $\times$ escenario $\times$ método) para los métodos GSP y 10 *trials* para los *baselines*, totalizando varios miles de evaluaciones de interpolación.

Un aspecto crítico es la prevención de fuga de datos (*data leakage*) en señales con fuerte autocorrelación temporal. Para mitigar este riesgo, cada segmento de señal se divide cronológicamente: el primer 70 % de las muestras constituye el **conjunto de optimización**, utilizado por Optuna para evaluar la función objetivo. A continuación, se descarta un **buffer de 2 segundos** ($2 \times f_s$ muestras) para contrarrestar la autocorrelación inducida por el filtrado pasabanda (0.5–40 Hz). El bloque remanente constituye el **conjunto de prueba**, sobre el cual se calculan todas las métricas reportadas en los Capítulos 4 y 5. Este protocolo emula una aplicación en tiempo real, donde los parámetros óptimos inferidos del pasado deben generalizar a muestras futuras no observadas durante la sintonización.

3.7. Evaluación Cuantitativa

El rendimiento de cada método se mide mediante las seis métricas definidas en la Sección 2.6: MAE, RMSE y SNR en el dominio de amplitud; DTW con ventana de Sakoe-Chiba para fidelidad morfológica; LSD y Coherencia para preservación espectral. Todas las métricas se promedian sobre los canales reconstruidos, y cada valor reportado corresponde exclusivamente al conjunto de prueba.

3.8. Matriz Experimental Consolidada

La Tabla 3.4 sintetiza el espacio experimental completo, permitiendo trazar cada resultado del Capítulo 4 hasta su configuración generadora.

Tabla 3.4: Matriz experimental consolidada. Cada celda representa una combinación evaluada bajo optimización bayesiana con separación cronológica estricta entrenamiento/prueba.

Dataset	Canales	Modos de pérdida	Niveles de severidad	Métodos optimizados	Grafo primario	Trials	Optuna
PhysioNet EEGMMIDB	64	Random, Nearby	10–40 % + 1–3 ch	TRSS, Tikhonov, Spline, RBF, ICA	k -NNG	30 (GSP) / 10 (baselines)	
BCI IV 2a	22	Random, Nearby	10–40 % + 1–3 ch	TRSS, Tikhonov, Spline, RBF, ICA	k -NNG	30 (GSP) / 10 (baselines)	
MNE Sample	60	Random, Nearby	10–40 % + 1–3 ch	TRSS, Tikhonov, Spline, RBF, ICA	k -NNG	30 (GSP) / 10 (baselines)	

3.9. Consolidación Estadística

Los resultados individuales se agregan mediante tablas pivote que resumen el rendimiento óptimo por familia, *dataset* y escenario. A partir de estas tablas se construyen rankings ordinales y se aplican pruebas de significancia no paramétricas a nivel de *trial*: la prueba U de Mann-Whitney para comparaciones pareadas y la delta de Cliff (δ) para cuantificar el tamaño del efecto, donde $|\delta| < 0,147$ se considera despreciable, $0,147 \leq |\delta| < 0,33$ pequeño, $0,33 \leq |\delta| < 0,474$ mediano y $|\delta| \geq 0,474$ grande [39]. La corrección por comparaciones múltiples se realiza mediante el método de Benjamini-Hochberg (FDR, *False Discovery Rate*) con $\alpha = 0,05$.

La visualización de resultados emplea formatos complementarios: mapas de calor que cruzan métodos con escenarios, gráficos radar multi-métrica, curvas de degradación SNR vs. proporción de pérdida, frentes de Pareto para *trade-offs* multi-objetivo, y series temporales de ERPs con sus correspondientes PSD para validación cualitativa.

3.10. Stack Tecnológico e Infraestructura

El *pipeline* completo se implementó en Python 3.10+, utilizando MNE-Python [2] para carga y manipulación de datos EEG; NumPy, SciPy y scikit-learn para álgebra lineal, descomposiciones espectrales e ICA; Optuna [12] para la optimización bayesiana; Pandas y Matplotlib para consolidación tabular y visualización; y la biblioteca `dtaidistance` para el cálculo eficiente de DTW en C.

3.11. Reproducibilidad

Todas las operaciones estocásticas —muestreo de máscaras, inicialización de ICA, particiones de Optuna— están gobernadas por semillas deterministas, garantizando resultados idénticos entre ejecuciones. Los artefactos de cada fase se almacenan bajo control de versiones (Git), y cada etapa del *pipeline* puede re-ejecutarse independientemente. Un módulo especializado captura y serializa

cualquier advertencia numérica —singularidad del Laplaciano, no-convergencia de ICA— para facilitar la auditoría posterior.

El protocolo experimental, los hiperparámetros óptimos encontrados, las métricas por configuración y el código fuente completo están disponibles en el repositorio público asociado a esta tesis, permitiendo la reproducción íntegra de los resultados o su extensión con nuevos métodos, *datasets* o métricas.

Bibliografía

- [1] A. Delorme and S. Makeig, “Eeglab: an open source toolbox for analysis of single-trial eeg dynamics including independent component analysis,” *Journal of Neuroscience Methods*, vol. 134, no. 1, pp. 9–21, 2004.
- [2] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen *et al.*, “Meg and eeg data analysis with mne-python,” *Frontiers in neuroscience*, vol. 7, p. 267, 2013.
- [3] F. Tadel, S. Baillet, J. C. Mosher, D. Pantazis, and R. M. Leahy, “Brainstorm: a user-friendly application for meg/eeg analysis,” *Computational Intelligence and Neuroscience*, vol. 2011, p. 879716, 2011.
- [4] F. Perrin, J. Pernier, O. Bertrand, and J. F. Echallier, “Spherical splines for scalp potential and current density mapping,” *Electroencephalography and Clinical Neurophysiology*, vol. 72, no. 2, pp. 184–187, 1989.
- [5] T.-P. Jung, S. Makeig, C. Humphries, T.-W. Lee, M. J. McKeown, V. Iragui, and T. J. Sejnowski, “Removing electroencephalographic artifacts by blind source separation,” *Psychophysiology*, vol. 37, no. 2, pp. 163–178, 2000.
- [6] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, “The emerging field of signal processing on graphs,” *IEEE Signal Processing Magazine*, vol. 30, no. 3, pp. 83–98, 2013.
- [7] A. Ortega, P. Frossard, J. Kovacevic, J. M. F. Moura, and P. Vandergheynst, “Graph signal processing: Overview, challenges, and applications,” *Proceedings of the IEEE*, vol. 106, no. 5, pp. 808–828, 2018.
- [8] S. K. Narang and A. Ortega, “Signal processing techniques for interpolation in graph structured data,” in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2013, pp. 5445–5449.
- [9] G. Puy, N. Tremblay, R. Gribonval, and P. Vandergheynst, “Random sampling of bandlimited signals on graphs,” *Applied and Computational Harmonic Analysis*, vol. 44, no. 2, pp. 446–475, 2018.

- [10] J. H. Giraldo, A. Mahmood, B. Garcia-Garcia, D. Thanou, and T. Bouwmans, “Reconstruction of time-varying graph signals via sobolev smoothness,” *IEEE Transactions on Signal and Information Processing over Networks*, vol. 8, pp. 201–214, 2022.
- [11] M. A. A. Calazans, F. A. B. S. Ferreira, F. A. N. Santos, F. Madeiro, and J. B. Lima, “Machine learning and graph signal processing applied to healthcare: A review,” *Bioengineering*, vol. 11, no. 7, p. 671, 2024. [Online]. Available: <https://www.mdpi.com/2306-5354/11/7/671>
- [12] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631.
- [13] G. Buzsáki, *Rhythms of the Brain*. Oxford University Press, 2006.
- [14] P. L. Nunez and R. Srinivasan, *Electric Fields of the Brain: The Neurophysics of EEG*, 2nd ed. Oxford University Press, 2006.
- [15] Y. Lai, W. van Drongelen, L. Ding, K. E. Hecox, V. L. Towle, D. M. Frim, and B. He, “Estimation of in vivo human brain-to-skull conductivity ratio from simultaneous extra- and intra-cranial electrical potential recordings,” *Clinical Neurophysiology*, vol. 116, no. 2, pp. 456–465, 2005.
- [16] R. Sharma and H. K. Meena, “Emerging trends in EEG signal processing: A systematic review,” *SN COMPUT. SCI.*, vol. 5, no. 4, p. 415, 2024. [Online]. Available: <https://link.springer.com/10.1007/s42979-024-02773-w>
- [17] R. Li, X. Yuan, M. Radfar, P. Marendy, W. Ni, T. J. O’Brien, and P. Casillas-Espinosa, “Graph signal processing, graph neural network and graph learning on biological data: A systematic review,” *IEEE Rev. Biomed. Eng.*, vol. 16, pp. 109–135, 2023. [Online]. Available: <https://ieeexplore.ieee.org/document/9585532/>
- [18] J. Jäger, A. Klein, M. Buhmann, and W. Skrandies, “Reconstruction of electroencephalographic data using radial basis functions,” *Clinical Neurophysiology*, vol. 127, no. 4, pp. 1978–1983, 2016. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1388245716000109>
- [19] A. Mazarguil, L. Oudre, and N. Vayatis, “Non-smooth interpolation of graph signals,” *Signal Processing*, vol. 196, p. 108480, 2022. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0165168422000275>
- [20] A. Weinstein, “Imputing missing electroencephalography data using graph signal processing,” in *18th International Symposium on Medical Information Processing and Analysis*, M. G. Linguraru, L. Rittner, N. Lepore, E. Romero Castro,

- J. Brieva, and P. Guevara, Eds. SPIE, 2023, p. 8. [Online]. Available: <https://www.spiedigitallibrary.org/conference-proceedings-of-spie/12567/2669735/Imputing-missing-electroencephalography-data-using-graph-signal-processing/10.1117/12.2669735.full>
- [21] X. Jiang, Z. Tian, and K. Li, “A graph-based approach for missing sensor data imputation,” *IEEE Sensors Journal*, vol. 21, no. 20, pp. 23 133–23 144, 2021, conference Name: IEEE Sensors Journal. [Online]. Available: <https://ieeexplore.ieee.org/document/9520399/?arnumber=9520399>
- [22] A. Hyvärinen and E. Oja, “Independent component analysis: algorithms and applications,” *Neural Networks*, vol. 13, no. 4-5, pp. 411–430, 2000.
- [23] S. Goerttler, F. He, and M. Wu, “Understanding concepts in graph signal processing for neurophysiological signal analysis,” 2023. [Online]. Available: <http://arxiv.org/abs/2312.03371>
- [24] M. Karasuyama and H. Mamitsuka, “Adaptive edge weighting for graph-based learning algorithms,” *Mach Learn*, vol. 106, no. 2, pp. 307–335, 2017. [Online]. Available: <http://link.springer.com/10.1007/s10994-016-5607-3>
- [25] V. Kalofolias, “How to learn a graph from smooth signals,” 2016. [Online]. Available: <http://arxiv.org/abs/1601.02513>
- [26] S. Shekkizhar and A. Ortega, “Graph construction from data by non-negative kernel regression,” in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2020, pp. 3892–3896.
- [27] V. Kalofolias and N. Perraudin, “Large scale graph learning from smooth signals,” 2019. [Online]. Available: <http://arxiv.org/abs/1710.05654>
- [28] S. K. Narang, A. Gadde, E. Sanou, and A. Ortega, “Localized iterative methods for interpolation in graph structured data,” 2013. [Online]. Available: <http://arxiv.org/abs/1310.2646>
- [29] Q. Zhang, L. Yang, Z. Yang, and C. Huang, “Recovery of bandlimited graph signals based on the reproducing kernel hilbert space,” *Digital Signal Processing*, vol. 151, p. 104565, 2024. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1051200424001908>
- [30] G. Morgenstern and T. Routtenberg, “Theoretical guarantees for sparse graph signal recovery,” *IEEE Signal Processing Letters*, vol. 32, pp. 266–270, 2025, conference Name: IEEE Signal Processing Letters. [Online]. Available: <https://ieeexplore.ieee.org/document/10787248/?arnumber=10787248>

- [31] Y. Zhao, X. Jian, F. Ji, W. P. Tay, and A. Ortega, “Generalized graph signal reconstruction via the uncertainty principle,” in *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2025, pp. 1–5. [Online]. Available: <https://ieeexplore.ieee.org/document/10889406/>
- [32] Y. Yan, J. Hou, Z. Song, and E. E. Kuruoglu, “Signal processing over time-varying graphs: A systematic review,” 2026. [Online]. Available: <http://arxiv.org/abs/2412.00462>
- [33] S. Krishnan, J. Choi, and J. Park, “Learning time-varying graph signals via koopman,” *IEEE Transactions on Signal and Information Processing over Networks*, vol. 12, pp. 16–30, 2026. [Online]. Available: <https://ieeexplore.ieee.org/document/11322857/>
- [34] H. Sakoe and S. Chiba, “Dynamic programming algorithm optimization for spoken word recognition,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 26, no. 1, pp. 43–49, 1978.
- [35] A. L. Goldberger, L. A. N. Amaral, L. Glass, J. M. Hausdorff, P. C. Ivanov, R. G. Mark, J. E. Mietus, G. B. Moody, C.-K. Peng, and H. E. Stanley, “Physiobank, physiotoolkit, and physionet: components of a new research resource for complex physiologic signals,” *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000.
- [36] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw, “Bci2000: a general-purpose brain-computer interface (bci) system,” *IEEE Transactions on Biomedical Engineering*, vol. 51, no. 6, pp. 1034–1043, 2004.
- [37] M. Tangermann, K.-R. Müller, A. Aertsen, N. Birbaumer, C. Braun, C. Brunner, R. Leeb, C. Mehring, K. J. Miller, G. R. Müller-Putz *et al.*, “Review of the bci competition iv,” *Frontiers in neuroscience*, vol. 6, p. 55, 2012.
- [38] A. Tamaru, J. Hara, H. Higashi, Y. Tanaka, and A. Ortega, “Optimizing $\$k\$$ in $\$k\NN graphs with graph learning perspective,” 2024. [Online]. Available: <http://arxiv.org/abs/2401.08245>
- [39] N. Cliff, *Dominance Statistics: Ordinal Analyses to Answer Ordinal Questions*. Psychological Bulletin, 1993, vol. 114, no. 3.