

Reconstrucción de Señales EEG mediante Procesamiento de Señales en Grafos e Interpolación Temporal

Carlos Saldivia

Departamento de Ingeniería Electrónica
Universidad Técnica Federico Santa María

Directores: Dr. Alejandro Weinstein, Dr. Matías Zañartu

Defensa de Tesis de Magíster – 2026

Contenidos

- 1 Introducción y Motivación
- 2 Marco Teórico: GSP y TRSS
- 3 Metodología y Diseño Experimental
- 4 Resultados
- 5 Conclusiones y Trabajo Futuro

El Electroencefalograma (EEG) y la Pérdida de Información

- El EEG es fundamental para el diagnóstico clínico (ej., epilepsia) y el diseño de Interfaces Cerebro-Computador (BCI).
- **El Problema Real:** La pérdida de información en uno o más canales no suele ser aleatoria; frecuentemente vemos *parches enteros* de electrodos perdidos por secado del gel o desconexión del amplificador.
- **Impacto Analítico:**
 - Interrumpe el análisis topográfico y localización de fuentes.
 - Distorsiona morfologías transitorias críticas, como los ERPs (ej. P300).
 - Obliga a descartar *trials* enteros.

Hipótesis de Trabajo

La interpolación puramente espacial falla bajo pérdida contigua severa. Incorporar la **inercia temporal** neurofisiológica mediante Procesamiento de Señales en Grafos (GSP) permite reconstruir fielmente la señal, preservando sus componentes espectrales y transitorios.

Limitaciones del Estado del Arte (Enfoques Clásicos)

Interpolación Geométrica (Ej: Spherical Splines de Perrin, 1989)

- Estándar *de facto* en EEGLAB y MNE-Python.
- *Supuesto*: Asume que la cabeza es una esfera estática y la señal decae exclusivamente por distancia euclidiana.
- **Fallas Estructurales:**
 - 1 Opera estrictamente en el dominio espacial **instante por instante** (t fijo).
 - 2 **Ignora la inercia neurofisiológica**: el voltaje cortical no "salta" de forma instantánea; tiene derivadas continuas.

Consecuencia

Las reconstrucciones euclidianas introducen ruido de alta frecuencia y, bajo degradación severa, colapsan invirtiendo la fase temporal de la señal.

Modelado GSP

- Se abandona la esfera y se pasa a un **Grafo Ponderado** $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$.
- W_{ij} captura la conectividad funcional o topológica.
- El **Laplaciano** $\mathbf{L} = \mathbf{D} - \mathbf{W}$ penaliza la variación espacial entre vecinos.

Regularización Tikhonov

Optimización instantánea:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{z}} \|\mathbf{y} - \mathbf{S}\mathbf{z}\|_2^2 + \alpha(\mathbf{z}^\top \mathbf{L}\mathbf{z})$$

El parámetro α controla qué tan suave queremos que sea la distribución de voltajes en el grafo.

Regularización Espacio-Temporal (TRSS)

El método **Temporal Regularized Sobolev Smoothness (TRSS)** optimiza la ventana completa simultáneamente $\mathbf{X} \in \mathbb{R}^{N \times T}$:

Función Objetivo TRSS

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z}} \underbrace{\|\mathbf{S}\mathbf{X} - \mathbf{S}\mathbf{Z}\|_F^2}_{1. \text{ Fidelidad}} + \underbrace{\alpha \operatorname{tr}(\mathbf{Z}^\top \mathbf{L} \mathbf{Z})}_{2. \text{ Suavidad Espacial}} + \underbrace{\beta \|\mathbf{Z} \mathbf{D}_t\|_F^2}_{3. \text{ Suavidad Temporal}}$$

1. Fidelidad

Obliga a que la solución coincida con los electrodos **sanos** registrados.


2. Espacio (α)

Penaliza variaciones bruscas entre electrodos **vecinos** según el Grafo (Laplaciano $\mathbf{L}$).

3. Tiempo (β)

Inercia. Penaliza derivadas temporales grandes ($\mathbf{D}_t$). Evita saltos no fisiológicos.

Pipeline Metodológico de la Investigación



Datasets Utilizados (Evaluación Externa):

Dataset	Canales	Densidad	Desafío Principal
PhysioNet EEG	64	Alta	Referencia / Ideal
MNE Sample	60	Alta	ERPs clínicos (N100, P300)
BCI IV 2a	22	Baja	Degradación Severa

- **Fair Benchmarking:** *Todos* los métodos (incluidas las Splines) fueron optimizados en

¿Por qué validación temporal con Buffer en lugar de K-Folds aleatorio?

- Si hubiéramos hecho *K-Folds aleatorio* a nivel de muestras, la autocorrelación de banda pasante del EEG habría causado **Data Leakage** masivo.
- Si hubiéramos hecho *K-Folds por sujeto*, cambiaría la topografía de la malla por la anatomía individual, rompiendo la optimización del Grafo.
- **Nuestra Solución (Hold-Out Cronológico):**
 - 1 Optimizamos hiperparámetros (α, β) en el 70 % inicial del registro.
 - 2 Excluimos 2 segundos (*buffer gap*) para romper la autocorrelación temporal.
 - 3 Evaluamos en el 30 % final.

Resultados Globales de Rendimiento (Optimizados)

Incluso tras dar a todos los métodos sus **mejores parámetros teóricos**:


Familia	MAE ↓	RMSE ↓	DTW ↓	SNR ↑	LSD ↓
Baseline Geom.	0.050	0.140	0.87	19.3 dB	2.25
GSP Espacial	0.086	0.208	1.22	14.1 dB	2.23
Temporal (TRSS)	0.038	0.104	0.74	20.8 dB	2.22

- La ventaja de TRSS es **estructural**. Las Spherical Splines no logran acortar la brecha en fidelidad de amplitud ni de forma (DTW).

Frontera de Pareto: Amplitud vs. Forma (BCI IV 2a)

Precisión (MAE) vs. Morfología (DTW)

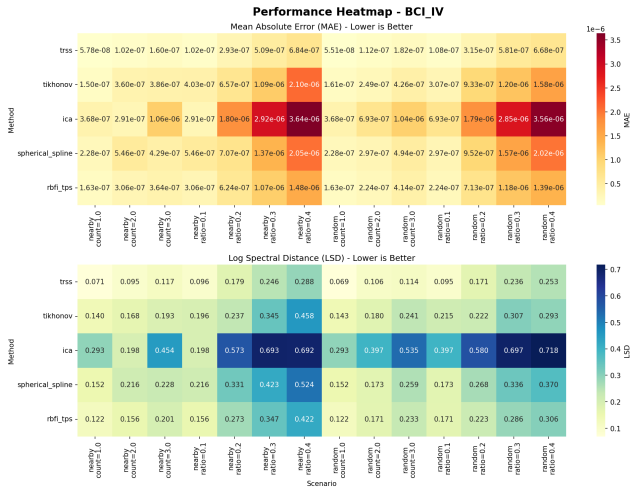
- Muestra el compromiso inherente de los métodos clásicos.
- **Cluster Geométrico (Morado/Azul):** Forma una barrera alejada del origen. Si ajustas para mejorar MAE, arruinas el DTW.
- **Dominancia TRSS:** Se ubica en la esquina inferior izquierda. Rompe la dicotomía logrando mínimo error de amplitud *simultáneamente* con mínima distorsión temporal.



Panorámica de Robustez: Mapa de Calor (BCI IV 2a)

Estabilidad en todas las condiciones


- Columnas: % de pérdida y topología (random/nearby).
- El colapso geométrico es visible en las columnas *nearby* de alta pérdida (tonos claros = alto error).
- **TRSS** se mantiene con la franja más oscura (menor error) de forma consistente, demostrando ser inmune a la densidad de la pérdida.




Reconstrucción de 1 Canal: Baja vs Alta Degradación (Escala Fija)

Reconstrucción de 1 Canal Faltante (Ground Truth en negro punteado). Escalas Y fijadas para visualización justa.

Pérdida Baja/Media (10% Nearby)




Pérdida Severa (40% Nearby)



Degradación bajo Pérdida Extrema (Colapso Geométrico)

Dataset BCI IV 2a (Solo 22 canales)

- Eje Y: Decibeles (SNR).
- Al alcanzar un 20-30 % de pérdida continua en un casco de baja densidad, los baselines geométricos sufren un colapso exponencial.
- **TRSS mantiene resiliencia lineal** al inyectar información del pasado y futuro.



Estudio de Ablación: ¿Qué aporta exactamente el tiempo (β)?

Para aislar la contribución de la inercia temporal, se contrastó **TRSS-Completo** (α, β) contra **TRSS-Espacial** ($\alpha, \beta = 0$).

Dominio Temporal (MAE)

Mejora Modesta ($\sim 0,6\%$)

La componente temporal no está diseñada para reducir el error absoluto medio; la amplitud es gobernada casi por completo por el Laplaciano espacial (α).

Dominio Espectral (LSD)

Mejora Pronunciada ($+8,5\%$)

Aislar el tiempo rescata la *Log Spectral Distance*. Evita ruido de alta frecuencia y saltos artificiales.

Tamaño de efecto grande ($\delta = -0,76$, $p < 0,005$).

Variante	LSD Promedio ↓	DTW Promedio ↓
TRSS-Espacial ($\beta = 0$)	2.45	0.81
TRSS-Completo ($\beta > 0$)	2.22	0.74

Reflexión: La regularización

temporal asegura **comportamiento oscilatorio fisiológico** en altas frecuencias (bandas beta, gamma),

- ❶ **Validación de Hipótesis:** La regularización combinada de Grafo (topología) y Sobolev (inercia temporal) supera de forma robusta y estructural a la extrapolación euclidiana clásica.
- ❷ **Fair Benchmarking:** La optimización multi-objetivo cerró la brecha en escenarios benignos, pero evidenció el **colapso estructural** geométrico ante fallas contiguas severas.
- ❸ **Preservación Diagnóstica:** El beneficio real de la componente temporal reside en la preservación de las bandas espectrales (PSD) y la morfología transitoria (ERPs), cruciales para clínica y BCI.

- **Procesamiento BCI Online:** TRSS procesa ventanas matriciales completas iterativamente. A futuro se deben implementar *ventanas deslizantes causales* y portar el álgebra a **GPU (CuPy)**.
- **Validación Descendente (Downstream Tasks):** Cuantificar empíricamente cómo la mejora espectral (LSD) de TRSS incrementa la exactitud (%) en clasificadores profundos (ej. EEGNet).
- **Grafos Dinámicos y Deep Learning:** Investigar cómo Grafos Neuronales (GNNs) podrían aprender topologías dependientes del tiempo, reemplazando las constantes estáticas α, β .

Gracias por su atención

Universidad Técnica Federico Santa María
Departamento de Ingeniería Electrónica

¿Preguntas?

Backup: Optimización de Hiperparámetros

Método	Parámetro	Rango (Log / Lineal)
Spherical Spline	eps (Suavidad Legendre)	$[10^{-8}, 10^{-2}]$
GSP Tikhonov	α (Regularización Espacial)	$[10^{-4}, 10^2]$
TRSS	α (Espacio), β (Tiempo)	$[10^{-3}, 10]$, $[10^{-4}, 1]$
	n_iter, lr (Descenso)	$[50, 500]$, $[10^{-4}, 0,1]$
Grafo (KNNG)	k , σ (Ancho kernel gaussiano)	$[2, N/2]$, $[0,01, 5]$

Se generaron 30 trials por configuración usando TPE para TRSS/Tikhonov, y 10 trials usando NSGA-II para los métodos baselines.

Backup: Derivación del Gradiente de TRSS

La función objetivo de TRSS:

$$J(\mathbf{Z}) = \|\mathbf{S}\mathbf{X} - \mathbf{S}\mathbf{Z}\|_F^2 + \alpha \text{tr}(\mathbf{Z}^\top \mathbf{L}\mathbf{Z}) + \beta \|\mathbf{Z}\mathbf{D}_t\|_F^2$$

El gradiente respecto a $\mathbf{Z}$ es:

$$\nabla_{\mathbf{Z}} J = 2\mathbf{S}^\top \mathbf{S}(\mathbf{Z} - \mathbf{X}) + 2\alpha \mathbf{L}\mathbf{Z} + 2\beta \mathbf{Z}\mathbf{D}_t\mathbf{D}_t^\top$$

- El operador $\mathbf{D}_t\mathbf{D}_t^\top$ corresponde al **Laplaciano de la cadena temporal** (grafos de ruta unidimensional).
- La matriz $\mathbf{S}$ fija las entradas conocidas, obligando a los canales perdidos a absorber el gradiente iterativamente.