

Reconstrucción de Señales EEG mediante Procesamiento de Señales en Grafos e Interpolación Temporal

Carlos Saldivia

Departamento de Ingeniería Electrónica
Universidad Técnica Federico Santa María

Directores: Dr. Alejandro Weinstein, Dr. Matías Zañartu

Defensa de Tesis de Magíster – 2026

Contenidos

- 1 Introducción y Motivación
- 2 Marco Teórico: GSP y Regularización Temporal
- 3 Metodología y Fair Benchmarking
- 4 Resultados Principales
- 5 Conclusiones y Trabajo Futuro

El Electroencefalograma (EEG) y la Pérdida de Información

- El EEG es el estándar de oro no invasivo para el monitoreo cortical clínico y el diseño de Interfaces Cerebro-Computador (BCI).
- **El Problema:** Durante la adquisición, frecuentemente se pierde información de uno o más electrodos por fallas de hardware, desconexión física o secado del gel.
- **Impacto:**
 - Interrumpe el análisis topográfico y la localización de fuentes.
 - Distorsiona métricas temporales (ERPs) y espectrales (PSD).
 - Obliga a descartar *trials* valiosos en algoritmos de clasificación.
- **Solución estándar:** Interpolar los canales faltantes a partir de los canales vecinos funcionales.

Limitaciones del Estado del Arte (Enfoques Clásicos)

Interpolación Geométrica (Ej: Spherical Splines)

- *Supuesto*: Asume que la cabeza es una esfera homogénea y que la conductividad depende exclusivamente de la distancia euclidiana entre canales.
- *Falla estructural 1*: Opera estrictamente en el dominio espacial **instante por instante**.
- *Falla estructural 2*: Ignora la **inercia neurofisiológica** del cerebro (los voltajes corticales son continuos en el tiempo).

Consecuencia Clínica

Al no tener "memoria" temporal, los métodos euclidianos clásicos generan reconstrucciones ruidosas que aplanan o invierten la fase de los transitorios rápidos, destruyendo biomarcadores como el P300.

- Transforma el dominio euclidiano en un **Grafo Ponderado** $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$.
- Cada nodo es un electrodo; cada arista W_{ij} representa conectividad (geométrica o funcional).
- El **Laplaciano del Grafo** $\mathbf{L} = \mathbf{D} - \mathbf{W}$ captura la "variación espacial" de la señal.

Regularización Tikhonov Espacial

Minimiza el error con los datos observados más una penalización a los saltos bruscos en el grafo:

$$\min_{\mathbf{z}} \|\mathbf{y} - \mathbf{S}\mathbf{z}\|_2^2 + \alpha(\mathbf{z}^\top \mathbf{L}\mathbf{z})$$

Regularización Temporal Espacio-Temporal (TRSS)

El método **Temporal Regularized Sobolev Smoothness (TRSS)** optimiza simultáneamente la topología espacial y la derivada temporal de toda la ventana $\mathbf{X} \in \mathbb{R}^{N \times T}$:

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{Z}} \underbrace{\|\mathbf{S}\mathbf{X} - \mathbf{S}\mathbf{Z}\|_F^2}_{\text{Fidelidad a los datos}} + \underbrace{\alpha \operatorname{tr}(\mathbf{Z}^\top \mathbf{L}\mathbf{Z})}_{\text{Suavidad Espacial}} + \underbrace{\beta \|\mathbf{Z}\mathbf{D}_t\|_F^2}_{\text{Suavidad Temporal}}$$

- α : Controla la dependencia de la topología funcional (Filtro paso-bajo espacial).
- β : Controla la inercia (Penaliza la primera derivada temporal, estabilizando la reconstrucción ante ruido).

Hipótesis

La integración de restricciones de suavidad espacial (GSP) junto con *priors* de continuidad temporal penalizada (TRSS) permite reconstruir canales faltantes de EEG de manera significativamente más precisa que los métodos geométricos estáticos.

Esta superioridad se reflejará crucialmente en la preservación fiel de la **morfología transitoria (ERPs)** y la **densidad espectral (PSD)**, en especial ante escenarios clínicos de pérdida espacial masiva y contigua.

Bases de Datos (Diversidad Espacial):

- *PhysioNet EEGBCI*: 64 ch (Alta densidad, Motor).
- *BCI IV 2a*: 22 ch (Baja densidad, Imaginería Motora).
- *MNE Sample*: 60 ch (Paradigma evocado ERPs).

Simulación de Fallas (Modos y Severidad):

- **Random**: Pérdida estocástica aislada.
- **Nearby**: Pérdida contigua de amplificador.
- Desde 10 % hasta **40 %** de la malla.

Métricas Transversales:

- Amplitud: MAE, RMSE, SNR.
- Forma: DTW (Dynamic Time Warping).
- Frecuencia: LSD, Coherencia.

Problema Endémico en la Literatura

Los nuevos métodos GSP suelen compararse contra *baselines* (como Spherical Splines) utilizando los "parámetros por defecto" de EEGLAB, generando una ventaja desleal inflada.

Solución Metodológica (Fair Benchmarking):

- Se integró **Optuna** (Muestreo Bayesiano TPE y NSGA-II) para optimizar los hiperparámetros de **todos los 18 métodos evaluados**.
- Se implementó *cross-validation* con un **buffer temporal de 2 segundos** para evitar fuga de datos (*data leakage*) por autocorrelación de la señal EEG.

Resultados Globales de Rendimiento


Una vez que **todos** los métodos operan en su límite de diseño teórico (Optimizados):

Familia	MAE ↓	RMSE ↓	SNR ↑	DTW ↓
Baselines (Sph. Splines)	0.050	0.140	19.3 dB	0.87
GSP Espacial (Tikhonov)	0.086	0.208	14.1 dB	1.22
Temporal (TRSS)	0.038	0.104	20.8 dB	0.74

- **Conclusión:** La superioridad temporal es una propiedad **estructural**. Incluso con hiperparámetros perfectos, las Splines Esféricas se ven limitadas por su falta de "memoria".


Degradación bajo Pérdida Extrema (Nearby 40 %)

- Escenario realista: se pierde el 40 % de los canales *agrupados en una sola zona*.
- Los baselines geométricos sufren un colapso exponencial de SNR.
- TRSS mantiene estabilidad lineal gracias a la inyección de rango desde la derivada temporal.



Reconstrucción de Potencial Evocado (MNE, 40% Nearby)

- Las Splines **invierten la fase** y destruyen el P300.
- TRSS preserva la trayectoria original por la restricción inercial de Sobolev.



Estudio de Ablación: El verdadero impacto de β

Para aislar la contribución de la regularización temporal (β), se evaluó TRSS-Completo vs TRSS-SinTemporal ($\beta = 0$) vs Spline.

- **En el Dominio del Tiempo (Error Puntual):** El aporte de β al MAE/RMSE es *modesto* ($\sim 0,6\%$) y no es estadísticamente significativo.
- **En el Dominio de Frecuencia (Fidelidad Espectral):** El LSD (Log Spectral Distance) mejora de forma dramática y **significativa** ($> 8,5\%$, $p < 0,005$).

Interpretación

Minimizar el error espacial (GSP) asegura amplitudes correctas en general, pero **solo el término temporal** β asegura un comportamiento oscilatorio fisiológicamente realista en bandas de alta frecuencia (Beta, Gamma).

- ❶ **Validación de Hipótesis:** La regularización topológica y temporal combinadas superan de forma estructural a la interpolación euclidiana. La jerarquía de rendimiento es un reflejo de la información agregada: Geométrica $\subset$ Topológica $\subset$ Espacio-Temporal.
- ❷ **Fair Benchmarking Crítico:** La metodología de optimización exhaustiva demostró que la brecha teórica persiste aun asumiendo algoritmos baselines perfectos.
- ❸ **Aporte Clínico:** TRSS es excepcionalmente robusto a zonas “ciegas” masivas (nearby failures), preservando biomarcadores como ERPs y distribuciones de PSD fundamentales para neurología y BCIs.

- **Aplicación en BCI Real-Time:** Adaptar la minimización global de TRSS para operar bajo *ventanas deslizantes causales* y portar la optimización iterativa de matrices a entornos acelerados (GPU/CuPy) para abatir la latencia.
- **Evaluación Downstream:** Cuantificar empíricamente cómo la mejora espectral (LSD) de TRSS se traduce en incrementos de exactitud (%) en clasificadores de neurociencia o interfaces motoras (*Deep Learning*).
- **Redes Neuronales y Grafos:** Utilizar Grafos Dinámicos (GNNs) para aprender topologías dependientes del tiempo, permitiendo una adaptación evolutiva a medida que el estado cognitivo del sujeto cambia.

Gracias por su atención

Universidad Técnica Federico Santa María
Departamento de Ingeniería Electrónica

¿Preguntas?